



申请代码	F0610
接收部门	
收件日期	
接收编号	6240073758



国家自然科学基金 申 请 书

(2024 版)

资助类别:	青年科学基金项目		
亚类说明:			
附注说明:			
项目名称:	面向生命科学领域表格科学数据优化算法研究		
申 请 人:	肖濛	BRID:	00805.00.96167
办公电话:	无		
依托单位:	中国科学院计算机网络信息中心		
通讯地址:	北京市海淀区中关村街道东升南路二号院中国科学院信息化大厦		
邮政编码:	100083	单位电话:	010-58812168
电子邮箱:	shaow@cnic.cn		

国家自然科学基金委员会



基本信息

申请人信息	姓名	肖濛	性别	男	出生年月	1995年01月	民族	汉族
	学位	博士	职称	助理研究员				
	是否在站博士后	是		电子邮箱	shaow@cnic.cn			
	办公电话	无		国别或地区	中国			
	申请人类别		依托单位全职					
	工作单位		中国科学院计算机网络信息中心					
	主要研究领域		自动数据优化, 人工智能, 知识表示					
依托单位信息	名称	中国科学院计算机网络信息中心						
	联系人	陈希	电子邮箱	chenxi@cnic.cn				
	电话	010-58812168	网站地址	www.cnic.cas.cn				
合作研究单位信息	单位名称							
项目基本信息	项目名称	面向生命科学领域表格科学数据优化算法研究						
	英文名称	Research on scientific tabular data optimization algorithms in the field of life sciences						
	资助类别	青年科学基金项目				亚类说明		
	附注说明							
	申请代码	F0610. 交叉学科中的人工智能问题				F0212. 数据科学与大数据计算		
	研究期限	2025年01月01日 -- 2027年12月31日				研究方向: 人工智能在生命科学中交叉		
	申请直接费用	30.0000万元						
	研究属性	目标导向类基础研究						
中文关键词		数据挖掘; 特征优化; 知识建模; 表格数据; 以数据为中心的人工智能						
英文关键词		Data Mining; Feature Optimization; Knowledge Modeling; Tabular Data; Data-Centric AI						



中文摘要	表格数据是生命科学领域数据的重要组成部分，借助其元数据内丰富的领域知识，能够有效描述物理世界中的概念。作为人工智能与生命科学交叉研究的基石，表格数据得到了广泛的关注与研究。但随着近年来测序技术的发展、电子病历的推广，这些表格数据逐渐呈现出高通量、低信息量的特性，这些数据的质量问题成为了领域交叉研究、应用推广的瓶颈。 本项目遵循理论技术与应用研究的模式，采用“1+3+3+1”的研究架构，围绕1个需求，凝练3个关键科学问题；在领域背景知识抽取与建模、基于知识的数据优化决策收集、多视角综合最优决策生成3个层面展开研究；结合国家生物信息中心重大科研需求，搭建1个数据优化原型系统，并开展实例测试。 项目申请人研究基础扎实，在以数据为中心的人工智能方法有着一定的理论积累和技术创新，并取得了一系列成果。本项目的实施能有力推动面向生命科学的数据优化算法研究，促进人工智能与生命科学交叉研究。
英文摘要	Tabular data is an essential part of data in the life sciences field. With its rich domain knowledge contained in metadata, it can effectively describe concepts in the physical world. Tabular data has received extensive attention and study as the cornerstone of interdisciplinary research between artificial intelligence and life sciences. However, with the development of sequencing technologies and the promotion of electronic medical records in recent years, these tabular data gradually show high throughput and low information content characteristics. These data quality issues have become a bottleneck in interdisciplinary research and application promotion. This project follows the theoretical technology and application research pattern, adopting a “1+3+3+1” research framework. It revolves around 1 requirement, refining 3 key scientific questions; it unfolds research on 3 levels: extraction and modeling of domain background knowledge, knowledge-based data optimization decision gathering, and multi-perspective integrated optimal decision-making generation, combined with the major scientific research needs of the National Center for Biotechnology Information, it builds 1 data optimization prototype system and carries out instance testing. The project applicant has a solid research foundation, with certain theoretical accumulation and technical innovation in the field of Data-Centric AI, and has achieved a series of results. Implementing this project can effectively promote research on data optimization algorithms for life sciences and foster interdisciplinary research between artificial intelligence and life sciences.



报告正文

参照以下提纲撰写，要求内容翔实、清晰，层次分明，标题突出。
请勿删除或改动下述提纲标题及括号中的文字。

(一) 立项依据与研究内容（建议 8000 字以内）：

1. 项目的立项依据（研究意义、国内外研究现状及发展动态分析，需结合科学研究发展趋势来论述科学意义；或结合国民经济和社会发展中迫切需要解决的关键科技问题来论述其应用前景。附主要参考文献目录）；

1.1 项目的研究意义

数据资源是人工智能技术发展的重要基础，是多学科研究发展的重要基石。利用我国丰富的数据资源是推动国家数字经济增长、提升国家竞争力的重大国家战略。在党中央与国务院所发布《新一代人工智能发展规划》中，将构建数据资源优势上升为国家战略。习近平总书记在多次讲话中强调“作为数字经济时代重要的生产要素，数据为数字经济持续健康发展提供了强劲动力”。“发挥数据的基础资源作用和创新引擎作用，加快形成以创新为主要引领和支撑的数字经济”。因此，探索新一代人工智能科技前沿，发展数字经济，聚焦人工智能驱动的科学（AI for Science）领域重大需求，建立新一代数据资源高效利用等场景为需求牵引的人工智能理论研究与应用发展新模式，具有重要价值。

伴随着国家发改委重大战略规划《“十四五”生物经济发展规划》内“加快信息技术赋能生物信息产业”的提出，海量测序数据、组学数据、电子健康记录等表格数据（Tabular Data）的数据量得到了爆炸式的增长。作为数据资源的主要组成部分、人工智能技术发展的基石，表格数据这一结构化的数据，能够有效地描述物理世界中各实体的概念及属性，得到了广泛的关注并支持了多个学科的科学的研究。然而，面对生物医学领域内的表格型数据，因为其独有的富领域知识、高通量、低信息量的特性，导致深度学习模型或机器学习模型展现出较弱的性能、低鲁棒性以及有限的泛化能力等问题，进而制约了生命科学数据资源的利用与人工智能交叉研究的开展。可以看出，以领域知识为引导，在数据优化为中心的人工智能技术（Data-Centric AI）形成技术突破，推进生命科学领域表格数据的高可靠质量优化，提高领域内数据资源利用率，支撑构建高鲁棒性的生命科学人工智能系统，具有重大的科学意义与战略价值。



针对支持构建高鲁棒生命科学人工智能系统的数据优化算法，需要针对领域知识建模、高通量数据的关键特征选择、低信息量数据的数理组合特征生成等方面展开深入研究。具体内容如下。

在知识建模方面：绝大多数表格数据的元数据潜藏着丰富的领域知识，这些知识来源广泛，具有很强的异构性。例如，基因测序数据的元数据是基因的名称，而这些基因可以在一些生物数据库（例如美国国家生物信息中心，NCBI）中检索领域专家撰写的功能描述或相关的学术论文。在一些罕见癌症的机理研究中，由于数据的样本量远远小于测量的化合物数量（ $n \ll d$ ），仅仅通过统计指标难以定位到关键的因子。因此，抽取这些学术研究、科学总结信息，为构建面向领域的数据优化算法提供关键知识支撑尤为重要。

在特征选择方面：随着生物技术的不断进步，单细胞 RNA 测序（scRNA-seq）等测序技术的发展为细胞间异质性和复杂性的研究提供了高分辨率的视角。但这类高通量数据在为生命科学研究带来巨大价值的同时，在分析它们时容易遭受维数灾难（Curse of Dimensionality），这意味着测序数据中真正具有生物学意义的数据相对稀少，并带来很高的计算成本。在这样的背景下，如何从这些数据中提取精简而有生物意义的信息，成为了需要面临的重要挑战。

在特征生成方面：生命科学领域表格数据的另外一个重要组成是电子病历数据，这些数据的缺陷在于数理特性多样、原始信息量过少。例如在糖尿病风险预测任务中，身体质量指数（Body Matter Index, BMI）是判断糖尿病风险的重要依据。而 BMI 可以通过组合身高与体重这两个低信息量特征，通过简单的数学变换生成。因此，依据不同疾病的背景，生成并构建适用于机器学习的数据集（ML-ready Datasets），是高鲁棒生命科学人工智能系统的核心保障。

综上，针对构建生命科学领域的高鲁棒人工智能系统，依然存在数据层面的核心挑战，这成为了信息化技术赋能生物信息产业的应用瓶颈。

对此，为解决现今的数据瓶颈，申请人长期从事自动数据优化算法研究、学科知识建模、领域知识图谱构建，并致力于探索人工智能驱动的生命科学新范式。依托团队具备人工智能与生命科学交叉领域前沿性的重点探索和前瞻性的应用部署能力，可以为项目顺利实施提供坚实的数据支持、算力支持与实际的应用场景。在探索数据优化为中心的人工智能技术理论突破的同时，项目将围绕生命科学应用场景，构建数据优化原型系统，以疾病相关研究为场景，开展测试验证，论证领域知识指导的数据优化技术的理论价值和应用前景。



1.2 国内外研究现状及发展动态

人工智能技术是赋能科学研究的重要支撑技术 [1]，同样也是生命科学研究新范式的重要要素之一 [2]，本部分围绕面向生命科学领域的表格科学数据优化算法研究，针对基于科技文献的科学领域知识建模、特征工程技术与特征生成技术三个方面的研究现状进行阐述，归纳和总结了现有方法存在的问题，为厘清项目研究的核心思路奠定基础。

1.2.1 基于科技文献的科学领域知识建模

在基于科技文献的科学领域知识建模领域，近期国内外学术研究主要集中于深度学习方面。近年来，随着大规模预训练语言模型的发展，其在自动化抽取科技文献中的情报知识方面展现出了显著的潜力和影响力。本文将对上述各研究方向进行详细介绍。

基于深度学习方法的语义建模方法是随着深度学习时代的到来，从早期的词嵌入模型 [3] 逐渐演变而来的多种方法。基于 CNN 的语义建模方法在各种自然语言处理任务中取得了显著的成功，如文本分类、情感分析、命名实体识别等。例如，Xiang Zhang 等人 [4] 提出了一种基于字符级别的卷积神经网络，能够从字符级别捕获文本特征。基于 RNN 的语义建模方法中通过内部隐藏状态来捕捉和记忆序列中的信息，从而建模词汇之间的依赖关系。传统的 RNN 在处理长序列时容易出现梯度消失或梯度爆炸的问题。为了解决这一问题，研究者提出了长短时记忆网络 [5] 和门控循环单元（Gated Recurrent Unit, GRU）[6] 等变种。基于注意力机制和自注意力机制的语义建模方法是一种在自然语言处理领域中用于捕捉文本中单词之间复杂依赖关系的方法。如带有注意力头的长短时记忆网络 [7] 以及基于自注意力机制的 Transformer 模型 [8]。

大语言模型时代的领域文献情报知识抽取是当前自然语言处理领域中的热点研究方向之一 [9]。大语言模型通常通过在大规模文本语料库上进行预训练 [10]，从而可以在各种下游任务上进行微调（Finetune），获得更好的性能；或是一些超大型的语言模型，通过提示（Prompt）的形式进行下游任务执行。当前，以 GPT-4 [11]、Llama [12] 为代表的大规模文本预训练模型已取得了突破性进展并在多个文本生成类的应用场景中取得了举世瞩目的性能表现，自然语言处理任务也因此进入了一个全新的时代。语言模型的范式也从预训练-微调（Pretrain - Finetune）的形式转换到预训练-提示（Pretrain - Prompt）[13] 的形式。此外，在生命科学领域，已有一些先驱通过大语言模型抽取文献情报



知识来辅助组学数据研究，如文献 [14] 通过 ChatGPT 来阅读基因功能描述文档获取领域情报知识，实现了零样本（Zero-shot）的组学数据标注与分析，文献 [15] 通过提示学习的方法，将编码的组学数据与学科背景知识输入到大语言模型中，通过模型已有的通识知识实现了高效的组学数据分析任务。文献 [16] 探索了大语言模型在材料化学领域的结构化知识抽取，训练后的语言模型可以轻松从一段原始文本中获取实体间的关联信息。这些工作都证明了大语言模型在科学领域知识抽取方面的巨大潜力。

1.2.2 围绕表格数据的特征选择技术

特征选择技术 [17] 是机器学习中的一个重要前置环节，涉及到使用数据集的相关性、冗余性、信息增益等特性或领域知识来筛选表格数据的特征，以减少维度并提高模型的训练效率。以下将对特征选择技术的四种主要分支及其在生命科学领域的发展进行介绍。

基于过滤方法（Filter Methods） 通过利用数据的统计特性导出的特征相关性评分，选择得分最高的特征 [18, 19]。例如，K-Best [20] 算法通过基于特定准则或度量对所有特征进行排名来操作。这个准则可以是与目标变量的相关性、互信息或任何其他反映特征重要性或重要性的统计度量。一旦特征被排名，就选择排名最高的 k 个特征。这些方法具有低计算复杂性，并且能够高效地从高维数据集中选择特征。但是，这些方法忽略了特征之间的依赖性和相互作用，从而导致选择的特征子集不一定是最优的。

基于包裹方法（Wrapper Methods） 采用预定义的机器学习 (ML) 模型以迭代方式评估所选特征子集的质量 [21--23]。由于这些方法评估了整个特征集，其性能通常优于过滤方法。MARLFS [24] 采用了多代理强化方法来操纵和构建特征组合，这对于搜索解决方案是有效的。然而，枚举所有可能的特征子集是一个 NP 难题，这意味着搜索可能需要海量的探索步数，并且很难达到最优。

基于嵌入方法（Embedded Methods） 将特征选择任务转换为 ML 模型预测损失的正则化项，以加速选择过程 [25--27]。LassoNet [28] 是一种代表性的嵌入方法，其结合了 Lasso 的正则化属性和神经网络的表达能力。该方法旨在处理具有复杂和非线性特征关系的高维数据。LassoNet 背后的关键原理是在神经网络的权重中引入了稀疏性，就像 Lasso（Least Absolute Shrinkage and Selection Operator）一样，并进一步地将 Lasso 与前馈神经网络结合起来。这些基于嵌入式的方法在其对应机器学习模型上表现出色，但通常难以泛化到其他模型上。



混合特征选择方法 (Hybrid Feature Selection Methods) 结合了过滤方法、包裹方法和嵌入方法的优点, 以达到在特征选择过程中更高的性能和效率。这些方法旨在利用不同特征选择技术的互补性质, 以识别出对预测模型最有用的特征子集。混合方法通常分为两个主要类别: 1) 同质方法 (Homogeneous Methods) [29, 30]: 这些方法结合了相同类型的特征选择策略, 但可能在不同的参数设置或不同的算法变种之间进行选择。它们通过迭代地应用相同类型的特征选择机制, 每次迭代基于前一次的结果进行调整和优化, 以此来增强特征选择过程的效果。2) 异质方法 (Heterogeneous Methods) [31, 32]: 这些方法结合了不同类型的特征选择技术, 比如先使用过滤方法以低计算成本快速减少特征空间的维度, 然后应用包裹或嵌入方法对剩余特征进行更细致的选择。异质方法试图通过整合不同的视角和评价标准, 来克服单一方法的局限性, 实现更全面和有效的特征选择。

针对生命科学领域的特征选择算法在生命科学领域中已有一些重要的研究场景与成果, 例如研究生物体和疾病的一个关键挑战是检测驱动发育、分化和转化的稀有分子程序和稀有细胞群 (RCP), 为解决这个挑战, 文献 [33] 基于保持单细胞数据的流形特性 (Manifold), 提出了一种无监督的特征选择算法 SCMER。文献 [34] 为解决低信息密度的单细胞数据难以识别驱动连续生物过程的关键特征问题, 提出了一种局部共变特征的动态选择方法 DELVE。文献 [35--37] 都改进了传统的特征选择方法, 对高通量、低信息密度的组学数据最优特征子集搜索进行了研究。这些方法都广泛考虑了生物数据的领域特性或是统计学特性, 但是并未针对学科领域知识应用进行探讨。

1.2.3 围绕表格数据的自动特征生成技术

自动特征生成技术是以数据为中心的人工智能技术与自动机器学习 (AutoML) 领域 [38] 涌现的一个新兴方向, 最早提到特征生成的研究 [39] 发现通过人工地变换表格形式数据集中已有的低信息量特征、生成关键的具有高信息量的特征, 能够优化数据集并提升下游机器学习模型的表现力。以下将对自动特征生成技术的主要分支进行介绍。

基于扩展-缩减的方法 (Expansion-Reduction Based Methods) 是早期的一种搜索最优特征空间的方法。这些方法首先通过给定的探索方式 [40] 或者贪婪搜索 [41] 决定的数学转换扩展原始特征空间, 然后通过选择有用的特征来缩减空间。再这样的思想下, 文献 [42] 与文献 [43] 通过解构传统的特征工程



过程,思考了传统特征工程过程的迭代优化,进而实现了针对表格数据的模拟人类专家的数据优化方法。后续的研究都聚焦于表格数据或者关系型数据库内数据优化任务,例如文献 [44, 45] 等。借助这样的迭代优化思路, Horn F 等人构建了 AutoFeat 这一个专业的表格数据优化工具箱,能够通过数学变换自动化地优化原始数据集 [46]。基于扩展-缩减的方法很好地用模型构建并自动化了特征工程这一亟需专业知识的数据科学方法。然而,由于搜索空间过大,同时搜索的方法过于低效,这些方法难以产生或评估复杂而有效的数学组合,进而导致性能不佳。

基于进化-评估的方法 (Evolution-Evaluation Based Methods) 是一种训练人工智能模型逐渐学习特征工程过程的数据优化方法。比较有代表性的工作如 [47] 将特征生成和选择集成到一个闭环学习系统中,并用多智能体强化学习方法训练。在这个过程中迭代地生成有效特征,并保留显著特征,直到达到最大迭代次数。一个改进性的工作 [48] 总结性地探讨了强化学习方法、奖励设计机制对数据优化决策生成过程的影响。也有部分工作采用进化算法建模这个优化过程 [49]。然而,尽管这些方法基于强化学习或进化算法,能够显著提高搜索的深度和广度,但由于这些方法仍然专注于如何在特征工程中模拟离散决策过程,最终的优化结果依然难以达到全局最优。

基于自动机器学习的方法 (Auto-ML Based Methods)。自动机器学习 (AutoML) 旨在自动找到最合适的模型架构 [50]。自动机器学习在许多领域的成功 [51] 以及自动机器学习和 AutoFeat 方法之间的相似性激发了研究人员将自动数据优化任务形式化为自动机器学习任务 [52] 以解决问题。例如一个先驱性的工作 DIFER [53] 采用了自动机器学习类的连续优化方法。但 DIFER 受限于采用随机初始化特征转换决策序列,故难以产生高阶特征转换,同时其转换性能并不稳定。最近的研究 [54] 尝试将离散的强化学习优化过程作为特征工程先验知识引入数据优化任务,这个方法在多个数据集上取得了优异的效果。但这些研究依然忽略了特征工程经验本质上依赖于多领域、多视角的知识交融,进而的一些特定领域的数据集上的数据质量改善效果有限。

1.3 总结

表格类数据的优化算法主要是针对数据集去冗余、高质量特征生成等场景,是模型训练的重要前序步骤。虽然针对高维表格类数据的冗余去除等场景,基于过滤、包裹、嵌入以及混合的特征选择技术取得了巨大的成功。但



是, 将这些方法应用于领域科学数据集时, 例如高维度、低样本量生命科学数据集, 这些基于数据的统计学特性的方法很容易学习到数据中的噪声而不是潜在的模式, 导致在新数据上的泛化能力差。此外, 高维数据意味着在特征选择过程中需要考虑的可能组合急剧增加, 这使得一些搜索策略(如一些基于包裹方法的算法)变得不可行。最后, 在高维小样本数据集中, 特征选择的结果可能对小的数据变动非常敏感, 导致选择特征子集的稳定性和可重复性差。部分先驱学者针对生命科学领域内数据的特性设计了算法, 但这些方法依然采用了特征选择技术的思想, 也存在上述类似的问题。特征生成技术是一个新兴方向, 旨在通过利用数学变换组合已有的低信息量特征, 形成具有高信息量的特征。这些方法的主要问题与特征选择技术类似, 例如搜索空间过大、离散的搜索策略不科学、评价的方法忽略了领域内的一些数据特性等。同时, 特征选择、生成方法都忽略了生命科学领域已存在的海量研究内容、背景知识。这些共性的问题都导致数据优化算法难以在生命科学领域场景中得到实际的应用。随着大语言模型技术的出现, 将知识注入语言模型以替代专家提供高价值背景知识已经成为了一个可以实现的目标, 这给领域科学表格数据的数据优化研究提供了新的研究思路。为了提高生命科学领域数据资源利用效率, 开发适应生命科学领域特性的表格数据优化算法, 不仅对提升该领域数据资源的利用效率至关重要, 也是支持国家生物信息技术发展的必要步骤。

参考文献

- [1] 鄂维南. AI 助力打造科学研究新范式 [J/OL]. 中国科学院院刊, 39: 10–16, 2024. <http://dx.doi.org/10.16418/j.issn.1000-3045.20231224001>.
- [2] 李鑫, 于汉超. 人工智能驱动的生命科学研究新范式 [J/OL]. 中国科学院院刊, 39: 50–58, 2024. <http://dx.doi.org/10.16418/j.issn.1000-3045.20231211001>.
- [3] Mikolov T, Chen K, Corrado G, et al. Efficient estimation of word representations in vector space[J]. arXiv preprint arXiv:1301.3781, 2013.
- [4] Zhang X, Zhao J, LeCun Y. Character-level convolutional networks for text classification[J]. Advances in neural information processing systems, 28, 2015.
- [5] Hochreiter S, Schmidhuber J. Long short-term memory[J]. Neural computation, 9(8): 1735–1780, 1997.
- [6] Chung J, Gulcehre C, Cho K, et al. Empirical evaluation of gated recurrent neural networks on sequence modeling[J]. arXiv preprint arXiv:1412.3555, 2014.
- [7] Tan M, Santos C d, Xiang B, et al. Lstm-based deep learning models for non-factoid answer selection[J]. arXiv preprint arXiv:1511.04108, 2015.
- [8] Vaswani A, Shazeer N, Parmar N, et al. Attention is All You Need[C] // Proceedings of



- the 31st International Conference on Neural Information Processing Systems : Vol 30. 2017: 5998–6008.
- [9] 赵鑫, 窦志成, 文继荣. 大语言模型时代下的信息检索研究发展趋势 [J/OL]. 中国科学基金, 37: 786–792, 2023. <http://dx.doi.org/10.16262/j.cnki.1000-8217.20231026.007>.
- [10] Devlin J, Chang M-W, Lee K, et al. Bert: Pre-training of deep bidirectional transformers for language understanding[J]. arXiv preprint arXiv:1810.04805, 2018.
- [11] OpenAI. GPT-4 Technical Report[J], 2023.
- [12] Touvron H, Lavril T, Izacard G, et al. Llama: Open and efficient foundation language models[J]. arXiv preprint arXiv:2302.13971, 2023.
- [13] Zhou Y, Muresanu A I, Han Z, et al. Large language models are human-level prompt engineers[J]. arXiv preprint arXiv:2211.01910, 2022.
- [14] Chen Y T, Zou J. GenePT: A Simple But Hard-to-Beat Foundation Model for Genes and Cells Built From ChatGPT[J]. bioRxiv : 2023–10, 2023.
- [15] Li C, Xiao M, Wang P, et al. scInterpreter: Training Large Language Models to Interpret scRNA-seq Data for Cell Type Annotation[J]. arXiv preprint arXiv:2402.12405, 2024.
- [16] Dagdelen J, Dunn A, Lee S, et al. Structured information extraction from scientific text with large language models[J]. Nature Communications, 15(1): 1418, 2024.
- [17] Li J, Cheng K, Wang S, et al. Feature selection: A data perspective[J]. ACM Computing Surveys (CSUR), 50(6): 1–45, 2017.
- [18] Peng H, Long F, Ding C. Feature selection based on mutual information criteria of max-dependency, max-relevance, and min-redundancy[J]. IEEE Transactions on pattern analysis and machine intelligence, 27(8): 1226–1238, 2005.
- [19] Ding H, Feng P-M, Chen W, et al. Identification of bacteriophage virion proteins by the ANOVA feature selection and analysis[J]. Molecular BioSystems, 10(8): 2229–2235, 2014.
- [20] Yang Y, Pedersen J O. A comparative study on feature selection in text categorization[C] // Icml: Vol 97. 1997: 35.
- [21] Leardi R. Genetic algorithms in feature selection[G] // Genetic algorithms in molecular modeling. [S.l.]: Elsevier, 1996: 67–86.
- [22] Liu K, Wang P, Wang D, et al. Efficient Reinforced Feature Selection via Early Stopping Traverse Strategy[C] // 2021 IEEE International Conference on Data Mining (ICDM). 2021: 399–408.
- [23] Altarabichi M G, Nowaczyk S, Pashami S, et al. Fast Genetic Algorithm for feature selection—A qualitative approximation approach[J]. Expert systems with applications, 211: 118528, 2023.
- [24] Liu K, Fu Y, Wang P, et al. Automating feature subspace exploration via multi-agent reinforcement learning[C] // Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. 2019: 207–215.



- [25] Tibshirani R. Regression shrinkage and selection via the lasso[J]. *Journal of the Royal Statistical Society: Series B (Methodological)*, 58(1): 267–288, 1996.
- [26] Kumagai A, Iwata T, Ida Y, et al. Few-shot Learning for Feature Selection with Hilbert-Schmidt Independence Criterion[J]. *Advances in Neural Information Processing Systems*, 35: 9577–9590, 2022.
- [27] Koyama K, Kiritoshi K, Okawachi T, et al. Effective nonlinear feature selection method based on hsc lasso and with variational inference[C] // *International Conference on Artificial Intelligence and Statistics*. 2022: 10407–10421.
- [28] Lemhadri I, Ruan F, Tibshirani R. LassoNet: Neural networks with feature sparsity[C] // *International Conference on Artificial Intelligence and Statistics*. 2021: 10–18.
- [29] Seijo-Pardo B, Bolón-Canedo V, Alonso-Betanzos A. Testing different ensemble configurations for feature selection[J]. *Neural Processing Letters*, 46(3): 857–880, 2017.
- [30] Pes B, Dessi N, Angioni M. Exploiting the ensemble paradigm for stable feature selection: a case study on high-dimensional genomic data[J]. *Information Fusion*, 35: 132–147, 2017.
- [31] Haque M N, Noman N, Berretta R, et al. Heterogeneous ensemble combination search using genetic algorithm for class imbalanced data classification[J]. *PloS one*, 11(1): e0146116, 2016.
- [32] Seijo-Pardo B, Bolón-Canedo V, Alonso-Betanzos A. On developing an automatic threshold applied to feature selection ensembles[J]. *Information Fusion*, 45: 227–245, 2019.
- [33] Liang S, Mohanty V, Dou J, et al. Single-cell manifold-preserving feature selection for detecting rare cell populations[J/OL], 1(5): 374–384, . <https://www.nature.com/articles/s43588-021-00070-7>.
- [34] Ranek J S, Stallaert W, Milner J, et al. Feature selection for preserving biological trajectories in single-cell data[J/OL], . <http://biorxiv.org/lookup/doi/10.1101/2023.05.09.540043>.
- [35] Missarova A, Jain J, Butler A, et al. geneBasis: an iterative approach for unsupervised selection of targeted gene panels from scRNA-seq[J/OL], 22(1): 333, . <https://genomebiology.biomedcentral.com/articles/10.1186/s13059-021-02548-z>.
- [36] Zhang Y, Petukhov V, Biederstedt E, et al. Gene panel selection for targeted spatial transcriptomics[J/OL], . <http://biorxiv.org/lookup/doi/10.1101/2023.02.03.527053>.
- [37] Xu Y, Li H-D, Lin C-X, et al. CellBRF: a feature selection method for single-cell clustering using cell balance and random forest[J/OL], 39: i368–i376, . https://academic.oup.com/bioinformatics/article/39/Supplement_1/i368/7210499.
- [38] Chen Y-W, Song Q, Hu X. Techniques for automated machine learning[J]. *ACM SIGKDD Explorations Newsletter*, 22(2): 35–50, 2021.
- [39] Kusiak A. Feature transformation methods in data mining[J]. *IEEE Transactions on Electronics packaging manufacturing*, 24(3): 214–221, 2001.
- [40] Katz G, Shin E C R, Song D. ExploReKit: Automatic feature generation and selec-



- tion[C] // 2016 IEEE 16th International Conference on Data Mining (ICDM). 2016 : 979–984.
- [41] Dor O, Reich Y. Strengthening learning algorithms by feature discovery[J]. Information Sciences, 189 : 176–190, 2012.
- [42] Kanter J M, Veeramachaneni K. Deep feature synthesis: Towards automating data science endeavors[C] // 2015 IEEE international conference on data science and advanced analytics (DSAA). 2015 : 1–10.
- [43] Khurana U, Turaga D, Samulowitz H, et al. Cognito: Automated feature engineering for supervised learning[C] // 2016 IEEE 16th International Conference on Data Mining Workshops (ICDMW). 2016 : 1304–1307.
- [44] Khurana U, Nargesian F, Samulowitz H, et al. Automating feature engineering[J]. Transformation, 10(10) : 10, 2016.
- [45] Lam H T, Thiebaut J-M, Sinn M, et al. One button machine for automating feature engineering in relational databases[J]. arXiv preprint arXiv:1706.00327, 2017.
- [46] Horn F, Pack R, Rieger M. The autofeat python library for automated feature engineering and selection[J]. arXiv preprint arXiv:1901.07329, 2019.
- [47] Wang D, Fu Y, Liu K, et al. Group-Wise Reinforcement Feature Generation for Optimal and Explainable Representation Space Reconstruction[C] // KDD '22 : Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. New York, NY, USA : Association for Computing Machinery, 2022 : 1826–1834.
- [48] Xiao M, Wang D, Wu M, et al. Traceable Group-Wise Self-Optimizing Feature Transformation Learning: A Dual Optimization Perspective[J/OL]. ACM Trans. Knowl. Discov. Data, 18(4), 2024. <https://doi.org/10.1145/3638059>.
- [49] Zhu G, Jiang S, Guo X, et al. Evolutionary Automated Feature Engineering[C] // PRICAI 2022: Trends in Artificial Intelligence: 19th Pacific Rim International Conference on Artificial Intelligence, PRICAI 2022, Shanghai, China, November 10--13, 2022, Proceedings, Part I. 2022 : 574–586.
- [50] Karmaker S K, Hassan M M, Smith M J, et al. Automl to date and beyond: Challenges and opportunities[J]. ACM Computing Surveys (CSUR), 54(8) : 1–36, 2021.
- [51] Wang D, Andres J, Weisz J D, et al. Autods: Towards human-centered automation of data science[C] // Proceedings of the 2021 CHI Conference on Human Factors in Computing Systems. 2021 : 1–12.
- [52] Chen X, Lin Q, Luo C, et al. Neural feature search: A neural architecture for automated feature engineering[C] // 2019 IEEE International Conference on Data Mining (ICDM). 2019 : 71–80.
- [53] Zhu G, Xu Z, Yuan C, et al. DIFER: differentiable automated feature engineering[C] // International Conference on Automated Machine Learning. 2022 : 17–1.
- [54] Wang D, Xiao M, Wu M, et al. Reinforcement-enhanced autoregressive feature transformation: Gradient-steered search in continuous space for postfix expressions[J]. Advances in Neural Information Processing Systems, 36, 2024.



2. 项目的研究内容、研究目标，以及拟解决的关键科学问题（此部分为重点阐述内容）；

2.1 关键科学问题

面向实现高鲁棒生命科学领域人工智能系统，针对生命科学领域的表格数据优化算法研究，本项目凝练以下三个层层递进的拟解决的关键科学问题。

关键科学问题 1：生命科学领域多模态高价值先验知识提取问题

在生命科学领域中，“高价值先验知识”泛指那些已有的研究成果、论述、因果关系等具有重要意义的信息。这些信息蕴含于众多已发表的生命科学研究文献、基因序列描述、基因调控网络、蛋白质功能特性等，来源于广泛而数量庞大的多模态数据集中。要解读生命科学领域数据集，这些知识是必不可少的。为了实现领域数据优化算法，有必要从这些多模态数据集中提取出高质量先验知识，并融合进数据优化算法的执行过程中。因此，高价值知识的提取与共性表达是实现生命科学领域数据优化算法的基础性问题。

关键科学问题 2：现有数据优化算法对领域知识的忽视问题

在建立鲁棒性高的人工智能系统中，高品质的数据资源扮演着至关重要的角色。在生命科学的原始数据集中，部分数据具有高通量特性，进而导致分析过程中会遇到维度诅咒等问题，与此同时，部分低质量表格数据包含的信息量过低，这些数据质量问题都会降低模型的鲁棒性。现有的方法聚焦于采用特征工程技术对数据集进行去冗余，以产出高质量数据集。而这些算法关注于统计学指标，忽略了领域知识的重要性，导致产出的数据集噪音大、冗余度高、特征信息量低。因此，结合领域知识的生命科学领域数据优化算法，是实现高鲁棒生命科学领域人工智能系统的关键步骤。

关键科学问题 3：数据优化算法难以在有限探索中达到综合最优的问题

主流的数据优化算法依然停留在步骤化地最优决策路径搜索过程，尤其在生命科学领域，面对海量的基因组学数据，这些“离散的”搜索方法难以在有限的探索次数中达到最优。此外，由于领域专家进行特征工程时需要参考多个角度的评价指标，而单一的指标难以形成全局最优解，只有综合多个梯度优化目标，才能实现综合最优特征优化决策序列。因此，如何建模特征优化算法在领域数据优化过程中的模拟特征工程专家行为的演化策略，并依此推理并构建最优的决策序列，是实现生命科学领域数据优化算法的核心问题。

版本: 24110319200101167



优化决策，进而模拟领域专家行为。

然后，针对单一优化目标难以获取最优决策问题，利用多智能体基因特征选择算法所收集的基因特征选择数据以及自动编码器等表示学习技术，构建融合多领域基因特征选择知识空间，模拟领域专家特征工程的演化策略，实现最优决策序列生成。

最后，结合实际场景对高质量数据资源的需要，构建生命科学领域数据优化原型系统，并围绕国家生物信息中心典型应用场景开展测试验证。

2.2.1 基于大语言模型的生命科学领域多模态知识注入

实现生命科学领域的多模态、多源知识的有效表达，并利用这些高价值知识，是实现领域数据优化算法的重要保证。这个任务主要的挑战来源于，这些高价值先验知识分散在广泛、多样化、多模态的数据集中。拟从大语言模型的领域科学多模态知识注入角度展开研究，**通过大语言模型模拟生命科学专家，建模领域背景知识，解决多模态高价值知识的统一表达问题。**

(1) 领域稀疏高价值先验知识注入

为实现对领域数据的深度理解和跨模态建模，首先从生物学知识库和专业论文矢量数据库中提取描述性文本。这些文本为生命科学领域数据提供丰富的上下文和语义背景。基于这些文本，对大型语言模型进行定制化微调，确保其具备领域知识。此外，利用生物学知识库构建专门的问答文本数据集，该数据集将作为多模态输入，辅助大语言模型从文本中提取有关基因组学、蛋白组学等语义信息，为建模生命科学的领域数据提供强大的知识支持。

(2) 生命科学数据的结构模态抽取

生命科学数据的结构模态在领域背景知识建模场景中至关重要，然后这些模态数据因为长度、结构复杂等问题难以直接输入到大语言模型中。为实现结构模态知识的注入，首先要构建与大语言模型在相同特征空间的结构模态编码器。拟首先采用自动编码器（Autoencoder）对结构信息进行抽取，同时利用对比学习（Contrastive Learning）技术将结构模态与大语言模型的语义模态进行匹配，为下一步共性知识的多模态对齐进行准备。

(3) 生命科学数据的共性知识的多模态对齐

依托微调的大语言模型，探索生命科学数据的结构知识信息与文本模态的语义知识之间的多模态对齐方法。该过程将结合基因组学、蛋白组学等数据的内在结构特性、抽取的文本数据的语义信息以及其他相关领域模态信息（例如



基因调控网络、基因共表达矩阵、基因启动子调控关系以及基因家族划分等), 实现生命科学数据的多维度、高层次的知识表示。

2.2.2 结合领域知识的多智能体自动数据优化算法研究

结合大语言模型抽取的专家背景知识, 构建领域数据优化算法, 是解决生命科学领域数据质量需求的重要前提。这个任务的主要挑战在于, 如何设计高通量数据的特征选择算法以及低信息量数据的特征生成算法, 并在这个过程中利用领域背景知识。拟从强化学习方法构建迭代的数据优化决策序列角度展开研究, 通过**结合领域知识的多智能体模拟领域特征工程专家在复杂数据优化过程中的操作策略, 以实现自动化的领域数据优化算法, 解决专家在人工特征工程的人力物力消耗以及优化过程中的领域知识需求问题。**

(1) 领域知识与数理特性结合的特征的表征

领域背景知识与特征的数理特性是特征工程专家进行人工特征优化的基础, 为了解决生命科学自动数据特征优化过程对领域背景知识的需求问题, 研究如何构建结合二者的特征的多角度表征方法。首先, 基于已经验证有效性的结合领域背景知识的大语言模型, 对基因、蛋白、患者基础信息等字段进行特征的表征初始化。此外, 利用统计学方法, 设计每一列特征的数理特性表征方法。基于这些特征的表征, 为后续自动数据优化提供知识驱动的基础。

(2) 高通量表数据特征选择

为解决当前对高通量数据分析过程中的维度灾难问题, 针对高通量数提取、精简出带有生物意义的高信息密度数据任务, 研究如何设计强化学习算法模拟特征工程专家行为。首先, 基于已收集的海量真实高通量基因测序数据或是蛋白组学数据, 针对各特征进行结合领域知识、数理特性的表征。基于该表征, 针对不同特征构建智能体, 并进行选择与否的决策。然后, 基于领域内生命科学指标, 对每次选择进行产生的数据集质量高低进行评价, 实现对各智能体的优化。最后, 利用收敛的智能体, 针对不同数据集进行特征选择, 利用下游领域特定任务作为评价, 验证算法的有效性。

(3) 低质量表格数据特征生成

为解决低质量特征信息量较弱问题, 针对其数理信息与领域背景知识, 通过数学变换, 生成高信息量特征, 研究如何设计强化学习算法模拟统计学与特征工程的专家行为。首先, 对数据集内特征进行基于统计学以及结合领域知识的融合表征。在此基础上, 构建级联的强化学习智能体, 构建特征生成计算树。



然后，在迭代构建计算树的过程中，通过多个领域内生命科学指标，对生成数据集的质量进行评估，并对智能体进行优化。最后，利用收敛的智能体，构建该数据集的特征生成计算树，并结合下游任务，验证算法的有效性。

2.2.3 融合多评价指标下综合数据优化决策序列生成

在有限步数的探索过程中，基于强化学习的多智能体产出的数据优化决策，可能无法达到最优效果，如何利用有限的探索，实现全局最优决策序列生成，是实现高效数据优化算法的核心。为了解决这个问题，**拟采用表示学习技术建模人工特征工程融合领域专家知识的数据优化行为、建模领域特征工程知识，并采用多目标优化技术，融合多个评价指标，实现最优决策序列生成。**

(1) 多视角数据优化行为建模

在各智能体逐渐掌握领域专家进行特征优化的行为模式、了解到基因之间的关联关系的过程中，将会累计大量的决策行为记录以及对这些决策记录的评价，通过收集这些决策可以获得在各智能体收敛初期具有高多样性的记录，同时也能够收集到收敛后高质量的基因特征选择记录。为解决基于强化学习的特征优化方法探索注重深度而缺乏广度的问题，结合角度的评价，基于表示学习方法，构建多视角数据优化行为的知识平面。

(2) 综合最优化决策序列搜索

离散的强化学习搜索方法在探索效率与扩展性上存在的问题，同时其缺少全局性，着重于深度却忽略了广度问题。为解决这个问题，基于已经构建的多视角数据优化行为知识平面，构建融合领域知识的数据优化知识空间，并在该连续空间下采用梯度上升策略进行最优决策序列表征搜索，将离散的决策任务转化为连续的空间优化任务。由于多个指标将会带来多个梯度优化目标，设计多目标优化策略，以实现综合最优化数据优化表征搜索。

(3) 最优特征优化决策链生成

通过将离散的决策问题转换为连续的优化问题，可以获取到综合最优的数据优化决策的表征，但从这个隐藏向量中解码并转换为离散决策步骤也存在特征转换的有效性问题。为了解决这个问题，在构建知识平面过程中，同步构建基于规则的解码器，利用生成式语言模型的思路，对生成的树状操作序列进行逐步骤的有效性纠错，保证运算的有效性。

2.2.4 针对生命科学领域的数据优化测试验证

针对实现高鲁棒生命科学领域人工智能系统，面向生命科学领域的数据优



化算法研究，本研究计划以先期工作作为研究的理论基础，以团队与多方合作者构建的生命科学原始数据集作为数据支持，以衰老、遗传发育、疾病辅助诊疗等国民生命健康需求为牵引，针对三大关键科学问题，结合国家生物信息中心相关业务场景数据需求，构建数据优化原型系统，提升数据资源利用效率，完成理论方法与关键技术的测试验证。

2.3 研究目标

本项目研究面向生物技术 (Biological Technology)、信息技术 (Information Technology) 与人工智能 (Artificial Intelligence) 的研究前沿，结合交叉学科的研究理念 (BT+IT+AI)，围绕生命科学领域表格科学数据质量低与数据资源利用低效的痛点问题，通过大语言模型知识注入，解决多模态高价值知识的统一表达问题，建模领域背景知识；结合领域知识，构建基于多智能体强化学习的模拟专家的数据优化方法，并利用可解释指标，收集带有领域背景知识的专家决策行为；将决策行为映射至多个评价指标相关的连续向量空间，使得离散的优化问题转换为连续优化问题，融合多领域知识平面，进行综合最优化决策搜索，解决数据优化过程中多视角知识缺失、关键信息遗漏等问题，并形成一套稳定的人工智能特征工程优化决策系统；最后，面向国家生物信息中心实际应用场景的数据质量需求，针对特定任务开展测试验证。本项目力求通过凝练的四个核心研究内容，支撑国家生物信息中心科研目标，探索领域数据优化基础理论框架，推动数据资源利用，并促进在生命科学领域的应用实践。

3. 拟采取的研究方案及可行性分析 (包括研究方法、技术路线、实验手段、关键技术等说明)；

3.1 总体研究方案

本项目聚焦于生命科学领域，结合领域背景知识建模、收集基于知识的数据优化策略、构建多视角综合数据优化知识平面、实现综合最优数据优化决策生成。目标是从数据优化的角度，改善生命科学领域下游机器学习、人工智能模型效果。本项目遵循理论创新、技术突破、测试验证等步骤展开研究。可以归结为“1+3+3+1”的研究架构，即围绕 1 个核心挑战 (实现高鲁棒生命科学领域人工智能系统)，围绕 3 个关键科学问题 (先验知识提取问题 → 数据优化的知识需求问题 → 决策的视角单一问题)，开展 3 个层面的研究工作 (领域知识建模 → 优化行为收集 → 综合决策生成)，搭建一个原型系统 (展开测试验证)。总体研究方案如图 2 所示。



在领域背景知识抽取与建模层面，结合领域内多模态高价值知识，在知识注入、结构模态建模、共性知识抽取三个方面展开研究。

在基于知识的数据优化算法层面，通过利用高价值知识，在设计领域知识与特征数理特性结合的特征表征、特征选择、特征生成三个方面展开研究。

在多视角综合最优决策生成层面，利用收集的离散决策，在多视角数据优化行为建模、综合最优决策序列搜索、最优决策链生成三个方面展开研究。

最后，针对国家生物信息中心相关场景对数据质量的需求，通过数据优化算法，构建高质量数据集，完成关键技术的测试验证。




图 2. 本项目总体研究方案

3.2 技术路线

本项目依照研究方案逻辑顺序，从基于大语言模型的生命科学领域多模态

知识注入、结合领域知识的多智能体数据优化算法研究以及融合多评价指标下综合数据优化决策序列生成，开展面向生命科学领域的数据优化算法研究。首先，研究基于大语言模型的领域知识注入方法，为后续数据优化的背景知识需求打下基础；然后，研究基于领域背景知识的多智能体自动数据优化算法，并在该过程中收集数据优化离散决策序列；最后，建模离散决策序列，构建多视角知识平面，并生成最优数据优化决策，从而生成高质量领域数据集。




图 3. 基于大语言模型的生命科学领域多模态知识注入

3.2.1 基于大语言模型的生命科学领域多模态知识注入

本部分针对生命科学领域中的多模态知识建模任务，通过采用预训练-微调的方案，基于大语言模型，旨在突破现有工作在泛化能力和知识嵌入方法上的局限性。为此，研究首先基于自指令（self-instruct）方法，采用领域专业论文中的描述性文本等内容对大型语言模型进行微调，以实现领域高价值先验知识的注入；然后，借助微调的大型语言模型，创建一个生命科学数据结构模式的编码器；最后，通过联合训练，进一步微调同时具备背景知识与组学结构知识的领域大语言模型。此研究为基于领域知识的数据优化算法提供知识支持。图 3 展示了本部分研究的主要架构图。



(1) 领域稀疏高价值先验知识注入

生命科学知识库与其相关的论文库具有较大的数据量、难以解析，为解决这些稀疏高价值先验知识的利用问题，申请人在前期工作中，已从 NCBI (National Center for Biotechnology Information) 收集了包含元数据的 800 万篇 XML 格式文献、针对各个基因、蛋白质的描述及各化合物的相关研究文献。

为了实现这些文献所包含的知识的注入，同时提高整个框架的自动化程度，采用自指令 (Self-instruct) 与指令生成 (Instruction Generation) 这一种半自动化的方法对已预训练完成的大语言模型 (例如 Llama2-70B) 进行知识注入。图 3 的上半部分是这个方法的一个示例。




图 4. 元指令示意

具体来说，对于文献数据与基因、蛋白等知识数据，首先依照生物学知识，手工撰写若干元指令 (Meta-instruct)，每条元指令由 {指令, 输入, 输出} 或 {指令, 输出} 的形式组成，图 4 是两种元指令的示例；随后利用大语言模型的生成式特点，利用生命科学知识库中的关联知识、论文矢量数据库中的非结构化数据与元数据，自动生成调优所需的问答数据；将生成的指令集与元指令计算 ROUGE-L (Longest Common Subsequence)，通过质量控制的方式去除一些低质量 (例如 ROUGE-L 小于 0.7) 或包含一些通常无法被大语言模型处理的关键词 (例如图像、图片、组学序列数据等) 的指令；最后通过低阶适应 (Low-Rank Adaptation) 的方式将问答所蕴含的知识高效嵌入大语言模型中。

在完成一批知识库中高质量知识的注入后，可以通过指令生成的方法，利用大语言模型解读收集的论文全文数据，抽取稀疏的知识，并根据论文描述的知识实现新一批的指令生成，进而实现半自动化迭代式的高质量知识注入。

(2) 生命科学数据的结构知识模态抽取

虽然生命科学领域的重要先验背景知识已经能够通过以上方式注入到大语言模型，大语言模型对于各类生命科学数据的结构模态知识所知甚少 (例如

单细胞测序数据、蛋白测序数据等), 同时其难以直接处理这些长度为数万的结构字符输入。而这些化合物的结构信息是进行数据优化的重要先验知识。为了利用已经注入的知识, 进而实现结构模态到文本语义模态的共性知识对齐的问题, 本研究拟通过对比学习的方式, 将语义空间与结构模态空间对齐, 实现对生命科学数据的结构模态建模。为了简化描述, 本章节将以大规模基因测序数据的结构模态抽取为叙述对象。




图 5. 以基因测序数据为例的结构模态抽取示意

图 5 是以基因测序数据为例的结构模态与大语言内知识的多模态对齐示意图。首先, 本工作针对大规模转录数据, 以基因排序编码 (Rank Value Encoding) 这一系列应用于 GeneFormer、GeneCompass 等组学大模型数据中的方法, 利用基因的表达量排序基因, 构建基因表达的顺序信息。然后, 当前组学大模型主要考虑通过自编码器的形式对输入组学数据的基因表达值或排序编码进行重构或掩码预测, 但该方法仅关注于结构模态的观测数据 (例如基因的表达值), 但忽略了基因的领域背景知识。为了进一步融合基因的生物学知识与细胞内基因表达信息, 首先, 采用注入领域知识的大语言模型对于每个基因的相关解释文本的嵌入式表达作为该基因的初始化表达。

给定一条组学数据 G_i 的表达: $G_i = \{x_i^{(j)}, g_i^{(j)}\}$, 其中 $x_i^{(j)}$ 与 $g_i^{(j)}$ 分别为 G_i 的第 j 个基因的表达量与基因名称。在上一章节训练完成的大语言模型为 ϑ , 此时该模型已经在稀疏知识注入过程中, 通过问答的方式了解了全部基因的功能, 则可以通过大语言的中间隐藏向量作为该基因的特征:

$$g_i^{(j)} \xrightarrow{\vartheta} e_i^{(j)}, \quad (1.1)$$



此处的 $e_i^{(j)}$ 可以看做是该基因的功能的语义化表达。随后，可以通过对基因序列进行基于掩码的自监督训练，来获取一个结构模态信息的编码器与解码器来重构输入结构模态的基因表达值与基因名称：

$$\begin{aligned} L_{rec} &= \frac{1}{|n_{unk}|} \sum_j \sum_{i \in n_{unk}} (\hat{x}_i^{(j)} - x_i^{(j)})^2, \\ L_{seq} &= \sum_{i \in n_{unk}} \sum_{c=1}^M p(g_i^{(j)}, c) \log q(c), \end{aligned} \quad (1.2)$$

其中 L_{rec} 的目标是重构被掩码的基因的表达值，而 L_{seq} 预测掩码位置的基因 ID。通过这两个损失函数的联合训练，可以使得编码器理解基因组学数据的结构信息。最后，可以通过对比学习框架，将该条组学信息与其标注相关的描述性文本的语义信息进行对齐，这部分可以显式地引入该组学数据的种群信息等的文本描述，从而获得更强的监督信号：

$$L_{con} = -\log \frac{\exp(\text{Enc}_g(G) \cdot Z^+ / \tau)}{\sum_{n=0}^k \exp(\text{Enc}_g(G) \cdot Z^- / \tau)} \quad (1.3)$$

其中 G 是一条组学数据， Z^+ 与 Z^- 是从微调后的大语言模型处获取的该条组学数据的正、负例描述的嵌入式语义表达（如图 5 中所示）。 $\text{Enc}_g(\cdot)$ 是结构模态的编码器。在组学数据建模阶段，可以通过对以上三个任务进行联合训练，以使得 $\text{Enc}_g(\cdot)$ 能够了解组学数据的结构信息，同时其输出的向量能够与其相关的语义知识在同一个向量空间中。

(3) 针对生命科学数据的共性知识多模态对齐

针对生命科学数据所具有的多模态、稀疏的知识难以建模问题，通过公式 1.1 至公式 1.3 完成了组学结构信息到大语言模型内语义的空间对齐，这为实现共性知识多模态对齐提供了基础。如图 2 右下角图例所示，为了使得大语言模型可以进一步理解生命科学数据中的结构与知识之间的关联，首先对于输入的结构模态相关的标注信息进行解析，通过元指令的形式利用大语言模型生成多条多样化的标注相关问题与答案。再通过结构模态的编码器 $\text{Enc}_g(\cdot)$ ，获得输入的结构模态数据的低维向量表示。

由于此处大语言模型的体量远远大于结构模态数据编码器，为了防止在大语言模型的共性知识多模态对齐的过程中，已完成训练的组学数据编码器遗忘组学数据的细节特征而学习任务相关的特征，可以采用一个较高网络层次的投



影层来增加整体模型的泛化性。随后采用低阶适应的训练方式将该问答、文本信息与输入的低维向量表示组合并对大语言模型的问答生成功能进行训练，优化目标如公式 1.4 所示。

$$P(X_A|G, X_Q) = \prod_{i=1}^l P_{\theta}(X_A^{[i]}|Z_G, Z_Q, Z_A^{[1:i-1]}), \tag{1.4}$$
$$Z_G = Proj_{\varphi}(Enc_g(G)),$$

上式中 X_Q 与 X_A 分别表示通过元指令生成问题与答案序列，基因的投影表达 Z_G 由公式 1.4 中的 $Proj_{\varphi}$ 投影方法通过组学数据编码器 $Enc_g(\cdot)$ 输出的组学数据向量表达生成。 $P_{\theta}(X_A^{[i]}|Z_G, Z_Q, Z_A^{[1:i-1]})$ 是给定已生成前 $i-1$ 步的序列语义表达 $Z_A^{[1:i-1]}$ 、输入问题的语义表达 Z_Q 与基因的投影表达 Z_G ，计算下一个字符 $X_A^{[i]}$ 的条件概率。

通过以上的优化目标，可以使得生命科学数据的结构特征与先验知识的语义特征映射到大语言模型所在的特征空间当中，从而使得其够理解组学模态的输入。同时模型可以根据提供的指示编码、输出领域背景知识。而对于生物领域内其他相关知识，例如基因调控网络、基因共表达矩阵、基因启动子调控关系以及基因家族划分等，可以通过类似思路实现以提示学习的形式指导模型进行序列生成或者问答生成，并以公式 1.4 中生成的形式以实现外部知识的注入。

3.2.2 结合领域知识的多智能体自动数据优化算法研究

图 6 是表格数据优化目标的示意图。结合领域知识的自动数据优化算法目的是解决传统数据优化问题中缺少自动化、缺乏领域知识指导等问题。主要包括领域知识与数理特性结合的特征的表征生成、高通量数据的特征选择以及低通量数据的特征生成。




图 6. 表格数据优化示意图

(1) 领域知识与数理特性结合的特征的表征生成

特征工程专家在进行人工特征工程时，其主要会考虑数据集的两个特性，分别是数据集的领域背景知识与数据集内特征的数理特性。而当前数据优化算法主要聚焦于利用统计学信息来获取数据集内部特征的数理特性，而忽略了领域背景知识。为了实现高效、自动的特征优化算法，需要让算法内的多智能体从以上两个角度了解数据集。

首先，数据集的背景知识可以通过本研究计划前部分训练的大语言模型获取。以生命科学数据集为例，可以通过“元数据”(Meta-Data)或表头名称，对该列特征进行初始化。比如基因的测序数据是一系列基因的特征，而其表头就是这一系列的基因名称，由于在之前的研究计划中，已经对基因名称与该基因的功能进行了对齐，可以直接利用大语言模型初始化这一个基因的属性：

$$g \xrightarrow{\vartheta} h_k, \quad (1.5)$$

此处 g 表示某一个基因的名称， h_k 表示这个基因的背景知识表示。用相同的方法，同样可以通过名称初始化蛋白质、其他化合物乃至身高、体重等特征的背景知识表达。此外，数据集内特征的数理特性也是数据优化过程中的重要依据。这里考虑采用均值、中位数、众数、范围、方差等 15 种常见的统计量来表示某一系列特征。如图 7 所示，右侧的向量可以作为该列特征在这个数据集上的表示。此时该列特征的表示可以用 $h = h_k \oplus h_s$ 表示， $\oplus$ 表示连接操作。




图 7. 特征的代表初始化示意图

(2) 高通量数据特征选择

生命科学领域高通量数据指的是基因、蛋白质、代谢物的测序数据，这些数据的特点是具有很高的维度 (N)，同时样本量 (M) 可能较少 ($N \gg M$)，

从而在机器学习模型的训练过程中容易引起过拟合等问题，从而影响模型的鲁棒性。图 8 展示了对高通量数据进行特征选择的重要性。




图 8. 高通量数据特征选择的重要性

为了解决以上问题，研究基于多智能体互动的自动特征选择方法，对冗杂的高通量数据集进行特征选择，从而凝练出有意义的信息。

首先，针对每一条特征 f_i ，都可以获取到其包含背景知识与数理信息的表征 h_i 。同理，对整个数据集 F ，有 $F = \{f_i\}_{i=1}^N$ 。设计一个可以训练的神经网络 $S(\cdot)$ ，其可以获取数据集在进行当前选择操作的整体情况。则可以针对第 i 个特征 f_i ，设计它的智能体行为函数如下：

$$a_i = \pi_i(S(F_t), h_i), \quad (1.6)$$

这里的 a_i 表示该智能体决定选择或者不选择特征 f_i ， F_t 表示在经过 t 轮循环后整个数据集内被选择的特征集合， $\pi_i(\cdot)$ 是第 i 个智能体的策略函数。

在所有智能体都完成选择后，可以构建当前步骤的数据集 F_{t+1} ，同时可以利用评价函数 $Eval(\cdot)$ 对数据集的表现进行评价。单次决策各智能体将会由“对整体表达基因的覆盖比例”、“基因表达的下游聚类可分性”、“细胞类型分类的准确性”等生物学指标对奖励进行加权计算，并通过各智能体是否进行选择或改变先前选择等情况对各个智能体进行奖励的分配。随后可以进行下一个阶段的智能体决策过程，并不断迭代直到各智能体收敛。

(3) 低质量数据特征生成

针对生命科学领域中部分数据质量差、生物学意义低的问题，研究基于多智能体的低质量数据生成方法，设计可溯源的特征变换框架，最终实现最优数据的生成。这里采用电子病历的数据优化这一典型场景作为示例，起始状态下的数据集由患者的基本信息组成。

首先，在历史的研究文献或是背景知识中，已经存在部分有效的数据生成计算方法，如图 9 所示，给定一个表格形式的电子病历，可以通过表头的“身高”字段直接检索获取 BMI 的变换方法。




图 9. 由知识注入的大语言模型直接构建的特征生成方法

此外，由于大部分的特征可能在知识库中不存在有效的变换。为了提高这些数据的质量，考虑到专家在进行特征的生成过程中，会首先从数据集中选择一个特征，然后再选择一种变换方法，最后根据变换是一元操作（例如开方、开根号等）或者二元操作（例如加、减、乘、除等）决定是否需要再选择一个特征，这样的变换过程与多智能体的协作类似，故采用多智能体强化学习方法建模特征生成任务。

类似于高通量特征选择过程，各个特征 f_i 可以依据图 7 的过程初始化其相关表示 h_i ，同样给定一个数据集 F 与状态函数 $S(\cdot)$ ，可以构建头特征选择智能体 $a_1 = \pi_h(S(F_t))$ ，其中 a_1 是选择的头特征， π_h 是头特征选择智能体的策略函数， F_t 是当前时间序列下的数据集。随后，依据选择的特征与当前数据集的状态，可以构建操作选择智能体 $a_o = \pi_o(S(F_t), h_1)$ ，其中 π_o 是操作选择智能体策略函数， a_o 是所选择的数学变换。最后，如果操作是二元变换，则可以通过尾特征选择智能体 $a_2 = \pi_h(S(F_t), h_1, o)$ 来选择尾部特征，其中 a_2 是尾部特征， o 是选择操作的独热嵌入式表达（One-hot Embedding）。

所构建的 (a_1, a_o) 或者 (a_1, a_o, a_2) 表示了当前步骤下的一个一元或者二元特征生成。通过这样的变换可以生成下一个步骤的数据集 F_{t+1} 。同样可以构建一个评估函数来评价这样的一组操作，并在迭代的过程中逐渐训练三个智能

体进行合作，从而能够生成高质量且具备生命科学意义的数据。由于每一个步骤的变换都会存储相应的决策过程，这样所有最终生成的特征都是可以溯源到原始数据集的，从而保证了特征生成过程中的可溯源性。

在各智能体逐渐掌握专家进行高通量特征选择、特征生成的行为模式、了解到各个特征之间的关联关系的过程中，将会累计大量的决策行为记录以及对这些决策记录的评价。通过收集这些决策可以获得在各智能体收敛初期具有高多样性的记录，同时也能够收集到收敛后高质量的特征选择行为记录。

3.2.3 融合多评价指标下综合数据优化决策序列生成

针对现有数据优化算法难以在有限探索步骤中达到综合最优的问题，研究多视角数据优化行为建模，实现对各个智能体内数据优化知识的表示；研究综合最优决策序列搜索，实现在连续的多块知识平面所组成的知识空间上搜索最优的决策序列；研究最优特征优化决策链生成，实现将连续的决策表示重新构建成离散的决策过程，并最终解决数据集的综合优化问题。图 10 是本章节研究的整体展示。




图 10. 融合多评价指标下综合数据优化决策序列生成的整体研究方案

(1) 多视角数据优化行为建模

多智能体强化学习方法是对数据优化任务中巨量的搜索复杂度（特征选择为 $O(2^N)$ ，而特征生成的搜索空间是无限的）的一种高效搜索方案。但为了获取到最优的决策序列，依然需要较大的时间成本。为了解决这个问题，可以利用有限的 T 轮强化学习探索（ $T \ll N$ ）所收集到的离散决策与评价来构建一个拟合的连续向量空间，在该向量空间中进行优化可以将离散决策搜索任务转换



为连续优化任务，进而通过解码器重构出更优的离散决策，能够极大减少任务所需要的循环数。

以高通量数据的特征选择为例,对于数据集 $F = \{X, y\}$, 其中 X 是待选择的特征, 而 y 是下游任务的标签。对其进行的特征选择任务可以看做是找到 X 内基因的一个子集 $f = \{f_1, f_2, \dots\}$, 使得 $X[f]$ 在下游任务中取得更优的表现。在前 T 轮强化学习探索的过程中, 可以收集到 T 个不同的子集记录 $\mathcal{R} = \{(f_i, V_i)\}_{i=1}^T$, 其中 $V_i = \{v_1, v_2, v_3, \dots\}$ 是在多个下游任务或生命科学评价指标下该次选择 f_i 的表现。此时, 可以利用一堆编码器 $\phi(\cdot)$ 与解码器 $\psi(\cdot)$ 令离散的决策序列 f_i 映射到连续的知识平面 Ω 上:

$$f \xrightarrow{\phi} E \xrightarrow{\psi} \hat{f}, \quad (1.7)$$

其中 E 是 f 映射到知识平面 Ω 上的一个点, $\hat{f}$ 是还原出的子集。此时, 给定一个评价函数 $Eval(\cdot)$, 原始的优化目标可以定义为:

$$f^* = \psi(E^*) = \underset{E \in \Omega}{\operatorname{argmax}} Eval(X[\psi(E)], y) \quad (1.8)$$

为了实现公式 1.8 中的优化目标, 可以通过一个与编码器解码器共同训练的评估器 $\omega(\cdot)$ 来拟合离散的评价函数 $Eval(\cdot)$, 则原始的离散优化问题可以转化为连续空间上的优化问题:

$$f^* = \psi(E^*) = \underset{E \in \Omega}{\operatorname{argmax}} \omega(X[\psi(E)]), \quad (1.9)$$

由于在前面的步骤中已经收集到 T 个不同的子集记录 $\mathcal{R}$, 其包含多个下游任务或生命科学评价指标 V 。给定任意一组评价指标 v , 可以依靠以下损失函数训练编码器-解码器-评估器架构:

$$L_{ae} = -\log P_{\psi}(f|E), \quad (1.10)$$

$$L_{\omega} = \text{MSE}(v, \omega(E)).$$

此处的 L_{ae} 是决策序列 f 的重构损失, L_{ω} 是评估器对编码后的隐藏表征 E 的评估损失, MSE 表示着均方误差 (Mean Squared Error)。通过对多个下游任务或生命科学评价指标 V 采用上述方法, 训练评估器以构建知识平面, 可以获

得数据优化行为的多视角知识空间。多视角知识空间能够将行为决策序列与这些决策的多维度评价嵌入到多个连续向量空间中，为后续的综合最优决策序列搜索提供基础。

(2) 综合最优决策序列搜索

依据公式 1.9 中的优化目标，可以获得在特定 $\omega(\cdot)$ 上最优的决策序列的连续向量表示 E^* ，但如何利用多组收敛的评估器，并生成综合最优的决策序列依然是需要解决的问题。

首先考虑利用梯度上升的方法，通过收敛的单个评估器来搜索最优决策序列，此时的单步搜索优化移动方向与长度 δ 可以通过评估器 $\omega(\cdot)$ 在某一个预选次优的向量表示的梯度上得到：

$$\delta = \eta \nabla_{\theta_{\omega}} L(\theta_{\omega}), \quad (1.11)$$

此处的 η 是单次搜索的步长，由给定的 E 出发移动 δ ，以获得 E^+ 这一个优化后的次优点，随后可以再次通过公式 1.11 获得 E^+ 下的步长与方向，进行下一次的搜索。如此连续的探索后可以获得从 E 出发的局部最优点，从多个备选连续向量开始搜索即可获得当前评价指标下的全局最优点。申请人在前期工作中已经过实验验证，该基于梯度优化的方法可以从一个高质量的起点出发搜索得到最优点。




图 11. 综合最优决策序列搜索

如图 11 所示，领域内的特征工程专家的知识可以看做是一个“真实知识平面”，尽管这个平面是不可知、无法表示的，但可以通过多智能体强化学习所收集、构建的多个不同评价指标的知识平面，来组合成知识空间实现拟合“真实知识平面”。在这个拟合的知识空间上进行搜索可以看做是专家在思考针对



某个数据集的最优决策生成。而为了实现综合最优的决策序列搜索，通过以上场景的思考，考虑多视角的综合最优化，并采用多目标优化的思路。与单目标优化类似，多目标优化的局部最优解可以通过梯度搜索的形式得到，对于次优连续表达 E^+ 以及收敛的 K 个共享编码器参数的评估器 $\{\omega_1, \dots, \omega_K\}$ ，其最优点 E^* 满足 Karush-Kuhn-Tucker (KKT) 条件：

1. 存在 $\alpha_1, \dots, \alpha_K \geq 0$ 满足 $\sum_{k=1}^K \alpha_k = 1$ 且 $\sum_{k=1}^K \alpha_k \nabla_{\theta_{\omega_k}} L^k(\theta_\phi, \theta_{\omega_k}) = 0$
2. 对于每一个评估器 ω_k ，满足 $\nabla_{\theta_{\omega_k}} L_k(\theta_\phi, \theta_{\omega_k}) = 0$

满足以上 KKT 条件的被称为帕累托驻点 (Pareto Stationary Point)，是综合最优点的必要条件，并可以转化为以下优化问题：

$$\min_{\alpha_1, \dots, \alpha_K} \left\{ \left\| \sum_{k=1}^K \alpha_k \nabla_{\theta_\phi} L_k(\theta_\phi, \theta_{\omega_k}) \right\|_2^2 \mid \sum_{k=1}^K \alpha_k = 1, \alpha_k \geq 0, \forall k \right\} \quad (1.12)$$

依据公式 1.12 中的优化目标，可以采用综合梯度优化方向对驻点进行搜索，并通过单目标优化场景类似的方式选出综合最优点。这个综合最优点会满足多个评价指标构架的知识平面的约束，进而接近真实知识平面上的最优点。

(3) 最优特征优化决策链生成

在完成了综合最优决策序列搜索后，还需要将连续向量表示的决策序列转化为离散的决策序列。在特征生成的过程中，可能会因为一些错误生成的操作，导致最后生成的变换无效或者产生数值错误；同时，多个计算的嵌套在序列形式的表示上可能会引起多义性，进而引起生成的序列计算顺序不明；最后，引入括号的决策链可能会过于长，从而让编码器解码器结构难以收敛。

$$(f_1 + ((f_1 + f_2)/f_3) - f_2), (\sqrt{f_1}), \dots, (...)$$

(a) 特征生成决策序列

$$\boxed{SOS} \boxed{f_2} \boxed{+} \boxed{[} \boxed{[} \boxed{[} \boxed{f_1} \boxed{+} \boxed{f_2} \boxed{]} \boxed{/} \boxed{f_3} \boxed{]} \boxed{-} \boxed{f_2} \boxed{]} \boxed{SEP} \boxed{\sqrt{\cdot}} \boxed{f_1} \boxed{SEP} \dots \boxed{SEP} \dots \boxed{EOS}$$

(b) 带括号的特征生成序列

$$\boxed{SOS} \boxed{f_2} \boxed{f_1} \boxed{f_2} \boxed{+} \boxed{f_3} \boxed{/} \boxed{f_3} \boxed{-} \boxed{+} \boxed{SEP} \boxed{f_2} \boxed{\sqrt{\cdot}} \boxed{SEP} \dots \boxed{SEP} \dots \boxed{EOS}$$

(c) 后续表达变换的特征生成序列

图 12. 决策链编码方案

为了解决这个问题，首先要设计一个无二义性同时足够精简的决策链编码方案。图 12 展示了特征生成决策序列的几种不同形式，可以看出后续表达变换形式可以在保证无二义性的同时足够精简。每一个决策链都使用特殊编码 $\langle SOS \rangle$ 来表示序列开始，用 $\langle SEP \rangle$ 来表示每条变换序列间的分隔，以防



止某一条序列出现问题后整个决策链非法， $\langle EOS \rangle$ 代表序列结束。

此外，为了解决在从连续向量表示中还原出离散的决策序列（用 Υ 来表示）时，可能会遇到解码过程中产生的决策序列非法的问题，可以采用束搜索（Beam Search）技术来减少非法决策序列的生成。具体而言，针对优化后的嵌入 E^* ，在 t 时刻，保持历史预测并设定束宽为 b ，记作 $\{\Upsilon_{<t}^i\}_{i=1}^b$ 。对第 i 束而言，解码器 ψ 在 t 时刻所识别的标记的概率分布为 γ ，计算方式如下：

$$P_t^i(\gamma) = P_\psi(\gamma|E, \Upsilon_{<t}^i) * P_\psi(\Upsilon_{<t}^i|E), \quad (1.13)$$

此处的 $P_t^i(\gamma)$ 是前一个解码步骤的概率分布与当前解码步骤的概率分布之间的连乘。在公式 1.13 推进的过程中，可以收集到每个波束的每一次解码的条件概率分布。之后，可以将具有 top- b 概率值的标记附加到每个波束的历史预测中，以获得新的历史集合 $\{\Upsilon_{<t+1}^i\}_{i=1}^b$ ，并迭代地推进这个解码过程，直到所有的束都预测出 $\langle EOS \rangle$ 。此时输出概率值最高的变换序列作为输出。

通过根据 $\langle SEP \rangle$ 将决策链分成不同的部分，并检查每个变换序列的有效性并删除无效的部分来保证整体运算的合法性。这里，有效性是通过衡量后缀表达式所表示的数学运算组合是否可以成功计算以产生新特征来决定的。这些有效的后缀表达式重构了一个特征变换操作序列 Υ ，用于生成优化后的特征空间 $F \xrightarrow{\Upsilon} F^*$ 。 F^* 即为综合考虑多视角与生命科学背景知识的最优数据集。

3.2.4 针对生命科学领域的的数据优化测试验证

本项目面向生命科学研究与人工智能交叉的典型应用场景，构建数据优化原型系统，围绕国家生物信息中心实际需求进行测试验证，并围绕相关研究的效果改善，论证本项目理论与技术的先进性。

（1）系统架构

生命科学领域的表格科学数据优化测试验证系统架构图如图 13 所示，包括数据资源层、知识抽取层、数据优化层及应用服务层。自底向上来说，数据资源层主要包括生命科学领域内的知识库，包括疾病知识库、基因知识库、蛋白知识库以及领域内相关的科研文献知识库等，此外，还包括真实的脱敏的疾病诊疗数据集，包括患者以及正常人群体的基因组单细胞测序数据、突变点位数据以及患者的基本数据。知识抽取层负责从领域背景知识数据库中抽取生命科学领域背景知识，并完成对大语言模型的知识注入，最后以融合背景知识的特征的表征的形式提供给数据优化层。数据优化层接受来源于真实脱敏数据集



中的高通量测序、突变点位数据，以及低质量的患者基本数据，通过冗余特征去除、高质量特征生成等为应用服务层提供优化后高质量的数据集。最后应用服务层采用深度学习、机器学习算法，依托数据优化后高质量的数据集，支持国家生物信息中心的解析遗传疾病的遗传基础机制、发掘疾病风险新基因、新生物标志物及治疗新靶标等任务，满足国家生物信息中心的重大需求。




图 13. 面向生命科学领域的表格数据优化测试验证系统架构图

(2) 系统测试验证

本项目将依据图 13 中的系统架构图，围绕国家生物信息中心的遗传疾病相关研究为应用场景，进行系统测试。具体场景将会围绕某脱敏的遗传疾病公开数据集，该数据集包括普通的参与人员与心血管、癌症等遗传疾病患病者的去识别化遗传、生活方式、健康信息以及生物样本。由于数据由高通量的测序数据以及突变位点数据还有低质量的健康信息、生活方式等复杂组成，由于数据的特性，将机器学习、深度学习模型直接应用在其之上效果很差。将会依据本课题构建的系统对其进行数据优化，提高人工智能模型的效果，促进交叉学科研究。

具体来说，会从来源于 NCBI、PubMed 等多个数据源构建的知识库中抽取生命科学背景知识，并将这些高质量先验知识注入大语言模型；通过大语言模型初始化给定的高通量数据或低质量数据的特征的特征；依靠特征选择与特征生成算法收集多种决策；将这些决策与其对应的多组评价指标下的表现进行



联合建模，构建综合知识空间；在这些连续的知识空间上执行搜索，获取综合最优的决策的连续向量表示；最后将向量表示进行还原，构建综合最优的决策链。通过应用决策链的变换，构建优化后的数据集，提升下游人工智能模型的鲁棒性，为后续生命科学研究提供支持。

3.3 可行性分析

本部分从分析本项目研究方案的可行性展开阐述，探讨了申请人依托团队开展的先期研究和探索结果，同时说明了申请人能够胜任该项目的研究任务。

研究目标明确。 本项目围绕生命科学领域与人工智能交叉研究中的关键数据质量需求，开展围绕领域高质量先验知识的抽取与注入、结合领域知识的多智能体数据优化算法研究、融合多评价指标下综合最优决策生成等三方面研究。重点突破多模态高价值知识的共性表达、自动数据优化算法、最优决策链生成等关键技术，并且结合国家生物信息中心的实际场景需求，进行测试验证，整体研究的目标明确。

研究内容充分。 本项目首先探索了领域内多模态高价值知识结合大语言模型的知识注入、结构模态建模、共性知识抽取。其次，研究领域知识与数理特性结合的特征表征、选择、生成，构建数据优化决策序列。然后，通过建模离散决策过程，构建多视角数据优化知识空间，实现离散决策的连续优化，完成综合最优决策链生成。最后，围绕数据优化原型系统，针对生命科学领域数据集，开展测试验证。本项目研究具有严密的逻辑性，多个内容之间有着清晰的体系规划，整体研究内容充分。

研究方案可行。 本项目在对数据优化、领域知识建模等方向的国内外研究现状进行了充分阐述与分析的基础上，结合申请人与依托团队长期的研究基础、数据基础、技术积累，明确了项目研究内容，并且设计了可行的项目研究方案，为顺利开展本研究奠定了良好的基础。

申请人依托多学科交叉团队，前期围绕领域知识的构建、通用领域数据优化开展了深入的研究，在多个本项目相关的关键技术点验证了研究方案的可行性，部分代表成果如下：

代表性成果 1：通用领域的数据优化算法

申请人在博士期间围绕通用领域的的数据优化任务开展了深入研究，并基于多智能体强化学习方法、表示学习方法，提出了一系列特征选择、特征生成模型。一方面，借助多智能体强化学习技术，能够在智能体收敛前期获取多样性



数据集	数据来源	任务类别	样本量	特征量	RDG	ERG	LDA	AFAT	NFS	TTG	GRFG	DIFER	MOAT
Higgs Boson	UCIrvine	C	50000	28	0.695	0.702	0.513	0.697	0.691	0.699	0.707	0.669	0.712
Amazon Employee	Kaggle	C	32769	9	0.932	0.934	0.916	0.930	0.932	0.933	0.932	0.929	0.936
PimaIndian	UCIrvine	C	768	8	0.760	0.761	0.638	0.765	0.749	0.745	0.754	0.760	0.807
SpectF	UCIrvine	C	267	44	0.760	0.757	0.665	0.760	0.792	0.760	0.818	0.766	0.912
SVMGuide3	LibSVM	C	1243	21	0.787	0.826	0.652	0.795	0.792	0.798	0.812	0.773	0.849
German Credit	UCIrvine	C	1001	24	0.680	0.740	0.639	0.683	0.687	0.645	0.683	0.656	0.730
Credit Default	UCIrvine	C	30000	25	0.805	0.803	0.743	0.804	0.801	0.798	0.806	0.796	0.810
Messidor_features	UCIrvine	C	1150	19	0.624	0.669	0.475	0.665	0.638	0.655	0.692	0.660	0.749
Wine Quality Red	UCIrvine	C	999	12	0.466	0.461	0.433	0.480	0.462	0.467	0.470	0.476	0.559
Wine Quality White	UCIrvine	C	4900	12	0.524	0.510	0.449	0.516	0.525	0.531	0.534	0.507	0.536
SpamBase	UCIrvine	C	4601	57	0.906	0.917	0.889	0.912	0.925	0.919	0.922	0.912	0.932
AP-omentum-ovary	OpenML	C	275	10936	0.832	0.814	0.658	0.830	0.832	0.758	0.849	0.833	0.885
Lymphography	UCIrvine	C	148	18	0.108	0.144	0.167	0.150	0.152	0.148	0.182	0.150	0.267
Ionosphere	UCIrvine	C	351	34	0.912	0.921	0.654	0.928	0.913	0.902	0.933	0.905	0.985
Housing Boston	UCIrvine	R	506	13	0.404	0.409	0.020	0.416	0.425	0.396	0.404	0.381	0.467
Airfoil	UCIrvine	R	1503	5	0.519	0.519	0.220	0.521	0.519	0.500	0.521	0.558	0.629
Openml_618	OpenML	R	1000	50	0.472	0.561	0.052	0.472	0.473	0.467	0.562	0.408	0.692
Openml_589	OpenML	R	1000	25	0.509	0.610	0.011	0.508	0.505	0.503	0.627	0.463	0.656
Openml_616	OpenML	R	500	50	0.070	0.193	0.024	0.149	0.167	0.156	0.372	0.076	0.526
Openml_607	OpenML	R	1000	50	0.521	0.555	0.107	0.516	0.519	0.522	0.621	0.476	0.673
Openml_620	OpenML	R	1000	25	0.511	0.546	0.029	0.527	0.513	0.512	0.619	0.442	0.642
Openml_637	OpenML	R	500	50	0.136	0.152	0.043	0.176	0.152	0.144	0.307	0.072	0.465
Openml_586	OpenML	R	1000	25	0.568	0.624	0.110	0.543	0.544	0.544	0.646	0.482	0.700

的优化决策，在收敛后期获取高质量的优化决策。另一方面，通过收集的特征选择、特征生成决策，构建知识平面，实现了单一视角的连续数据优化决策链生成。依据这两个方面的思想，在金融风控、医学诊疗等 23 个开源数据集上对于分类与回归这两类经典机器学习任务进行了通用数据优化模型验证，模型效果如表 1 所示，可以发现 MOAT 通过连续数据优化，能够比多智能体强化学习方法 GRFG 搜索到更优秀的数据优化决策，这是由于离散的优化方法搜索能力有限所导致的。

在这些工作的基础上，申请人依托主持的博士后基金面上项目“基于数据智能的单细胞组学数据优化算法研究”，围绕多智能体在高通量数据下收敛效



率低、奖励获取过于平滑等效率与有效性问题，采用特征选择先验知识注入的思路开展了先期工作，并构建了一个基于多智能体强化学习的高通量组学特征选择算法，如表 2 所示，已在在多个生物公开数据集上进行了性能与效率验证，与当前最优方法 CellBRF 相比，初步论证了框架在高通量数据集上的有效性。

表 2. 基于多智能体强化学习的高通量组学特征选择算法的预研性能展示

数据集	细胞数量	基因数量	细胞类别数量	数据规模	Ours (先期工作)				CellBRF		
					运行时间	效果	选择基因数	重合基因数	运行时间	效果	选择基因数
Chu1	758	19176	6	小数据集	18.62	0.8629	235	117	4.06	0.844	249
	515	20345	5	小数据集	74	0.5025	226	119	4.22	0.444	246
	466	22085	9	小数据集	133	0.681	343	168	4.76	0.742	357
	203	23337	4	小数据集	31.79	0.8042	153	75	3.59	0.808	140
Goolam	124	41388	8	小数据集	4.3	0.7326	337	170	4.37	0.655	357
Koh	498	60483	9	小数据集	20.194	0.9943	337	170	5.22	0.991	321
Kumar	361	22394	4	小数据集	37.15	0.99	95	41	4.04	0.989	106
Leng	247	19084	247	小数据集	25.73	0.8779	165	82	4.31	0.946	133
Li	561	57241	7	小数据集	25.73	0.947	226	132	5.86	0.854	242
Maria2	759	33694	7	小数据集	53.35	0.5384	128	69	4.4	0.525	122
Robert	194	23418	2	小数据集	31	0.6717	42	22	3.5	0.5558	26
Ting	187	21583	7	小数据集	71.45	0.8209	234	109	4.1	0.653	231
Cao	4186	13488	10	大数据集	305.55	0.635	117	61	9.46	0.607	111
Chu2	1018	19097	7	大数据集	4.24	0.999	211	111	4.46	0.964	227
Han	2746	20670	16	大数据集	457.99	0.7864	258	136	8.45	0.764	249
MacParland	14653	5000	11	大数据集	1782.13	0.831	377	190	34.3	0.763	100
Maria1	1277	33694	7	大数据集	23.74	0.653	144	73	5.84	0.626	127
Puram	3363	23686	8	大数据集	374.51	0.8132	287	146	11.41	0.745	277
Yang	1119	46609	6	大数据集	102.27	0.6761	229	115	6.88	0.626	262

* 表中汇报的“效果”为细胞聚类的表现，使用 NMI (Normalized Mutual Information) 评价，标蓝色的为较好的结果。

本部分研究将为“研究内容 2：结合领域知识的多智能体自动数据优化算法研究”及“研究内容 3：融合多评价指标下综合数据优化决策序列生成”提供理论及技术基础支撑。

代表性成果 2：生命科学领域知识建模




图 15. 领域知识注入后的单细胞组学数据表征可视化

申请人依托主持的国家资助博士后计划“基于大规模语言模型的基因组学



复杂语义特征对齐研究”、特别研究助理资助计划“基于大语言模型的组学数据建模方法研究”，与中国科学院动物研究所北京干细胞与再生医学研究院紧密合作，开展了针对大语言模型的大规模学术知识注入的先期探索工作。

具体而言，通过利用 Llama-13b 这一通用领域大语言模型，采用自指令问答形式进行了领域知识注入的先期工作，并在基于单细胞组学数据的跨物种细胞标注任务上取得了一定的效果。图 15 是这个先期探索的可视化展示，可以发现领域知识注入后构建的单细胞表征相对于直接基于 GPT-3.5 的 GenePT 方法，有着更好的空间可分性。

蛋白名称	大语言模型总结的摘要	NCBI知识库中专家撰写摘要
RCAN2	"RCAN2, a gene located on chromosome 6, encodes a membrane-associated protein with ankyrin repeats, a protein phosphatase-1-interacting domain, and a CAAX box domain. Its synthesis is inhibited by transforming growth factor beta-1. The protein may bind to the membrane through its CAAX box domain and act as a signaling molecule through interaction with protein phosphatase-1. Alternative splicing generates multiple isoforms. RCAN2 is implicated in angiogenesis regulation, with its serum concentrations correlating with anthropometric and metabolic parameters. Additionally, it plays a role in inhibiting calcineurin activity and modulating VEGF-mediated angiogenesis."	"This gene encodes a member of the regulator of calcineurin (RCAN) protein family. These proteins play a role in many physiological processes by binding to the catalytic domain of calcineurin A, inhibiting calcineurin-mediated nuclear translocation of the transcription factor NFATC1. Expression of this gene in skin fibroblasts is upregulated by thyroid hormone, and the encoded protein may also play a role in endothelial cell function and angiogenesis. Alternatively spliced transcript variants encoding multiple isoforms have been observed for this gene."
PTPRR	"The protein tyrosine phosphatase receptor type R (PTPRR) is a membrane-associated protein with five ankyrin repeats, a protein phosphatase-1-interacting domain, and a carboxy-terminal CAAX box domain. It is negatively regulated by androgen receptor signaling and is an early target of androgen stimulation. PTPRR inactivation, through CpG island methylation and histone-tail marks, is associated with colorectal cancer progression. PTPRR, along with PTPN5 and PTPN7, specifically inactivates MAPKs, and its downregulation enhances cell motility. The glycosylation of immunoglobulin G (IgG) influences its effector function, and PTPRR may be a potential therapeutic target for neurodegenerative diseases."	"The protein encoded by this gene is a member of the protein tyrosine phosphatase (PTP) family. PTPs are known to be signaling molecules that regulate a variety of cellular processes including cell growth, differentiation, mitotic cycle, and oncogenic transformation. This PTP possesses an extracellular region, a single transmembrane region, and a single intracellular catalytic domain, and thus represents a receptor-type PTP. Silencing of this gene has been associated with colorectal cancer. Multiple transcript variants encoding different isoforms have been found for this gene. This gene shares a symbol (PTPRQ) with another gene, protein tyrosine phosphatase, receptor type, Q (GeneID 374462), which is also located on chromosome 12."
PTPRN2	"PTPRN2 encodes a membrane-associated protein with five ankyrin repeats, a protein phosphatase-1-interacting domain, and a carboxy-terminal CAAX box domain. Its synthesis is inhibited by transforming growth factor beta-1. The protein may bind to the membrane through its CAAX box domain and act as a signaling molecule through interaction with protein phosphatase-1. Alternative splicing generates multiple transcript variants encoding different isoforms. The protein's intricate framework of assembly protein complexes and its involvement in cellular processes and signaling events make it a crucial player in cellular function and regulation."	"This gene encodes a protein with sequence similarity to receptor-like protein tyrosine phosphatases. However, tyrosine phosphatase activity has not been experimentally validated for this protein. Studies of the rat ortholog suggest that the encoded protein may instead function as a phosphatidylinositol phosphatase with the ability to dephosphorylate phosphatidylinositol 3-phosphate and phosphatidylinositol 4,5-diphosphate, and this function may be involved in the regulation of insulin secretion. This protein has been identified as an autoantigen in insulin-dependent diabetes mellitus. Alternative splicing results in multiple transcript variants."

图 16. 大语言模型利用文献生成的蛋白功能描述与 NCBI 知识库中专家撰写的功能描述对比

此外，申请人在博士期间对交叉学科领域知识建模的研究基础上，广泛探索了通过提示学习技术，利用大语言模型对交叉领域知识进行总结、生成，并在 NCBI 知识库上实践了基于领域文献的自动化的基因/蛋白功能描述生成。图 16 展示了这个先期工作的效果。可以发现，大语言模型不但可以很好地总结蛋白的功能，同时还能够从文献中获取一些专家未能总结出的蛋白功能。例如 PTPRR 蛋白，通过领域的背景知识，大语言模型不但提到了 PTP 家族的其他两种蛋白，PTPN5 与 PTPN7，同时基于另外一篇文献总结出：“PTPRR 可能



是治疗某些神经退行性疾病的潜在药物靶点。”（生成的内容：“...PTPRR may be a potential therapeutic target for neurodegenerative diseases.”，此处知识来自于 Eswaran J 在 2006 年的一篇文献：Crystal structures and inhibitor identification for PTPN5, PTPRR and PTPN7: a family of human MAPK-specific protein tyrosine phosphatases）

本部分研究将为“**研究内容 1：基于大语言模型的生命科学领域多模态知识注入**”提供理论及技术基础支撑。

代表性成果 3：跨物种生命科学数据积累

申请人依托多学科交叉团队，参与建立了目前已知最大规模、包含小鼠和人类等多物种的超过 1.26 亿细胞的高质量训练数据集 scCompass-126M，并支持了组学数据大模型的训练任务。建立了谱系全景数据库，实现从转录组、单细胞转录组、表观基因组等不同层面的数据集，捕捉了人类和经典模式生物等 10 余个物种从胚胎、胎儿、成人到老年阶段细胞谱系的变化，实现了不同条件下基因表达改变的汇聚融合。完成了千万级别生物学文献的入库，其中包括 800 万篇全文。初步实现了基因、蛋白等生命科学相关数据的知识库构建。申请人依托团队，获取了 56 万人（5 万患者和 51 万对照）的冠心病队列数据，包括高通量的全基因组/全外显子组测序数据和低信息量的电子病历数据，目标在未来解析心脑血管疾病的遗传基础机制，发掘疾病风险新基因、新生物标志物及治疗新靶标。

本部分成果将为“**关键技术验证：针对生命科学领域的数据优化测试验证**”提供数据基础与实际应用场景。

4. 本项目的特色与创新之处：

本项目围绕生命科学领域与人工智能领域交叉过程中出现的数据瓶颈，以及支撑国家生物信息中心数据需求，从领域先验知识提取、数据优化知识需求、决策视角单一等科学问题出发，开展了知识建模、行为收集、决策生成三个角度的研究。具体创新内容包括理论、技术和应用三个部分。

（1）理论与技术创新：

本项目的理论创新在于构建以多模态领域共性知识表达研究、针对特定领域的多智能强化学习的数据优化研究、数据优化知识平面连续空间优化研究三个角度的理论工作。本项目提出了面向生命科学领域的数据优化技术，包括基于大语言模型的领域知识建模方法、结合领域知识的多智能体自动数据优化算



法、综合多评价指标下综合数据优化决策链生成算法，深度交融了生命科学领域与人工智能领域，解决了领域内数据利用的瓶颈问题，提升下游人工智能模型的鲁棒性和表现力。

(2) 应用创新：

本项目聚焦于国家生物信息中心实际科研需求，以团队收集的多来源真实脱敏数据为基础，开发可溯源的数据优化原型系统。针对国民生命健康需求，验证本项目成果的先进性，并同时支撑团队其他应用场景，推进生命科学学科与人工智能学科的交叉研究开展。

5. 年度研究计划及预期研究结果（包括拟组织的重要学术交流活动、国际合作与交流计划等）。

5.1 年度研究计划

本项目执行期为 2025 年 1 月至 2027 年 12 月共三年，针对本项目的研究内容，指定的年度计划如下：

第一年度上半年（2025 年 1 月至 2025 年 6 月）：围绕先期工作所累积的成果与数据基础，进一步与合作单位推进领域知识库、论文矢量数据库的构建。基于已有的数据基础，完善多智能体强化学习在生命科学领域高通量数据上的数据优化算法研究。

第一年度下半年（2025 年 7 月至 2025 年 12 月）：与生命科学领域内专家展开深度合作，基于构建的领域知识库、论文数据库，研究基于大语言模型的领域知识注入方法，为后续基于领域知识的数据优化算法提供基础支撑。

第二年度上半年（2026 年 1 月至 2026 年 6 月）：建模领域知识与表格数据之间的关联关系，进而研究领域知识在数据优化角度上的应用，围绕电子病历数据，实现生命科学领域通用的多智能体强化学习特征生成算法。

第二年度下半年（2026 年 7 月至 2026 年 12 月）：围绕国家生物信息中心科研需求，持续推进领域知识建模在高通量组学、蛋白组学、代谢组学的关键化合物定位、关键通路解析上的应用，开发结合领域知识的多智能体强化学习特征选择算法、多视角数据优化决策生成。

第三年度上半年（2027 年 1 月至 2027 年 6 月）：集成现有成果，针对实际业务需求展开应用验证，形成理论及技术体系。围绕某脱敏的遗传疾病公开数据集，预期完成该领域的数据优化系统，与国家生物信息中心合作开展相关研究，实现应用验证。



第三年度上半年(2027年7月至2027年12月):整理项目开展过程中的代码资源并开源,整理研究报告,完成项目结题。

5.2 预期研究结果

本项目预期取得如下研究结果:

(1) 理论与技术成果

建立面向生命科学领域的表格科学数据优化理论,包括基于大语言模型的领域知识建模方法、结合领域知识的多智能体自动数据优化算法、综合多评价指标下综合数据优化决策链生成算法。具体成果如下:

1. 建立注入生命科学领域知识的大语言模型,具备理解表格数据元数据的能力。
2. 建立结合领域知识的自动数据优化算法,具备围绕单一视角,针对领域内高通量数据进行特征选择,以及对低质量数据进行数学变换实现特征生成。
3. 建立综合多评价指标下综合数据优化决策链生成算法,具备结合领域知识与数据优化知识,实现多视角的数据优化。
4. 围绕国家生物信息中心的典型业务需求,完成领域数据优化,进行测试验证。
5. 以工具箱形式公开相关代码,推动、支持生命科学领域与人工智能领域学科交叉研究。

(2) 论文及专利成果

发表领域内 CCF-A/B 类会议或 IEEE/ACM 汇刊论文 5 篇及以上;相关技术申请国家发明专利 4 项。

(3) 人才培养与交流

依托本项目,培养相关领域硕士研究生 2 名。项目期间参与或举办数据优化主题的研讨会 1 次,参与国际会议 3 次及以上,扩大数据优化为中心的人工智能技术以及相关技术在生命科学领域应用的影响力。

(二) 研究基础与工作条件

1. 研究基础 (与本项目相关的研究工作积累和已取得的研究工作成绩);

项目负责人肖蒙于 2023 年 6 月在中国科学院计算机网络信息中心获工学博士学位,导师为周园春研究员,期间与新加坡科技研究所信息通讯研究所



(I²R, A*STAR) 进行联合培养，**获中国科学院学生最高奖中国科学院院长特别奖**。肖蒙于 2023 年以助理研究员（博士后）身份加入中国科学院计算机网络信息中心，**并于 2024 年入选北京市青年人才托举计划**，中国博士后基金会国家资助博士后计划，中国科学院特别研究助理资助计划，主持一项博士后面上基金项目，以骨干成员参与国家自然科学基金重点项目“面向领域大数据的知识图谱构建”（2024 年已结项），国家发改委重大专项“国家生物信息中心”，重点研发计划青年科学家项目等。

申请人近三年在计算机协会推荐数据挖掘、人工智能领域下 A/B 类的高水平国际期刊、国际学术会议如 *IEEE TKDE*、*NeurIPS*、*Artificial Intelligence*、*ACM TKDD*、*ICDM*、*IJCAI* 等发表论文十余篇，包括第一/通讯（共同）作者十篇，其中**一篇论文入选 NeurIPS 2023 Spotlight（亮点论文）**。申请六项国家专利，其中已授权一项。相关科技创新成果应用于国家生物信息中心、国家自然科学基金大数据知识管理服务系统、爱尔眼科集团眼健康自动诊疗系统等，并被中国科学报登报报道。担任 *SIGKDD*、*ICLR*、*WWW*、*ACM MM* 等 CCF 推荐国际学术会议的程序委员会委员，担任 *ICDM 2023* 的 *Data-Centric AI Workshop* 联合主席（Co-chair）。

申请人对以数据优化为核心的人工智能系统、领域知识建模、大数据技术有着一系列具有延续性、成体系的研究背景。前期工作已经探索了与本项目相关的通用领域的数据优化算法、交叉学科领域特别是生命科学领域的知识建模。相关代表性成果与预研实验为本项目的顺利实施提供了**重要的理论基础**。

申请人的依托单位是国家生物信息中心共建单位，为申请者提供了丰富的生物信息科学数据资源和实际的应用场景。作为国家生物信息中心的共建单位，目前已经汇集生物领域的数据资源超过 6PB，总记录条数超过 50 多亿。申请人前期参与建立了目前已知最大规模、包含小鼠和人类等多物种的超过 1.26 亿细胞的高质量训练数据集 scCompass-126M，并支持了组学数据大模型的训练任务。建立了谱系全景数据库，实现从转录组、单细胞转录组、表观基因组等不同层面的数据集，捕捉了人类和经典模式生物等 10 余个物种从胚胎、胎儿、成人到老年阶段细胞谱系的变化，实现了不同条件下基因表达改变的汇聚融合。完成了千万级别生物医学文献的入库，其中包括 800 万篇全文。初步实现了基因、蛋白等生命科学相关数据的知识库构建。积累的大量领域知识和相关数据，为本项目的顺利实施提供了**坚实的数据基础**。



申请人与中国科学院动物研究所北京干细胞与再生医学研究院、中国科学院北京基因组研究所建立了一定的合作基础。深度参与中国科学院多学科交叉研究团队组成的“指南针联盟”(XCompass Consortium), 参与推进人工智能驱动的生命科学研究新范式研究, 为本项目的顺利实施提供了**广泛的应用前景**。

申请人的相关学术成果:

- [1] **Meng Xiao**, Ziyue Qiao, Yanjie Fu, Hao Dong, Yi Du, Pengyang Wang, Hui Xiong, Yuanchun Zhou. “Hierarchical Interdisciplinary Topic Detection Model for Research Proposal Classification”. *IEEE Transactions on Knowledge and Data Engineering (TKDE)*, 2023, (CCF-A 类推荐国际期刊, IF=9.2, JCR Q1)
- [2] **Meng Xiao**, Dongjie Wang, Min Wu, Kunpeng Liu, Hui Xiong, and Yuanchun Zhou, Yanjie Fu. “Traceable Group-Wise Self-Optimizing Feature Transformation Learning: A Dual Optimization Perspective”. *ACM Transactions on Knowledge Discovery from Data (TKDD)*, 2024, (CCF-B 类推荐国际期刊, IF=4.3, JCR Q1)
- [3] **Meng Xiao**, Dongjie Wang, Min Wu, Pengfei Wang, Yuanchun Zhou, Yanjie Fu. “Beyond Discrete Selection: Continuous Embedding Space Optimization for Generative Feature Selection”. *IEEE International Conference on Data Mining 2023, (ICDM)*, 2023, (CCF-B 类推荐国际会议).
- [4] Dongjie Wang[†], **Meng Xiao**[†] (共同一作), Min Wu, Pengfei Wang, Yuanchun Zhou, Yanjie Fu. “Reinforcement-Enhanced Autoregressive Feature Transformation: Gradient-steered Search in Continuous Space for Postfix Expressions”. *Advances in Neural Information Processing Systems 36, (NeurIPS)*, 2023, (CCF-A 类推荐国际会议, Spotlight 亮点论文).
- [5] **Meng Xiao**, Dongjie Wang, Min Wu, Ziyue Qiao, Pengfei Wang, Kunpeng Liu, Yuanchun Zhou, Yanjie Fu. “Traceable Automatic Feature Transformation via Cascading Actor-Critic Agents”. *SIAM International Conference on Data Mining 2023, (SDM)*, 2023, (CCF-B 类推荐国际会议).
- [6] **Meng Xiao**, Ziyue Qiao, Yanjie Fu, Yi Du, Pengyang Wang, Yuanchun Zhou. “Expert knowledge-guided length-variant hierarchical label generation for proposal classification”. *IEEE International Conference on Data Mining 2021, (ICDM)*, 2021, (CCF-B 类推荐国际会议).
- [7] Xunxin Cai, **Meng Xiao*** (通讯作者), Zhiyuan Ning, and Yuanchun Zhou, “Re-



solving the Imbalance Issue in Hierarchical Disciplinary Topic Inference via LLM-based Data Augmentation” *IEEE International Conference on Data Mining 2023*, (ICDM), 2023, (CCF-B 类推荐国际会议).

[8] Ziyue Qiao[†], Luo Xiao[†], **Meng Xiao[†]** (共同一作), Hao Dong, Yuanchun Zhou, Hui Xiong. “Semi-supervised Domain Adaptation in Graph Transfer Learning” . *The 32nd International Joint Conference on Artificial Intelligence*, (IJCAI), 2023, (CCF-A 类推荐国际会议).

[9] Xu Ye[†], **Meng Xiao[†]** (共同一作), Zhiyuan Ning, Weiwei Dai, Wenjuan Cui, Yi Du, Yuanchun Zhou. “NEEDED: Introducing Hierarchical Transformer to Eye Diseases Diagnosis” . *SIAM International Conference on Data Mining 2023*, (SDM), 2023, (CCF-B 类推荐国际会议).

[10] Mengyi Huang[†], **Meng Xiao[†]** (共同一作), Ludi Wang, Yi Du. “DP-CRE: Continual Relation Extraction via Decoupled Contrastive Learning and Memory Structure Preservation” . *LREC-COLING 2024*, (COLING), 2024, (CCF-B 类推荐国际会议).

[11] Hao Dong, Pengyang Wang, **Meng Xiao**, Zhiyuan Ning, Pengfei Wang, Yuanchun Zhou. “Temporal Inductive Path Neural Network for Temporal Knowledge Graph Reasoning” . *Artificial Intelligence*, (AIJ), 2024, (CCF-A 类推荐国际期刊, IF=14.1, JCR Q1).

[12] Ping Xu, Zhiyuan Ning, **Meng Xiao**, Guihai Feng, Xin Li, Yuanchun Zhou, Pengfei Wang. “scCDCG: Efficient Deep Structural Clustering for single-cell RNA-seq via Deep Cut-informed Graph Embedding” . *29th International Conference on Database Systems for Advanced Applications* (DASFAA), 2024, (CCF-B 类推荐国际会议).

[13] Ziyue Qiao, Yanjie Fu, Pengyang Wang, **Meng Xiao**, Zhiyuan Ning, Denghui Zhang, Yi Du, Yuanchun Zhou. “RPT: Toward Transferable Model on Heterogeneous Researcher Data via Pre-Training” . *IEEE Transactions on Big Data*, (TBD), 2022, (CCF-C 类推荐国际期刊, IF=7.2, JCR Q1).

[14] Yuanchun Zhou, Weijun Wang, Ziyue Qiao, **Meng Xiao**, Yi Du. “科技大数据知识图谱构建方法及应用研究综述” . *中国科学: 信息科学*. 2020, (CCF-T1 类推荐期刊).



2. 工作条件（包括已具备的实验条件，尚缺少的实验条件和拟解决的途径，包括利用国家实验室、国家重点实验室和部门重点实验室等研究基地的计划与落实情况）；

申请人的依托单位中国科学院计算机网络信息中心拥有多个国家级和省部级的创新基地与平台，**是唯一同时拥有网络、数据和计算的国家级创新平台的机构**（国家一级运营商-中国科技网、国家基础学科公共科学数据中心、国家超级计算（中国科学院）中心），大数据分析计算技术国家地方联合工程实验室的牵头单位，大数据分析系统国家工程研究中心的共建单位，是大数据应用服务技术北京市工程实验室、中国科学院科学数据总中心等省部级创新平台的依托单位，中国信息协会科学数据专业委员会、国际数据委员会 (CODATA) 的中国全国委员会的秘书长单位。

依托单位能为申请者提供先进的信息化基础设施。中国科技网拥有与国内各互联网骨干网（超过 400G）和欧美主要学术网络高速互联，与欧洲科研网 GEANT 共建跨洲际 100G 网络高速互联，正推进加入亚太欧洲 100G 科研环网 AER，实现 100G 资源互备。拥有 315PF 算力资源，150PB 存储资源。

依托单位能为申请者提供丰富的科学数据和文献资源。作为中国科学院科学数据总中心，牵头中国科学院科学数据中心体系建设，目前形成一个总中心、18 个学科中心、13 个优秀所级中心，汇聚的各类科学数据资源总量超过 70PB。牵头建设开放可信的全球数据发布共享平台-科学数据银行 ScienceDB，已成为全球万余种学术期刊推荐的论文关联数据存储与发布服务平台，目前超过 80 多个国家和地区的科研人员在 ScienceDB 发布和共享数据近 800 万条。牵头中国科学院期刊数字化平台建设，覆盖全院 400 多种期刊、预印本平台 ChinaXiv 和中国科学引文数据库 CSCD 等，覆盖 8000 万多篇文献，其中生物领域的文献超过 2000 万篇。

依托单位作为国家生物信息中心共建单位，为申请者提供了丰富的生物信息科学数据资源和实际的应用场景。作为国家生物信息中心的共建单位，目前已经汇集生物领域的数据资源超过 6PB，总记录条数超过 50 多亿。在此基础上，通过数据资源整合，形成一些高质量的科学数据产品，比如和中国科学院动物研究所合作建立了谱系全景数据库 Lineage Landscape，实现从转录组、单细胞转录组、表观基因组等不同层面的数据集，捕捉了人类和经典模式生物等 10 余个物种从胚胎、胎儿、成人到老年阶段细胞谱系的变化，实现了不同条件下



基因表达改变的汇聚融合。总体而言, Lineage Landscape 收集了超过 660 万个细胞的数据, 包括 1500 万个差异表达基因条目信息。此外, 申请人参与收集并构建不同物种的单细胞转录组开源数据, 经过筛选、清洗、均一化等预处理流程, 建立了目前已知最大规模、包含小鼠和人类的超过 1.26 亿细胞的高质量训练数据集 scCompass-126M。

依托单位为申请者提供了配套特别研究助理计划支持, 并且依托合作导师组织集研究与工程于一体的项目团队, 支持申请者开展深入的研究, 并为申请者研究成果落地提供工程人员的支撑。

合作导师周国春研究员是中国科学院计算机网络信息中心副主任、学术委员会主任, 国务院特殊津贴获得者, 国家生物信息中心建设总工程师, 中国科学院科学数据总中心主任, 大数据分析系统国家工程研究中心副主任, 中国信息协会常务理事, 中国档案学会科技档案与科学数据管理学术委员会副主任, 中国互联网协会区块链技术应用工作委员会副主任委员; 长期从事科学数据与数据智能的研究工作, 负责中国科学院科学数据中心体系建设。正在和曾经主持国家自然科学基金重点项目、国家重点研发计划项目等 20 多项。发布国家标准 7 项; 出版专著 5 本; 申请专利 80 多项, 授权 40 多项; 在 *IJCAI*、*AAAI*、*IEEE TKDE*、*Artificial Intelligence*、*Protein&Cell*、*Nucleic Acids Research* 等人工智能、数据挖掘、生物信息领域知名国际期刊发表高质量论文 100 多篇; 获省部级一等奖、二等奖各 1 项; 获 2023 年度中国科学院优秀导师称号; 培养的学生曾获中国科学院院长特别奖、中国科学院院长优秀奖、中国政府优秀来华留学生奖等。

3. 正在承担的与本项目相关的科研项目情况 (申请人正在承担的与本项目相关的科研项目情况, 包括国家自然科学基金的项目和国家其他科技计划项目, 要注明项目的资助机构、项目类别、批准号、项目名称、获资助金额、起止年月、与本项目的关系及负责的内容等);
无

4. 完成国家自然科学基金项目情况 (对申请人负责的前一个已资助期满的科学基金项目 (项目名称及批准号) 完成情况、后续研究进展及与本申请项目的关系加以详细说明。另附该项目的研究工作总结摘要 (限 500 字) 和相关成果详细目录)。
无

(三) 其他需要说明的情况



1. 申请人同年申请不同类型的国家自然科学基金项目情况（列明同年申请的其他项目的项目类型、项目名称信息，并说明与本项目之间的区别与联系）。

无

2. 具有高级专业技术职务（职称）的申请人是否存在同年申请或者参与申请国家自然科学基金项目的单位不一致的情况；如存在上述情况，列明所涉及人员的姓名，申请或参与申请的其他项目的项目类型、项目名称、单位名称、上述人员在该项目中是申请人还是参与者，并说明单位不一致原因。

无

3. 具有高级专业技术职务（职称）的申请人是否存在与正在承担的国家自然科学基金项目的单位不一致的情况；如存在上述情况，列明所涉及人员的姓名，正在承担项目的批准号、项目类型、项目名称、单位名称、起止年月，并说明单位不一致原因。

无

4. 其他。

无



肖濛（BRID: 00805.00.96167）简历

2024版

中国科学院计算机网络信息中心，助理研究员

教育经历：

- (1) 2019-09 至 2023-06，中国科学院大学，计算机应用技术，博士
- (2) 2015-09 至 2018-06，中国地质大学（武汉），软件工程，硕士
- (3) 2011-09 至 2015-06，东华理工大学，地理信息系统，学士

博士后工作经历：

- (1) 2023-07 至 今，在站，中国科学院计算机网络信息中心

科研与学术工作经历（博士后工作经历除外）：

- (1) 2022-02 至 2023-02，Agency for Science, Technology and Research, Institute for Infocomm Research, 无
- (2) 2018-08 至 2019-08，中国科学院，计算机网络信息中心，助理工程师

曾使用其他证件信息：

无

近五年主持或参加的国家自然科学基金项目/课题：

无

近五年主持或参加的其他科研项目/课题（国家自然科学基金项目除外）：

- (1) 中国博士后科学基金会，面上项目，2023M743565，基于数据智能的单细胞组学数据优化算法研究，2024-01 至 2026-01，8万元，在研，主持
- (2) 中国博士后科学基金会，国家资助博士后计划，GZC20232736，基于大规模语言模型的基因组学复杂语义特征对齐研究，2024-01 至 2026-01，24万元，在研，主持
- (3) 中国科学院，特别研究助理资助计划，无，基于大语言模型的组学数据建模方法研究，2024-01 至 2026-01，60万元，在研，主持
- (4) 中华人民共和国科学技术部，国家任务/国家重点研发计划/青年项目，2022YFF0712200，基于领域知识图谱的光电催化材料挖掘软件，2023-01 至 2025-12，200万元，在研，参与

代表性研究成果和学术奖励情况（填写代表性论文时应根据其发表时的真实情况如实规范列出所有作者署名，并对本人署名情况进行标注，包括：①作者署名按姓氏排序；②唯一第一作者；③共同第一作者；④唯一通讯作者；⑤共同通讯作者；⑥其他情况）：

一、代表性论著（请在“申请书详情”界面，点开“人员信息”-“代表性成果”卡片查看对应的全文）：

- (1) Meng Xiao; Ziyue Qiao; Yanjie Fu; Hao Dong; Yi Du; Pengyang Wang; Hui Xiong; Yuanchun Zhou; Hierarchical Interdisciplinary Topic Detection Model for Research Proposal Classification, *IEEE Transactions on Knowledge and Data Engineering* (CCF-A类推荐国际期刊, ACM/IEEE会刊, JCR一区, 影响因子9.2), 2023, 35(9): 9685-9699 (期刊论文) (本人标注: 唯一第一作者)
- (2) Meng Xiao; Dongjie Wang; Min Wu; Kunpeng Liu; Hui Xiong; Yuanchun Zhou; Yanjie Fu;



Traceable group-wise self-optimizing feature transformation learning: A dual optimization perspective, *ACM Transactions on Knowledge Discovery from Data* (CCF-B类推荐国际期刊, ACM/IEEE会刊, JCR一区, 影响因子4.3), 2024, 18(4): 1-22 (期刊论文) (本人标注: 共同第一作者)

(3) Meng Xiao; Dongjie Wang; Min Wu; Pengfei Wang; Yuanchun Zhou; Yanjie Fu ; Beyond Discrete Selection: Continuous Embedding Space Optimization for Generative Feature Selection, *IEEE International Conference On Data Mining* (CCF-B类国际会议, 2023年接受率9.3%, 数据挖掘领域三大顶级会议), Shanghai, China, 2023-12-1至2023-12-4 (会议论文) (本人标注: 共同第一作者)

(4) Dongjie Wang; Meng Xiao (共同一作); Min Wu; Pengfei Wang; Yuanchun Zhou; Yanjie Fu ; Reinforcement-Enhanced Autoregressive Feature Transformation: Gradient-steered Search in Continuous Space for Postfix Expressions, *Advances in Neural Information Processing Systems (NeurIPS) 2023* (CCF-A类推荐国际会议, Spotlight亮点论文, 三大人工智能顶级会议), New Orleans, US, 2023-12-10至2023-12-16 (会议论文) (本人标注: 共同第一作者)

(5) Meng Xiao; Ziyue Qiao; Yanjie Fu; Yi Du; Pengyang Wang; Yuanchun Zhou ; Expert Knowledge-Guided Length-Variant Hierarchical Label Generation for Proposal Classification, *International Conference On Data Mining* (CCF-B类国际会议, 2021年接受率9.8%, 数据挖掘领域三大顶级会议), Auckland, New Zealand, 2021-12-7至2021-12-10 (会议论文) (本人标注: 共同第一作者)

二、论著之外的代表性研究成果和学术奖励:

- (1) 肖濛 (1/1); 中国科学院院长奖特别奖, 中国科学院, 其他, 其他, 2023(肖濛) (科研奖励)
- (2) 肖濛 (1/1); 北京市青年人才托举计划, 北京市科学技术协会, 人才计划, 其他, 2024(肖濛) (科研奖励)
- (3) 肖濛; 周园春; 宁致远; 蔡勋鑫 ; 一种基于超大规模语言模型的富语义标签数据增广方法, 2023-10-12, 中国, 2023113204843 (专利)
- (4) 杜一; 肖濛; 乔子越; 周园春 ; 一种可利用专家知识的申请书多标签层次分类技术, 2022-07-26, 中国, 202110866392X (专利)
- (5) 周园春; 许萍; 王鹏飞; 肖濛; 宁致远 ; 基于深度图切割的scRNA-seq数据聚类方法及装置, 2023-10-16, 中国, 2023113350958 (专利)



附件信息

序号	附件名称	备注	附件类型
1	TKDE2023-1	第1-4页，CCF-A类推荐国际期刊，ACM/IEEE会刊，JCR一区，影响因子9.2	代表性论著
2	TKDE2023-2	第5-8页，CCF-A类推荐国际期刊，ACM/IEEE会刊，JCR一区，影响因子9.2	代表性论著
3	TKDE2023-3	第9-11页，CCF-A类推荐国际期刊，ACM/IEEE会刊，JCR一区，影响因子9.2	代表性论著
4	TKDE2023-4	第12-14页，CCF-A类推荐国际期刊，ACM/IEEE会刊，JCR一区，影响因子9.2	代表性论著
5	TKDE2023-5	第14页，CCF-A类推荐国际期刊，ACM/IEEE会刊，JCR一区，影响因子9.2	代表性论著
6	ICDM2023	CCF-B类国际会议，2023年接受率9.3%，数据挖掘领域三大顶级会议	代表性论著
7	TKDD2024	CCF-B类推荐国际期刊，ACM/IEEE会刊，JCR一区，影响因子4.1	代表性论著
8	NeurIPS2023	CCF-A类推荐国际会议，Spotlight亮点论文，三大人工智能顶级会议	代表性论著
9	ICDM2021	CCF-B类国际会议，2021年接受率9.8%，数据挖掘领域三大顶级会议	代表性论著



项目名称： 面向生命科学领域表格科学数据优化算法研究

资助类型： 青年科学基金项目

申请代码： F0610. 交叉学科中的人工智能问题

国家自然科学基金项目申请人和参与者承诺书

为了维护国家自然科学基金项目评审公平、公正，共同营造风清气正的科研生态，本人**在此郑重承诺**：严格遵守《中华人民共和国科学技术进步法》《国家自然科学基金条例》《关于进一步加强科研诚信建设的若干意见》《关于进一步弘扬科学家精神加强作风和学风建设的意见》《关于加强科技伦理治理的意见》以及科技部、自然科学基金委关于科研诚信建设有关规定和要求；申请材料信息真实准确，不含任何涉密信息或敏感信息，不含任何违反法律法规或违反科研伦理规范的内容；在国家自然科学基金项目申请、评审和执行全过程中，恪守职业规范和科学道德，遵守评审规则和工作纪律，杜绝以下行为：

- （一）抄袭、剽窃他人申请书、论文等科研成果或者伪造、篡改研究数据、研究结论；
- （二）购买、代写申请书；购买、代写、代投论文，虚构同行评议专家及评议意见；购买实验数据；
- （三）违反成果发表规范、署名规范、引用规范，擅自标注或虚假标注获得科技计划等资助；
- （四）在项目申请书中以高指标通过评审，在项目计划书中故意篡改降低相应指标；
- （五）以任何形式打听或散布尚未公布的评审专家名单及其他评审过程中的保密信息；
- （六）本人或委托他人通过各种方式和途径联系有关专家进行请托、游说、“打招呼”，违规到评审会议驻地窥探、游说、询问等干扰评审或可能影响评审公正性的行为；
- （七）向工作人员、评审专家等提供任何形式的礼品、礼金、有价证券、支付凭证、商业预付卡、电子红包，或提供宴请、旅游、娱乐健身等任何可能影响评审公正性的活动；
- （八）违反财经纪律和相关管理规定的行为；
- （九）其他弄虚作假行为。

如违背上述承诺，本人愿接受国家自然科学基金委员会和相关部门做出的各项处理决定，包括但不限于撤销科学基金资助项目，追回项目资助经费，向社会通报违规情况，取消一定期限国家自然科学基金项目申请资格，记入科研诚信严重失信行为数据库以及接受相应的党纪政务处分等。

申请人签字：



项目名称： 面向生命科学领域表格科学数据优化算法研究
资助类型： 青年科学基金项目
申请代码： F0610. 交叉学科中的人工智能问题

国家自然科学基金项目申请单位承诺书

为了维护国家自然科学基金项目评审公平、公正，共同营造风清气正的科研生态，**本单位郑重承诺**：申请材料中不存在违背《中华人民共和国科学技术进步法》《国家自然科学基金条例》《关于进一步加强科研诚信建设的若干意见》《关于进一步弘扬科学家精神加强作风和学风建设的意见》《关于加强科技伦理治理的意见》以及科技部、自然科学基金委关于科研诚信建设有关规定和要求的情况；申请材料符合《中华人民共和国保守国家秘密法》和《科学技术保密规定》等有关法律法规和规章制度要求，不含任何涉密信息或敏感信息；申请材料不含任何违反法律法规或违反科研伦理规范的内容；申请人符合相应项目的申请资格；依托单位、合作研究单位、申请人及主要参与者不在限制申报、承担或参与财政性资金支持的科技活动的期限内；在项目申请和评审活动全过程中，遵守有关评审规则和工作纪律，杜绝以下行为：

（一）以任何形式打听或公布未公开的项目评审信息、评审专家信息及其他评审过程中的保密信息，干扰评审专家的评审工作；

（二）组织或协助申请人/参与者向工作人员、评审专家等给予任何形式的礼品、礼金、有价证券、支付凭证、商业预付卡、电子红包等；宴请工作人员、评审专家，或组织任何可能影响科学基金评审公正性的活动；

（三）支持、放任或对申请人/参与者抄袭、剽窃、重复申报、提供虚假信息（含身份和学术信息）等不当手段申报国家自然科学基金项目疏于管理；

（四）支持或协助申请人/参与者采取“打招呼”“围会”等方式影响科学基金项目评审；

（五）其他违反财经纪律和相关管理规定的行为。

如违背上述承诺，本单位愿接受自然科学基金委和相关部门做出的各项处理决定，包括但不限于停拨或核减经费、追回项目已拨经费、取消本单位一定期限国家自然科学基金项目申请资格、记入科研诚信严重失信行为数据库以及主要责任人接受相应党纪政务处分等。

依托单位公章：

日期： 年 月 日