



申请代码	F060505
接收部门	
收件日期	
接收编号	6183000348



国家自然科学基金 申 请 书

(2018 版)

资助类别:	重点项目		
亚类说明:			
附注说明:	面向领域大数据的知识图谱构建		
项目名称:	面向领域大数据的知识图谱构建		
申 请 人:	周园春	电 话:	010-58812561
依托单位:	中国科学院计算机网络信息中心		
通讯地址:	北京中关村南四街4号中科院软件园区4号楼406室		
邮政编码:	100190	单位电话:	010-58812267
电子邮箱:	zyc@cnic.cn		
申报日期:	2018年03月14日		

国家自然科学基金委员会



基本信息

申请人信息	姓名	周园春	性别	男	出生年月	1975年02月	民族	汉族
	学位	博士	职称	研究员	每年工作时间（月）		6	
	是否在站博士后	否		电子邮箱	zyc@cnic.cn			
	电话	010-58812561		国别或地区	中国			
	个人通讯地址	北京中关村南四街4号中科院软件园区4号楼406室						
	工作单位	中国科学院计算机网络信息中心/大数据部						
	主要研究领域							
依托单位信息	名称	中国科学院计算机网络信息中心						
	联系人	王侨	电子邮箱	wangqiao@cnic.cn				
	电话	010-58812267	网站地址	www.cnic.cas.cn				
合作研究单位信息	单位名称							
	清华大学 北京百度网讯科技有限公司							
项目基本信息	项目名称	面向领域大数据的知识图谱构建						
	英文名称	Research on Knowledge Graph Construction for domain-specific big data						
	资助类别	重点项目				亚类说明		
	附注说明	面向领域大数据的知识图谱构建						
	申请代码	F060505. 知识获取与知识图谱						
	基地类别	大数据分析计算技术国家地方联合工程实验室						
	研究期限	2019年01月01日 -- 2023年12月31日				研究方向：知识图谱		
	申请直接费用	306. 1000万元						
中文关键词		知识图谱构建；知识推理；知识表示；深度学习；知识图谱应用						
英文关键词		Knowledge Graph Construction; Knowledge Reasoning; Knowledge Representation; Deep Learning; Knowledge Graph Application						



中文摘要	领域知识的引入使得知识图谱的表示与构建、推理与认知、数据管理等遇到了新的问题，主要表现在如何合理恰当的将领域知识融合到知识图谱构建全流程中，以提高知识图谱对领域实体、关系表达的准确性，从而增强基于领域的知识图谱的推理与认知能力，同时结合领域数据特点提高数据访问的性能。基于此问题，本项目拟从面向领域大数据的知识图谱表示与构建技术、推理与认知技术、分布式管理技术入手，研究基于深度迁移学习、深度强化学习的知识图谱静态、动态表示与构建方法，研究基于图模型、概率因子的推理与认知方法，研究基于数据划分、图结构的分布式管理方法，并以科技领域和POI (Point of Interest) 为例，实现对相关工作的应用验证，在国家自然科学基金委和百度公司进行示范应用，为诸如电子政务、教育科技、生活服务等国计民生领域大数据知识图谱构建提供理论基础及技术指导。
英文摘要	If domain knowledge properly being incorporated into the whole process of Knowledge Graph construction, it is possible to improve the accuracy of knowledge graph on domain entity and relation expression, and thus enhance the reasoning and cognition ability of the domain-based knowledge graph. Moreover, the data access performance can also be improved by the integration of domain features. To this end, this project aims to develop knowledge graph representation and construction techniques, reasoning and cognitive techniques, and distributed management techniques for domain-specific big data. Specifically, by combining domain knowledge, we study the static and dynamic representation of Knowledge Graph based on deep transfer learning and deep reinforcement learning construction method, reasoning and cognitive method based on graph model and probability factor, distributed management method based on data partitioning and graph structures. The results of this project will be validated in scientific and mobile domains. In summary, this project will provide a theoretical and technical guidance for domain-specific know graph construction, and the project will be deployed by the National Natural Science Foundation of China and Baidu Inc. as the application demonstration.



项目组主要参与者（注：项目组主要参与者不包括项目申请人）

编号	姓名	出生年月	性别	职 称	学 位	单位名称	电话	电子邮箱	证件号码	每年工作 时间（月）
1	唐杰	1977-01-04	男	研究员	博士	清华大学	010-62788788	jery.tang@gmail.com	130302197701043514	6
2	朱勇	1976-10-25	男	研究员	博士	北京百度网讯科技有 限公司	010-58004747	zhuyong@baidu.com	340104197610252012	6
3	沈志宏	1977-12-24	男	研究员	博士	中国科学院计算机网 络信息中心	010-58812561	bluejoe@cnic.cn	342921197712243012	6
4	杜一	1988-03-06	男	副研究员	博士	中国科学院计算机网 络信息中心	15810134970	duyi@cnic.cn	371526198803066014	6
5	刘德兵	1976-03-04	男	副研究员	博士	清华大学	010-62788788	debingliu@tsinghua.edu.cn	51292419760304797X	8
6	祝恒书	1986-12-31	男	研究员	博士	北京百度网讯科技有 限公司	010-50817844	zhuhengshu@baidu.com	650104198612310711	6
7	吴章生	1980-09-28	男	助理研究员	硕士	中国科学院计算机网 络信息中心	010-58813376	wzs@cnic.cn	352229198009286511	10
8	赵江华	1989-05-12	女	博士生	硕士	中国科学院计算机网 络信息中心	15001220275	zjh@cnic.cn	130627198905120049	10
9	王卫军	1981-10-28	男	博士生	硕士	中国科学院计算机网 络信息中心	18503887608	wwj_860@163.com	410782198110282818	10

总人数	高级	中级	初级	博士后	博士生	硕士生
30	7	6	3	1	5	8



国家自然科学基金项目资金预算表（定额补助）

项目申请号：6183000348

项目负责人：周园春

金额单位：万元

序号	科目名称	金额
	(1)	(2)
1	一、项目直接费用	306.1000
2	1、设备费	8.0000
3	(1)设备购置费	8.00
4	(2)设备试制费	0.00
5	(3)设备改造与租赁费	0.00
6	2、材料费	29.70
7	3、测试化验加工费	17.00
8	4、燃料动力费	0.00
9	5、差旅/会议/国际合作与交流费	30.00
10	6、出版/文献/信息传播/知识产权事务费	51.80
11	7、劳务费	142.80
12	8、专家咨询费	26.80
13	9、其他支出	0.00
14	二、自筹资金来源	0.00



预算说明书（定额补助）

（请按《国家自然科学基金项目资金预算表编制说明》中的要求，对各项支出的主要用途和测算理由及合作研究外拨资金、单价≥10万元的设备费等内容进行详细说明，可根据需要另加附页。）

1.设备费

本项目实施拟新采购10台工作电脑，平均每台8000元，总计8万元。

2.材料费

本项目在实施过程中，相关大规模数据计算所需存储、计算资源由项目申请依托单位提供，在过程中相关设备损耗，因此需要购买一定数量的硬盘、cpu、显卡等其他配件，其中硬盘、cpu、内存约每年2块，显卡每年4块，按5年计入，共计29.70万元。预算明细如下。

配件类型	规格	单价（元）	数量(块/年)	合计（万元）
硬盘	接口类型：SATA3；容量：8TB；缓存：>256MB；转速：7200RPM	4000.00	2	4.00
CPU	E5-2640V3	6000.00	2	3.00
显卡	显存：>32GB	8000.00	4	16.00
内存条	DDR4 16GB	1700.00	2	1.70
材料费合计				29.70

3.测试化验加工费

本项目在实施过程中，拟以科技领域和兴趣点（POI）为例，实现对相关工作的应用验证，其中原型系统的开发主要由项目依托单位完成，同时拟委托具有科研评价能力的第三方对相关成果的性能及效果进行测试。

面向国家自然科学基金委项目成果数据研发的应用验证系统，将委托第三方进行测试，并委托第三方研发系统的非核心前端展示功能，该项委托开发测试预计6人月，以1.5万元 / 月计，共计9万元。

拟委托具有科研评价能力的第三方，如中国科学院心理研究所、北京邮电大学等机构进行测试与评估，该项委托预算8万元。

以上测试化验加工费总计预算17万元。

4. 燃料动力费

本项目实施所需的燃料动力，将由依托单位提供，无燃料动力费。

5. 差旅/会议/国际合作与交流费

本项目预计差旅/会议/国际合作与交流费30万元，不超过总预算的10%。

**6. 出版/文献/信息传播/知识产权事务费**

根据任务需要，本项目拟发表论文30-40篇，申请专利5项，申请软件著作权4-6项。本项目出版/文献/信息传播/知识产权事务费预算51.80万元，具体测算依据如下。

序号	费用名称	与项目研究关系	金额 (万元)	测算依据
1	软件著作权	研究成果申请软件著作权所需的代理费、申请费等相关费用	1.8	申请 4-6 项软件著作权，按照 3000 元/项计算，3000 元/项*6 项=1.80 万元
2	出版费	用于本项目研究结果的整理发表工作。	24.00	发表论文 30-40 篇，出版费用约 6000 元/每篇，计 24 万元
3	专利代理服务费	研究成果申请相关发明专利	3.00	按照 6000 元 / 项计算，5 件专利计 3.00 万元
4	购置相关资料、购买书籍；影像资料留存拷贝制作、展板定制、资料打印、复印及装订	用于本项目核心成果研发的技术支持	3.00	每年按 6000 元计，共 3.00 万元
5	项目执行过程中产生的文献检索、第三方数据交换费	引入第三方数据及所产生的数据交换、文献检索费用	16.00	预计引入除本项目已有数据之外的第三方数据 4 亿条，计 16.00 万元
6	文献检索	根据参考文献设计方案、决定关键技术的选择、论文发表时参考文献的选用等	4.00	预计 4 万元
出版/文献/信息传播/知识产权事务费合计			51.80	

7. 劳务费

本项目开展过程中，参与本项目的硕士研究生10-15人、博士研究生6-8人，预计硕士研究生参与时间每人24月，博士研究生参与时间每人40月（期间硕士生、博士毕业，会引入新研究生，继续参与本项目）。同时聘用2名临时人员，参与系统的界面、交互设计，预计16万元。同时，拟邀请1名访问学



者参与本项目核心技术研发，参与时间不少于12个月，以每月1.5万元计，预计18万元。劳务费合计142.80万元。

序号	人员类别	承担任务	劳务费标准 (元/月)	工作时间 (月)	人数	金额(万元)
1	硕士生	参与项目中数据处理模型、相关性模型的实现	1200.00	24	15	43.20
2	博士生	参与项目中数据处理模型、相关性模型的涉及	1800.00	40	8	57.60
3	临时聘用人员	用于多个系统界面、交互设计	4000.00	30	2	24.00
4	访问学者	参与本项目核心技术研发	15000.00	12	1	18.00
劳务费合计						142.80

8.专家咨询费

本项目开展过程中，拟举行一次技术交流活动，4次项目年度报告会及通讯咨询活动。其中拟组织两次技术交流活动邀请国内正高级职称专家总计40人次，预算经费8.00万元。拟通过通讯咨询形式对专家进行咨询40人次，预算2.8万元。拟定期举行年度报告会，拟邀请正高级职称专家60人次，预算12.0万元。拟组织一次结题报告会，预算4万元。专家咨询费合计26.80万元。

序号	咨询事由	咨询人次	咨询次数	咨询天数	人均标准 (元)	经费/万元	备注
1	技术交流活动	40	2	1	正高级职称 2000 元/天	8.00	聘请国内资深专家进行专业技术交流。
2	通讯咨询	40	40	1	700 元/次	2.80	为提高效率、避免专家或项目参加人员城市内或城市间往来，涉及内容一般为项目实施过程的关键技术。
3	年度报告会	60	4	1	正高级职称 2000 元/天	12.00	本项目拟定期举行年度报告会。



4	结题 报告 会	20	1	1	正高级职称 2000 元/天	4.00	本项目拟组织一次结题报告会
		专家咨询费合计				26.80	

9.其它支出
无。

NSFC 2018



报告正文

(一) 立项依据与研究内容 (建议 8000 字以下):

1. 项目的立项依据 (研究意义、国内外研究现状及发展动态分析,需结合科学研究发展趋势来论述科学意义;或结合国民经济和社会发展中迫切需要解决的关键科技问题来论述其应用前景。附主要参考文献目录);

1.1 研究意义

国家“十三五”规划中提出要实施国家大数据战略,提出“全面推进重点领域大数据有效整合,深化政府数据和社会数据关联分析、融合利用,统筹布局建设国家大数据平台,提高宏观调控、市场监管、社会治理和公共服务精准性和有效性。”这对大数据的分析方法与支撑技术都提出了较高要求。传统数据关联和融合方法、知识表示与学习、数据挖掘与计算都面临着各应用领域数据多源异构、尺度多样、时空演变等挑战问题。这些问题已成为制约基于大数据发展和应用的瓶颈。在这样的背景下,大数据对智能服务的需求已经从单纯的搜集获取信息,转变为自动化的知识提供服务,这也给知识图谱提出了很多挑战性的问题。

各大科技公司纷纷加强了知识图谱相关技术研究。Google 通过整合大量开源知识库并加入用户数据沉淀,推出知识图谱搜索功能,优化搜索结果。Facebook 基于社交网络大数据挖掘打造人与人的线上关系,构建社交图谱,并开展社交广告的商业化服务。Twitter 则提出了兴趣图谱的概念,重在构建人与事物的兴趣关系。百度依托在搜索方面的积累,在中国开展研究并推广知识图谱[1]。除了互联网上的海量数据,各个行业也有大量的行业数据和专业数据,通过构建行业知识图谱,为传统行业注入新动能,并使传统行业实现升级。如通过构建金融知识图谱,可以帮助金融行业在智能投顾、反欺诈以及风险控制等领域发挥重要作用。因此以知识图谱为基础,通过对领域或者行业数据进行分析,可以在社会治理和公共服务的各个领域形成无时不有、无处不在的智能化环境,从而大幅提升全社会的智能化水平和人民的生活品质。

在大数据应用持续深入以及人工智能快速发展过程中,知识图谱面临跨领域快速迁移、数据异构繁杂、知识表达多样、图谱关系复杂、计算性能要求高等多方面的挑战,主要具体表现为以下几个方面:



(1) 大数据环境下知识图谱表示与构建。面对海量领域数据,传统以本体和语义网为代表的技术路线在构建大规模知识图谱方面存在诸多不足,人工编织知识图谱的传统做法无法适应科技大数据的迅猛增长;传统远程监督产生的训练集噪音大,导致基于监督学习的实体和实体关系识别方法效果不佳;亟需协同专家群体和机器算法,最大化专家群体标记对于算法效能的提升,进而加快知识图谱构建。

(2) 大数据环境下知识图谱的隐含关系挖掘、语义分析与演化。基于海量异构大数据的知识表示与发现具有样本规模巨大、特征空间多维、需求模式差异、计算模型多样等特点,从而导致了大数据蕴含知识的表示、发现、分析与判定的计算复杂性非常高,且这些数据稀疏性、数据歧义、准确率低、时空尺度下动态演化等特征,使得知识库实体、关联关系有关蕴含着大量的信息未被考虑或有效利用。

(3) 大规模知识图谱的高效管理与计算。传统的 RDF 存储管理系统,采用基于内存、文件系统和关系数据库的存储方法,很难满足大体量的要求。现有的图数据存储管理系统往往采取和图计算分析系统不同的存储格式以及系统架构,这就造成了“存算”系统之间的脱节,在进行图分析的时候,往往需要先花费大量的时间进行数据的批量转换和导入。

正是这些科学技术问题给面向领域大数据的知识图谱的研究工作带来了巨大的挑战,从这些根本问题出发开展本课题的研究具有重要的科学研究意义。

1.2 国内外现状与发展态势分析

随着知识图谱和深度学习的大热,相关的研究涉及实体以及关系识别、实体链接、知识库填充、知识推理等有一定的研究积累。这些研究成果我们开展面向领域大数据的知识图谱构建研究具有重要的借鉴作用。

1.2.1 代表性知识库

知识库的构建方法多种多样,构建的知识库规模大小也不尽相同。CYC[2]是一个人工构建的知识库,规模相对来说不是很大,但内置一个智能的推理引擎。YAGO 结合 WordNet 和 Wikipedia,根据预定义好的启发式规则自动抽取概念和关系,构成一个较高质量的知识库[3]。NELL 直接从给出的种子集合,利用构建的学习模块和质量控制模块,通过不断的迭代,形成知识库[4]。Wentao Wu 等



人[5]则提出了 Probase, 一个规模更大覆盖更广的知识库, 并且对每个知识都融进了置信度。Yafang Wang[6]把 Wikipedia 中的时序性知识加入到 YAGO 中, 得到 Timely YAGO, 并可以支持时序事实的查询。Dong 等人[7]从大量 Web 页面资源提取出相应的事实, 利用概率融合模型对提取出的事实进行学习和推理, 构造更大型的知识库 (Knowledge Vault)。百度知识图谱[1]依托海量互联网数据, 综合运用语义理解、知识挖掘、知识整合与补全等技术, 提炼出高精度知识, 并组织成图谱。

1.2.2 实体链接及关系抽取

近年来, 深度学习方法在实体链接、关系抽取和实体对齐等领域都有效果良好的运用[8-11]。Yaming Sun 等人提出的对提及、上下文和实体建模的方法综合应用了卷积神经网络 (Convolutional Neural Network) [12]和 Neural Tensor Network (NTN) [13]。在进行实体链接时, 一般同时考虑同一上下文中的多个提及, 希望链接结果中它们各自的目标实体间关联程度尽量大[14], 两个实体间关联程度的计算方法一般都采用了 Milne 和 Witten 提出的计算方法[15]。Cheng 和 Roth 提出了 relational score 来衡量两个实体间是否有关联[16], Ceccarelli 等人还提出了使用学习的方法来得到实体间的关联程度[17]。Cucerzan 等人将总体关联程度定义为子图中所有边权重和[18]。Pan 等人[19][20]使用了 AMR (Abstract Meaning Representation) 方法, 将一个句子的语义融入一个有根节点、有向、有标签且无环的图结构中, 这样可以表示出更深层次的语义信息。

Socher 提出使用递归神经网络 (RNN) 来解决关系抽取问题[21]。该模型可以学习任意句法类型和长度的短语和句子的组合向量表示, 该方法一定程度上利用了分析树带来的信息。2014 年 YoonKim 的工作中提出了 Text-CNN 模型[9]在关系抽取方面有着较好的表现。和原始的 ImageNet CNN 结构[22]相比不同, Text-CNN 中只有一层 convolution-pooling 层以及更少的特征图。Ren 等人[23]提出了一个联合抽取实体和关系的框架 CoType, 它设计了一个数据驱动的文本分割算法用来检测实体提及, 然后联合把实体提及、关系提及、文本特征和类型标签嵌入到两个低维空间中。文献[24]提出一种 ENCORE 关系抽取模型, 构建教师-学生网络, 最后结合 Text-CNN 模型进一步提高了在关系抽取上的表现。

1.2.3 知识学习与推理



知识学习可以在低维空间中高效计算实体和关系的语义联系,有效解决数据稀疏问题,使知识获取、融合和推理的性能得到显著提升[25]。传统的强化学习方法包括动态规划、蒙特卡洛、时序差分、Q-learning[26]。DQN[27]是 Google DeepMind 2013 年提出的深度强化学习算法,在 2015 年发表于《Nature》,它将 Q-learning 与深度学习相结合,使用神经网络来估计动作的价值函数,解决了状态过多情况下的学习效率问题。A3C[28]是 Google DeepMind 2015 年提出的更通用的深度增强学习算法。A3C 完全使用了 Actor-Critic 框架,并实现了异步训练,在提升效果的同时加快了训练速度。文献[29][30]则引入了人的行为,通过对人的行为的建模学习,同时利用人的经验知识,能够加快策略的学习。

不同于传统知识推理,由于知识图谱中知识表达形式的简洁直观、灵活丰富,面向知识图谱的知识推理方法也更加多样化[31]。

目前学术界研究比较活跃是基于向量之间转换的推理方法,最具有代表性是 Bordes 等人[32]提出的 TransE 模型,将高维知识图谱中的实体和关系嵌入到一个低维连续向量空间中,利用代数几何结构对实体和关系之间的联系进行学习和推理,进而达到完善知识图谱的目的。由于 TransE 模型不能用在处理复杂关系上,一系列基于它的扩展模型纷纷被提出,如 TransH 模型[33]、m-TransH 模型[34]、TransR 模型[35]、TransD 模型[36]、TransM 模型[37]、TransSparse 模型[38]、TransE-NMM 模型[39]、TransA 模型[40]、puTransE 模型[41]等。然而,在实际的知识图谱中,许多实体缺失实体描述。因此 Wang 等人[42]提出 TEKE(Text-Enhanced Knowledge Embedding),引入文本语料中丰富的上下文信息扩展知识图谱的语义结构。Ji 等[43]提出跨知识图谱的表示方法 cross-KG,同时学习两个不同知识图谱的表示。

基于张量分解方法的知识推理最具有代表性和影响力的是 Maximilian Nickel 等人[44]年提出的三阶张量分解 RESCAL。随后相关科研人员在此基础上进行完善和改进[45-48]。在基于路径的知识图谱学习和推理方法中,Lao 等人[49-50]提出了路径排列算法 PRA,使其能更加适合于大型数据库中大量关系类型的路径推理能力,并提升了关系路径推理预测的质量。Neelakantan 等人[51]基于递归神经网络 RNN 对知识图谱中的路径进行学习和推理。Guu 等人[52]组合已有的推理模型(RESCAL 和 TransE)对知识图谱进行路径学习和推理。Yang



等人[53]提出了一种通用模型框架,并在路径推理过程中添加逻辑约束条件,从而达到知识图谱的学习和推理作用。Lin 等人[54]提出基于多路径学习和推理模式,同时结合语义成分进行知识图谱的学习和推理。Wu 等人[55]结合实体之间的成对关系以及实体间的路径内在交互关系进行知识图谱学习和推理过程。在实际的知识图谱学习和推理过程中,基于路径推理方法通常与张量分解和基于转换的方法相结合。其它学习和推理方法由于知识图谱是近几年才发展起来的,主要包括基于神经网络的推理[56]、结合语义和逻辑规则的推理[57-58]、结合其它文本资料库的推理[59-61]。

1.2.4 知识图谱数据管理方法

知识图谱数据管理的一个核心问题是如何有效地存储和查询 RDF 等数据集[62]。总体来说有两套完全不同的思路:第一是可以利用已有的成熟的数据库管理系统来存储知识图谱数据: RDF 数据的三元组模型可以很容易映射成关系模型,将面向 RDF 知识图谱的 SPARQL 查询转换为面向此类成熟数据库管理系统的查询,因此大量研究者尝试了使用关系数据模型来设计 RDF 存储和检索的方案[63-66]。第二是采用图的方式来管理知识图谱数据:通过将 RDF 三元组看作带标签的边, RDF 知识图谱数据很自然地符合图模型结构。因此,有研究者从 RDF 图模型结构的角度来看待 RDF 数据,将 RDF 数据视为一张图,并通过对 RDF 图结构的存储来解决 RDF 数据存储问题[67-68]。然而,利用图模型来设计 RDF 存储与查询也存在着诸多问题,如:相对于普通的图模型, RDF 图上的边具有标签,并可能成为查询目标;另外典型的图算法往往时间复杂度较高。

在面向领域的知识图谱应用研究中,熊辉等人通过结合用户偏好,社会影响力,行为轨迹等异质数据,从多个角度出发,提出了一套面向 POI 多源数据融合与推荐算法[69-71]。唐杰等人构建面向科技领域学术图谱系统 AMiner,在高质量语义内容生成、异构科技情报网络深度挖掘、语义搜索与智能知识服务,以及科技情报大数据分析挖掘服务平台等多个方面取得技术突破。

参考文献

- [1] 王海峰、李莹、吴甜、朱勇. 大规模知识图谱研究及应用. 中国计算机学会通讯[J], 2018, 14(1): 47-53
- [2] M. Sozio, A. Gionis. The community-search problem and how to plan a successful



cocktail party[C]. Proceedings of the 16th ACM SIGKDD international conference on Knowledge discovery and data mining (KDD), 2010.

[3] Suchanek F M, Kasneci G, Weikum G. YAGO: A large ontology from wikipedia and wordnet[J]. Web Semantics Science Services & Agents on the World Wide Web(WWW), 2007, 6(3):203-217

[4] A. Carlson, J. Betteridge, B. Kisiel, B. Settles, E.R. Hruschka Jr. and T.M. Mitchell. Toward an Architecture for Never-Ending Language Learning[C]. In Proceedings of the Conference on Artificial Intelligence (AAAI), 2010.

[5] Wentao Wu, Hongsong Li, Haixun Wang and Kenny Q. Zhu. Probase: A Probabilistic Taxonomy for Text Understanding[C]. In Proceedings of the ACM SIGMOD International Conference on Management of Data (SIGMOD), 2012: 481-492.

[6] Yafang Wang, Mingjie Zhu, Lizhen Qu, et al. Timely YAGO: harvesting, querying, and visualizing temporal knowledge from Wikipedia[C]. International Conference on Extending Database Technology (EDBT2010). ACM, 2010:697-700.

[7] Dong, Xin, Gabrilovich, et al. Knowledge vault: a Web-scale approach to probabilistic knowledge fusion[C]. Proc of the 20th Int Conf on Knowledge Discovery and Data Mining. New York: ACM, 2014: 601-610.

[8] Z. He, et.al. Learning Entity Representation for Entity Disambiguation[C]. ACL, 2013.

[9] 漆桂林, 高桓, 吴天星. 知识图谱研究进展[J]. 情报工程, 2017, 3(1):4-25.

[10] Kim, Yoon. Convolutional neural networks for sentence classification. ArXiv, 2014.

[11] Y. Lecun, L. Bottou 和 Y. Bengio, Gradient-based learning applied to document recognition [J]. Proceedings of the IEEE, 1998.

[12] 庄严, 李国良, 冯建华. 知识库实体对齐技术综述[J]. 计算机研究与发展, 2016, 53(1):165-192.

[13] R. Socher, A. Perelygin, J. Wu. Recursive deep models for semantic compositionality over a sentiment treebank[C]. Proceedings of the conference on empirical method in natural language processing (EMNLP), 2013.

[14] Z. Guo, D. Barbosa. Robust entity linking via random walks[C]. Proceedings of the 23rd ACM International Conference on Conference on Information and Knowledge Management. ACM, 2014.

[15] I. Witten 和 D. Milne. An effective, low-cost measure of semantic relatedness obtaine



from Wikipedia links[C]. Proceeding of AAAI Workshop on Wikipedia and Artificial Intelligence: an Evolving Synergy, AAAI Press, Chicago, USA, 2008.

[16] X. Cheng, D. Roth. Relational inference for wikification[C]. Proceedings of the conference on empirical methods in natural language processing (EMNLP). Association Computational Linguistics, 2013.

[17] D. Ceccarelli, C. Lucchese, S. Orlando. Learning relatedness measures for entity linking[C]. Proceedings of the 22nd ACM international conference on Information & Knowledge Management. ACM, 2013.

[18] C. S. Large-Scale Named Entity Disambiguation Based on Wikipedia Data[C]. Proceedings of the conference on empirical methods in natural language processing (EMNLP). Association for Computational Linguistics, 2007.

[19] X. Pan, T. Cassidy, U. Hermjakob. Unsupervised entity linking with abstract meaning representation[C]. Proceedings of the 2015 Conference of the North American Chapter of the Association for Computational Linguistics–Human Language Technologies, 2015.

[20] L. Banarescu , C. Bonial , S. Cai , Madalina Georgescu , Kira Griffitt , Ulf Hermjakob , Kevin Knight , Philipp Koehn , Martha Palmer , Nathan Schneider. Abstract meaning representation for semantic banking[C]. Proc ACL 2013 Workshop on Linguistic Annotation and Interoperability with Discourse, 2013.

[21] R. Socher. Semantic compositionality through recursive matrix-vector spaces[C]. EMNLP-CoNLL, 2012.

[22] A. Krizhevsky, I. Sutskever, E. Hinton. Imagenet classification with deep convolutional neural networks[C]. NIPS, 2012.

[23] Xiang Ren, Zequi Wu, Wenqi He, Meng Qu, Clare R. Voss, Heng Ji, Tarek F. Abdelzaher, Jiawei Han. CoType: Joint Extraction of Typed Entities and Relations with Knowledge Bases[C]. In WWW, 2017.

[24] Siliang Tang, Jinjian Zhang, Ning Zhang, Fei Wu, Jun Xiao, and Yueting Zhuang. ENCORE: External Neural Constraints Regularized Distant Supervision for Relation Extraction[C]. In Proceedings of the 40th International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR '17), Shinjuku, Tokyo, Japan. pp. 1113-1116, 2017.

[25] 刘知远, 孙茂松, 林衍凯等. 知识表示学习研究进展[J]. 计算机研究与发展, 2016, 53(2):247-261.



- [26] Sutton R. and Barto A. Reinforcement Learning: an Introduction. MIT Press, 1998.
- [27] Volodymyr Mnih, Koray Kavukcuoglu, David Silver, et. al. Human-level control through deep reinforcement learning[J]. Nature, 518:529-533.
- [28] Mnih V, Badia A P, Mirza M, et. al. Asynchronous methods for deep reinforcement learning[C]. In Proc. of ICML' 16, New York, USA. pp. 1928-1937, 2016.
- [29] Christiano P, Leike J, Brown T B et al. Deep reinforcement learning from human preferences. arXiv preprint arXiv:1706.03741, 2017.
- [30] Hester T, Vecerik M, Pietquin O et. al. Learning from Demonstrations for Real World Reinforcement Learning. arXiv preprint arXiv:1704.03732, 2017.
- [31] 官赛萍, 靳小龙, 贾岩涛, 王元卓, 程学旗. 面向知识图谱的知识推理研究进展[J]. 软件学报, 2018, 29(10).<http://www.jos.org.cn/1000-9825/5551.htm>.
- [32] Bordes A, Usunier N, Garcia-Duran A, Weston J, Yakhnenko O. Translating embeddings for modeling multi-relational data. In: Proc. of Advances in Neural Information Processing Systems. Red Hook, NY: Curran Associates Inc, 2013. 2787-95.
- [330] Wang Z, Zhang J, Feng J, Chen Z. Knowledge graph embedding by translating on hyperplanes. In: Proc. of the 28th AAAI Conference on Artificial Intelligence. Menlo Park, CA: AAAI, 2014. 1112-9.
- [34] Wen J, Li J, Mao Y, Chen S, Zhang R. On the representation and embedding of knowledge bases beyond binary relations. arXiv preprint arXiv:160408642, 2016.
- [35] Lin Y, Liu Z, Sun M, Liu Y, Zhu X. Learning entity and relation embeddings for knowledge graph completion. In: Proc. of the 29th AAAI Conference on Artificial Intelligence. Menlo Park, CA: AAAI, 2015. 2181-7.
- [36] Ji G, He S, Xu L, Liu K, Zhao J. Knowledge graph embedding via dynamic mapping matrix. In: Proc. of the 53rd Annual Meeting of the Association for Computational Linguistics-Volume 1. Stroudsburg, PA: ACL, 2015. 687-96.
- [37] Fan M, Zhou Q, Chang E, Zheng TF. Transition-based Knowledge Graph Embedding with Relational Mapping Properties. In: Proc. of the 28th Pacific Asia Conference on Language, Information and Computation. Stroudsburg, PA: ACL, 2014. 328-37.
- [38] Ji G, Liu K, He S, Zhao J. Knowledge graph completion with adaptive sparse transfer matrix. In: Proc. of the 30th AAAI Conference on Artificial Intelligence. Menlo Park, CA: AAAI, 2016. 985-91.



- [39] Nguyen DQ, Sirts K, Qu L, Johnson M. Neighborhood mixture model for knowledge base completion. arXiv preprint arXiv:1606.06461, 2016.
- [40] Jia Y, Wang Y, Lin H, et al. Locally adaptive translation for knowledge graph embedding[C]. Thirtieth AAAI Conference on Artificial Intelligence. AAAI Press, 2016:992-998.
- [41] Tay Y, Luu AT, Hui SC. Non-parametric estimation of multiple embeddings for link prediction on dynamic knowledge graphs[C]//Proc. of the 31st AAAI Conference on Artificial Intelligence. Menlo Park, CA: AAAI, 2017. 1243-1249.
- [42] Wang Z, Li J. Text-enhanced representation learning for knowledge graph[C]. International Joint Conference on Artificial Intelligence. AAAI Press, 2016:1293-1299.
- [43] Ji G, Liu K, He S, et al. Knowledge graph completion with adaptive sparse transfer matrix[C]. Thirtieth AAAI Conference on Artificial Intelligence. AAAI Press, 2016:985-991.
- [44] Nickel M, Tresp V, Kriegel H P. A three-way model for collective learning on multi-relational data[C]. International Conference on International Conference on Machine Learning. Omnipress, 2011:809-816.
- [45] Nickel M, Tresp V, Kriegel H P. Factorizing YAGO: Scalable Machine Learning for Linked Data[C]. WWW. ACM, 2012:271-280.
- [46] Nickel M, Tresp V. Logistic tensor factorization for multi-relational data [C]. Proceedings of the 30th International Conference on Machine Learning, Atlanta, Georgia, USA, 2013: 1-3.
- [47] Krompaß D, Nickel M, Tresp V. Large-scale factorization of type-constrained multi-relational data[C]. International Conference on Data Science and Advanced Analytics. IEEE, 2014:18-24.
- [48] Chang K W, Yih W T, Yang B, et al. Typed Tensor Decomposition of Knowledge Bases for Relation Extraction[C]. EMNLP. 2014: 1568-1579.
- [49] Lao N, Cohen W W. Relational retrieval using a combination of path-constrained random walks [J]. Machine Learning, 2010, 81(1):53-67.
- [50] Lao N, Mitchell T, Cohen W W. Random walk inference and learning in a large scale knowledge base[C]. Conference on Empirical Methods in Natural Language Processing, EMNLP 2011, 27-31 July 2011, John McIntyre Conference Centre, Edinburgh, Uk, A Meeting of Sigdat, A Special Interest Group of the ACL. DBLP, 2011:529-539.
- [51] Neelakantan A, Roth B, Mccallum A. Compositional Vector Space Models for



Knowledge Base Completion[J]. Computer Science, 2015:1-16.

[52] Guu K, Miller J, Liang P. Traversing Knowledge Graphs in Vector Space [J]. Computer Science, 2015: 318-327.

[53] Yang B, Yih W-T, He X, et al. Embedding entities and relations for learning and inference in knowledge bases [C]. Proceedings of the International Conference on Learning Representations (ICLR) San Diego, USA, 2015: 1-12.

[54] Lin Y, Liu Z, Sun M. Modeling relation paths for representation learning of knowledge bases [C]. Conference on Empirical Methods in Natural Language Processing, Lisbon, Portugal, 2015: 705-714.

[55] Wu F, Song J, Yang Y, et al. Structured embedding via pairwise relations and long-range interactions in knowledge base [C]. The Twenty-Ninth AAAI Conference on Artificial Intelligence, Texas, USA, 2015: 1663-1670.

[56] Socher R, Chen D, Manning C D, et al. Reasoning with neural tensor networks for knowledge base completion[C]. International Conference on Neural Information Processing Systems. Curran Associates Inc. 2013:926-934.

[57] Guo S, Wang Q, Wang B, et al. Semantically Smooth Knowledge Graph Embedding[C]. Meeting of the Association for Computational Linguistics and the, International Joint Conference on Natural Language Processing. 2015:84-94.

[58] Wang Q, Wang B, Guo L. Knowledge base completion using embeddings and rules[C]. International Conference on Artificial Intelligence. AAAI Press, 2015:1859-1865.

[59] Wang Z, Zhang J, Feng J, et al. Knowledge Graph and Text Jointly Embedding[C]. Conference on Empirical Methods in Natural Language Processing. 2014:1591-1601.

[60] Wang Z, Zhang J, Feng J, et al. Knowledge Graph and Text Jointly Embedding[C]. Conference on Empirical Methods in Natural Language Processing. 2014:1591-1601.

[61] Toutanova K, Chen D, Pantel P, et al. Representing Text for Joint Embedding of Text and Knowledge Bases[C]. EMNLP. 2015:21-28.

[62] 邹磊. 知识图谱的数据应用和研究动态[J]. 中国计算机学会通讯, 2017, 13(8): 49-55.

[63] RDF Access to Relational Databases[OL].
<http://www.w3.org/2003/01/21-RDF-RDB-access/>.

[64] W3C Semantic Web Advanced Development for Europe (SWAD-Europe) [OL].



http://www.w3.org/2001/sw/Europe/reports/scalable_rdbms_mapping_report/.

[65] Storing RDF in a relational database [OL].

<http://infolab.stanford.edu/~melnik/rdf/db.html>.

[66] Pan Z, Heflin J. DLDB: Extending Relational Databases to Support Semantic Web Queries. Proceedings of the Workshop on Practical and Scaleable Semantic Web Systems. 2003: 109-113.

[67] Zou L, Özsu M T, Chen L, et al. gStore: A Graphbased SPARQL Query Engine [J]. VLDB Journal, 2014, 23(4):565-590.

[68] Zeng K, Yang J, Wang H, et al. A distributed graph engine for web scale RDF data [J]. Proceedings of the VLDB Endowment. 2013, 6(4): 265-276.

[69] Yanchi Liu, Chuanren Liu, Xinjiang Lu, Mingfei Teng, Hengshu Zhu, Hui Xiong. Point-of-Interest Demand Modeling with Human Mobility Patterns[C]. Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2017:947-955.

[70] Yanchi Liu, Chuanren Liu, Bin Liu, Meng Qu, Hui Xiong*. Unified Point-of-Interest Recommendation with Temporal Interval Assessment[C]. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2016: 1015-1024.

[71] Zijun Yao, Yanjie Fu, Bin Liu, Yanchi Liu, Hui Xiong. POI recommendation: A temporal matching between POI popularity and user regularity[C]. Proceedings of the 16th IEEE International Conference on Data Mining, 2016: 549-558.

2. 项目的研究内容、研究目标，以及拟解决的关键科学问题（此部分为重点阐述内容）；

2.1 研究内容

本项目将从面向领域大数据的知识图谱表示与构建技术、面向领域大数据的知识图谱推理与认知技术、分布式知识图谱数据管理系统关键技术及面向特定领域大数据的知识图谱构建及应用四个方面展开研究（如图 1 所示）。




图 1 研究内容框架图

1. 面向领域大数据的知识图谱表示与构建技术

(1) 研究基于深度迁移学习的实体和实体关系识别。研究端到端的基于深度迁移学习的实体和实体关系识别方法，提出适合实体和关系联合识别的结合 Attention 机制的 Seq2seq 深度学习模型，并结合迁移学习技术，将在多类大规模领域数据语料上训练好的复杂模型迁移到新类型的图谱理解上，降低标记数据的人力物力开销。研究基于无监督学习的训练集自动生成方法，克服远程监督产生的训练集噪音大的缺陷。

(2) 研究基于深度强化学习的群体增强的知识图谱填充。研究基于深度强化学习的众包任务遴选策略，以及实体和关系识别 DNN 模型的调整策略，协同机器算法和专家群体，构建大规模面向领域的大数据治理知识图谱，挑选对于机器而言最有价值的众包任务，邀请领域专家群体进行标注，然后基于深度神经网络的 Reward 预测器来预测任务遴选动作以及模型调整动作的 Reward，进而调整众包任务遴选策略以及 DNN 模型调整策略。

(3) 研究面向动态领域知识图谱的表示学习算法。真实的知识图谱的结构往往是动态变化的，其实体和关系会增减或者变化，现有的研究工作大都是针对静态的知识图谱学习其表示，本项目拟研究面向动态知识图谱的表示学习方法，学习得到一个隐空间，使得映射到该隐空间的节点能够保持结构特征和动态特征，供大规模图上的推理算法使用，自动扩充知识图谱或者检测知识图谱中的不一致。

2. 面向领域大数据的知识图谱推理与认知技术



(1) 研究大规模知识实体的网络关系分析方法。研究一阶谓词逻辑、描述逻辑以及规则等推理表示方法,从大规模、半结构化或非结构化的数据源自动提取概念及其上下位关系,将符号逻辑模型中的推理机制应用于表示学习中不断扩充和优化,提升大数据环境下知识表示与语义分析能力;研究子图的推理方法中,基于 path-constraint、random walk、path ranking 等算法,利用关系路径中的蕴涵信息,通过图中两个实体间的多步路径来预测它们之间的语义关系。研究基于深度表示学习方法的知识图谱三元组编码技术,将它们的语义信息映射到低维的浅层特征表示空间(语法、语义空间),以推测知识图谱中存在的隐式知识。

(2) 研究基于概率因子图模型的隐含语义分析方法。遵循知识图谱的模式定义与语义词表,实体与关系的语义标注,基于深度语义模型和半监督学习算法从相关语料中提取出实体之间的关联关系;研究基于概率模型的语义相似度计算方法,计算多个目标属性之间的隐含语义,提高实体关系识别的准确率和召回率;研究基于深度语义模型的实体融合技术,以直接优化消歧任务为训练目标,自动学习上下文和实体的特征表示和“上下文-实体定义”相似度度量,对上下文多个实体同时消歧,实现隐含关联语义分析。

(3) 研究时空多尺度场景下知识图谱动态更新的检测方法。根据实时采集多源数据的动态变化,基于知识库语义模型得到实体和关系在知识图谱空间的浅层特征表示,多模态的深度神经网络模型框架,研究知识图谱内容及网络结构的实时更新检测方法;研究基于模式层、数据层更新算法,实体关系概念属性以及概念之间上下位关系逻辑结构变化的检测技术;研究基于知识的概念意图标注算法,基于用户行为挖掘、深度语义相似、函数式语义树的语义形式化技术,开放空间下的实体关系识别与认知技术。

3. 研究分布式知识图谱数据管理系统关键技术

(1) 研究基于数据划分的分布式知识图谱高效管理技术。针对领域知识图谱节点及关系的大规模特征,研究 RDF 型知识图谱数据在不同计算节点上的存储策略。研究系统局部计算特性、图数据进行结构化查询在各计算中心本地局部计算与局部匹配方法、局部匹配结果归并与连接方法。在利用 RDF 管理知识图谱过程中,研究 RDF 知识图谱数据在不同机器上分布与数据源“自治”方法,构建联邦性分布式 RDF 知识图谱;研究图数据结构化查询分解方法,构建子查询分配与通信策略;研究不同 RDF 数据源局部匹配结果连接方法。



(2) 研究基于图结构的索引和查询优化策略。针对领域知识图谱的多元查询需求,研究模式匹配在图查询及在特定领域查询方法与策略;设计面向持续更新数据图的图模式匹配查询处理算法,研究基于结构和节点内容相似性相结合的图模式匹配查询;针对领域数据呈现的复杂关联、多边性,研究索引的轻量级更新以及动态图中索引更新问题,研究基于多级摘要图的方式,将索引更新约束在局部范围内;研究关联数据中“语义路径模式”挖掘,通过挖掘路径实现与自然语言中关系短语的语义表达的直接对应,更加准确地发现知识图谱中不同实体之间的语义关联。

(3) 研究大规模知识图谱的“存算”动态适配策略。针对图谱数据高效查询和图数据批量分析两类需求带来的存储方式、软件架构的差异性,研究适合大规模图数据的存储管理系统与大规模图数据的计算分析框架的动态适配及调优算法;研究高效的数据迁移以及免迁移动态适配的方法,满足大数据存取的性能,同时降低大数据分析过程中的海量数据迁移带来的时间开销。

4. 面向特定领域大数据的知识图谱构建及应用验证

基于相关的研究成果,以学术图谱及 POI 知识图谱为例,进行应用验证。

(1) 面向科技领域大数据的学术图谱构建。科技领域知识在人员、成果消岐、数据动态变化上有该领域固有的特点,需要充分考虑科研人员依托单位、研究方向的变化,以及科研成果所属方向的变化等。以国家自然科学基金大数据知识管理服务平台及智慧中科院项目所积累的科技领域在科研人员、科研成果、科研项目、研究领域等数据为基础,集成本项目在知识图谱构建、推理及大数据管理上的研究成果,面向科技领域构建基于“人—机构—成果—项目”的知识图谱,实现基于该知识图谱的学者查询及推荐、智能评审推荐、研究方向推荐,并在国家自然科学基金委等进行验证。

(2) 兴趣点 (Point of Interest, POI) 知识图谱构建及应用。不同于一般的知识图谱,POI 知识图谱必须考虑对空间信息的语义表示,同时 POI 知识图谱需要考虑 POI 间时空关系的挖掘及多源外部数据的融合问题。POI 知识图谱因其数据时空特征上的特殊性,在知识图谱构建实体与关系构建时时有其特殊性。基于本项目研究成果,针对 POI 知识图谱进行研究与应用,抽取并构建基于“人—社区—城市”的知识图谱,实现 POI 知识实体的补充与融合,研究基于 POI 知识图谱的应用,并在百度公司进行验证。



2.2 研究目标

本项目针对领域大数据知识图谱构建过程中存在的网络关系复杂、时空多尺度及动态演化等问题展开研究，从表示与构建、推理与认知、存储与管理、应用与验证四个角度展开研究，研究基于深度迁移学习、深度强化学习的表示与构建方法，研究基于规则推理、监督与半监督学习、子图匹配推导、深度语义模型的推理与认知方法，研究数据划分和图结构的分布式数据存储与计算方法，提高知识图谱的丰富度、消除实体歧义、进行实体对齐、完成实体融合，提升领域知识图谱的高精准检索与推荐服务能力。以科技领域和兴趣点（POI）为例，实现对相关工作的应用验证，为诸如电子政务、教育科技、生活服务等国计民生领域大数据知识图谱构建提供理论基础及技术指导。

2.3 关键科学问题

（1）面向领域大数据知识图谱表示与构建问题。面对海量领域数据，传统以本体和语义网为代表的技术路线在构建大规模知识图谱方面存在诸多不足，人工编织知识图谱的传统做法无法适应科技大数据的迅猛增长；传统远程监督产生的训练集噪音大，导致基于监督学习的实体和实体关系识别方法效果不佳；亟需协同专家群体和机器算法，最大化专家群体标记对于算法效能的提升，进而加快知识图谱构建；缺乏面向动态知识图谱的表示学习方法。本研究拟结合深度强化学习技术，解决面向领域大数据知识图谱表示与构建的问题。

（2）领域知识图谱的隐含关系挖掘与演化问题。领域知识图谱中实体、实体属性以及事实关系的多样性与异构性，造成大规模实体及关系冲突、实例关系无法动态更新等问题，例如在互联网百亿级实体、千亿级事实关系图谱中，知识来源广泛、知识重复、关联不明确、时间粒度不一致等，这些数据稀疏性、数据歧义、准确率低、时空尺度下动态演化等特征，使得知识库实体、关联关系有关蕴含着大量的信息未被考虑或有效利用，需要进一步融合、利用多源异质、动态跟踪检测等，进一步提升现有知识表示模型的推理能力以及性能。

（3）大规模知识图谱的高效管理与计算问题。现有的图数据存储管理系统往往采取和图计算分析系统不同的存储格式以及系统架构，这就造成了“存算”系统之间的脱节，在进行图分析的时候，往往需要先花费大量的时间进行数据的批量转换和导入。本研究拟采用大规模知识图谱的“存算”动态适配方法，提高数



据分析的性能，并通过整合关系网络数据管理系统和关系网络数据计算框架，实现存储管理与计算分析的一体化。

3. 拟采取的研究方案及可行性分析（包括研究方法、技术路线、实验手段、关键技术等说明）；

3.1 研究方案

本项目的总体研究方案如 2 图所示。首先研究领域大数据在语义特性上的规律，主要包括基于模块化、层次化方法大特定领域大数据模型以及基于自动机的领域大数据动态表示方法。基于此，从分布式知识图谱数据管理和领域知识图谱构建两方面同步展开研究。在分布式知识图谱数据管理方面，主要通过基于 RDF、分布式图数据库、优化方法，实现大规模领域数据的高效存储、快速检索、并行计算。在领域知识图谱构建方面，首先对领域知识图谱的表示与构建进行研究，通过实体关系识别、静态图谱构建与填充、动态图谱实现与优化等步骤实现领域知识图谱的表示与构建；进一步，进行推理与认知方面进行研究，主要通过基于图模型、概率模型及深度学习方法实现领域知识图谱的高质量推理。以知识图谱数据管理方法及领域知识图谱构建方法为依托，进行应用验证，在构建学术知识图谱和 POI 知识图谱之后，实现基于学术知识图谱的学者查询及推荐、智能评审推荐、研究方向推荐，并且实现 POI 知识实体的补充与融合、基于 POI 的兴趣点推荐及基于 POI 的动向分析。




图 2 研究方法框架图

1.面向领域大数据的知识图谱表示与构建技术

(1) 基于深度迁移学习的实体和实体关系识别

实体和实体关系识别对于文本语料理解至关重要,传统方法是先检测文本中的实体提及并对它们分类,然后抽取关系,这样会导致误差的传播和积累,比如不正确的实体类型会作为特征影响后续关系抽取的精度。本项目拟首先结合Seq2seq与Attention,然后结合迁移学习的技术,在已有领域数据上训练得到的模型能力迁移到新领域之上,减轻新领域数据缺少标记数据的困难。

Seq2Seq技术的思路是通过深度神经网络模型将一个输入序列映射为一个输出序列,这一过程由编码输入与解码输出两个环节组成。Attention模型是一种类似于人脑注意力工作机制的模型。Seq2Seq与Attention结合分为Encoder阶段、Attention阶段与Decoder阶段。本项目使用该方法,将Seq2Seq与Attention融入领域知识图谱的实体关系识别中。

(2) 基于深度强化学习的群体增强的知识图谱填充

知识图谱构建和填充需要机器算法和专家群体的协同,机器算法的成功应用需要相当数量的高质量标记数据,众包是获取高质量数据标记的主要手段,但是众包的周期长、成本高,专家群体不能够在短时间内,对所有的实体关系识别结果进行反馈,需要有优秀的众包任务遴选策略,遴选的待标注众包任务最能够提高算法效能,这本身就是一个重要的研究问题。另一方面,如何根据专家的反馈

来调整实体和实体关系识别的 DNN 模型也是一个重要的研究问题。本项目拟使用基于深度强化学习来进行协同研究，技术框架如图 3 所示。




图 3 基于深度强化学习的群体增强的知识图谱填充框架

项目拟采用深度强化学习方法来控制实体和关系识别 DNN 模型调整，以及实体和关系众包任务遴选。强化学习模型由 Agent 和 Environment 两部分组成，包括状态集 S ，动作集 A 和反馈值集 R 。Agent 与 Environment 持续进行交互：

$$s_0 \xrightarrow{a_0} r_0, s_1 \xrightarrow{a_1} r_1, s_2 \xrightarrow{a_2} r_2 \rightarrow \dots$$

Agent 在持续的交互过程中，获得的总反馈为：

$$r_0 + \gamma r_1 + \gamma^2 r_2 + \dots = \sum_{i=0}^{\infty} \gamma^i r_i$$

其中 γ 为折扣因子。Agent 的任务就是学习一个控制策略 $\pi: S \rightarrow A$ ，使得总反馈值的期望最大化。

(3) 面向动态知识图谱的表示学习算法

现实中知识图谱的结构往往是动态变化的。本项目拟提出面向动态网络结构的表示学习算法。给定一个网络的从时间 1 至时间 t 的结构 $G_1, G_2, \dots, G_t$ ，算法



的目标是学习得到一个隐空间，使得映射到该隐空间的结点能够保留其结构特征、动态特征。

算法的核心部分是对网络中的三角闭合过程进行建模，该过程描述了三个实体之间构成的开三角向闭合三角演化的过程。以第 t 个时间片为例，倘若存在开三角 (v_i, v_j, v_k) ，其中 v_i 和 v_j 相互不认识，但他们有共同好友 v_k 。现在 v_k 将决定是否介绍 v_i 和 v_j 相识——即这两个结点在下一个时间片 $t+1$ 建立一条边。假设 v_k 将根据和另外两人的相对位置做出这个决定，即由长度为 K 的向量决定：

$$\hat{\mathbf{x}}_{ijk}^t = \langle \mathbf{w}_{ik}^t * (\mathbf{u}_k^t - \mathbf{u}_i^t) + \mathbf{w}_{jk}^t * (\mathbf{u}_k^t - \mathbf{u}_j^t) \rangle$$

其中 $\mathbf{w}_{ik}^t$ 为节点 v_i 和 v_k 在当前时间片 t 的边权， $\mathbf{u}_i^t$ 是节点 v_i 当前在隐空间中的表达向量。此外，定义一个长度为 K 的向量 q 。由此，开三角 (v_i, v_j, v_k) 在下一个时间片闭合的概率为：

$$P_{\text{triad}}^t(i, j, k) = \frac{1}{1 + \exp(-\langle \mathbf{q}, \hat{\mathbf{x}}_{ijk}^t \rangle)}$$

基于以上对问题的分解，本项目拟设计 Expectation Maximization 的算法对约束进行求解，实现面相动态知识图谱的表示学习方法研究。

2. 面向领域大数据的知识图谱推理与认知技术

使用 TransE 知识图谱事实关系挖掘与推理、基于混合规则与分布式表示的隐含语义推理技术，来实现事实、关系及隐含语义的推理。在关系推理领域，以 TransE 算法为代表的关系推理模型，因其具有推理准确性高和算法可并行等优点而成为近期研究热点，目前仍在快速发展过程中。TransE 模型参考了 RESCAL 量分解模型（tensor factorization model）。该模型采用三阶张量对知识图谱中的事实 (h, r, t) 进行建模，参数模型的函数表达为：

$$f(\mathbf{h}, \mathbf{r}, \mathbf{t}) = \mathbf{h}^T \mathbf{W}_r \mathbf{t} = \sum_{a=1}^k \sum_{b=1}^k \mathbf{W}_{abr} \mathbf{h}_a \mathbf{t}_b$$

其中， $\mathbf{h}, \mathbf{t} \in \mathbb{R}^k$ 为三元组的头、尾实体在 k 维空间的向量表达， $\mathbf{W}_r \in \mathbb{R}^{k \times k}$ 表示关系 r 的权重矩阵。受 RESCAL 模型启发，基于结构化表达的 SE(structured embedding) 关系推理算法。参数模型的函数表达如下：

$$f(\mathbf{h}, \mathbf{r}, \mathbf{t}) = \|\mathbf{M}_{rh} \mathbf{h} + \mathbf{M}_{rt} \mathbf{t}\|_2$$



其中, M_{rh} 和 M_{rt} 分别表示关系 r 关于头和尾实体的线性变换。由于 SE 和 RESCAL 算法在大规模真实数据集上的推理准确性较低, Bordes 等人受 word2vec 词表达算法的启发提出了 TransE 建模假设, 放弃了 RESCAL 算法采用关系矩阵变换的实体映射方式, 转而采用 $h + r = t$ 的方式进行推理。参数模型为:

$$f(h, r, t) = \|h + r - t\|_2$$

其中, 符号 $\|x\|_2$ 表示向量 x 的二范数。TransE 算法的基本思路是将知识图谱中的实体与关系均映射到特定维度的实向量空间中, 得到实体与关系的向量表达 (称为 embedding), 关系推理建模的目标是对于任意已知事实 (h, r, t) , 使得 $f(h, r, t)$ 的值尽可能小。TransE 算法因其计算效率高 (可并行) 和算法召回率高而受到学术界的高度关注。

在基于混合规则与分布式表示的隐含语义推理中, 分布式表示辅助规则发现方面拟采用上下文敏感的推理规则发现方法。首先, 构建关系图 (如图 4), 抽象关系元组 (如 $X \text{ buy } Y$) 和实例化特征 (如 $X = \text{Facebook}$ 和 $Y = \text{WhatsApp}$) 作为节点, 边代表抽象关系元组和实例化特征的共现 (如 $X \text{ buy } Y$ 和 $X = \text{Facebook}$ 之间的连边) 或抽象关系元组之间的语义依赖关系 (同义词、上位词等, 如 $X \text{ buy } Y$ 和 $X \text{ purchase } Y$ 之间的连边)。然后, 基于关系图学习特定上下文的关系表示, 形式化为抽象关系元组与对应特征上下文敏感的相关性得分的拼接向量, 相关性得分通过关系元组到特征带自启动的随机行走计算。最后, 计算关系向量之间的相似度, 大于阈值的关系对及对应上下文形成推理规则。这里, 上下文信息的利用体现在随机行走重启概率的计算上, 对于上下文无关 (相关性通过词相似度计算) 的特征节点设置高的重启概率, 反之设置低的重启概率。




图 4 关系图实例



规则辅助基于分布式表示的推理方面,无缝嵌入逻辑规则和物理规则,并形式化推理为整型线性规划问题(ILP)。物理规则包括关系对应的实体类型限制、关系对应的实体数目限制等。逻辑规则:关系 r_1 可以推出关系 r_2 , 则关系 r_1 连接的两个实体也被关系 r_2 连接。通过整型线性规划集成表示模型和规则。目标函数基于三元组的得分函数,可以用上述任何表示模型的得分函数,而每个规则形式化为一个需要满足的条件。

3. 分布式知识图谱数据管理系统关键技术

为了管理超大规模的知识图谱数据,拟采用大规模分布式存储和 RDF 查询引擎的方法。通过采用 HDFS、NoSQL 等分布式存储,支持横向扩展,可容纳数千万个顶点和边,并支持 ACID 事务,支撑上千并发用户和计算复杂图形遍历。为实现高效的语义查询,面向知识图谱的语义特性,基于图查询引擎设计 RDFGraph2PG 翻译器和 SparQL2GraphQL 翻译器。通过 RDFGraph2Pg 翻译器实现 RDF 图到属性图的映射,即接受 RDF Graph (RDF 资源、属性、RDF link) 作为输入,将其转换成属性图(节点、边、标签)。在读取的时候,从 HDFS、NoSQL 数据库中加载到属性图信息,结合 RDF Schema 将其转换成 RDF Graph。通过 SparQL2GraphQL 翻译器实现 SPARQL 查询语句到图查询语句的转换,通过采用语句缓存、模式匹配、谓词下推等技术,实现高效的语义查询功能。




图 5 基于 Hadoop 架构的 RDF 存储与查询

拟基于 RDPG (Resilient Distributed Property Graph) 技术实现大规模图数据的计算分析。RDPG 是一种点和边都带属性的有向多重图,为了实现大规模图的高效计算与处理,RDPG 采用图的分布式或者并行处理方法,即将图拆分成很多



的子图，然后分别对这些子图进行计算，计算的时候可以分别迭代进行分阶段的计算，即对图进行并行计算。同时由于图数据库关注于图的随机存取效率，而图计算框架关注于图的顺序遍历效率，目前的图数据库并不能较好的支持图的计算分析，因此本研究拟采用在线适配的方法，实现图存储管理到图计算分析框架之间的在线数据转换转换。通过采用流式计算技术，在图的写操作（增加、修改、删除）时，通过触发器机制同步完成 RDPG 信息的更新；最后，在图的计算分析时，通过预存的分布式图索引信息，结合图的原始信息，在线生成 RDPG 信息，从而完成图的典型分析和复杂分析。




图 6 分布式图的迭代计算

3.2 可行性分析

(1) 项目研究目标明确，内容具体，要点清晰，各部分内容之间逻辑清晰，具有内在的关联性，方案可行。项目组成员单位已经对各项关键技术进行了前期研究，取得了一些初步结果；研究方法规范、具体，很好地将定性定量、理论分析与实证研究结合在一起，技术路线清晰，操作性强。

(2) 研究基础。本课题承担单位中国科学院计算机网络信息中心、清华大学和百度公司在本项目领域具有雄厚的研究基础。中科院计算机网络信息中心是中国科学院科研信息化和管理信息化的支撑服务机构、大数据分析计算技术国家地方联合工程实验室依托单位，具有持续达 30 年之久的科学数据资源汇聚管理、关联融合和分析挖掘的研发经验，是国内科学数据管理共享和应用领域的旗



舰机构，至今已经集成整合了超过 3PB 的科学数据资源，逐渐形成了独具特色的“数据服务-信息服务-知识服务”科学数据服务模式，同时依托国家自然科学基金委和中国科学院人才项目资源库，开展基于知识图谱的科技大数据关键技术研究 and 应用系统研发，授权发明专利 20 多项；近几年在熊辉教授的带领下，在数据关联融合、分析挖掘与推荐系统等方面在 KDD、TKDE 等顶级期刊和会议上发表 30 篇论文，具有良好的理论基础和应用场景。清华大学唐杰团队一直从事知识图谱、学者画像、学术搜索等研究工作，在高质量语义内容生成、知识驱动的智能推荐、基于隐含语义的大规模网络排序等方面提出很多创新性的成果，在 CCF A 类论文 50 多篇，授权发明专利 22 项，13 次在国际竞赛中获得第一，研发的 AMiner 系统收录 100 多个科技文献库、1.36 亿学者语义信息、2.28 亿论文元数据信息、873 万知识概念，服务于服务 220 个国家和地区 732 万独立 IP 用户。百度公司构建了全球最大的中文知识图谱，包含亿级实体和千亿级事实，覆盖数十个垂直细分类别，支持超大规模知识推理和知识挖掘，广泛应用于百度搜索、信息流等重要产品中，服务亿万互联网用户；百度地图全球 POI 总数超 1.5 亿，月活跃用户超过 3 亿。

(3) 从工作量及时间保障来看，一方面，本课题的研究内容与课题组各成员的研究方向高度吻合，有利于已有研究基础的充分利用；另一方面，本项目的各项研究内容之间联系紧密、逐层递进，有利于相关研究结果的复用，节省研究时间；再者，人员搭配合理，时间计划可行。

(4) 从工作条件上看，项目组已经具备了研究所必需的软硬件及数据资源积累。在前期研究工作中，积累了众多的硬件设备，有利于我们进行实验系统的研发；另外，我们还具有独具特色的应用场景、数据资源，并具有充分的工程开发队伍，有利于项目的顺利完成。

综上所述，无论是从项目研究的整体方法的科学性，从项目参与者组成的合理性，以及从项目参与单位在相关研究方向和应用的积累方面，均为本项目的顺利开展并达到预期目标提供了可靠的保障。

4. 本项目的特色与创新之处；

本项目的特色与创新之处主要有：



(1) 项目以典型应用为基础、以情景分析为依托,在面向领域大数据知识图谱构建理论与技术方面开展创新性研究。项目基于团队在科技知识图谱、百度中文知识图谱、百度 POI 兴趣点知识图谱等应用场景的深入分析,依托在知识图谱、智能推荐、深度学习、商业智能等相关研究基础,深入开展领域大数据知识图谱构建理论与关键技术的相关研究,形成可指导质量与规模协调、通用与垂直平衡的大数据领域知识图谱的理论方法和共性技术。

(2) 理论方法研究与工程实现、实证研究相结合研究模式。本项目在典型需求分析下,开展面向领域大数据的知识图谱构建技术研究,逐步形成原型系统,依托现有的大规模数据资源和应用基础(科技知识图谱、兴趣点知识图谱)进行迭代验证,不断完善优化,最终形成具有实际指导和应用作用的领域大数据知识图谱理论体系和关键技术。研究团队也是融研究、工程与应用于一体的科研队伍,团队成员既有承担过国家自然科学基金等研究项目的经历,在顶级期刊和会议上发表上百篇的论文,也有承担过服务于互联网用户大规模系统的研发经验。

(3) 项目探索具有适配大规模、可溯源、易集成、易查询和不确定性的领域知识图谱的知识表示、自动预测补全、隐含关系挖掘与推理、高效存取与计算等理论方法和关键技术,形成质量与规模协调平衡的领域大数据知识图谱体系,并在科技领域和兴趣点(POI)应用验证,为电子政务、教育科技、生活服务等国计民生领域大数据知识图谱构建提供理论基础及技术指导。

5. 年度研究计划及预期研究结果(包括拟组织的重要学术交流活动、国际合作与交流计划等)。

5.1 年度研究计划

本项目计划用 5 年时间完成,具体计划如下:

第一年度(2019 年 1 月-2019 年 12 月)

调研、梳理和分析面向领域大数据的知识图谱构建的相关理论体系、大规模知识图谱构建的方法与技术;在此基础上建立面向领域大数据知识图谱的技术理论体系、关键技术和整体框架设计。

第二年度(2020 年 1 月-2020 年 12 月)



完成基于深度迁移学习的实体和实体关系识别技术的研究；完成基于深度强化学习的群体增强的知识图谱填充；完成面向动态知识图谱的表示学习算法的研究工作；结合深度强化学习技术完成面向领域大数据知识图谱的表示与构建技术的研究工作。

第三年度（2021 年 1 月-2021 年 12 月）

完成大规模知识实体的网络关系分析方法、基于概率因子图模型的隐含语义分析方法和时空多尺度场景下知识图谱动态更新的检测方法的研究；完成面向领域大数据的知识图谱推理与认知技术的研究工作，提升现有知识表示模型的推理能力以及性能。

课题中期检查。

第四年度（2022 年 1 月-2022 年 12 月）

完成基于数据划分的分布式知识图谱高效管理技术的研发工作；完成基于图结构的索引与查询优化策略、大规模知识图谱的“存算”动态适配策略的研究；实现存储管理与计算分析的一体化，完成分布式知识图谱数据管理系统关键技术的研发工作。

第五年度（2023 年 1 月-2023 年 12 月）

基于前阶段的研究成果，完成面向特定领域大数据的知识图谱的构建及应用研究；完成面向科技领域构建基于“人-机构-成果-项目”学术图谱的构建，并在国家自然科学基金委完成应用验证工作；完成针对 POI 知识图谱的研究与应用，抽取并构建基于“人-城市-环境”的知识图谱，研究 POI 知识图谱的应用并在百度公司进行验证。

项目结项。

5.2 预期研究成果

通过本项目的研究，将形成面向领域的知识图谱构建的理论、方法和技术，构建通过示范性应用验证的领域知识图谱平台。

（1）从领域大数据知识图谱构建过程中的网络关系复杂、时空对尺度及动态演化问题出发，依托自然语言处理技术、知识表示与推理技术、本体工程与本体学习理论等，研究形成一系列领域知识图谱表示与构建、推理与认知、存储与管理的理论、技术与方法。



(2) 从应用与验证的角度出发,以科技领域和兴趣点(POI)为例,实现领域知识图谱的相关应用验证工作,形成一系列面向应用的理论成果与技术方法,指导领域知识图谱在电子政务、教育科技、生活服务等国计民生领域的应用。

(3) 突破面向领域大数据的知识图谱表示与构建,知识图谱推理与认知,分布式知识图谱数据管理系统等关键技术,申请专利 3-5 项,获得 4-6 项软件著作权。

(4) 发表国内外高水平期刊、会议论文 30-40 篇左右,其中 CCF A 类不少于 12 篇。

(5) 培养一批面向领域知识图谱构建及应用技术研究的学科人才,其中博士生 6-8 人,硕士生 10-15 人。

(6) 本课题将安排赴国外参与短期合作交流 5 人次以上,累计时间超过 12 个月;同时邀请境外知名专家学者 5 人次以上,就课题研究中的一些关键问题进行深入交流。

(二) 研究基础与工作条件

1. 研究基础(与本项目相关的研究工作积累和已取得的研究工作成绩);

中国科学院计算机网络信息中心一直承担中科院的学术画像 ARP 系统的研发和运行保障工作,是中科院人才计划项目评审系统的研发和服务单位,为中科院“百人计划”等项目的评审、人才引进和培养提供支持。目前正在承担国家自然科学基金委员会“国家自然科学基金大数据知识管理服务平台”研发,基于国家自然科学基金委管理的 600 万科研人员、20 余万科研项目及上千万科研成果,以“项目—成果—人员”为核心,构建了由近两千万实体及上亿条关系的知识网络,初步形成了基金委科研画像库和学术关系图谱,在科研社区发现、基金委项目评审辅助推荐等进行了有益的尝试。项目拟聘请美国罗格斯-新泽西州立大学熊辉教授作为学术顾问,熊辉教授从 2016 年 1 月开始被中科院聘为海外评审专家,并被中科院计算机网络信息中心聘为客座研究员。熊辉教授是国际公认的数据挖掘领域目前最为活跃的顶尖学者之一,是华人学者的杰出代表。熊辉教授熊辉博士现为美国罗格斯-新泽西州立大学正教授并终身教授、ACM 杰出科学家,2016



年被授予 RBS 院长讲席教授、中国教育部“长江学者(讲座教授)”和中国科学院海外评审专家, 获得 2009 罗格斯大学最高学术奖, IEEE ICDM-2011 最佳研究论文。担任 Encyclopedia of GIS (Springer)的共同主编, 以及 IEEE Transactions on Data and Knowledge Engineering (TKDE)、 IEEE Transactions on Big Data (TBD)、ACM Transactions on Knowledge Discovery from Data (TKDD) 和 ACM Transactions on Management Information Systems (TMIS) 的副主编。担任 KDD-2012 企业及政府主题的共同程序主席、IEEE-ICDM 2013 的共同程序主席、IEEE-ICDM 2015 的共同大会主席及 KDD 2018 的研究专题程序委员会主席。针对本项目研究内容上的相关工作, 项目组在熊辉教授的指导下在基于大数据的用户画像、个性化推荐服务等相关领域的理论和技术研究方面取得了创新性的研究成果, 已在包括 TKDE、TMC 等 IEEE/ACM Trans 国际权威刊物, 和包括 KDD、IJCAI、AAAI、UbiComp、WSDM、ICDM、CIKM 和 SDM 等国际高水平学术会议上发表多篇论文, 成果应用于包含用户兴趣点推荐、人才管理、城市计算、移动情景感知和移动应用推荐等多个领域。

清华大学唐杰老师团队, 长期从事数据挖掘、学术图谱等领域的研究工作, 承担国家及部委级项目 10 余项, 发表论文 200 余篇, 其中 CCF A 类期刊/会议论文 60 篇, 申请发明专利 40 项, 获得授权 20 多项。建成科技情报大数据挖掘与服务系统 AMiner, 是国内最早研发的、也是至今访问量最大的学术社会网络分析与挖掘系统, 该系统通过建立学者社会网络的方式提供更精确的语义服务功能, 系统收录科技文献超过 2.3 亿, 学者条目超过 1.3 亿, 年度访问量 1100 万次, 科研数据下载 230 万次, 核心技术在科技部人才中心, 中国工程院知识中心, 国家自然科学基金委、华为、搜狗、腾讯等 20 余家企事业单位得到应用; 系统 API 还为全球最大出版社 Elsevier 和 SIGKDD'10-12、PKDD'11、ICDM'11、WSDM'11、ISWC'10 等 20 余个重要国际会议提供论文-审稿人自动分发和提供语义信息服务, 被多个国际研究机构认为是世界上最有代表性的学术社会网络分析系统之一。获得 2017 年北京市科学技术奖一等奖, 2013 年中国人工智能学会吴文俊人工智能科技进步一等奖。

北京百度网讯科技有限公司, 在前沿人工智能、语义识别、数据挖掘、大数据处理等全球领先的核心技术, 构建了全球最大的中文知识图谱, 包含亿级实体



和千亿级事实，覆盖数十个垂直细分类别，支持超大规模知识推理和知识挖掘，广泛应用于百度搜索、信息流等重要产品中，服务亿万互联网用户。团队研发的百度学术收录 120 学术站点，索引 12 亿学术资源页面，建设学术文献超过 4 亿。团队研发的百度地图正在深度构建兴趣点知识图谱，全球兴趣点总数超过 1.5 亿，月活跃用户超过 3 亿。承担 863 项目“互联网语言翻译系统研制”课题，获 2015 年国家科技进步二等奖，承担核高基专项“基于框计算的新一代搜索引擎和浏览器”项目，完成了新一代搜索引擎与浏览器技术和产品的研发，获 2013 年中国电子学会科技进步一等奖。

2. 工作条件（包括已具备的实验条件，尚缺少的实验条件和拟解决的途径，包括利用国家实验室、国家重点实验室和部门重点实验室等研究基地的计划与落实情况）；

中国科学院计算机网络信息中心是中国互联网的诞生地，是国家发改委大数据分析计算技术国家地方联合工程实验室、大数据应用服务技术北京市工程实验室、中国科学院计算科学应用研究中心依托单位，承担国家发改委促进大数据重大工程项目“科学大数据公共服务平台与创新应用示范”。拥有万兆级国际出口带宽的先进科研服务网络（中国科技网）、超过 30P 聚合计算能力的超级计算环境和 52PB 以上分布式云环境等基础设施。计算机网络信息中心运行和管理我国最早的互联网骨干网之一的中国科技网（CSTNET），是国际学术网络的重要成员，与国内各互联网骨干网和欧美主要学术网络高速互联，承担着国家下一代互联网示范工程任务，在未来网络、云计算等前沿技术领域是国内一支重要力量。在我国最早提供超级计算服务，是中国国家网络运行管理中心和北方主节点，是中国超级计算创新联盟的发起单位和中国首家英特尔并行计算中心，在高性能计算领域的算法、软件与应用研发及人才培养方面发挥着重要作用。

清华大学牵头承建大数据系统软件国家工程实验室，项目团队依托于清华信息科学与技术（筹）国家实验室、智能技术与系统国家重点实验室，已建成的科技情报挖掘与智能服务系统 AMiner，已有全领域论文文献及专家学者库，收录论文文献超过 2.3 亿及论文引用关系 7.5 亿，收录学者 1.3 亿，其中超过 40 万专家通过了人工标注与审核，建立了如各国院士、大奖获得者、ACM fellow、各领域知名学者、知名高校教师、优秀青年人才等特色专家子库超过 160 个。



百度是深度学习技术及应用国家工程实验室牵头单位、获批建设科技部首批四个国家新一代人工智能开放创新平台之一--自动驾驶平台、承担国家发改委“互联网+”重大工程项目“人工智能基础资源公共服务平台”。百度每天提供数十亿次服务，拥有较为完备的互联网信息服务基础设施，包括高性能的硬件资源，稳定高效的基础系统服务；目前搭建新型超大规模计算机集群和数据存储平台，建设基础资源数据库，支持语音、图像、视频和地理信息的存储和计算，支持自动数据标签化、分类管理等功能。百度拥有海量网络资源，涵盖了各种公开的学术数据库、期刊官网以及其他学术平台类网络资源，同时类型也涵盖广泛，百度学术收录 120 学术站点，索引 12 亿学术资源页面，具备数据深度加工和集成的技术实力。同时拥有国内领先的兴趣点知识图谱数据资源，全球兴趣点总数超过 1.5 亿。

3. 正在承担的与本项目相关的科研项目情况（申请人和项目组主要参与者正在承担的与本项目相关的科研项目情况，包括国家自然科学基金的项目和国家其他科技计划项目，要注明项目的名称和编号、经费来源、起止年月、与本项目的关系及负责的内容等）；

无。

4. 完成国家自然科学基金项目情况（对申请人负责的前一个已结题科学基金项目（项目名称及批准号）完成情况、后续研究进展及与本申请项目的关系加以详细说明。另附该已结题项目研究工作总结摘要（限 500 字）和相关成果的详细目录）。

面向候鸟迁徙行为的数据挖掘算法研究，61003138

该项目进展顺利，完成了既定的工作目标，后续研究已在候鸟迁徙行为挖掘成果的基础上结合多源数据（生态环境数据、疾病数据）研究候鸟迁徙行为和生态环境之间的关联关系、候鸟迁徙行为与疾病传播之间的关联关系，为生态环境的保护及疾病防护提供支持；在后续研究过程中发现跨领域数据资源的融合关联越来越重要。因此本课题拟针对领域大数据知识图谱相关技术进行深入研究，并在科技和兴趣点（POI）领域进行验证。

工作总结摘要：



候鸟迁徙行为过程主要中涉及到栖息地发现、迁徙路线追踪以及栖息地之间的活动关系等。为此如何寻找候鸟迁徙过程的栖息地、追踪候鸟的迁徙路线、挖掘栖息地之间的关系对候鸟和生态环境的保护、禽流感等疾病传播和防治的研究具有重要的意义。针对目前对于候鸟迁徙的卫星跟踪数据处于人工处理的现状,本项目研究相关数据挖掘算法并应用这些算法对高达百万级数据量的候鸟迁徙的卫星跟踪数据进行数据分析。研究基于密度的层次聚类算法发现栖息地、基于聚类的多时间序列关联性分析算法追踪候鸟迁徙的路线、以带权重的连通图挖掘的算法寻找栖息地之间的关系,最后将这些算法应用到实际的青海湖区域候鸟迁徙卫星跟踪数据当中,并以 WebGIS 平台可视化展现算法挖掘的结果,为动物学家和生态学家进一步的研究提供坚实的基础。

主要相关成果目录:

[1] Yuanchun Zhou, Mingjie Tang, Weike Pan, Jinyan Li, Weihang Wang, Jing Shao, Liang Wu, Jianhui Li*, Qiang Yang and Baoping Yan. "Bird Flu Outbreak Prediction via Satellite Tracking". IEEE Intelligent Systems, 2014, 29(4):10-17 (SCI, IF 2.154)

[2] Yuwei Wang, Yuanchun Zhou*, Ying Liu, Ze Luo, Danhuai Guo, Jing Shao, Fei Tan, Liang Wu, Jianhui Li, Baoping Yan. A grid-based clustering algorithm for wild bird distribution. Frontiers of Computer Science, 2013, 7(4):475-485 (SCI, IF 0.298)

[3] Mingjie Tang, Yuanchun Zhou*, Jinyan Li, Weihang Wang, Peng Cui, Yuansheng Hou, Ze Luo, Jianhui Li, Fuming Lei, Baoping Yan. "Exploring the Wild Birds' Migration Data for the Disease Spread Study of H5N1: A Clustering and Association Approach". Knowledge and Information Systems: An International Journal (KAIS) (SCI, IF 2.221), 2011, 5, pp227-251

[4] Peng Cui, YuanSheng Hou, MingJie Tang, Haiting Zhang, Yuanchun Zhou, Zuohua Yin, Shan Guo, Zhi Xing, Yubang He, Diann J. Prosser, John Y. Takekawa, Baoping Yan, Fumin Lei*. Movement patterns of Bar-headed Geese *Anser indicus* during breeding and post-breeding periods at Qinghai Lake, China. Journal OF Ornithology, 2011, 1, pp.83-92 (SCI, IF 1.636)

[5] Diann J. Prosser, Peng Cui, John Y. Takekawa, Mingjie Tang, Yuansheng Hou, Bridget M. Collins, Baoping Yan, Nichola J. Hill, Tianxian Li, Yongdong Li,



Fumin Lei, Shan Guo, Zhi Xing, Yubang He, Yuanchun Zhou, David C. Douglas, William M. Perry, Scott H. Newman. Wild Bird Migration across the Qinghai-Tibetan Plateau: A Transmission Route for Highly Pathogenic H5N1. PLoS ONE 6(3): e17622. doi:10.1371/journal.pone.0017622.(SCI, IF 4.092)

[6] Danhuai Guo, Yuanchun Zhou*, Yingqiu Zhu, Jianhui Li: Species Distribution Modeling via Spatial Bagging of Multiple Conditional Random Fields. DASFAA 2016: 437-450

[7] Yuanchun Zhou, Jing Shao*, Xuezhi Wang, Ze Luo, Jianhui Li, Baoping Yan. Bird-SDPS: A Migratory Birds' Spatial Distribution Prediction System. The 9th IEEE International Conference on eScience (eScience2013), October 2013, pp.9-16

[8] Yuwei Wang, Ze Luo, Gang Qin, Yuanchun Zhou, Danhuai Guo, Baoping Yan. Mining Common Spatial-Temporal Periodic Patterns of Animal Movement. The 9th IEEE International Conference on eScience (eScience2013), October 2013, pp.17-26 (Best Student Paper)

[9] Liang Wu, Alvin Chin, Guandong Xu, Liang Du, Xia Wang, Kangjian Meng, Yonggang Guo, Yuanchun Zhou*. Who Will Follow Your Shop? Exploiting Multiple Information Sources in Finding Followers. The 18th International Conference on Database Systems for Advanced Applications (DASFAA2013), April 2013, pp.401-415

[10] Qingling Chang, Shiting Xu, Yuanchun Zhou*, Jing Shao, Jianhui Li, Baoping Yan. Linked Data Platform D2R+. the 7th Chinese Semantic Web Symposium and 2nd Chinese Web Science Conference(CSWS 2013), CCIS 406, August 2013, pp.11-22

[11] Shasha Li, Yuanchun Zhou*, Jianhui Li, Ze Luo, Zheng Kou, Tianxian Li, Baoping Yan, Application of Data Mining in Research of Avian Influenza Virus Cross-Species Infection. The 7th IEEE International Conference on eScience(eScience2011), December 2011, pp.89-96

[12] Liang Wu, Yuanchun Zhou*, Fei Tan, Fenglei Yang, Jianhui Li: Generating Syntactic Tree Templates for Feature-Based Opinion Mining. ADMA 2011: 1-12

[13] Shao Jing, Zhou Yuanchun*, Li Jianhui, Wang Xuezhi, Luo Ze, Yan Baoping. Spatial distribution analysis of wild bird migration in Qinghai Lake based



on Maximum Entropy modeling. The 2011 International Conference on Networking and Distributed Computing (ICNDC 2011), September 2011, pp.140-144

[14] Luo Ze, Yan Baoping*, Zhou Yuanchun, Li Jian, Tang, Mingjie, Zhang Haiming, Shao Jing, Li Shasha, LiTianxian, Kou Zheng, Lei Fumin, Cui Peng, Hou Yuansheng, He Yubang, Xing Zhi. e-Science Practice for Wild Birds' Monitoring and Protection in Qinghai Lake Region. The 7th IEEE International Conference on eScience(eScience2011), December 2011, pp.355-362

[15] Luo Ze, Zhou Yuanchun, Li Jian, Shao Jing, Yang Tao, Wang Jinyi, Lei Fumin, Li Tianxian, Xing Zhi, Yan Baoping. Cyberinfrastructure for Joint Research in Qinghai Lake Nature Reserve. the 2011 International Conference on Environmental Science and Information Application Technology (ESIAT 2011), June 2011, pp.1781-1790

[16] Zhang Haiming, Li Jianhui*, Zhou Yuanchun, Wang Xuezhi; Xue Zhenghua, Yan Baoping. Large-scale storage and high-performance processing environment for remote sensor images. 2011 International Conference on Networking and Distributed Computing (ICNDC 2011), September 2011, pp.75-78

（三）其他需要说明的问题

1. 申请人同年申请不同类型的国家自然科学基金项目情况（列明同年申请的其他项目的项目类型、项目名称信息，并说明与本项目之间的区别与联系。

无。

2. 具有高级专业技术职务（职称）的申请人或者主要参与者是否存在同年申请或者参与申请国家自然科学基金项目的单位不一致的情况；如存在上述情况，列明所涉及人员的姓名，申请或参与申请的其他项目的项目类型、项目名称、单位名称、上述人员在该项目中是申请人还是参与者，并说明单位不一致原因。

无。



3. 具有高级专业技术职务（职称）的申请人或者主要参与者是否具有高级专业技术职务（职称）的申请人或者主要参与者是否存在与正在承担的国家自然科学基金项目的单位不一致的情况；如存在上述情况，列明所涉及人员的姓名，正在承担项目的批准号、项目类型、项目名称、单位名称、起止年月，并说明单位不一致原因。

无。

4. 其他。

无。

NSFC 2018



周园春 简历

中国科学院计算机网络信息中心，大数据部，研究员

教育经历（从大学本科开始，按时间倒序排序；请列出攻读研究生学位阶段导师姓名）：

(1) 2002.9 - 2006.7, 中国科学院计算技术研究所, 计算机系统结构, 博士, 导师: 阎保平

(2) 1999.9 - 2002.7, 中国科学院合肥智能机械研究所, 模式识别与智能系统, 硕士, 导师: 李淼

(3) 1994.9 - 1997.7, 中国科学技术大学, 计算机软件, 大学, 导师: 胡晓军

科研与学术工作经历（按时间倒序排序；如为在站博士后研究人员或曾进入博士后流动站（或工作站）从事研究，请列出合作导师姓名）：

(1) 2017.1-至今, 大数据分析计算技术国家地方联合工程实验室, 理事会, 秘书长

(2) 2016.5-至今, 中国科学院计算机网络信息中心, 大数据部, 研究员

(3) 2014.1-至今, 大数据应用服务技术北京市工程实验室, 副主任, 首席科学家

(4) 2014.1-2016.4, 中国科学院计算机网络信息中心, 科学数据中心, 研究员

(5) 2013.9-2014.3, 美国罗格斯大学, 商学院（熊辉教授组）, 访问学者

(6) 2009.1-2013.12, 中国科学院计算机网络信息中心, 科学数据中心, 副研究员

(7) 2006.4-2008.12, 中国科学院计算机网络信息中心, 科学数据中心, 助理研究员

曾使用其他证件信息（申请人应使用唯一身份证件申请项目，曾经使用其他身份证件作为申请人或主要参与者获得过项目资助的，应当在此列明）：

主持或参加科研项目（课题）及人才计划项目情况：

1、国家重点研发计划课题，2016YFB0501901，协同精密定位总体构架与服务平台设计，2016/07-2021/06，2720.65万，在研，主持

2、国家烟草专卖局重大专项，SJ，烟草科研大数据，2018/01-2021/12，11700万，在研，技术首席

3、海洋专项办，气象水文大数据分析系统，2016/01-2018/03，298万，结题，主持

4、国家自然科学基金委委托项目，国家自然科学基金大数据知识管理服务平台，256.8万，结题，技术负责人

5、国家自然科学基金重点基金，91224006，面向非常规突发事件应急管理的云服务体系和关键技术，2013/01-2015/12，200万，结题，参加



6、中国科学院“十二五”信息化专项, XXH12504, 科技数据资源整合与共享工程, 2012/01-2015/12, 6700万, 结题, 课题一负责人

7、国家自然科学基金培育项目, 91324019, 面向非常规突发事件应急管理的大数据时空可视化服务研究, 2014/01-2014/12, 15万, 结题, 参加

8、国家自然科学基金青年基金, 61003138, 面向候鸟迁徙行为的数据挖掘算法研究, 2011/01-2013/12, 20万, 结题, 主持

代表性研究成果和学术奖励情况(每项均按时间倒序排序)

(请注意: ①投稿阶段的论文不要列出; ②对期刊论文: 应按照论文发表时作者顺序列出全部作者姓名、论文题目、期刊名称、发表年代、卷(期)及起止页码(摘要论文请加说明); ③对会议论文: 应按照论文发表时作者顺序列出全部作者姓名、论文题目、会议名称(或会议论文集名称及起止页码)、会议地址、会议时间; ④应在论文作者姓名后注明第一/通讯作者情况: 所有共同第一作者均加注上标“#”字样, 通讯作者及共同通讯作者均加注上标“*”字样, 唯一第一作者且非通讯作者无需加注; ⑤所有代表性研究成果和学术奖励中本人姓名加粗显示。)

按照以下顺序列出: ①10篇以内代表性论著; ②论著之外的代表性研究成果和学术奖励。

一、10篇以内代表性论著

(1) Pengfei Wang^(#); Guannan Liu; Yanjie Fu; **Yuanchun Zhou**^(*); Jianhui Li, Spotting Trip Purposes from Taxi Trajectories: A General Probabilistic Model, ACM Transactions on Intelligent Systems and Technology, 2018.02.01, 9(3): 01~26

(期刊论文)

(2) Pengfei Wang^(#); Wenjuan Cui; Ruijun Wang; **Yuanchun Zhou**^(*); Jianhui Li, A Matrix Factorization Based Flight Destination Recommendation System, Information Sciences (期刊论文)

(3) **Yuanchun Zhou**^(#); Yang Zhang; Yong Ge; Zhenghua Xue; Yanjie Fu; Danhuai Guo; Jing Shao; Tiangang Zhu; Xuezhi Wang; Jianhui Li, [An efficient data processing framework for mining the massive trajectory of moving objects](#)^(*), Computers, Environment and Urban Systems, 2017.1, 61: 129~140 (期刊论文)

(4) Cui, Wenjuan; Wang, Pengfei; Du, Yi; Chen, Xin; Guo, Danhuai; Li, Jianhui; **Zhou, Yuanchun**^(*), [An algorithm for event detection based on social media data](#)^(*), Neurocomputing, 2017.3.6, 254(3): 53~58 (期刊论文)

(5) 赵江华^(#); 穆舒婷; 王学志; 林青慧; 张兮; **周园春**^(*), [科学数据众包处理研究](#), 计算机研究与发展, 2017.2, (02): 284~294 (期刊论文)



(6) Wu, Liang^(#); Du, Liang; Liu, Bo; Xu, Guandong; Ge, Yong; Fu, Yanjie; Li, Jianhui; **Zhou, Yuanchun**^(*); Xiong, Hui, [Heterogeneous Metric Learning with Content-Based Regularization for Software Artifact Retrieval](#)[✓], IEEE International Conference on Data Mining, Shenzhen, 2014.12.14-2014.12.17
(会议论文)

(7) Danhuai Guo^(#); **Yuanchun Zhou**^(*); Yingqiu Zhu; Jianhui Li, [Species Distribution Modeling via Spatial Bagging of Multiple Conditional Random Fields](#), The 21st International Conference on Database Systems for Advanced Applications (DASFAA 2016), Dallas, 2016.04.16-2016.04.19 (会议论文)

(8) Du, Yi; Ma, Cuixia; Wu, Chao; Xu, Xiaowei; Guo, Yike; Zhou, Yuanchun; Li, Jianhui, [A Visual Analytics Approach for Station-Based Air Quality Data](#)[✓], SENSORS, 2017.1, 17(1) (期刊论文)

(9) Guo, Danhuai^(#); **Zhou, Yuanchun**^(*); Zhu, Yingqiu; Li, Jianhui, [Species distribution modeling via spatial bagging of multiple conditional random fields](#)[✓], International Conference on Database Systems for Advanced Applications (DASFAA), Dallas, TX, 2016.4.16-2016.4.19 (会议论文)

(10) Xiao, Xiao^(#); Ge, Yong; Guo, Yunchang; Guo, Danhuai; Shen, Yi; **Zhou, Yuanchun**^(*); Li, Jianhui, [Automated detection for probable homologous foodborne disease outbreaks](#)[✓], The Pacific-Asia Conference on Knowledge Discovery and Data Mining, Ho Chi Minh City,, 2015.5.19-2015.5.22 (会议论文)

二、论著之外的代表性研究成果和学术奖励

(1) 黄瑞芳; **周园春**; 鞠永茂; 沈 坚; 张春华, 气象与大数据, 科学出版社, 2017.8.1 (学术专著)

(2) **周园春**(2/10), [大规模地理空间数据云服务关键技术与应用](#), 北京市政府, 科技进步, 省部二等奖, 2016.12.8
(黎建辉; **周园春**; 王学志; 林青慧; 杨风雷; 胡良霖; 张波; 沈志宏; 吴章生; 薛正华)
(科研奖励)

(3) **Yuanchun Zhou**^(*) (4/4), Mining Common Spatial-temporal Periodic Patterns of Animal Movement, 科研信息化国际著名会议 IEEE eScience, 科研信息化国际著名会议 IEEE eScience最佳学生论文奖, 其他, 2013.8.1
(Yuwei Wang; Ze Luo; Gang Qin; **Yuanchun Zhou**^(*)) (科研奖励)

(4) **Yuanchun Zhou**^(*) (9/9), Click-Through Prediction for Sponsored Search Advertising with Hybrid Models, 数据挖掘顶级会议KDD, KDD Cup 2012 Track



2的第三名, 其他, 2012. 8. 1

(Xingxing Wang; Shijie Lin; Dongying Kong; Liheng Xu; Qiang Yan; Siwei Lai;
Liang Wu; Guibo Zhu; **Yuanchun Zhou**^(*)) (科研奖励)

(5) 中国标准, 黎建辉; 胡良霖; 朱艳华; 王静; 王卫华; 尹海清; 王卷乐; **周园春**;
李冰; 张辉; 刘宇峰; 高瑜蔚; 柏永青; 姜雪; 马文静, 科学数据引用, GB/T 35294-2017
, 全国信息技术标准化技术委员会, 2017. 12. 29 (标准)

(6) 中国标准, 胡良霖; 黎建辉; 陈希; 王静; 李娜; 郭晓峰; 赵辉; 尹海清; **周园春**;
李冰; 于铁强; 蔡立志; 龙凯; 夏琦; 黄先芝; 崔云鹏; 陈曙东; 周力; 姜雪;
高瑞鑫; 王建华, 数据溯源描述模型, GB/T 34945-2017, 全国信息技术标准化技术委员会
, 2017. 11. 1 (标准)

(7) 杜一; 郭旦怀; 陈昕; **周园春**; 黎建辉, 一种基于WEB的多模型数据可视化开发方
法及平台[🔗], 2014. 12. 29, 中国, CN201410849397. 1 (专利)

(8) 孟珍; 黎建辉; **周园春**; 王学志, 一种基于大树构建子树的系统进化树重建方法[🔗]
, 2014. 12. 22, 中国, CN201410806842. 6 (专利)

(9) 郭旦怀; 杜一; 黎建辉; **周园春**, 一种基于空间场景草图描述的交互式空间场景
检索方法, 2013. 12. 12, 中国, CN201310682924. X (专利)

(10) 韦远科; 黎建辉; 冯凯; 杨垣; **周园春**; 赵红新; 甘宁, 一种云计算系统中的资
源统一调度方法[🔗], 2013. 10. 31, 中国, CN201310532750. 9 (专利)

(11) 王学志; **周园春**; 黎建辉; 林青慧, 一种基于互联网的遥感数据分析工具的封装
服务方法[🔗], 2013. 5. 16, 中国, CN201310182081. 7 (专利)

(12) 黎建辉; 沈庚; **周园春**; 王学志; 韦远科; 张洋, 一种基于分布式文件系统的海
量地学数据并行处理方法[🔗], 2013. 3. 11, 中国, ZL201310076895. 2 (专利)

(13) 黎建辉; 孟珍; **周园春**; 邵靖; 曹巍, 一种系统进化树的重建方法[🔗], 2013. 2. 7,
中国, CN201310049516. 0 (专利)

(14) 杨风雷^(#); 黎建辉; 崔建业; 李晓东; **周园春**; 归文胜; 汪海燕; 杨俊峰, 一种
网页信息相关地域的识别方法[🔗], 2012. 11. 29, 中国, CN201210500929. 1 (专利)

(15) 薛正华; 黎建辉; **周园春**; 沈庚; 张洋, 一种集群系统应用软件快速部署方法[🔗],
2011. 11. 30, 中国, CN201110391526. 3 (专利)

(16) 杨风雷; 黎建辉; 杨俊峰; 虞路清; **周园春**, 一种及时高效的互联网信息爬取方
法[🔗], 2011. 12. 20, 中国, CN201110430997. 0 (专利)

(17) 黎建辉; 杨风雷; 林青慧; 沈志宏; 胡良霖; **周园春**, 一种面向全球变化研究的
空间科学数据自动汇聚方法[🔗], 2011. 8. 2, 中国, CN201110220536. 0 (专利)



(18) 杨风雷; 林青慧; 黎建辉; 沈志宏; 胡良霖; 周园春, 面向全球变化研究的空间科学数据元数据自动汇聚方法, 2011.8.2, 中国, CN201110220537.5 (专利)

(19) 一种基于互联网的遥感数据分析工具的封装服务方法, 专利, 技术作价投资, 中科智慧水运科技创新(广州)有限公司, 60.0000万元, 2017.9.28 (成果技术转移)

(20) 一种针对SolrCloud的大数据SQL查询方法及系统, 专利, 技术作价投资, 中科智慧水运科技创新(广州)有限公司, 60.0000万元, 2017.9.28 (成果技术转移)

(21) 一种基于Memcached的大数据缓存交互式查询方法, 专利, 技术作价投资, 中科智慧水运科技创新(广州)有限公司, 60.0000万元, 2017.9.28 (成果技术转移)

NSFC 2018



除非特殊说明，请勿删除或改动简历模板中蓝色字体的标题及相应说明文字

参与者 简历

唐杰，清华大学，计算机科学技术系，特别研究员

教育经历（从大学本科开始，按时间倒序排序；请列出攻读研究生学位阶段导师姓名）：

2002/09 - 2006/07，清华大学，计算机系，博士，导师：王克宏

1999/09 - 2002/07，燕山大学，计算机系，硕士，导师：邓成玉

1995/09 - 1999/07，燕山大学，自动化系，学士，导师：王丽田

科研与学术工作经历（按时间倒序排序；如为在站博士后研究人员或曾进入博士后流动站（或工作站）从事研究，请列出合作导师姓名）：

2016/12 - 今，清华大学，计算机系，特别研究员，长聘副教授

2009/12 - 2016.12，清华大学，计算机系，副教授

2006/08 - 2009/12，清华大学，计算机系，讲师

2011/03 - 2011/08，康奈尔大学，计算机系，访问学者

2009/07 - 2009/08，伊利诺伊香槟分校，计算机系，访问学者

2008/05 - 2008/07，香港科技大学，计算机系，访问学者

曾使用其他证件信息（申请人应使用唯一身份证件申请项目，曾经使用其他身份证件作为申请人或主要参与者获得过项目资助的，应当在此列明）

无

主持或参加科研项目（课题）及人才计划项目情况（按时间倒序排序）：

1. 国家自然科学基金与英国皇家学会联合基金(牛顿高级学者基金)，社交网络群体行为分析，2015/03-2018/02，50万元+11.1万英镑，已结题，主持；

2. 国家863高技术研究发展计划，2014AA015103，基于行为心理动力学模型的群体行为分析与事件态势感知技术，2014/01-2016/12，632万元，已结题，主持；

3. 国家自然科学基金优秀青年基金，61222212，知识发现与知识工程，2013/01- 2015/12，100万元，已结题，主持；

4. 北京市科技新星人才计划，Z111101054511093，2011/12-2014/12，20万元，已结题，主持。



5. 国家自然科学基金面上项目, 61073073, 大规模 Web 社会网络的动态建模与分析, 2011/01-2013/12, 38万元, 已结题, 主持;

6. 国家863高技术研究发展计划, 2009AA01Z138, 基于概率图模型的异构XML数据集成与检索, 2009/01-2011/12, 80万元, 已结题, 主持。

代表性研究成果和学术奖励情况 (每项均按时间倒序排序)

(请注意: ①投稿阶段的论文不要列出; ②对期刊论文: 应按照论文发表时作者顺序列出全部作者姓名、论文题目、期刊名称、发表年代、卷(期)及起止页码(摘要论文请加以说明); ③对会议论文: 应按照论文发表时作者顺序列出全部作者姓名、论文题目、会议名称(或会议论文集名称及起止页码)、会议地址、会议时间; ④应在论文作者姓名后注明第一/通讯作者情况: 所有共同第一作者均加注上标“#”字样, 通讯作者及共同通讯作者均加注上标“*”字样, 唯一第一作者且非通讯作者无需加注; ⑤所有代表性研究成果和学术奖励中本人姓名加粗显示。)

按照以下顺序列出: ①10篇以内代表性论著; ②论著之外的代表性研究成果和学术奖励。

一、期刊论文

[1] Jing Zhang, **Jie Tang***, Cong Ma, Hanghang Tong, Yu Jing, Juanzi Li, Walter Luyten, and Marie-Francine Moens. Fast and Flexible Top-k Similarity Search on Large Networks. ACM Transactions on Information Systems (TOIS), 2017, Volume 36, Issue 2, Article No. 13. (CCF A类期刊)

[2] **Jie Tang***, Tiancheng Lou, Jon Kleinberg, and Sen Wu. Transfer Learning to Infer Social Ties across Heterogeneous Networks. ACM Transactions on Information Systems (TOIS), 2016, Volume 34, Issue 2, Article No. 7. (CCF A类期刊, 谷歌引用17次)

[3] Yizhou Sun, **Jie Tang**, Jiawei Han, Cheng Chen, and Manish Gupta. Co-Evolution of Multi-Typed Objects in Dynamic Star Networks. IEEE Transaction on Knowledge and Data Engineering (TKDE), 2014, Volume 26, Issue 12, Pages 2942-2955. (CCF A类期刊, 教师第一作者, SCI影响因子: 2.476)

[4] Hong Huang, **Jie Tang***, Lu Liu, JarDer Luo, and Xiaoming Fu*. Triadic Closure Pattern Analysis and Prediction in Social Networks. IEEE Transaction on



Knowledge and Data Engineering (TKDE), 2015, Volume 27, Issue 12, Pages 3374-3389. (CCF A类期刊, 教师第一作者, SCI影响因子: 2.476)

[6] Jing Zhang, Zhanpeng Fang, Wei Chen, and **Jie Tang***. Diffusion of "Following" Links in Microblogging Networks. IEEE Transaction on Knowledge and Data Engineering (TKDE), 2015, Volume 27, Issue 8, Pages 2093-2106. (CCF A类期刊, SCI影响因子: 2.476)

二、会议论文

[1] **Jie Tang*** and Wendy Hall. Cross-domain Ranking via Latent Space Learning. In Proceedings of the 31st AAAI Conference on Artificial Intelligence (AAAI'17), pages 2618-2624.

[2] **Jie Tang***, Sen Wu, and Jimeng Sun. Confluence: Conformity Influence in Large Social Networks. In Proceedings of KDD'13, pages 347-355. (CCF A类国际会议, SCI他引10次, 谷歌引用90次)

[3] Jing Zhang, **Jie Tang***, Cong Ma, Hanghang Tong, Yu Jing, and Juanzi Li. Panther: Fast Top-k Similarity Search on Large Networks. In Proceedings of KDD'15, pages 1445-1454. (CCF A类国际会议)

[4] Yutao Zhang, **Jie Tang***, Zhilin Yang, Jian Pei, and Philip Yu. COSNET: Connecting Heterogeneous Social Networks with Local and Global Consistency. In Proceedings of KDD'15, pages 1485-1494. (CCF A类国际会议)

[5] **Jie Tang***, Zhanpeng Fang, and Jimeng Sun. Incorporating Social Context and Domain Knowledge for Entity Recognition. In Proceedings of WWW'15, pages 517-526. (CCF A类国际会议)

三、专著

[1] **Jie Tang*** and Juanzi Li. Semantic Mining of Social Networks. Morgan & Claypool Publishers, 2015. 205 pages.

四、授权发明专利

[1] 李涓子, 樊绮娜, 李军, **唐杰**, 张鹏, 许斌, 一种基于词频和多元文法的新闻关键词抽取方法, 2007.11.9, 中国, 200710177074.2

[2] 李涓子, 常诚, 张阔, 李军, 张鹏, **唐杰**, 许斌, 基于元数据分析的新闻事件检测方法, 2007.12.4, 中国, 200710178687.8

[3] **唐杰**, 张静, 李涓子, 基于专家值传播算法的社会网络专家信息处理系



统及方法, 2007.6.22, 中国, 200710117719.3

[4] 唐杰, 李涓子, 在大规模社会网络中基于路径评分的个人关系发现方法, 2007.11.9, 中国, 200710177066.8

[5] 唐杰, 杨子, 一种文档的检索方法和装置, 2009.11.24, 中国, 200910238289.X

[6] 唐杰, 唐文斌, 基于约束优化的专家匹配方法及系统2010.11.19 中国, 201010554304.4

[7] 唐杰, 张宁, 基于统一概率模型的个性化用户标签建模与推荐方法, 2010.11.16, 中国, 201010546780.1

[8] 李涓子, 张啸, 王志春, 侯磊, 李虎, 唐杰, 基于用户定制的本体匹配系统及方法, 2011.7.27, 中国, CN201110064824.1

[9] 李涓子, 王志春, 赵越, 张啸, 侯磊, 唐杰, 一种多策略组合的本体或实例匹配方法, 2012.1.4, 中国, CN201110247261.X

五、会议特邀学术报告

Jie Tang, AMiner: Mining Deep Knowledge from Scientific Networks. February 2016, WSDM'16

六、获得学术奖励

[1] 唐杰 (1/9), 科技情报大数据挖掘及服务平台, 北京市人民政府, 北京市科学技术奖, 一等奖, 2017年

(唐杰, 李涓子, 张阔, 张静, 许斌, 刘德兵, 茹立云, 张宇韬)

[2] 唐杰 (1/14), 研究者社会网络搜索与挖掘系统ArnetMiner, 中国人工智能学会, 吴文俊人工智能科学技术进步奖, 一等奖, 2013年

(唐杰, 李涓子, 陈桂生, 高博, 张静, 万怀宇, 刘德兵, 鄢兴雨, 许斌, 刘玉超, 张宇韬, 杨洋, 宫继兵, 王健飞)



除非特殊说明，请勿删除或改动简历模板中蓝色字体的标题及相应说明文字

参与者 简历

朱勇，百度公司，人工智能技术委员会主席/知识图谱部主任架构师

教育经历（从大学本科开始，按时间倒序排序；请列出攻读研究生学位阶段导师姓名）：

2000/08-2006/12, 美国佐治亚理工学院计算机系, 博士, 导师: Mostafa Ammar

1997/09-2000/07, 中科院自动化所, 硕士, 导师: 谭铁牛

1992/09-1997/07, 中国科技大学自动化系, 学士

科研与学术工作经历（按时间倒序排序；如为在站博士后研究人员或曾进入博士后流动站（或工作站）从事研究，请列出合作导师姓名）：

2014/04-至今, 百度, 主任架构师

2010/05-2014/04, Google（美国）, 高级软件工程师

2006/09-2010/05, Amazon（美国）, 软件工程师

曾使用其他证件信息（申请人应使用唯一身份证件申请项目，曾经使用其他身份证件作为申请人或主要参与者获得过项目资助的，应当在此列明）

无

主持或参加科研项目（课题）及人才计划项目情况（按时间倒序排序）：

无

代表性研究成果和学术奖励情况（每项均按时间倒序排序）

（请注意：①投稿阶段的论文不要列出；②对期刊论文：应按照论文发表时作者顺序列出全部作者姓名、论文题目、期刊名称、发表年代、卷（期）及起止页码（摘要论文请加以说明）；③对会议论文：应按照论文发表时作者顺序列出全部作者姓名、论文题目、会议名称（或会议论文集名称及起止页码）、会议地址、会议时间；④应在论文作者姓名后注明第一/通讯作者情况：所有共同第一作者均加注上标“#”字样，通讯作者及共同通讯作者均加注上标“*”字样，唯一第一作者且非通讯作者无需加注；⑤所有代表性研究成果和学术奖励中本人姓名加粗显示。）

按照以下顺序列出：①10篇以内代表性论著；②论著之外的代表性研究成果和学术奖励。



一、期刊论文

[1] **Y. Zhu**, C. Dovrolis and M. Ammar, Dynamic Overlay Routing Based on Available Bandwidth Estimation: A Simulation Study, Computer Networks, 2006, Volume 50, Issue 6, Pages 742-762

[2] **Y. Zhu**, T. Tan and Y. Wang, Font Recognition Based on Global Texture Analysis, IEEE Transaction on Pattern Analysis and Machine Intelligence (TPAMI), 2001, Vol.23, No.10, Pages 1192-1200

二、会议论文

[1] **Y. Zhu**, C. Dovrolis and M. Ammar, How to be a better ISP without owning a network, IEEE INFOCOM 2007

[2] **Y. Zhu** and M. Ammar, Algorithms for Assigning Substrate Network Resources to Virtual Network Components, IEEE INFOCOM 2006

[3] **Y. Zhu**, A. Jukan, M. Ammar and W. Alanqar, End-to-End Service Provisioning in Multi-granularity Multi-domain Optical Networks, IEEE International Conference on Communications (ICC), 2004

[4] **Y. Zhu**, A. Jukan and M. Ammar, Multi-Segment Wavelength Routing in Large-Scale Optical Networks, IEEE International Conference on Communications (ICC), 2003

[5] **Y. Zhu**, Y. Wang, and T. Tan, Biometric Personal Identification Based on Iris Pattern, ICPR 2000

[6] **Y. Zhu**, Y. Wang, and T. Tan, Biometric Personal Identification Based on Handwriting, 15th International Conference on Pattern Recognition (ICPR), 2000.

[7] **Y. Zhu**, Y. Wang, and T. Tan, Font Recognition Base on Global Texture Analysis, Proc. 5th International Conference on Document Analysis and Recognition (ICDAR), 1999

三、授权发明专利

[1] 谭铁牛、**朱勇**，基于纹理分析的字体和笔迹识别方法，2013.11.19，中国，ZL 99105851.8

[2] 谭铁牛、**朱勇**、王蕴红，基于虹膜识别的身份鉴定方法与装置，2014.03.31，中国，ZL99110825.6

四、获得学术奖励

[1] **朱勇** (6/6)，虹膜图像获取与识别技术，国家科技部，国家技术发明奖，二等奖，2005

(谭铁牛，王蕴红、马力、孙哲南、崔家礼、**朱勇**)



[2] **朱勇** (8/15), 知识图谱技术及应用, 中国电子学会, 科技进步奖, 一等奖, 2017

(王海峰, 李莹, 吴甜, 黄际洲, 吴华, 赵世奇, 牛正雨, **朱勇**, 陆超, 刘占一, 吴海锋, 梁海金, 宋勋超, 王浩, 吕雅娟)

NSFC 2018



除非特殊说明，请勿删除或改动简历模板中蓝色字体的标题及相应说明文字

参与者 简历

沈志宏，中国科学院计算机网络信息中心，大数据部，研究员

教育经历（从大学本科开始，按时间倒序排序；请列出攻读研究生学位阶段导师姓名）：

2009/09-2013/01,中国科学院大学，数字图书馆，博士，导师：张晓林

1998/09-2001/06,江苏大学，机械制造及其自动化，硕士，导师：蔡兰

1994/09-1998/06，扬州大学，机械制造及其自动化，学士

科研与学术工作经历（按时间倒序排序；如为在站博士后研究人员或曾进入博士后流动站（或工作站）从事研究，请列出合作导师姓名）：

2001/7-至今，中国科学院计算机网络信息中心，科学数据中心

曾使用其他证件信息（申请人应使用唯一身份证件申请项目，曾经使用其他身份证件作为申请人或主要参与者获得过项目资助的，应当在此列明）

无

主持或参加科研项目（课题）及人才计划项目情况（按时间倒序排序）：

1. 中科院十三五信息化专项，“科学大数据工程”课题“科学大数据管理与分析平台建设”，630万，在研，负责人

2. 国家重点研发计划，“科学大数据管理系统”，2016/07-2019/06，3235万元，在研，参与（课题负责人）

3. 中科院十二五信息化专项，“科技数据资源整合与共享工程”子课题“科学数据管理与共享云服务平台”，2012/01-2015/12，400万元，结题，子课题负责人

代表性研究成果和学术奖励情况（每项均按时间倒序排序）

（请注意：①投稿阶段的论文不要列出；②对期刊论文：应按照论文发表时作者顺序列出全部作者姓名、论文题目、期刊名称、发表年代、卷（期）及起止页码（摘要论文请加以说明）；③对会议论文：应按照论文发表时作者顺序列出全部作者姓名、论文题目、会议名称(或会议论文集名称及起止页码)、会议地址、会议时间；④应在论文作者姓名后注明第一/通讯作者情况：所有共同第一作者均加注上标“#”字样，通讯作者及共同通讯作者均加注上标“*”字样，唯



一第一作者且非通讯作者无需加注；⑤所有代表性研究成果和学术奖励中本人姓名加粗显示。)

按照以下顺序列出：①10篇以内代表性论著；②论著之外的代表性研究成果和学术奖励。

一、期刊论文

- [1] 黎建辉, **沈志宏**, 孟小峰.科学大数据管理: 概念、技术与系统.计算机研究与发展. 2017(2)
- [2] **沈志宏**, 黎建辉, 张晓林.面向LOD的关联发现过程的定位、目标与复杂性分析. 中国图书馆学报. 2013(6)
- [3] **沈志宏**, 黎建辉, 张晓林.关联数据互联技术研究综述:应用、方法与框架.图书情报工作. 2013(14)
- [4] **沈志宏**, 刘筱敏, 郭学兵等.关联数据发布流程与关键问题研究——以科技文献、科学数据的发布为例.中国图书馆学报. 2013(2)
- [5] **沈志宏**, 张晓林, 黎建辉.OpenCSDB: 关联数据在科学数据库中的应用研究.中国图书馆学报, 2012(5)
- [6] **沈志宏**, 张晓林.语义网环境下数据溯源描述模型研究综述.现代图书情报技术. 2011(4)
- [7] **沈志宏**, 张晓林.关联数据及其应用现状综述. 现代图书情报技术. 2010(1)

二、会议论文

- [1] Liang Li, **Zhihong Shen**, Jianhui Li, Dongjiang Liu, Huajin Wang, Lipeng Wang, Qinglan Sun: A Resilient Index Graph for Querying Large Biological Scientific Data. BigData Congress 2017: 435-443
- [2] Wenjuan Cui, Yi Du, **Zhihong Shen**, Yuanchun Zhou, Jianhui Li. Personalized microblog recommendation using sentimental features. 2017 IEEE International Conference on Big Data and Smart Computing (BigComp)
- [3] Shaopeng He, Jianhui Li, **Zhihong Shen**. F2R: Publishing file systems as Linked Data. 2013 10th International Conference on Fuzzy Systems and Knowledge Discovery (FSKD)
- [4] Jianhui Li, Yuanchun Zhou, Wei Shang, Cungen Cao, **Zhihong Shen**, Fenglei Yang, Xiao Xiao, Danhuai Guo A cloud Computation Architecture for Unconventional Emergency Management.. WAIM2013
- [5] **Zhihong Shen**, Yanfei Hou, Jianhui Li. Voovle: A linked data search engine for scientific data. FSKD2012.
- [6] **Zhihong Shen**, Yufang Hou, Jianhui Li Publishing distributed files as Linked



Data.FSKD2011.

三、获得学术奖励

[1] 沈志宏(8/10),大规模地理空间数据云服务关键技术与应用,北京市政府,北京科学技术二等奖,2016年

(黎建辉,周园春,王学志,林青慧,杨风雷,胡良霖,张波,沈志宏,吴章生,薛正华)

[2] 2013年度中国科学院院长优秀奖

NSFC 2018



除非特殊说明，请勿删除或改动简历模板中蓝色字体的标题及相应说明文字

参与者 简历

杜一，中国科学院计算机网络信息中心，大数据部，副研究员

教育经历（从大学本科开始，按时间倒序排序；请列出攻读研究生学位阶段导师姓名）：

2008/9月-2013/7，中国科学院软件研究所，人机交互北京市重点实验室，博士，导师：戴国忠研究员

2004/9月-2008/7，山东大学，计算机学院，学士

科研与学术工作经历（按时间倒序排序；如为在站博士后研究人员或曾进入博士后流动站（或工作站）从事研究，请列出合作导师姓名）：

2015/12-至今，中国科学院计算机网络信息中心，副研究员

2013/7-2015/12，中国科学院计算机网络信息中心，助理研究员

曾使用其他证件信息（申请人应使用唯一身份证件申请项目，曾经使用其他身份证件作为申请人或主要参与者获得过项目资助的，应当在此列明）

无

主持或参加科研项目（课题）及人才计划项目情况（按时间倒序排序）：

1. 国家重点研发计划，2017YFC1601504，基于多源数据的食源性疾病实时预警技术体系研究，2018/01-2021/12，2065万元，在研，参加（课题负责人）

2. 国家自然科学基金青年项目，61402435，模型驱动的大规模时空数据可视化开发方法研究，2015/01-2017/12，26万元，结题，主持

3. 国家自然科学基金面上项目，61273269，图文混合笔输入文档分析与识别的理论与方法研究，2013/01-2016/12，81万元，结题，参与

4. 国家自然科学基金青年项目，61303162，基于真实隐喻的儿童交互式学习环境研究，2014/01-2016/12，25万元，结题，参与

代表性研究成果和学术奖励情况（每项均按时间倒序排序）

（请注意：①投稿阶段的论文不要列出；②对期刊论文：应按照论文发表时作者顺序列出全部作者姓名、论文题目、期刊名称、发表年代、卷（期）及起止页码（摘要论文请加以说明）；③对会议论文：应按照论文发表时作者顺序列出全部作者姓名、论文题目、会议名称（或会议论文集名称及起止页码）、会议地址、会议时间；④应在论文作者姓名后注明第一/通讯作者情况：所有共同第一作者均



加注上标“#”字样，通讯作者及共同通讯作者均加注上标“*”字样，唯一第一作者且非通讯作者无需加注；⑤所有代表性研究成果和学术奖励中本人姓名加粗显示。）

按照以下顺序列出：①10篇以内代表性论著；②论著之外的代表性研究成果和学术奖励。

一、期刊论文

[1] 杜一，田丰，戴国忠，E-UIDL用户界面描述语言下的开发方法，软件学报，26(7)，pp. 1772-1784，2015.

[2] 杜一，郭旦怀，周园春，黎建辉，一种大规模时空数据处理与可视化框架，计算机研究与发展，51(s2)，pp. 10-17，2015.

[3] 任磊，魏永长，杜一，戴国忠，面向小界面大数据可视化的语义Focus+Context人机交互技术，计算机学报，2015. 38(12)，p. 2488-2498

[4] 任磊，杜一，马帅，张小龙，大数据可视分析综述，软件学报，2015. 25(19)，p. 1909-1936

[5] 杜一，田丰，马翠霞，戴国忠，王宏安，基于多尺度描述方法的移动用户界面生成框架，计算机学报，36(11):p.2179-2190.2013

[6] 杜一，任磊，DaisyVA:支持信息多面体可视分析的智能交互式可视化平台，计算机辅助设计与图形学学报，25(8): p. 1-6. 2013

[7] 杜一，邓昌智，田丰，任磊，戴国忠，一种可扩展的用户界面描述语言，软件学报，2013. 24(5): p. 1127-1142

[8] 杜一，田丰，王锋，戴国忠，王宏安，一种移动环境下的用户模型. 软件学报，2011. 22(Supp2): p. 120-128

[9] Yi Du, Cuixia Ma, Dongxing Teng, Guozhong Dai. CONCEPT-SKETCH: A Tool for Cooperative Visual Analytics. International Journal of Advanced Intelligence (IJAI), 2011. 3(1): p. 95-113

[10] 滕东兴，杜一，马翠霞，王宏安，戴国忠，虚拟教学环境中基于草图的自适应用户界面研究. 软件学报，2009. 20(zk): p. 298-305

二、会议论文

[1] Danhuai Guo, Yi Du, A Visualization Platform for Spatio-Temporal Data: a Data Intensive Computation Framework, in the 23rd International conference on Geoinformatics 2015, Wuhan, China, 2015.

[2] Lei Ren, Jin Cui, Yi Du, Guozhong Dai, Multilevel Interaction Model For Hierarchical Tasks In Information Visualization, in The 6th International Symposium on Visual Information Communication and Interaction (VINCI 2013) Tianjin, China,



2013, pp. 11-16.

[3] Yingying Jiang, Feng Tian, Guang Li, Xiaolong (Luke) Zhang, **Yi Du**, Guozhong Dai, Hongan Wang, Speechtouch: Precise Cursor Positioning on Touch Screen Mobiles, 15th International Conference on Human-Computer Interaction with Mobile Devices and Services (MobileHCI 2013), 2013, Munich, 2013

[4] **杜一**, 吕菲, 田丰, 马翠霞, 侯文君, 戴国忠, 一种支持超视频创建与可视呈现的草图界面技术, 第八届全国和谐人机环境联合学术大会(HHME2012), 2012, pp:87-92, 广州, 2012

[5] **杜一**, 田丰, 马翠霞, 戴国忠, 王宏安, 基于多尺度描述方法的移动用户界面生成框架, 中国计算机大会(CNCC2012), 2012, 大连, 2012

[6] **杜一**, 田丰, 戴国忠, 王宏安, Uniform Mobile User Model :一种移动环境下的用户模型, 第七届和谐人机环境联合学术会议(HHME2011), 2011, pp: 5-10, 北京, 2011

[7] **Yi Du**, Cuixia Ma, Dongxing Teng, Guozhong Dai, Cooperative Concept Map Based on Cognitive Model for Visual Analysis, 2011. The 3rd Visual Information Communication - International Symposium (VINCI 2010), 2010, pp:76-83, Beijing, 2010

三、授权发明专利

[1] **杜一**, 郭旦怀, 周园春, 黎建辉, 一种基于WEB的多模型数据可视化开发方法及平台, 2014.10.01, 中国, 2014108493971

[2] 郭旦怀, **杜一**, 周园春, 黎建辉, 一种基于访问热度的时空数据服务调度方法, 2014.10.1, 中国, 2014108485284

[3] 郭旦怀, **杜一**, 周园春, 黎建辉, 一种交互式空间场景检索方法, 2013.10.01, 中国, 201310682924X



除非特殊说明，请勿删除或改动简历模板中蓝色字体的标题及相应说明文字

参与者 简历

刘德兵，清华大学，计算机系，高级工程师

教育经历（从大学本科开始，按时间倒序排序；请列出攻读研究生学位阶段导师姓名）：

1999/09 – 2007/06，中国科学院计算技术研究所，JDL联合实验室，硕博连读，导师：高文

1995/09 – 1999/07，北京交通大学，计算机系，本科，导师：张义水

科研与学术工作经历（按时间倒序排序；如为在站博士后研究人员或曾进入博士后流动站（或工作站）从事研究，请列出合作导师姓名）：

2013/04 – 至今，清华大学，计算机系，高级工程师

2010/09 – 2013/04，特艺（中国）科技有限公司，北京研究院，高级研究员

2007/09 – 2009/09，特艺（中国）科技有限公司与北京邮电大学联合培养博士后，导师：马华东

2007/07 – 2010/08，特艺（中国）科技有限公司，北京研究院，研究员

曾使用其他证件信息（申请人应使用唯一身份证件申请项目，曾经使用其他身份证件作为申请人或主要参与者获得过项目资助的，应当在此列明）

无

主持或参加科研项目（课题）及人才计划项目情况（按时间倒序排序）：

1. 中国工程院知识中心项目，学术活动专业知识服务系统，2017/1-2017/12，300万元，在研，参与；

2. 国家863高技术研究发展计划，基于用户意图理解的POI多属性综合排序技术研究，2015AA124102，2015/04-2017/10，10万元，在研，子课题负责人。

3. 国家863高技术研究发展计划，基于行为心理动力学模型的群体行为分析与事件态势感知技术，2014AA015103，2014/01-2016/12，432万元，在研，参与。

代表性研究成果和学术奖励情况（每项均按时间倒序排序）

（请注意：①投稿阶段的论文不要列出；②对期刊论文：应按照论文发表时作者顺序列出全部作者姓名、论文题目、期刊名称、发表年代、卷（期）及起止页码



(摘要论文请加以说明)；③对会议论文：应按照论文发表时作者顺序列出全部作者姓名、论文题目、会议名称(或会议论文集名称及起止页码)、会议地址、会议时间；④应在论文作者姓名后注明第一/通讯作者情况：所有共同第一作者均加注上标“#”字样，通讯作者及共同通讯作者均加注上标“*”字样，唯一第一作者且非通讯作者无需加注；⑤所有代表性研究成果和学术奖励中本人姓名加粗显示。)

按照以下顺序列出：①10篇以内代表性论著；②论著之外的代表性研究成果和学术奖励。

一、期刊论文

[1] Gu, Xiaodong, Guoping Qiu, Xu Feng, **Debing Liu**, and Zhibo Chen. Region of interest weighted pooling strategy for video quality metric. Telecommunication Systems, 2012, 49 (1):63-73.

二、会议论文

[1] Jingyuan Liu, **Debing Liu**, Xingyu Yan, Li Dong, Ting Zeng, Yutao Zhang, and Jie Tang. AMiner-mini: A People Search Engine for University. CIKM, pp. 2069-2071, 2014.

[2] Yang, Yang, Jianfei Wang, Yutao Zhang, Wei Chen, Jing Zhang, Honglei Zhuang, Zhilin Yang, Bo Ma, Zhanpeng Fang, Sen Wu, Xiaoxiao Li, **Debing Liu**, and Jie Tang. "SAE: social analytic engine for large networks." ACM Knowledge Discovery and Data Mining (2013): 1502-1505.

三、获得学术奖励

[1] **刘德兵** (6/9)，科技情报大数据挖掘及服务平台，北京市人民政府，北京市科学技术奖，一等奖，2017年

(唐杰，李涓子，张阔，张静，许斌，**刘德兵**，茹立云，张宇韬)

[2] **刘德兵** (7/14)，研究者社会网络搜索与挖掘系统ArnetMiner，中国人工智能学会，吴文俊人工智能科学技术进步奖，一等奖，2013年

(唐杰，李涓子，陈桂生，高博，张静，万怀宇，**刘德兵**，鄢兴雨，许斌，刘玉超，张宇韬，杨洋，宫继兵，王健飞)



除非特殊说明，请勿删除或改动简历模板中蓝色字体的标题及相应说明文字

参与者 简历

祝恒书，百度公司，百度研究院，研究员

教育经历（从大学本科开始，按时间倒序排序；请列出攻读研究生学位阶段导师姓名）：

2009/09-2014/11，中国科学技术大学，计算机学院，博士（硕博连读），
导师：陈恩红

2005/09-2009/07，中国科学技术大学，计算机学院，学士学位

科研与学术工作经历（按时间倒序排序；如为在站博士后研究人员或曾进入博士后流动站（或工作站）从事研究，请列出合作导师姓名）：

2014/12-至今，百度，百度研究院，研究员

2012/08-2013/09，美国罗格斯大学，商学院，访问博士生

2010/07-2012/07，诺基亚，诺基亚研究中心，访问博士生

曾使用其他证件信息（申请人应使用唯一身份证件申请项目，曾经使用其他身份证件作为申请人或主要参与者获得过项目资助的，应当在此列明）

无

主持或参加科研项目（课题）及人才计划项目情况（按时间倒序排序）：

无

代表性研究成果和学术奖励情况（每项均按时间倒序排序）

（请注意：①投稿阶段的论文不要列出；②对期刊论文：应按照论文发表时作者顺序列出全部作者姓名、论文题目、期刊名称、发表年代、卷（期）及起止页码（摘要论文请加以说明）；③对会议论文：应按照论文发表时作者顺序列出全部作者姓名、论文题目、会议名称(或会议论文集名称及起止页码)、会议地址、会议时间；④应在论文作者姓名后注明第一/通讯作者情况：所有共同第一作者均加注上标“#”字样，通讯作者及共同通讯作者均加注上标“*”字样，唯一第一作者且非通讯作者无需加注；⑤所有代表性研究成果和学术奖励中本人



姓名加粗显示。)

按照以下顺序列出：①10篇以内代表性论著；②论著之外的代表性研究成果和学术奖励。

一、期刊论文

[1] **Hengshu Zhu**, Hui Xiong, Yong Ge, and Enhong Chen, Discovery of Ranking Fraud for Mobile Apps, IEEE Transactions on Knowledge and Data Engineering (IEEE TKDE), 27(1):74-87, 2015.

[2] **Hengshu Zhu**, Chuanren Liu, Yong Ge, Hui Xiong, Enhong Chen, Popularity Modeling for Mobile Apps: A Sequential Approach, IEEE Transactions on Cybernetics (IEEE TC), 45(7): 1303-1314, 2015.

[3] **Hengshu Zhu**, Enhong Chen, Hui Xiong, Huanhuan Cao, Jiilei Tian, Mobile App Classification with Enriched Contextual Information, IEEE Transactions on Mobile Computing (IEEE TMC) 13(7): 1550-1563, 2014.

[4] **Hengshu Zhu**, Enhong Chen, Hui Xiong, Kuifei Yu, Huanhuan Cao, Jilei Tian, Mining Mobile User Preferences for Personalized Context-Aware Recommendation, ACM Transactions on Intelligent Systems and Technology (ACM TIST), 5(4):58, 2014.

二、会议论文

[1] Tong Xu, **Hengshu Zhu***, Chen Zhu, Pan Li, and Hui Xiong, Measuring the Popularity of Job Skills in Recruitment Market: A Multi-Criteria Approach, In Proceedings of the Thirty-Second AAAI Conference on Artificial Intelligence (AAAI'18), New Orleans, LA, USA, 2018

[2] Huayu Li, Yong Ge, **Hengshu Zhu***, Hui Xiong, Hongke Zhao, Prospecting the Career Development of Talents: A Survival Analysis Perspective, In Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD-2017), Page 917-925, Halifax, Nova Scotia, Canada, 2017.

[3] Hao Lin, **Hengshu Zhu***, Yuan Zuo, Chen Zhu, Hui Xiong, Junjie Wu, Collaborative Company Profiling: Insights from an Employee's Perspective, In Proceedings of the 31st AAAI Conference on Artificial Intelligence (AAAI-2017), Page 1417-1423, San Francisco, CA, USA, 2017



[4] **Hengshu Zhu***, Hui Xiong, Fangshuang Tang, Qi Liu, Yong Ge, Enhong Chen, Yanjie Fu, Days on Market: Measuring the Liquidity of Real Estate Markets, In Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD-2016) , San Francisco, CA, USA, 2016.

[5] Qing Wang, **Hengshu Zhu***, Wei Hu, Zhiyong Shen, Yuan Yao, Discerning Tactical Patterns for Professional Soccer Teams: An Enhanced Topic Model with Applications, In Proceedings of the 21st ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD-2015), Sydney, Australia, August 10-13, 2015.

[6] **Hengshu Zhu**, Hui Xiong, Yong Ge, Enhong Chen, Mobile App Recommendations with Security and Privacy Awareness, The 20th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD-2014) :951-960, New York, NY, USA, August 24-27, 2014.

三、授权发明专利

[1] 朱琛, 祝恒书, 熊辉, 丁鹏亮, 招聘信息的处理方法及装置, 2016.02.03, 中国, CN105303333A

[2] 吴海山, 祝恒书, 沈志勇, 用于人群风险预警的方法及装置, 2015.11.25, 中国, CN105095991A

[3] 王擎, 祝恒书, 胡伟, 沈志勇, 体育运动的战术识别方法和装置, 2015.07.15, 中国, CN104778373A

[4] 祝恒书, 吴海山, 沈志勇, 用户相似度确定方法和装置, 2015.07.08, 中国, CN104765873A

[5] 祝恒书, 沈志勇, 基于建筑物价值评估的计算方法和装置, 2015.07.01, 中国, CN104751007A

四、会议特邀学术报告

[1] 祝恒书, 数据智能:基于机器学习的大数据分析实践, 中国防震减灾优秀人才百人计划学术论坛, 北京, 2017年12月

[2] 祝恒书, 数据智能:基于机器学习的大数据智能分析实践, 地球科学大数据与人工智能学术研讨会, 北京, 2017年11月



[3] 祝恒书, AI + BI: 大数据人工智能驱动的企业市场洞察实践, 第三届全国大学生创业家成长计划夏令营, 合肥, 2017年7月

[4] 祝恒书, 面向商务智能的大数据分析实践, 百度高校技术汇, 合肥, 2016年6月

[5] 祝恒书, 普适商务环境下的大数据分析, 第九届中国R语言会议, 北京, 2016年5月

五、获得学术奖励

[1] 祝恒书, 面向移动商务的数据挖掘方法及应用研究, 中国科学院优秀博士学位论文奖, 中国科学院, 2016

[2] 祝恒书, 面向移动商务的数据挖掘方法及应用研究, 中国人工智能协会优秀博士学位论文奖, 中国人工智能协会, 2016

[3] 祝恒书, 中国科学院院长特别奖, 中国科学院, 2014

[4] 怀宝兴, 宝腾飞, 祝恒书, 刘淇, 一种基于概率主题模型的命名实体链接方法, 2014年度中国数据挖掘年会, 最佳学生论文奖

[5] Xue Bai, Yun Xiong, Yangyong Zhu, **Hengshu Zhu**, Time Series Representation: A Random Shifting Perspective. WAIM 2013, Best Student Paper Award (2013年度国际网络时代信息管理大会, 最佳学生论文奖)

[6] **Hengshu Zhu**, Enhong Chen, Huanhuan Cao, Finding Experts in Tag based Knowledge Sharing Communities. KSEM 2011, Best Student Paper Award (2011年度国际知识科学与工程与管理大会, 最佳学生论文奖)



除非特殊说明，请勿删除或改动简历模板中蓝色字体的标题及相应说明文字

参与者 简历

吴章生，中国科学院计算机网络信息中心，大数据部，工程师

教育经历（从大学本科开始，按时间倒序排序；请列出攻读研究生学位阶段导师姓名）：

2017/09-至今，中国科学院大学，中国科学院计算机网络信息中心，在读博士，导师：周园春

2010/09-2013/06，成都理工大学，地球科学学院，硕士，导师：简季

2000/09-2004/06，东华理工学院，测量系，学士，导师：邹时林

科研与学术工作经历（按时间倒序排序；如为在站博士后研究人员或曾进入博士后流动站（或工作站）从事研究，请列出合作导师姓名）：

1. 2013/07-至今，中国科学院计算机网络信息中心，工程师

曾使用其他证件信息（申请人应使用唯一身份证件申请项目，曾经使用其他身份证件作为申请人或主要参与者获得过项目资助的，应当在此列明）

无

主持或参加科研项目（课题）及人才计划项目情况（按时间倒序排序）：

1. 国家重点研发计划，2016YFB1000600，科学大数据管理系统，2016/07-2019/06，3235万元，在研，参与

代表性研究成果和学术奖励情况（每项均按时间倒序排序）

（请注意：①投稿阶段的论文不要列出；②对期刊论文：应按照论文发表时作者顺序列出全部作者姓名、论文题目、期刊名称、发表年代、卷（期）及起止页码（摘要论文请加以说明）；③对会议论文：应按照论文发表时作者顺序列出全部作者姓名、论文题目、会议名称（或会议论文集名称及起止页码）、会议地址、会议时间；④应在论文作者姓名后注明第一/通讯作者情况：所有共同第一作者均加注上标“#”字样，通讯作者及共同通讯作者均加注上标“*”字样，唯一第一作者且非通讯作者无需加注；⑤所有代表性研究成果和学术奖励中本人姓名加粗显示。）

按照以下顺序列出：①10篇以内代表性论著；②论著之外的代表



性研究成果和学术奖励。

一、期刊论文

[1] 杜园园,吴章生,朱小杰.基于大数据的航道采集系统的架构设计[J].科研信息化技术与应用,2016,7(06):69-78.

[2] 黎建辉,周园春,胡良霖,刘峰,朱艳华,沈志宏,吴章生,张杨.中国科学院科学数据云建设与服务[J].大数据,2016,2(06):3-13.

[3] 黎建辉,虞路清,张波,刘峰,吴章生.科技云探索科研服务新模式[J].中国教育网络,2015(08):37-39.

二、获得学术奖励

吴章生(9/10),大规模地理空间数据云服务关键技术与应用,北京市人民政府,北京市科学技术奖,二等奖,2016

(黎建辉,周园春,王学志,林青慧,杨风雷,胡良霖,张波,沈志宏,吴章生,薛正华)



附件信息

序号	附件名称	备注	附件类型
1	Spoiling Trip Purposes from Taxi Trajectories	发表在著名期刊ACM Transactions on Intelligent Systems and Technology (ACM TIST)上	代表性论著
2	A Matrix Factorization Based Flight Destination Re	被著名期刊Information Sciences接收	代表性论著
3	An efficient data processing framework for mining	发表在SCI期刊CEUS2017上	代表性论著
4	An algorithm for event detection based on social m	发表在SCI期刊Neruccomputing2017上	代表性论著
5	科学数据众包处理研究	发表国内一起学报计算机研究与发展2017上	代表性论著
6	Heterogeneous Metric Learning with Content-based	发表在CCF B类会议ICDM2014上	代表性论著
7	Bird Flu Outbreak Prediction	发表在IEEE Intelligent Systems2014上	代表性论著
8	北京市科学技术一等奖	科技情报大数据挖掘及服务平台	科技奖励
9	中国电子学会一等奖	知识图谱技术及应用	科技奖励
10	北京市科学技术二等奖	大规模地理空间数据云服务关键技术与应用	科技奖励
11	中科院特聘研究员（周园春）	入选2017年中国科学院特聘研究员（骨干人才）计划	其他
12	客座研究员（熊辉）	中科院计算机网络信息中心聘熊辉教授客座研究员证明	其他
13	中科院海外评审专家（熊辉）	中国科学院海外评审专家评审	其他
14	中标通知书	国家自然科学基金大数据知识管理平台中标通知书	其他
15	国家标准-科学数据引用	国家推荐标准-科学数据引用	其他
16	国家标准-数据溯源描述模型	国家推荐标准-数据溯源描述模型	其他

**签字和盖章页(此页自动生成, 打印后签字盖章)**

接收编号: 6183000348

申请人: 周园春

依托单位: 中国科学院计算机网络信息中心

项目名称: 面向领域大数据的知识图谱构建

资助类别: 重点项目

亚类说明:

附注说明: 面向领域大数据的知识图谱构建

申请人承诺:

我保证申请书内容的真实性。如果获得资助, 我将履行项目负责人职责, 严格遵守国家自然科学基金委员会的有关规定, 切实保证研究工作时间, 认真开展工作, 按时报送有关材料。若填报失实和违反规定, 本人将承担全部责任。

签字:

项目组主要成员承诺:

我保证有关申报内容的真实性。如果获得资助, 我将严格遵守国家自然科学基金委员会的有关规定, 切实保证研究工作时间, 加强合作、信息资源共享, 认真开展工作, 及时向项目负责人报送有关材料。若个人信息失实、执行项目中违反规定, 本人将承担相关责任。

编号	姓名	工作单位名称 (应与加盖公章一致)	证件号码	每年工作 时间(月)	签字
1	唐杰	清华大学	130302197701043514	6	
2	朱勇	北京百度网讯科技有限公司	340104197610252012	6	
3	沈志宏	中国科学院计算机网络信息中心	342921197712243012	6	
4	杜一	中国科学院计算机网络信息中心	371526198803066014	6	
5	刘德兵	清华大学	51292419760304797X	8	
6	祝恒书	北京百度网讯科技有限公司	650104198612310711	6	
7	吴章生	中国科学院计算机网络信息中心	352229198009286511	10	
8	赵江华	中国科学院计算机网络信息中心	130627198905120049	10	
9	王卫军	中国科学院计算机网络信息中心	410782198110282818	10	

依托单位及合作研究单位承诺:

已按填报说明对申请人的资格和申请书内容进行了审核。申请项目如获资助, 我单位保证对研究计划实施所需要的人力、物力和工作时间等条件给予保障, 严格遵守国家自然科学基金委员会有关规定, 督促项目负责人和项目组成员以及本单位项目管理部门按照国家自然科学基金委员会的规定及时报送有关材料。

依托单位公章

合作研究单位公章1

合作研究单位公章2

日期:

日期:

日期: