



申请代码	F0605
接收部门	
收件日期	
接收编号	

国家自然科学基金 申 请 书

(2024 版)

资助类别：	青年科学基金项目		
亚类说明：			
附注说明：			
项目名称：	基于图提示微调的图预训练模型迁移学习方法研究		
申 请 人：	乔子越	BRID：	00580.00.87611
办公电话：			
依托单位：	大湾区大学（筹）		
通讯地址：			
邮政编码：		单位电话：	0769-22898725
电子邮箱：	joeleo2014@163.com		

国家自然科学基金委员会



基本信息

申请人信息	姓名	乔子越	性别	男	出生年月	1996年07月	民族	汉族
	学位	博士	职称	研究员				
	是否在站博士后	否		电子邮箱	joeleo2014@163.com			
	办公电话			国别或地区	中国			
	申请人类别	依托单位全职						
	工作单位	大湾区大学（筹）/信息科学技术学院						
	主要研究领域							
依托单位信息	名称	大湾区大学（筹）						
	联系人	赖梦瑶		电子邮箱	mylai@gbu.edu.cn			
	电话	0769-22898725		网站地址	https://www.gbu.edu.cn/			
合作研究单位信息	单位名称							
项目基本信息	项目名称	基于图提示微调的图预训练模型迁移学习方法研究						
	英文名称	Research on Transfer Learning Methods for Graph Pre-trained Models Based on Graph Prompt Tuning						
	资助类别	青年科学基金项目				亚类说明		
	附注说明							
	申请代码	F0605. 模式识别与数据挖掘						
	研究期限	2025年01月01日 -- 2027年12月31日				研究方向：数据挖掘		
	申请直接费用	30.0000万元						
	研究属性	自由探索类基础研究						
中文关键词		图神经网络；社交网络挖掘；多源数据挖掘；迁移学习；提示微调						
英文关键词		Graph Neural Networks; Social Network Mining; Multi-Source Data Mining; Transfer Learning; Prompt Tuning						



中文摘要	随着人工智能的深入应用，图数据分析挖掘在多个领域如社交网络、推荐系统等有着重要作用。近年来，预训练模型在自然语言处理和计算机视觉中的重要性愈发凸显，展现出高效学习和迁移能力。然而，图的复杂结构和异质属性导致传统的预训练和微调框架在图领域面临泛化性和适应性不足的问题。本项目以此为出发点，结合图提示微调技术展开图预训练模型的迁移学习研究。目标是结合图提示的数据增强机制、适配融合机制和可控适应机制，从基本层、跨模态、跨域三个方面逐步推进，研究图预训练的提示微调方法。具体来说，拟研究基于图数据增强的图提示微调方法，基于适配融合的多模态图提示微调方法，以及基于可控适应的跨域图提示微调方法，实现提高图预训练模型面向跨模态、跨领域图数据迁移学习的泛化和适应能力，推动人工智能技术的创新，提升图分析算法在众多产业应用中的效率和效果。
英文摘要	With the deep application of artificial intelligence, graph data analysis and mining play a significant role in various fields such as social networks and recommendation systems. In recent years, the importance of pre-trained models in natural language processing and computer vision has become increasingly prominent, demonstrating high efficiency in learning and transferability. However, the complex structure and heterogeneous properties of graphs have led to challenges in generalizability and adaptability for traditional pre-training and fine-tuning frameworks in the graph domain. This project starts from this premise and combines graph prompt fine-tuning technology to undertake research on the transfer learning of graph pre-trained models. The goal is to integrate graph prompt-based data augmentation mechanisms, adaptation integration mechanisms, and controllable adaptation mechanisms, progressively advancing from the basic level, across modalities, and across domain, to study the prompt-based fine-tuning methods for graph pre-training. Specifically, the plan is to investigate graph prompt fine-tuning methods based on graph data augmentation, multimodal graph prompt fine-tuning methods based on adaptation integration, and cross-domain graph prompt fine-tuning methods based on controllable adaptation, aiming to improve the generalization and adaptability of graph pre-trained models for transfer learning across multimodal and cross-domain graph data, thereby promoting the innovation of artificial intelligence technology and enhancing the efficiency and effectiveness of graph analysis algorithms in numerous industrial applications.



报告正文

参照以下提纲撰写，要求内容翔实、清晰，层次分明，标题突出。
请勿删除或改动下述提纲标题及括号中的文字。

（一）立项依据与研究内容（建议 8000 字以内）：

1. 项目的立项依据（研究意义、国内外研究现状及发展动态分析，需结合科学研究发展趋势来论述科学意义；或结合国民经济和社会发展中迫切需要解决的关键科技问题来论述其应用前景。附主要参考文献目录）；

1.1 研究意义

图（Graph），又称网络（Network），是由节点（实体）和边（实体间的关系）构成的数据结构，图数据分析技术广泛应用于社交网络分析、个性化推荐系统、知识图谱构建、网络安全监测、生物信息学、药物发现、交通网络优化以及金融风险评评估等[1][2]。图分析的普遍应用促进了这些领域决策制定的智能化，加速了新技术和解决方案的发展。图数据相较于其他数据类型的一个关键特性是其能够表示复杂的关系和交互模式，包含丰富的结构化信息。在处理海量的文本和图像等非结构化数据时，预训练模型（Pre-trained Model）成为了研究的热点，这种模型通过在大规模数据集上进行预训练，然后在特定任务上进行微调（Fine-tuning）训练的框架，已经证明了其有效性。如 OpenAI 的 GPT 系列模型[4][5]、Google 的 ViT 系列[5]模型都已成功应用于自然语言处理和计算机视觉领域的多种任务中。预训练和微调框架的好处在于能够显著提升模型的学习效率和知识迁移能力，特别是在标签稀缺的下游任务中。因此，将预训练和微调框架应用于海量图数据上，研究图预训练模型（Graph Pre-trained Model）的迁移学习，对于提高图数据处理和分析的能力和效率至关重要。

尽管预训练和微调框架在文本和视觉领域已经取得了显著进展，但在图数据领域，预训练模型的迁移学习面临着一些独特的挑战，尚未取得同样的突破。预训练模型处理的基本单元是令牌（Token），例如文本中的字符和图像中的像素点，这些基本单元具有普适性和可迁移性，使得预训练模型能够轻松适应新的任务或数据集。然而，在图数据具有结构复杂性、节点和边具有异质性和动态性，这种普适性的基本单元并不直观，面临着令牌集合漂移（Token set shift）问题。图由节点和边组成，每个节点可能代表不同的实体类型，边也可能表示多种关系类

型，在特定的预训练图数据集中，节点和边的类型集合往往是固定的，这与文本和图像领域的情况不同，后者通过不同的排列组合可以生成几乎无限多的单词或图像。在图数据领域，下游任务的节点或边可能需要模型重新学习以适应新的实体或类型（例如推荐系统中的新商品品类），特别是当这些新元素在预训练阶段未被模型“见过”时，使得图预训练模型无法充分理解和适应下游图数据，这是导致传统图预训练和微调框架泛化能力不足的核心问题。




图 1. 文本预训练模型和图预训练模型迁移学习中的提示微调

针对这一问题，提示微调（Prompt Tuning）为图预训练模型的迁移学习提供了新的解决思路。提示微调作为预训练微调框架的一种前沿研究方向，能够通过设计与下游任务相关的提示来指导模型学习。提示学习的核心思想是在下游数据中添加一种模型可以理解的“提示”，指导预训练模型高效地适应新任务或环境。如图 1 所示，借鉴于自然语言处理领域中通过在输入数据中插入或修改特定词汇以辅助模型理解新方法的方法，图提示微调（Graph Prompt Tuning）采用对输入数据图进行简单而有效的调整策略，如增加节点属性或拓扑连接，或者以某种特定的方式重新组织图结构，以促进模型对预训练模型令牌集合外的图数据的理解及其快速适配，从而增强模型在迁移过程中的泛化能力和适应性。

目前，图预训练微调模型的研究取得了长足的进展，但图预训练模型提示微调研究仍然处于初级阶段。在图预训练模型方面，GPT-GNN[6]借用类似于 GPT 的训练思路，通过自监督的生成式的预测节点属性和拓扑连接训练图预训练模型；GCC[7]通过基于 NCE 损失的自监督学习机制，训练图预训练模型，学习图数据中的通用模式信息；申请人也曾提出过针对于富含文本属性的学术网络的



图预训练模型 RPT[8],设计了分别用于提取语义和社区信息的自监督学习模型和融合两种信息的对比学习模型。然而,这些预训练模型使用传统的微调训练方法,在迁移到分布于预训练图显著不同的下游图数据时,模型的泛化能力和适应性会受到限制。在图提示学习方面,一些初步的研究成果展示了其潜力。GPPT[9]通过手工定义的图结构提示和随机初始化的任务提示,实现了图预训练模型对下游任务的迁移和适应;KDD 2023 的最佳论文 ALL in One[10]设计了一种简洁的图属性提示和结构提示,并使用元学习优化来提升图预训练模型对下游模型的适应能力;申请人的论文 SGDA[11]中提出了一种修改下游图数据分布的“漂移参数”以提升图预训练模型的跨域适应能力,可以看作是图提示的一种雏形。这些初步的成果展现了提示微调对于图预训练模型迁移学习的潜力。

总的来说,图提示微调仍面临着若干挑战和不足。主要的难点在于如何设计高效通用的图提示技术,实现对图预训练模型在下游图数据上的泛化知识迁移。另一方面,传统的图迁移学习研究往往只局限于具有简单属性和单一领域的图任务上,如何在复杂的图数据上借助提示有效融合多源知识,以及如何借助提示学习提高图预训练迁移学习中的跨域适应能力,最终实现图预训练模型在跨模态、跨领域的图数据上的知识迁移和应用仍然是一个开放性的问题。申请人通过已往的研究发现,提示学习在图预训练模型迁移学习中还拥有着更加深层次的潜力未待发掘,提示学习潜在的数据增强机制、适配融合机制和可控适应机制对于提升图预训练模型在上述问题上的迁移和适应能力有着极高的研究价值。

基于以上分析,本项目拟在申请人已往研究的基础上,以图预训练模型在微调过程中泛化能力不足的问题为出发点,结合图提示微调技术展开图预训练模型的迁移学习研究。目标结合图提示的数据增强机制、适配融合机制和可控适应机制,从基本图提示微调,跨模态图提示微调,跨域图提示微调三个方面逐步推进。主要包括:(1)针对传统图预训练微调框架泛化性不足的问题,研究基于图数据增强的图提示微调方法,自动生成和学习高效的图提示,提升图预训练模型的泛化能力;(2)针对下游图中多模态语义信息利用不足的问题,研究基于适配融合的多模态图提示微调方法,实现复杂属性图上的高效知识融合适应;(3)针对具有显著差异的跨域图上的适应性差的问题,研究基于可控适应网络的跨域图提示微调方法,实现在明显分布差异下的跨域图自适应。最终实现提高图预训练模型面向跨模态、跨领域图数据迁移学习的泛化和适应能力。



1.2 国内外研究现状

针对本项目拟申请的研究课题，下面主要从三个相关方面综述国内外研究现状，包括图表示学习算法，图预训练方法、图微调方法。

1.2.1 经典图表示学习方法

图表示学习是最基础的图预训练模型。图表示学习的目标是将图中的节点、边或整个图转换成低维度、密集的向量表示，这些向量能够有效捕捉和表达原始图结构中的信息和关系，并用于如节点分类、链接预测的下游任务中。

(1) 基于矩阵分解的方法。网络通常可以用某种形式的矩阵表示，例如邻接矩阵和拉普拉斯矩阵，其中矩阵的每行反映了节点的邻域结构信息。节点向量表示的直观方法包括使用这些矩阵的行或通过矩阵分解降低维度。矩阵分解是一种重要的数学方法，包括奇异值分解（SVD）和特征值分解。GraRep[12]提出了一种基于全局结构信息矩阵分解的节点嵌入方法，该方法综合利用了各种 k 跳关系的信息。HOPE[13]使用广义 SVD 分解高阶邻近矩阵。TADW[14]在矩阵分解框架中引入了顶点的文本特征。MMDW[15]在基于矩阵分解的统一学习框架中，将标记信息合并到顶点表示中。尽管基于矩阵分解的方法在多领域成功应用，但它们存在信息捕捉不足和扩展性差的局限。

(2) 基于随机游走模型的方法。基于随机游走的图表示学习算法通过模拟在图上的随机游走过程来学习节点的向量表示，这种方法能够有效捕捉图中节点的局部结构信息以及节点间的邻近性。这一类算法的核心思想是：如果两个节点在多次随机游走中频繁共现，则这两个节点在图中的结构上是接近的，因此它们的向量表示也应该是相似的。DeepWalk[16]利用 Skip-Gram 模型关注局部结构，而 Node2Vec[17]通过调整游走策略平衡局部与全局信息。LINE[18]针对大规模网络优化一阶和二阶相似度；HARP[19]通过层次化方法捕捉图的层次结构。这类算法的模型通常较为简单，计算效率高，易于实现，然而，这些方法也有局限性，如难以直接应用于带有丰富边信息（如权重、标签）的图，以及在处理大规模图数据时的扩展性问题。

(3) 基于优化的方法。基于优化的网络表示学习算法通过设计合适的目标函数来建模图的结构和语义信息，然后利用优化技术最小化或最大化这一函数以获得节点向量表示。例如，LINE[18]模型利用 KL 离散度优化捕获一阶和二阶邻近度，通过边缘采样策略最小化目标函数以获得节点嵌入。APP[20]模型关注节点间的非对称近似和高阶相似性。在异质网络中，LSHM[21]、PTE[22]等模型



通过结合分类损失和正则化损失或最小化条件概率来学习节点的表示。互信息优化方法，如 DGI[23]、InfoGraph[24]通过最大化局部与全局表示或图级与子结构表示间的互信息来提供无监督学习方案。基于优化的方法往往具有容易过拟合，对于负采样依赖性强的特点，往往需要结合一些模型泛化技术来提升学习到的网络表示的质量。图预训练模型可以视为基于优化的图表示学习方法在此方向的延伸和发展。

1.2.2 图预训练方法进展分析

(1) 图预训练模型骨干网络。图预训练模型的骨干网络（Backbone）是指用于图表示学习的核心神经网络结构，它能够从图结构中提取出有效的特征表示。这些骨干网络是图预训练模型中至关重要的部分，直接影响模型学习到的表征的质量，可以划分为图神经网络（Graph Neural Networks, GNN）和图变换器（Graph Transformer, GT）。图神经网络通过直接在图结构数据上运行来捕获节点之间的关系和图形的全局结构。GNN 的基本思想是通过节点的邻居聚合信息来更新节点的表示，例如，其中 GCN[25]通过图卷积实现信息聚合，GAT[26]引入注意力机制调整邻居权重，而 GraphSAGE[27]采用采样和聚合策略，特别适用于大规模图数据。GT 引入了 Transformer 架构至图结构数据处理中，结合了图结构数据的特性与 Transformer 的自注意力机制，以更有效地捕捉图中的节点间复杂关系。例如，TokenGT[28]使用拉普拉斯特征向量作为节点位置编码，使得模型能够识别和利用节点周围的子图结构。Graphformers[29]直接从邻接矩阵中提取结构信息，使模型在学习节点中心性方面更具表达能力。GTN[30]是一种专门设计来处理异构图的 Transformer 模型。它通过动态学习异构图中不同类型的边来生成新的图拓扑，从而能够更有效地捕获图中的复杂关系和结构信息。

(2) 图预训练算法。图预训练使图模型能够理解图结构和语义信息，从而编码有意义的节点或图嵌入。一些图预训练方法通产以自监督的方式学习。基于自监督任务，这些图预训练方法可以被分为两类对比预训练和生成预训练。对比图预训练方法旨在最大化不同视图之间的互信息，这迫使模型捕获各种视图中的不变语义信息。例如，GCC[7]将节点子图的嵌入视为节点嵌入，考虑同一节点的不同子图为正例和不同节点为负例。之后，模型采用 NCE 损失将正样本拉近并将负样本推远，迫使编码器捕获通用模式。GraphCL[31]和 GRACE[32]通过图增强生成两个视图，然后使用 InfoNCE 损失对节点级嵌入进行对比，推动图模型获得不变表示。MA-GCL[33]专注于操纵视图编码器的神经架构，而不是扰乱



图输入或模型参数。DGI[23]使用一个判别器来最大化节点嵌入和图嵌入之间的互信息，并最小化节点和损坏图嵌入之间的信息。生成预训练方法的目的是使GNN能够理解图的一般结构和属性语义。例如，VGAE[34]将VAE扩展到图领域，首先使用GCN作为编码器生成节点嵌入，然后通过节点嵌入的内积重构邻接矩阵，GPT-GNN[6]提出了自监督的边和属性生成任务，推动模型理解属性和结构的内在依赖关系，模型可以学习高阶结构和语义信息。GraphMAE[35]认为之前的生成方法过分强调结构信息；相反，它们在自监督的方式下采用特征重构和重新掩码解码策略。GROVER[36]引入了节点和边的任务，预测局部子图内的上下文感知属性。

1.2.3 图微调方法进展分析

(1) 图传统微调算法。对于模型在同一领域内进行预训练和下游任务的情况，可以利用预训练模型生成节点嵌入或图嵌入，然后微调一个外部的特定任务层，以将预训练模型泛化到下游任务。DGI[23]和GRACE[32]利用预训练的编码器获得节点嵌入，然后利用带标签数据微调逻辑回归分类器来处理节点分类任务。此外，还有一个更实用的场景，即在已知图上进行预训练，而在未见过的图上进行测试。预训练模型不能适当地编码未知图，因此我们需要在这种情况下微调模型。GPT-GNN[6]利用带标签数据微调一个下游任务特定的解码器，指导预训练模型适应下游任务。此外，最近提出了一些参数高效的微调方法。AdapterGNN[37]在消息传递阶段之前和之后使用两个并行的适配器来修改输入图。这种基于添加的方法只需要微调引入的参数。G-Adapter[38]提出了一种针对图变换器的参数高效微调方法，通过消息传递将图结构引入到微调中。尽管微调方法取得了显著的成功，但它们通常需要足够的带标签数据来调整模型参数。AUX-TS[39]通过测量图预训练任务与目标任务的梯度之间的余弦相似度来量化辅助任务与目标任务之间的一致性，使得图预训练模型更好地适应目标任务并提高知识转移的有效性。此外，传统的微调方法由于图数据具有结构化和多样化特征特性，在特定下游任务中泛化能力受限。因此，针对图基础模型的更高级的微调技术仍待探索。

(2) 图提示微调算法。近来，提示微调作为一种新策略被提出，它旨在避免对预训练模型的全参数微调，同时更好地适应多任务和零样本学习场景。针对图数据的提示调整，已有若干研究展开探讨。例如，GPPT[9]通过为每个类别生成一对标记的提示函数，将所有的节点分类任务转换成链接预测任务。



GraphPrompt[40]则是基于子图相似性，将预训练和下游任务融合到一个统一的任务框架中，并通过标记数据学习针对每个任务的特定提示向量，这种方法调整了模型的输出操作，减少了链接预测与下游任务之间的差异。AAGOD[41]提出了一种通过在原始输入图的邻接矩阵上添加一个可学习的、针对每个实例特定的提示放大器，以实现数据中心的操作方式。All In One[10]将节点级和图级任务统一转换为图级任务，通过将一个额外的子图作为提示与节点子图合并处理，模型随后利用合并后的图生成预测。GPF[42]向图中每个节点引入了一个统一的特征修改向量，该向量可被优化，以便在任何预训练策略下适配预训练的 GNN 模型。PRODIGY[43]旨在提示图上预训练一个上下文学习器，使预训练模型能够在不需要对任何参数进行优化的情况下，适应多种下游任务。尽管这些方法已在很多图迁移学习场景下提升了性能，图提示的结构设计通用性、多模态语义融合能力、跨域适应性和解释性仍需进一步探索。

1.2.4 研究现状小节

本项目介绍了现有图预训练模型迁移技术的技术积累和最新进展。这些技术通过利用大量未标记的图数据，使得模型在没有显式监督的情况下学习到丰富的图结构和节点特征信息，从而在多种下游任务上实现知识的有效迁移和应用。

然而，传统的图表示学习方法往往专注于特定的图结构和特定的任务，这限制了它们的泛化能力。相比之下，图预训练模型通过在大规模图数据上预训练，能够学习到更丰富、更通用的图结构和节点特征信息，然而传统的图预训练和微调框架往往忽视了目标任务与预训练任务之间的潜在不一致性，导致知识迁移效率不高，泛化性不足。一些研究试图通过引入可学习的提示向量来桥接图预训练任务和下游任务之间的差异，从而提高迁移效率。然而，这些探索虽然在理论上具有创新性，但实际应用中仍处于初级阶段，面临着诸如提示设计缺乏通用性、多模态语义融合和跨域适应性差的问题。如何高效的提升图预训练模型在迁移学习过程中的泛化性和适应性仍然是一个重大挑战。

1.3 应用前景

中国发布的《新一代人工智能发展规划》明确提出，要加快人工智能基础研究和应用研究，推动人工智能与实体经济深度融合。国家“十四五”规划中提出要迎接数字时代，激活数据要素潜能，提出“充分发挥海量数据和丰富应用场景优势，促进数字技术与实体经济深度融合，赋能传统产业转型升级，催生新产业新业态新模式，壮大经济发展新引擎”。这对大数据的信息抽取和挖掘分析相关的



支撑技术都提出了较高要求。近年来，预训练大模型逐渐兴起，在许多领域引起了越来越多的关注，如自然语言处理，计算机视觉，以及图数据挖掘。近期，由 OpenAI 推出的预训练大型语言模型 ChatGPT 在人机对话上也展示出了惊人的能力，证明了预训练模型的潜力和经济价值，预训练模型及微调应用成为了大数据的高效信息抽取和挖掘分析的核心人工智能技术。

图数据分析在众多领域中扮演着至关重要的角色，尤其是在处理复杂系统和网络结构时。基于图提示学习的图预训练迁移学习技术通过引入和优化提示学习策略来增强图模型对下游任务的适应性和效率，因此在多个领域中展现出广泛的应用前景。例如，电商、社交媒体等领域，图预训练迁移学习技术能够通过理解用户行为和社交网络结构的复杂图模式，提升个性化推荐的准确度和用户体验；基于图的预训练模型能够处理和融合来自不同源的数据（如图像、文本、声音等），在多模态学习任务中展现出强大的潜力，比如在医疗影像分析、跨媒体内容检索等领域；通过结合图结构数据和文本数据的预训练模型，可以提升知识图谱的构建和查询效率，同时能在自然语言处理任务如文本摘要、问答系统等等中，通过理解和利用背后的知识图谱，提高模型的准确性和可解释性；在药物发现和生物医药领域，图预训练迁移学习技术可以通过更有效地捕捉分子结构和蛋白质相互作用的复杂图结构信息，加速新领域药物发现流程，提高新药研发的效率和成功率；在城市计算领域，基于图的预训练模型可以用于理解和预测城市交通流、旅行需求等复杂的空间-时间图数据，为跨区域城市规划和交通管理提供支持，从而优化城市资源分配和交通流量管理。总之，图预训练模型迁移学习技术在这些应用中提高了模型的通用性和适应性，极大地提升了效率和效果。

参考文献：

- [1] 石川, 王睿嘉, and 王啸, “异质信息网络分析与应用综述,” 软件学报, vol. 33, pp. 598–621, 2022, doi: 10.13328/j.cnki.jos.006357.
- [2] 涂存超, 杨成, 刘知远, and 孙茂松, “网络表示学习综述,” 中国科学:信息科学, vol. 47, pp. 980–996, 2017.
- [3] A. Radford *et al.*, “Language models are unsupervised multitask learners,” *OpenAI Blog*, vol. 1, no. 8, p. 9, 2019.
- [4] T. Brown *et al.*, “Language Models are Few-Shot Learners,” in *Advances in Neural Information Processing Systems*, H. Larochelle, M. Ranzato, R. Hadsell, M. F. Balcan, and H. Lin, Eds., 2020, pp. 1877–1901.
- [5] A. Dosovitskiy *et al.*, “An Image is Worth 16x16 Words: Transformers for Image



- Recognition at Scale,” in *International Conference on Learning Representations*, 2020.
- [6] Z. Hu, Y. Dong, K. Wang, K.-W. Chang, and Y. Sun, “Gpt-gnn: Generative pre-training of graph neural networks,” in *Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, 2020, pp. 1857–1867.
- [7] J. Qiu *et al.*, “Gcc: Graph contrastive coding for graph neural network pre-training,” in *Proceedings of the 26th ACM SIGKDD international conference on knowledge discovery & data mining*, 2020, pp. 1150–1160.
- [8] Z. Qiao *et al.*, “RPT: Toward Transferable Model on Heterogeneous Researcher Data via Pre-Training,” *IEEE Trans. Big Data*, vol. 9, no. 01, pp. 186–199, 2023.
- [9] M. Sun, K. Zhou, X. He, Y. Wang, and X. Wang, “Gppt: Graph pre-training and prompt tuning to generalize graph neural networks,” in *Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, 2022, pp. 1717–1727.
- [10] X. Sun, H. Cheng, J. Li, B. Liu, and J. Guan, “All in One: Multi-Task Prompting for Graph Neural Networks,” in *Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, 2023, pp. 2120–2131.
- [11] Z. Qiao, X. Luo, M. Xiao, H. Dong, Y. Zhou, and H. Xiong, “Semi-supervised Domain Adaptation in Graph Transfer Learning,” in *32nd International Joint Conference on Artificial Intelligence, IJCAI 2023*, International Joint Conferences on Artificial Intelligence, 2023, pp. 2279–2287.
- [12] S. Cao, W. Lu, and Q. Xu, “Grarep: Learning graph representations with global structural information,” in *Proceedings of the 24th ACM international on conference on information and knowledge management*, 2015, pp. 891–900.
- [13] M. Ou, P. Cui, J. Pei, Z. Zhang, and W. Zhu, “Asymmetric transitivity preserving graph embedding,” in *Proceedings of the 22nd ACM SIGKDD international conference on Knowledge discovery and data mining*, 2016, pp. 1105–1114.
- [14] C. Yang, Z. Liu, D. Zhao, M. Sun, and E. Y. Chang, “Network representation learning with rich text information,” in *IJCAI*, 2015, pp. 2111–2117.
- [15] C. Tu, W. Zhang, Z. Liu, M. Sun, and others, “Max-margin deepwalk: Discriminative learning of network representation,” in *IJCAI*, 2016, pp. 3889–3895.
- [16] B. Perozzi, R. Al-Rfou, and S. Skiena, “Deepwalk: Online learning of social representations,” in *Proceedings of the 20th ACM SIGKDD international conference on Knowledge discovery and data mining*, 2014, pp. 701–710.
- [17] A. Grover and J. Leskovec, “node2vec: Scalable feature learning for networks,” in *Proceedings of the 22nd ACM SIGKDD international conference on Knowledge discovery and data mining*, 2016, pp. 855–864.
- [18] J. Tang, M. Qu, M. Wang, M. Zhang, J. Yan, and Q. Mei, “Line: Large-scale information network embedding,” in *Proceedings of the 24th international conference on world wide*



- web, 2015, pp. 1067–1077.
- [19] H. Chen, B. Perozzi, Y. Hu, and S. Skiena, “Harp: Hierarchical representation learning for networks,” in *Proceedings of the AAAI conference on artificial intelligence*, 2018.
- [20] C. Zhou, Y. Liu, X. Liu, Z. Liu, and J. Gao, “Scalable graph embedding for asymmetric proximity,” in *Proceedings of the AAAI conference on artificial intelligence*, 2017.
- [21] Y. Jacob, L. Denoyer, and P. Gallinari, “Learning latent representations of nodes for classifying in heterogeneous social networks,” in *Proceedings of the 7th ACM international conference on Web search and data mining*, 2014, pp. 373–382.
- [22] J. Tang, M. Qu, and Q. Mei, “Pte: Predictive text embedding through large-scale heterogeneous text networks,” in *Proceedings of the 21th ACM SIGKDD international conference on knowledge discovery and data mining*, 2015, pp. 1165–1174.
- [23] P. Veličković, W. Fedus, W. L. Hamilton, P. Liò, Y. Bengio, and R. D. Hjelm, “Deep Graph Infomax,” in *International Conference on Learning Representations*, 2018.
- [24] F.-Y. Sun, J. Hoffman, V. Verma, and J. Tang, “InfoGraph: Unsupervised and Semi-supervised Graph-Level Representation Learning via Mutual Information Maximization,” in *International Conference on Learning Representations*, 2019.
- [25] M. Welling and T. N. Kipf, “Semi-supervised classification with graph convolutional networks,” in *J. International Conference on Learning Representations (ICLR 2017)*, 2016.
- [26] P. Veličković, G. Cucurull, A. Casanova, A. Romero, P. Liò, and Y. Bengio, “Graph Attention Networks,” in *International Conference on Learning Representations*, 2018.
- [27] W. L. Hamilton, R. Ying, and J. Leskovec, “Inductive representation learning on large graphs,” in *Proceedings of the 31st International Conference on Neural Information Processing Systems*, 2017, pp. 1025–1035.
- [28] J. Kim *et al.*, “Pure transformers are powerful graph learners,” *Adv. Neural Inf. Process. Syst.*, vol. 35, pp. 14582–14595, 2022.
- [29] J. Yang *et al.*, “GraphFormers: GNN-nested transformers for representation learning on textual graph,” *Adv. Neural Inf. Process. Syst.*, vol. 34, pp. 28798–28810, 2021.
- [30] S. Yun, M. Jeong, R. Kim, J. Kang, and H. J. Kim, “Graph transformer networks,” *Adv. Neural Inf. Process. Syst.*, vol. 32, 2019.
- [31] Y. You, T. Chen, Y. Sui, T. Chen, Z. Wang, and Y. Shen, “Graph contrastive learning with augmentations,” *Adv. Neural Inf. Process. Syst.*, vol. 33, pp. 5812–5823, 2020.
- [32] Y. Zhu, Y. Xu, F. Yu, Q. Liu, S. Wu, and L. Wang, “Deep Graph Contrastive Representation Learning,” in *ICML Workshop on Graph Representation Learning and Beyond*, 2020.
- [Online]. Available: <http://arxiv.org/abs/2006.04131>
- [33] X. Gong, C. Yang, and C. Shi, “Ma-gcl: Model augmentation tricks for graph contrastive learning,” in *Proceedings of the AAAI Conference on Artificial Intelligence*, 2023, pp.



4284–4292.

- [34] T. N. Kipf and M. Welling, “Variational Graph Auto-Encoders,” *NIPS Workshop Bayesian Deep Learn.*, 2016.
- [35] Z. Hou *et al.*, “Graphmae: Self-supervised masked graph autoencoders,” in *Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, 2022, pp. 594–604.
- [36] Y. Rong *et al.*, “Self-supervised graph transformer on large-scale molecular data,” *Adv. Neural Inf. Process. Syst.*, vol. 33, pp. 12559–12571, 2020.
- [37] S. Li, X. Han, and J. Bai, “AdapterGNN: Efficient Delta Tuning Improves Generalization Ability in Graph Neural Networks,” in *Proceedings of the AAAI conference on artificial intelligence*, 2024.
- [38] A. Gui, J. Ye, and H. Xiao, “G-Adapter: Towards Structure-Aware Parameter-Efficient Transfer Learning for Graph Transformer Networks,” in *Proceedings of the AAAI conference on artificial intelligence*, 2024.
- [39] X. Han, Z. Huang, B. An, and J. Bai, “Adaptive transfer learning on graph neural networks,” in *Proceedings of the 27th ACM SIGKDD Conference on Knowledge Discovery & Data Mining*, 2021, pp. 565–574.
- [40] Z. Liu, X. Yu, Y. Fang, and X. Zhang, “Graphprompt: Unifying pre-training and downstream tasks for graph neural networks,” in *Proceedings of the ACM Web Conference 2023*, 2023, pp. 417–428.
- [41] Y. Guo, C. Yang, Y. Chen, J. Liu, C. Shi, and J. Du, “A Data-centric Framework to Endow Graph Neural Networks with Out-Of-Distribution Detection Ability,” in *Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, 2023, pp. 638–648.
- [42] T. Fang, Y. Zhang, Y. Yang, C. Wang, and L. Chen, “Universal prompt tuning for graph neural networks,” *Adv. Neural Inf. Process. Syst.*, vol. 36, 2024.
- [43] Q. Huang *et al.*, “Prodigy: Enabling in-context learning over graphs,” *Adv. Neural Inf. Process. Syst.*, vol. 36, 2024.

2. 项目的研究内容、研究目标, 以及拟解决的关键科学问题(此部分为重点阐述内容);

2.1 研究内容

本项目拟开展基于提示微调的图预训练模型迁移学习研究, 针对现有的图预训练模型微调方法泛化性不足, 在跨模态跨域图数据上适应性不足的问题, 结合图提示的数据增强机制、适配融合机制和可控适应机制, 从基本图提示, 多模态

图提示，跨域图提示三个层面展开研究，项目的整体框架如图 2 所示。

首先，研究基于图数据增强的图提示微调方法，实现对图数据的增强以提升对下游图任务的泛化能力。在此基础上，研究基于适配融合的多模态图提示微调方法，实现图多模态信息上的高效知识融合和适应。最后，研究基于可控适应网络的跨域图提示微调方法，实现在显著分布差异下的跨域图自适应。整体来看，基于图数据增强的图提示微调方法为后续研究提供基本的图提示微调框架支撑。基于适配融合的多模态图提示微调方法是该框架在复杂属性图上的扩展，使得图预训练模型的迁移学习具备多模态融合和知识增强的能力。基于可控适应网络的跨域图提示微调方法是在上述研究在跨域迁移上的进一步扩展，使得图预训练模型的迁移学习具备在显著分布差异下的跨域图自适应能力。




图 2. 本项目的主要内容

2.1.1 基于图数据增强的图提示微调方法

相对于传统文本图像等数据类型，图数据由于其结构化和非线性特征不具备显著的普适性和可迁移性，基于传统预训练和微调框架图迁移学习研究泛化能力不足。图提示通过向图中引入先验知识或额外信息，来辅助模型理解下游图结构特征和节点间的潜在关系，使得预训练模型能够在不同的图结构和多样的下游任务中展示出高度的适应性。然而现有的图提示方法通常在节点属性层面引入可训练的提示向量，忽略相对于图拓扑结构的提示设计。

本项目拟研究基于图数据增强的图提示微调方法。(1) 针对图数据非线性特



征导致图结构提示难以定义的问题，研究基于图结构学习的图提示生成模型，利用耿贝尔分布采样生成离散图结构提示，实现可训练的具备属性和结构的图提示；（2）针对图提示和下游图数据高效结合的问题，研究基于图提示注入的图数据增强技术，自动构建图提示和下游图数据之间的边，实现图提示针对于下游任务的图数据修改和增强；（3）针对图提示相对于下游任务适应性和可解释性不足的问题，研究基于图原型的图任务提示微调方法，根据下游任务的标签信息和聚类策略生成图原型作为提示，最终实现面向高效适应下游任务的图预训练模型提示微调方法。

2.1.2 基于适配融合的多模态图提示微调方法

现实世界的图中节点属性往往具有的复杂多模态信息，例如社交网络中往往包含丰富文本和图像特征，另一方面，下游任务中的图标签也包含着丰富语义信息，对于这些信息的利用对于图学习任务至关重要。随着不同模态的预训练模型如 GPT 和 ViT 的发展，使得这些信息的高效利用具有潜力。现有的图提示方法通常只关注于传统的带有数值属性的图数据，难以利用多模态的语义知识，主要局限于缺乏一个统一提示微调框架，以支持不同模态信息的知识融合，同时未能充分探索和利用预训练模型在理解和处理多模态数据方面的潜力。

本项目拟研究基于适配融合的多模态图提示微调方法。（1）针对不同模态对应的预训练模型的映射空间不一致的问题，研究基于适配器的模态表示融合模型，利用模态特定的适配器模型和交叉注意力机制，修改模态分布空间并形成统一的多模态图节点属性表示；（2）针对如何使图预训练模型高效的理解多模态知识的问题，研究基于多模态图提示对比学习方法，设计多模态图提示并利用图结构作为对比学习的监督信号，实现面向图预训练模型的模态间信息融合和对齐；（3）针对下游图任务中的标签语义信息理解和利用困难的问题，研究大语言模型增强的图任务提示微调方法，基于大语言模型将标签文本转为图任务提示，提升在下游任务上的推理能力。最终实现适配融合多模态知识的图提示微调方法。

2.1.3 基于可控适应的跨域图提示微调方法

图预训练模型在不同的下游任务中进行迁移学习时，面临的一个主要挑战是下游数据与训练数据之间的分布差异，例如不同的时间段、不同的研究主题或领域，导致学术网络之间在关系模式和节点属性上存在明显的变化。这种跨域的分布差异是影响预训练模型适应能力的关键因素。现有的图提示工作往往只借助图提示来隐式的弥补这种分布差异，在面临更大的分布差异往往效果不佳，不足



以充分捕捉和适应复杂的结构变化和关系模式的差异。

本项目拟研究基于可控适应的跨域图提示微调方法。(1) 针对传统图提示在跨域迁移时弥补显著分布差异的不足问题, 研究基于条件控制网络的图提示生成模型, 利用下游图数据生成分布相关的条控图提示, 实现对分布差异的精细感知并提升模型预测的泛化能力;(2) 针对如何高效消除跨域迁移时的显著分布差异问题, 研究基于对抗学习的跨域图分布对齐方法, 使得条控图提示和图预训练模型输出的跨域节点表征具有相似分布, 实现消除分布差异对预训练模型泛化性的影响;(3) 针对在零样本情景下的跨域迁移学习任务适应性差的问题, 研究基于条控图提示的跨域自适应微调方法, 通过基于节点普适性权重的概率信息最大化自监督优化目标, 最终实现预训练模型在具有显著分布差异的跨域下游任务上的判别和适应能力的提升。

2.2 研究目标

本项目的研究目标是面向图预训练模型的迁移学习问题, 突破传统微调方法泛化性不足的问题, 研究基于提示微调的图预训练模型迁移技术, 实现图预训练模型在跨模态、跨领域的下游图分析任务上的知识迁移和应用。**目标结合目标结合图提示的数据增强机制**、适配融合机制和可控适应机制的优势, 首先改善传统微调方法在迁移学习中泛化性不足的问题, 实现更高效的图提示微调方法, 实现更有效的图预训练模型迁移适应; 进一步, 基于多模态图提示有效利用下游图中多模态语义信息, 实现图多模态信息上的高效知识融合适应; 最后提升预训练模型在具有显著差异的跨域图上的适应性, 最终实现提高图预训练模型面向跨模态、跨领域图数据迁移学习的泛化和适应能力。

2.3 拟解决的关键科学问题

(1) 传统图预训练模型微调框架的泛化性不足问题。~~预训练模型通常在大型且多样化的数据集上进行训练并可以迁移到多种下游任务中, 因其具有较高的泛化性可以显著提升模型的效果和知识迁移能力, 尤其在文本与视觉领域效果显著。然而由于图数据具有结构化和多样化特征特性, 不具备文本和视觉领域里如字符和像素点等具有高度的普适性的基本构成单元, 通常具有显著的分布外迁移问题, 传统图预训练模型微调框架在特定下游任务中泛化能力受限。提示微调方法能够通过设计与下游任务相关的提示来指导模型微调, 更高效地适应新数据和任务。本研究旨在通过更高效的图提示在数据层面优化预训练模型消~~



除分布差异，实现对面向下游任务的下游图数据增强，提升图预训练模型的泛化能力。这是本项目拟解决的一个关键科学问题。

(2) 图预训练模型跨模态、跨域迁移中的适应性不足问题。图数据由于其固有的信息连接特性和类型的复杂性，使得图预训练模型在进行迁移学习时面临跨模态和跨领域的挑战。例如在社交网络中，数据往往融合了多种文本和图像特征。不同时间和地理位置的社交网络在关系模式和节点属性上可能会展现出显著的差异。这种多模态和多领域的特征为预训练模型的适应性提出了新的挑战。现有图提示微调的研究主要集中在具有数值属性的图数据上，难以充分利用多模态数据中的语义知识。同时在跨领域迁移过程中往往不能有效捕捉并适应于复杂的结构变化和关系模式的差异。本研究旨在针对下游图中多模态语义信息利用不足的问题，实现复杂多模态图上的高效语义知识融合，针对具有显著差异的跨域图上的适应性差的问题，实现在明显分布差异下的跨域图自适应。最终实现提高图预训练模型面向跨模态、跨领域图数据迁移学习的适应能力。这是本项目拟解决的另一个关键科学问题。

3. 拟采取的研究方案及可行性分析(包括研究方法、技术路线、实验手段、关键技术等说明);

3.1 拟采取的研究方案

本项目算法研究与实验设计迭代开展，充分利用申请人前期的工作积累和实验室现有资源，基于申请人前期在图表示学习，图预训练和微调模型，图领域适应等相关方面的研究基础，针对预训练模型在微调过程中泛化能力不足的问题，结合图提示微调技术展开图预训练模型的迁移学习研究。针对如何自动生成和学习图提示的问题，研究基于图数据增强的图提示微调方法，实现对图数据的增强以提升对下游图任务的泛化能力。在此基础上，针对多模态图数据上的迁移学习的问题，研究基于适配器的多模态图提示微调方法，实现复杂属性图上的高效知识融合和适应。最后，针对跨域图数据上的迁移学习问题研究基于可控适应网络的跨域图提示微调方法，实现在明显分布差异下的跨域图自适应。研究方案层次递进，针对每项研究内容，本项目拟在不同场景下的真实数据上展开实验，探索图提示微调技术在图预训练模型的迁移学习的应用。

3.1.1 基于图数据增强的图提示微调方法

本部分利用图提示作为数据增强手段，通过向图中引入先验知识或额外信息，



来辅助模型理解下游图结构特征和节点间的潜在关系。图提示的灵活性和调整能力使得预训练模型能够在不同的图结构和多样的下游任务中展示出高度的适应性。整体研究方案如图 3 所示：




图 3. 基于图数据增强的图提示微调方法研究方案

(1) 基于结构学习的图提示生成模型

首先，在自然语言中，提示通常是预定义的文本片段，图数据的复杂性和非线性特征导致其更难手工定义，因此，本项目借鉴了在更常用的软提示（Soft Prompt）的概念。软提示是一种可训练的、嵌入式的提示参数，它不是预定义的固定文本，而是通过训练过程中的优化来调整其值。这种方法的优势在于它能够自动适应特定任务的需求，而不需要人工干预来设计复杂的提示语句。

本项目拟开发一种自动构建可训练图提示的方法，并将其注入到下游图数据上完成迁移学习。具体而言，设下游图为 $G = (V, E)$ ，其中 V 是节点集，包含 n 个节点；每个节点有一个特征向量。图提示表示为 $G' = (Z, S)$ ，其中 Z 是节点属性提示集， $|Z|$ 是图提示节点数。每个属性提示可以由一个与输入图中节点特征相同大小的标记向量 z_i 表示。实际中，提示节点数量通常远小于下游图节点数量。 $S = (i, j) | i, j \in Z$ 是节点间成对边构成的图结构提示，可以通过图结构学习模型构建。假设每一条边的权重 $w_{i,j}$ 服从伯努利分布 $w_{i,j} \sim \text{Bernoulli}(p_{i,j})$ ，并将概率定义为节点属性的点积 $p_{i,j} = \sigma(z_i \cdot z_j)$ 。基于 *Gumbel - Softmax* 函数近似从边的分布中的采样：

$$w_{i,j} = \sigma \left(\left(p_{i,j} + \log \frac{\delta}{1-\delta} \right) / \tau \right)$$

其中 σ 表示 *sigmoid* 激活函数， δ 是从标准高斯分布中采样的随机值， τ 是



人工设置的温度参数。*Gumbel – Softmax* 操作通过提供一种连续的分布来近似从分类分布中的采样，同时允许反向传播算法通过采样过程，从而使得对于离散图结构提示的优化可导。

(2) 基于图提示注入的图数据增强

然后，在得到可训练的图提示 $G' = (Z, S)$ 后，通过插入图提示，可以为下游图中的节点添加额外的特征信息，同时通过在图中引入新的边（基于提示信息），可以修改或增强图的拓扑结构。可以帮助模型更好地理解每个节点的属性和捕捉节点间的关系。图提示可以作为一种先验知识，引导模型学习过程中重点关注某些特定的节点或路径，帮助模型学习到更加符合下游任务的表示和决策，提升对下游图的理解和快速适应，进而可以提高迁移的泛化和适应能力。

本项目拟开发一种可训练的图提示注入数据增强技术。定义注入函数，指示如何将图提示 G' 添加到输入下游图 G 中，操作后的图表示为 $G'' = f(G, G')$ 。首先将图提示和下游图进行合并操作，即 $G' = (V \cup Z, E \cup S)$ 。接着定义图提示和下游图之间的边，同样使用基于图结构学习的思路定义边的权重，计算下游图节点表示 x_i 和图提示之间的相似度，利用 *Gumbel – Softmax* 函数近似从边的分布中的采样，设定阈值选取概率较大的边。通过前述的设计，图属性提示和结构提示能够被有效地注入到下游的图数据中。在微调过程中，预训练模型的参数通常会被冻结以保持之前学习到的知识，而与图提示相关的参数则会在下游任务的指导下进行训练和优化。这一训练过程专注于调整提示参数，以便更好地适应例如提高节点分类的准确度或优化链接预测的性能。

(3) 基于图原型的图任务提示微调

最后，在下游图任务层面，本项目引入图原型来设计图任务提示，原型是指代表一类子图或图模式的典型例子。这种提示的目的是在图预训练模型的微调中引入这些原型以改善模型对于特定任务的处理能力，它利用图的子结构来捕捉重要的拓扑信息和节点特征。

本项目拟开发一种基于图原型的图任务提示技术。以节点分类下游任务为例，首先得到图预训练网络编码图 G'' 中每个节点的表示向量，然后应用聚类算法（如 k-means）对这些表示向量进行分组。每个聚类的中心节点，即与聚类质心最接近的节点，被选作原型。计算 $C_k = \arg \min_{v_i \in V} |f(v_i) - \mu_k|^2$ ，其中 $f(v_i)$ 是节点的表示向量， μ_k 是聚类 k 的均值，这样可以得到所有原型节点的集合 C 。然后选择这些节点的子图：

$$V(C) = \{d(u, v) \leq \beta | u \in V\}, \quad and$$

$$E(C) = \{(u, u') \in E | u \in V(C), u' \in V(C)\}$$

最终，把这些原型子图作为图任务提示，可以将每个节点与这些图任务提示进行相似性比较得到其最可能的类别，即 $l_v = \arg \max_{c \in C} sim(f(v_i), f(c))$ 。在微调训练过程中，可以结合分类损失和在图原型上的对比学习优化可训练图提示。在下游任务中没有标注时，可以只使用自监督对比学习进行优化。

3.1.2 基于适配融合的多模态图提示微调方法

本部分利用图提示作为多模态知识融合手段，针对具有复杂属性的图，设计轻量级的适配器模块并将其插入到不同模态预训练模型的特定层中，并利用多模态图提示对比学习融合多模态知识。基于大语言模型增强的图任务微调进一步提升了对任务类别语义知识的利用。整体研究方案如图 4 所示：




图 4. 基于适配器的多模态图提示微调方法研究方案

(1) 基于适配器的模态表示融合模型

首先，现实世界的图中节点属性往往具有的复杂多模态信息，例如，社交网络和推荐系统网络上的内容可能同时包含文本和图像，而科研文章可能包含丰富文本等。本项目针对每种模态使用相应的预训练模型来得到其表征。例如，对于文本模态，使用基于 Transformer 的模型 GPT 或 LLaMA 来提取文本特征；对于图像模态，使用 Vision Transformer (ViT) 来提取图像特征。此外，CLIP 模型提供了一种处理文本和图像模态的统一方式，通过对齐文本和图像的表达空间，使得不同模态之间的信息可以更加容易地关联起来。

由于每个预训练模型通常会将数据映射到不同的表示空间，本项目拟开发一



种基于适配器的模态表示方法，引入适配器（Adapter）网络修改不同模态表示的分布，使它们在同一表示空间内，从而可以更有效地进行信息融合。具体来说，适配器网络通过一系列可学习的变换层来调整原始模态特征的分布。适配器包含多个线性变换层和非线性激活函数，被插入在图预训练模型的每一层中，并且针对不同的模态具有特定参数，公式如下所示：

$$\hat{x}^l = \text{FeedForward_down}(x^l)$$

$$\hat{x}^l = \text{NoLiner}(\hat{x}^l)$$

$$x^{l+1} = \text{FeedForward_up}(\hat{x}^l)$$

其中 x^l 为第 l 层的输入。为了进一步融合经过适配器网络处理的模态特定表示，可以使用交叉注意力网络（Cross-Attention Networks）。使得模型在处理一种模态的同时，考虑到另一种模态的上下文信息，从而实现更加细致和深入的信息融合。具体来说，交叉注意力网络通过计算不同模态特征之间的注意力分数，来动态地调整各模态特征的权重，使得相关联的特征可以被突出表示，而不相关的特征则被抑制。

（2）多模态图提示对比学习

其次，本项目拟研究一种基于多模态图提示的对比学习模型来指导多模态属性融合。先针对每个模态设计并插入模态特定的提示。这些提示旨在捕捉模态特有的特征和信息，使用上述适配器网络和交叉注意力机制处理每个模态的提示，将它们融合为统一的节点属性提示。将融合后的节点属性提示整合到图提示中，形成一种有效的多模态图提示（Multimodal Graph Prompt），用于增强多模态图数据的表示能力。

为了学习融合多模态表示，使用图结构本身作为信号，基于相邻节点之间的信息相关性，采用对比学习策略对齐不同模态表示。该方法认为图中相邻的节点应该具有相似的表示，利用对比学习强化这种相似性，从而融合和对齐不同模态的知识。对比学习的公式可以简化表示为：

$$L = -\log \frac{\exp(\text{sim}(z_i, z_j)/\tau)}{\sum_{k=1}^N \exp(\text{sim}(z_i, z_k)/\tau)}$$

其中， z_i 和 z_j 是相邻节点的表示， z_k 是负样本的表示， $\text{sim}(z_i, z_j)$ 是相似度函数，如余弦相似度， τ 是温度参数，控制软化程度。在整个多模态融合过程中，图预训练模型的参数被冻结，不同模态的提示以及用于生成这些提示的适配器网络参数被同时优化。这样做的目的是图预训练模型能够更好地适应于下游任务时，通过细致的模态间信息融合和对齐，提高模型对复杂数据结构和多模



态信息的理解能力。

(3) 大语言模型增强图任务提示微调

最后，下游图任务中的标签语义信息往往被人忽视。而这些信息实际上富含有用的上下文和含义，能够为模型提供额外的指导。传统方法倾向于将标签简单地转换成独热（One-hot）编码形式，这种做法虽然简单，但忽略了标签本身所蕴含的丰富语义信息，限制了模型理解和利用这些信息进行更有效决策的能力。

本项目拟研究一种基于大语言模型增强的图任务提示微调方法。首先，将标签信息以文本提示的形式加入到大语言模型中。这一步骤允许模型直接处理标签的文本描述，从而获得关于标签的丰富语义表示。例如，对于文档节点分类任务中的“图机器学习”标签，我们可以将其描述性文本“这是一篇主题为图机器学习的文档”作为提示输入到大语言模型中。通过大语言模型处理上述文本提示后，得到每个标签的深层语义表示，将基于图任务提示的标签表示与基于多模态图提示的节点表示进行相似度计算 $l_v = \arg \max_{c \in C} \text{sim}(f(v_i), g(c))$ ，确定每个节点最可能属于的类别。

这种方法超越了传统的独热编码，使模型能够捕捉和利用标签的内在含义。通过理解标签的深层次语义，模型能够更好地处理未见过的样本或者那些在训练过程中较为罕见的类别，从而提高其泛化能力。在训练过程中，标签的表示同样可以作为对比学习中的节点的正样本，优化提示参数进而增强迁移学习过程中对多种模态知识的融合能力。

3.1.3 基于可控适应的跨域图提示微调方法

本部分利用图提示的条件控制机制，针对图预训练模型的跨域适应，设计基于条件控制网络的跨域图提示，实现预训练模型可控迁移。同时利用跨域图分布对齐方法和目标图域自适应学习，显著消除分布差异并提高模型在特定下游任务上的适应性。整体研究方案如图 5 所示：

(1) 条件控制图提示生成模型

首先，图预训练模型进行迁移时下游数据往往与训练数据具有分布差异，这叫做分布外（Out-of-Distribution）问题。例如学术网络中，文科领域和理科领域的学者节点在合作模式和文本主题属性上都有着显著的不同；同一领域内不同的时期间图的分布差异也十分明显，这种跨域的分布差异是导致预训练模型泛化能力不足的一个关键因素。




图 5. 基于条件控制网络的跨域图提示微调方法研究方案

本项目拟研究一种基于条件控制的图提示生成方法。引入了针对图数据的条件控制网络 *GraphControl()*，该网络能够获取到显式的下游图分布信息。条件控制网络通过一个条件生成过程，利用下游特定的图属性信息来生成条件。这一过程的核心在于利用核函数 $kernel(z_i, z_j)$ 或相似度度量，来衡量不同节点间的相似性，从而生成一个特征邻接矩阵。该矩阵不仅反映了节点间的关系，还整合了下游任务的特定属性，为模型提供了一种显式的图分布信息。

生成的条件信息作为跨域图提示（Cross-domain Graph Prompt）加入到下游图中，作为跨域图数据增强技术。在训练过程中，这使得预训练模型能够更精准地感知到分布差异，更好的识别不变（Invariant）特征，从而提高在目标任务上的性能和泛化能力。

（2）基于对抗学习的跨域图分布对齐

接着，在条件控制跨域图提示的基础上，实现下游图在表征层面与预训练图的分布对齐，实现预训练模型在参数冻结情况下对下游图数据的适应能力。这主要通过分布对齐的优化目标更新条件控制网络，进而引导图预训练模型理解更加通用的特征表达实现的。

本项目拟研究一种基于对抗学习的跨域图分布对齐方法。对抗学习是一种通过训练生成器和判别器进行竞争来优化模型性能的方法。在跨域图分布对齐的场景中，可以采用简单的对抗学习框架，其中条件控制网络和图预训练模型作为生成器 $G(x)$ 负责调整目标图的节点表示，使其更接近预训练图的节点表示分布，而判别器 $D(x)$ 则尝试区分调整后的目标图表示和预训练图表示。



$$\min_G \max_D E_{x \sim G_{\text{预训练}}} [\log D(x)] + E_{z \sim G_{\text{下游}}} [\log (1 - D(G(z)))]$$

其中 $G_{\text{预训练}}$ 和 $G_{\text{下游}}$ 分布代表采样的部分预训练图和下游图数据。通过这种方法，生成器不断学习生成更符合预训练图分布的目标图表示，而判别器则努力识别出生成的表示和真实的预训练图表示之间的差异。通过不断的迭代，最终使得目标图的节点表示与预训练图节点表示在分布上对齐。

(3) 基于条控图提示的自适应微调

最后，在下游图任务层面，目标是使得融合了跨域图提示的下游图节点表示能够更好的适应于下游任务，尤其是在下游任务标签缺失的情况下。这样的问题被称作零样本（Zero-shot）提示微调，尤其在大语言模型的下游应用中，零样本提示微调成为了主流的方法，这能极大地提高预训练模型的迁移应用效率。

本项目拟研究一种基于条件控制图提示的预训练模型自适应微调方法，在不需要下游任务样本标签的情况下，完成对图预训练模型无监督自适应的知识迁移。该方法以跨域图提示作为优化参数，在融合了跨域图提示的下游图节点表示上进行优化，提出一种基于节点普适性权重的概率信息最大化损失函数：

$$L = -E_{v \in V^t} \left[\hat{s}_v \sum_{k=1}^C p_{v,k} \log(p_{v,k}) \right]$$

其中 V^t 是下游图的节点集合， p_v 是节点的概率输出， $\hat{s}_v$ 代表节点的普适性权重，接近其类别的结构重心的节点 v 将具有高完整性分数，反之亦然。通过优化 L ，模型优先考虑具有高分类置信度的节点，减少对潜在噪声节点的关注，确保处理未标记数据时更好地准确性，同时增强了模型的判别和适应能力。

3.2 可行性分析

(1) 符合国家政策支持和市场需求。

中国发布的《新一代人工智能发展规划》明确提出，要加快人工智能基础研究和应用研究，推动人工智能与实体经济深度融合。国家“十四五”规划中提出要迎接数字时代，激活数据要素潜能，提出“充分发挥海量数据和丰富应用场景优势，促进数字技术与实体经济深度融合，赋能传统产业转型升级，催生新产业新业态新模式，壮大经济发展新引擎”。这对大数据的信息抽取和挖掘分析相关的支撑技术都提出了较高要求。近年来，预训练大模型逐渐兴起，在许多领域引起了越来越多的关注，如自然语言处理，计算机视觉，以及图数据挖掘。近期，由 OpenAI 推出的预训练大型语言模型 ChatGPT 在人机对话上也展示出了惊人的能力，证明了预训练模型的潜力，预训练模型及微调应用成为了大数据的高效信



息抽取和挖掘分析的核心人工智能技术。因此，在海量图数据不断产生的当下，研究面向大规模多模态图数据的预训练大模型同样有着重要意义。

同时，随着大数据时代的到来，各类数据的处理和分析需求日益增加。图数据作为一种重要的数据结构，广泛存在于社交网络、推荐系统、知识图谱等领域。基于图的预训练模型能够有效处理这类数据，提高数据分析的效率和准确性，市场对此类技术的需求强烈。企业和组织面临的诸多问题，如用户行为预测、欺诈检测、智能推荐等，都可以通过利用图神经网络技术来解决。该项目的研究成果能够帮助企业更好地理解 and 利用其数据，从而在激烈的市场竞争中获得优势。当前市场上对新技术的接受度高，特别是能够带来明显效益提升的技术。基于图的预训练模型和迁移学习技术的研究，可以推动人工智能技术的创新，满足市场对高效、智能解决方案的追求。

(2) 本项目构成了申请人先前研究工作的延伸，申请人在此领域内拥有丰富的研究背景和技术基础。

本项目申请人一直从事人工智能、数据挖掘相关方法的研究，长期主要专注于图迁移学习、图预训练模型，图神经网络等图学习相关领域的研究，并取得了优秀的成果。申请人的博士论文题目为《融合邻域信息的网络表示学习算法研究》，针对传统图数据、异质图、知识图谱等开展了预训练图表示学习模型的研究，具有扎实的相关理论研究和实践基础；申请人的博士后研究项目的题目为《大规模异质网络数据挖掘及应用研究》，包括了高效图神经网络、图迁移学习，图小样本学习等研究课题，是本项目研究的前序研究和技术储备。申请人近五年以第一作者身份在 IJCAI、AAA、TWEB、TBD、ICDM 等本领域学术期刊和会议发表图学习相关学术论文 6 篇，另共同第一作者论文 3 篇；基于图核神经网络的 POI 推荐为主题的论文入选 ICDM 2022 最佳排名论文 (Best ranked papers) 之一，基于图表示学习的姓名消歧算法获 2019 年 Biendata 数据竞赛金奖 (1st/131)；另外，申请人与中国科学院大学、香港科技大学 (广州)、加利福尼亚大学洛杉矶分校、亚利桑那州立大学的合作者保持密切的交流合作，为研究提供扎实的理论基础。申请人与阿里巴巴、腾讯等科技公司也保持着深入交流合作，相关合作研究与本项目直接相关，为项目完成提供了丰富的应用场景。基于以上分析，申请人前期的研究和积累为开展本项目研究打下了坚实理论和应用基础，为本项目的成功实施提供了可靠保证。



(3) 研究目标和内容切实可行，技术路线清晰合理，论证充分可信。

本项目开展了基于提示微调技术的图预训练模型迁移学习的创新性研究，立足于坚实的研究基础，并设定了明确的研究目标。研究通过三个相互关联的模块构建了一个从基础层、跨模态到跨域的自底向上的技术体系，旨在整合图提示数据增强、融合适配和可控适应的技术优势，提升图预训练模型的泛化性和适应性。首先，该项目致力于解决传统微调方法在迁移学习应用中泛化能力不足的问题，推动图提示微调方法的效率和效果，增强图预训练模型的迁移适应性。接着，项目利用多模态图提示技术高效地融合下游图数据中的多模态语义信息，以此实现在具有复杂属性的图上进行知识融合。最后，项目旨在提高预训练模型对跨域图数据显著差异的适应性，从而增强其在跨模态和跨领域迁移学习中的泛化与适应能力。项目各部分紧密相连，构成一个完整的研究循环，每个研究环节都有明确的焦点和具体的内容，相互支持，共同推进。项目设计借鉴了相关的前期研究成果，例如 Sun 等获得 KDD 2023 最佳论文奖的 All in One 图提示模型和 Liu 等 (WWW 2023) 提出的 GraphPrompt 等工作最早作出了图提示微调研究的探索，为本项目的研究提供了基础。本项目同时充分借鉴了其他相关领域的研究基础，通过数据增强、融合适配和可控适应等技术作为研究的切入点，有效整合了多个方向的研究优势，明确了跨模态和跨领域图预训练模型迁移学习的技术路径，确保了技术实施的针对性和可操作性。

4. 本项目的特色与创新之处；

本项目主要特色与创新之处在于研究思路和研究方法。目前的传统的图训练模型迁移学习模型面临泛化性和适应性不足的问题，本项目提出使用图提示微调的研究思路来提升迁移学习的效果。同时，国内外基于图提示微调的图预训练模型迁移学习研究仍然处于初级阶段，本项目从数据增强、融合适配和可控适应等新的研究方法作为切入点，提升图预训练模型的泛化性和适应性。

项目的特色与创新之处体现在如下三个方面：

(1) 研究基于图数据增强的图提示微调方法，自动生成和注入高效的图提示，提升图预训练模型的泛化能力。不同于现有的图提示方法通常在节点属性层面引入可训练的提示向量，忽略相对于图拓扑结构的提示设计的问题。研究基于图结构学习的图提示生成模型，实现可训练的具备属性和结构的图提示，并基于图提示注入实现图提示针对于下游任务的图数据增强，最后借助图原型方法作



为任务提示，实现面向高效适应下游任务的图预训练模型提示微调方法。

(2) 研究基于适配融合的多模态图提示微调方法，实现多模态图上的预训练模型高效适配融合适应。不同于现有的图提示方法通常只关注于传统的带有数值属性的图数据，难以利用多模态的语义知识的问题。研究基于适配器的模态表示融合模型，设计多模态图提示并利用图结构作为对比学习的监督信号，实现面向图预训练模型的模态间信息融合和对齐，同时利用大语言模型增强的图任务提示，最终实现适配融合多模态知识的图预训练模型提示微调方法。

(3) 研究基于可控适应网络的跨域图提示微调方法，实现在明显分布差异下的预训练模型跨域图自适应。不同于现有的图提示工作往往只借助图提示来隐式的弥补分布差异，不足以充分捕捉和适应复杂的结构变化和关系模式的差异的问题。研究基于条件控制网络的图提示生成模型，实现对分布差异的精细感知，并基于对抗学习的跨域图分布对齐，实现消除分布差异，最后基于条控图提示的实现跨域自适应微调，最终实现具有显著分布差异的跨域图预训练模型提示微调方法。

5. 年度研究计划及预期研究结果（包括拟组织的重要学术交流活动、国际合作与交流计划等）。

5.1 年度研究计划

本项目计划三年完成，各年度具体计划如下：

年度	研究计划
2025 年 1 月-12 月	1) 对国内外图迁移学习相关领域最新研究成果进行深入调研和分析； 2) 与国内外专家学者进行广泛交流、制定总体研究方案； 3) 针对第一个研究点展开研究，设计基于结构学习的图提示生成模型、基于图提示注入的图数据增强方法、基于图原型的图任务提示微调方法； 4) 完成至少 3 篇高水平论文的投稿，并至少申请发明专利 1 项；
2026 年 1 月-12 月	1) 针对第二个研究点展开研究，设计基于适配器的模态表示融合模型、多模态图提示对比学习方法和大语言模型增强图任务提示微调方法；



	2) 完成至少 4 篇高水平论文的投稿, 并至少申请发明专利 1 项; 3) 邀请国内专家交流 1 次; 4) 参加国际会议 1 次(如 NeurIPS, ICML, AAAI, IJCAI, KDD, WWW 等);
2027 年 1 月-12 月	1) 针对第三个研究点展开研究, 设计条件控制图提示生成模型、基于对抗学习的跨域图分布对齐方法和基于条控图提示的自适应微调方法; 2) 完成至少 3 篇高水平论文的投稿, 并至少申请发明专利 1 项; 3) 邀请国内专家交流 1 次; 4) 融合三年研究成果, 形成图提示学习网络算法包; 5) 对研究成果进行归纳, 准备项目验收材料。

5.2 预期研究成果

(1) 完成基于图数据增强的图提示微调方法、基于适配融合的多模态图提示微调方法、基于可控适应的跨域图提示微调方法三个研究点的全部研究任务, 在常用基准及开放场景数据集上进行验证。

(2) 并形成具有较高水平的学术研究成果, 于国内外本领域重要学术期刊和会议 (CCF-B 及以上) 发表论文 6-8 篇以上。

(3) 申请国内或国际发明专利不少于 3 项。

(4) 参加国际会议交流和报告项目的研究成果不少于 2 次。

(5) 形成可解释神经网络算法包 1 个。

(6) 参与培养研究生 3-6 人。

(7) 提交研究成果总结报告。

(二) 研究基础与工作条件

1. 研究基础 (与本项目相关的研究工作积累和已取得的研究工作成绩);

申请人乔子越于 2017-2022 年师从周园春研究员在中国科学院计算机网络信息中心硕博连读并获得计算机应用技术博士学位。2022 年以博士后研究员身



份加入香港科技大学(广州)人工智能学域熊辉教授(IEEE Fellow, AAAS Fellow)科研团队继续开展图学习研究。申请人于 2024 年加入大湾区大学(筹)信息科学技术学院,担任助理教授,开展人工智能、数据挖掘中图机器学习相关的研究。

申请人长期主要专注于图迁移学习、图预训练模型,图神经网络等图学习相关领域的研究,并取得了优秀的成果。申请人的博士论文题目为《**融合邻域信息的网络表示学习算法研究**》,针对传统图数据、异质图、知识图谱等开展了预训练图表示学习模型的研究,具有扎实的相关理论研究和实践基础;申请人的博士后研究项目的题目为《**大规模异质网络数据挖掘及应用研究**》,包括了高效图神经网络、图迁移学习,图小样本学习等研究课题,是本项目研究的前序研究和技术储备。申请人近五年以第一作者身份在 IJCAI、AAAI, ICDM 等人工智能领域权威学术会议和 IEEE TBD、ACM TWEB 等数据挖掘领域权威学术期刊发表和录用图学习相关一作学术论文 6 篇,另有共同第一作者论文 3 篇,其他合作论文 10 篇,申请相关专利 9 项;基于图神经网络的 POI 推荐为主题的论文入选 ICDM 2022 最佳排名论文(Best ranked papers)之一,基于图表示学习的姓名消歧算法获 2019 年 Biendata 数据挖掘竞赛金奖(1st/131);获得中国国家留学基金委(CSC) 2020 年度博士联合培养公派出国留学奖学金,中国科学院院长优秀奖,北京市优秀毕业生奖,博士生国家奖学金,中国科学院优秀毕业生奖等奖项。

本项目申请人具有良好的数学理论基础、良好的计算机编程和算法分析能力。在图神经网络、图表示学习、图预训练模型、迁移学习研究等方面已经积累了一些和本项目相关的研究成果,以下举例说明:

(1) 申请人在图表示学习算法上有丰富的应用实施经验。图表示学习的自监督学习是图预训练模型的必要技术,是本项目的核心前提技术。

在社交网络分析中,同名消歧一直被视为一个很有意义但具有挑战性的问题。例如在学术网络中,由于不同的研究者可能拥有相同或极其相似的名字,这就导致了在引文和出版物中正确识别和区分个体的困难。这种情况下,准确地将论文和成果归属于正确的作者变得尤为重要,但同时也非常复杂。针对这一问题,申请人提出了一种提出了一种高效基于图表示学习的姓名消歧方法,如图 6 所示,通过构建论文直接的关系网络,使用基于元路径随机游走的异质网络嵌入方法结合语义表征学习方法学习节点的表征向量,并使用基于 DBSCAN 与规则匹配结合的聚类方法完成论文到作者的准确分配,达到消歧的效果。该方法在 2019

Biendata 竞赛平台 “OAG-WhoIsWho”数据挖掘比赛中从 131 个队伍中脱颖而出，以较大的领先优势获得第 1 名的成绩。




图 6 基于图表示学习的社交网络姓名消歧方法框架

(2) 申请人在图神经网络的研究中具有扎实的研究基础。图神经网络是图预训练模型最常用的骨干网络 (Backbone)，是本项目的核心前提技术。

传统的图神经网络 (GNN) 在处理异构图时面临挑战，因为它们通常将不同类型的节点信息聚合到同一特征空间中，忽略了节点间的类型差异和结构层次。申请人提出了一种新型图神经网络—树结构感知图神经网络 (T-GNN)。如图 7 所示，T-GNN 模型通过两个主要模块解决这一问题：集成的层次聚合模块和关系度量学习模块。第一个模块通过结合 GNN 和门控循环单元 (GRU)，来保留树状结构中的层次和序列邻域信息。第二个模块旨在通过将不同类型的节点嵌入到具有独立分布的类型特定空间中，来保留节点间的异质性。通过广泛的实验验证，T-GNN 在节点聚类、分类、归纳式节点聚类和分类以及链接预测任务上展现了优越的性能。相关研究成果发表在数据挖掘顶级会议 2020 IEEE International Conference on Data Mining 上，并被协同过滤经典算法 Item-KNN 和图划分经典算法 METIS 的作者明尼苏达大学杰出教授 George Karypis 在其论文 的模型设计中引用。




图 7 树结构感知的图神经网络

(3) 申请人在图预训练和微调模型的研究上已有相关研究成果，与本项目的研究内容密切相关。

申请人提出了针对学术网络的图预训练模型（RPT），并将其迁移到多种学术网络分析和数据挖掘的下游任务中。如图 8 所示，通过将学术网络数据分为语义文档集和社区网络两部分，并设计层次化文本 Transformer 和局部社区 GNN 编码器分别从这两类数据中捕获信息。论文提出了三个自监督学习目标来训练整个模型，并通过对比学习来验证这些捕获的信息是否属于同一实体。此外，还引入了两个辅助任务：层次化掩码语言模型和社区关系预测，以提取语义和社区信息，并改进预训练。最后，通过在 DBLP、ACM 和 MAG 数字图书馆中提取的大型学术网络数据集上预训练 RPT，并在三个下游任务上进行微调，验证了该预训练对学术网络下游任务的有效性。相关研究成果 2022 年发表在了数据挖掘权威期刊 IEEE Transactions on Big Data (JCR-1 区, IF 7.2) 上。




图 8 融合多模态信息的学术网络预训练和微调模型

(4) 申请人在图跨域迁移学习的研究上也取得了相关成果，与本项目的研究内容密切相关。

申请人提出了一种图域适应方法（SGDA），旨在解决将预训练模型从源图向未标记的目标图转移知识的问题。由于图的拓扑和属性通常具有显著的跨域差异，而且在真实世界场景中，目标图中的节点可能缺失标记，这对图迁移学习提出了严峻挑战。SGDA 通过添加自适应偏移参数和对抗性学习来解决域偏移问题，同时采用基于节点后验分数的伪标签技术来缓解标签稀缺问题，改进目标图上的分类性能。通过在多个公开数据集上的实验验证了 SGDA 在不同实验设置下的有效性。文章中提出的“自适应偏移参数”可以看作是图提示的一种雏形，用于修改图分布并对图数据增强。相关成果发表在 2023 International Joint Conference on Artificial Intelligence (CCF-A) 上，同时两篇延续工作也在投稿中。




图9 图跨域迁移学习框架

除此之外，申请人在与本项目相关的图数据增强[SCIS 2024 、ICDM 2022]、图多模态学习[TKDE 2023]、知识图谱表示学习[AAAI 2021, IJCAI 2023]上具有丰富研究经验。综上所述，本项目是前期研究工作进一步的自然延伸和深度拓展。项目申请人具有良好的科研创新精神和承担科研项目的能力，为本项目的顺利完成提供了强有力的保证。

2. 工作条件（包括已具备的实验条件，尚缺少的实验条件和拟解决的途径，包括利用国家实验室、国家重点实验室和部门重点实验室等研究基地的计划与落实情况）；

本项目的依托单位大湾区大学是在国家粤港澳大湾区建设背景下创建的一所以理工科为主的新型高水平研究型大学。大湾区大学贯彻《粤港澳大湾区发展规划》的重大战略举措，是由广东省人民政府举办、东莞市政府投入保障为主的公办普通高等学校。立足湾区、面向世界、着眼未来开展办学，致力于打造科教融合、产教融合、湾区融合、面向前沿的高等学府。学校坐落在广东东莞松山湖科学城和滨海新区，重点聚焦物质科学、理学、信息科学技术、先进工程、生命科学、金融管理等6个领域，开展本科生、硕士及博士研究生全日制学历教育。学校将从实验场地、团队组建等方面给予申请人全方位支持，包括：

1. 提供足够的实验和办公空间：学校松山湖校区选配科研实验用房约25000平方米，选配校校、校企合作用房约26000平方米、选配产学研用房约20000平方米。本项目承担单位提供现有设备包括PC、服务站和办公用房的使用、维护以及管理费用，保障项目部分任务的执行。

2. 提供充足的团队支撑保障：学校提供充足经费支持教研人员招聘博士后和研究助理，帮助申请人组建团队。同时，还支持与国内外知名高校联合办学，共同联合培养博士生、硕士生。同时，大湾区大学已与北京大学、香港中文大学、



松山湖材料实验室等高校和机构合作共享共建研究院、实验室，全力保障申请人开展高水平科学研究。同时大湾区大学与同在松山湖的华为技术有效公司等工业界实体保持着密切的交流。

3. 硬件设施和数据资源支持：学校能够提供项目开展所需基础设备，拥有丰富的计算 GPU 计算资源和研究条件，可满足项目的模型训练需求，为项目的顺利开展奠定坚实的基础。也可通过松山湖材料实验室等周边高端科技平台资源合作共享提供设备支持。本项目利用网络上丰富的开源数据，前期已下载整理拥有百万节点的学术网络、商品网络等图数据，提供了充足的数据支撑。

申请人及所在团队对本项目的准备是充分的，申请人相信，在前期的研究基础以及现有的工作条件下，能够在基于图提示微调的图预训练模型迁移学习研究方面取得高水平的理论与应用成果。

3. 正在承担的与本项目相关的科研项目情况（申请人正在承担的与本项目相关的科研项目情况，包括国家自然科学基金的项目和国家其他科技计划项目，要注明项目的资助机构、项目类别、批准号、项目名称、获资助金额、起止年月、与本项目的关系及负责的内容等）；
无。

4. 完成国家自然科学基金项目情况（对申请人负责的前一个已资助期满的科学基金项目（项目名称及批准号）完成情况、后续研究进展及与本申请项目的关系加以详细说明。另附该项目的研究工作总结摘要（限 500 字）和相关成果详细目录）。

无。

（三）其他需要说明的情况

1. 申请人同年申请不同类型的国家自然科学基金项目情况（列明同年申请的其他项目的项目类型、项目名称信息，并说明与本项目之间的区别与联系）。

无。

2. 具有高级专业技术职务（职称）的申请人是否存在同年申请或者参与申请国家自然科学基金项目的单位不一致的情况；如存在上述情况，列明所涉及人员的姓名，申请或参与申请的其他项目的项目



类型、项目名称、单位名称、上述人员在该项目中是申请人还是参与者，并说明单位不一致原因。

无。

3. 具有高级专业技术职务（职称）的申请人是否存在与正在承担的国家自然科学基金项目的单位不一致的情况；如存在上述情况，列明所涉及人员的姓名，正在承担项目的批准号、项目类型、项目名称、单位名称、起止年月，并说明单位不一致原因。

无。

4. 其他。

无。



乔子越（BRID: 00580.00.87611）简历

2024版

大湾区大学（筹），信息科学技术学院，研究员

教育经历：

- (1) 2017-09 至 2022-06，中国科学院大学，计算机应用技术，博士
- (2) 2013-09 至 2017-07，武汉大学，计算机科学与技术，学士

博士后工作经历：

- (1) 2022-06 至 2024-03，广州市香港科大霍英东研究院

科研与学术工作经历（博士后工作经历除外）：

- (1) 2024-03 至 今，大湾区大学（筹），信息科学技术学院，研究员
- (2) 2021-05 至 2021-10，阿里巴巴，达摩院，研究实习员

曾使用其他证件信息：

无

近五年主持或参加的国家自然科学基金项目/课题：

无

近五年主持或参加的其他科研项目/课题（国家自然科学基金项目除外）：

- (1) 广州市人力资源和社会保障局；广州南沙区人才发展局，博士后科研项目经费，无，大规模异质网络数据挖掘及应用研究，2022-08 至 2024-03，30万元，结题，主持
- (2) 腾讯控股有限公司，横向项目，无，CRM系统大数据挖掘服务，2022-11 至 2023-02，100万元，结题，参与
- (3) 中华人民共和国科学技术部，科技部创新方法工作专项，2019IM020100，基于群智理论的创新方法新系统研究与应用示范，2019-12 至 2021-11，150万元，结题，参与

代表性研究成果和学术奖励情况（填写代表性论文时应根据其发表时的真实情况如实规范列出所有作者署名，并对本人署名情况进行标注，包括：①作者署名按姓氏排序；②唯一第一作者；③共同第一作者；④唯一通讯作者；⑤共同通讯作者；⑥其他情况）：

一、代表性论著（请在“申请书详情”界面，点开“人员信息”-“代表性成果”卡片查看对应的全文）：

- (1) Ziyue Qiao; Yanjie Fu; Pengyang Wang; Meng Xiao; Zhiyuan Ning; Yi Du; Yuanchun Zhou ; RPT: Toward Transferable Model on Heterogeneous Researcher Data via Pre-Training, *IEEE Transactions on Big Data*, 2022, 9(1): 186-199 （期刊论文）（本人标注：唯一第一作者）
- (2) Ziyue Qiao; Pengyang Wang; Pengfei Wang; Zhiyuan Ning; Yanjie Fu; Yi Du; Yuanchun Zhou; Jianqiang Huang; Xian-Sheng Hua; Hui Xiong ; A Dual-Channel Semi-Supervised Learning Framework on Graphs via Knowledge Transfer and Meta-Learning, *ACM Transactions on the Web*, 2023 （期刊论文）（本人标注：唯一第一作者）
- (3) Ziyue Qiao; Xiao Luo; Meng Xiao; Hao Dong; Yuanchun Zhou; Hui Xiong ; Semi-supervised Domain Adaptation in Graph Transfer Learning, *2023 International Joint Conference on Artificial*



Intelligence (IJCAI), <https://ijcai-23.org/>, 2023-08-19至2023-08-25 (会议论文) (本人标注: 唯一第一作者)

(4) Ziyue Qiao; Zhiyuan Ning; Yi Du; Yuanchun Zhou ; Context-Enhanced Entity and Relation Embedding for Knowledge Graph Completion, *Proceedings of the AAAI Conference on Artificial Intelligence*, <https://aaai.org/conference/aaai/aaai-21/>, 2021-2-2至2021-2-9 (会议论文) (本人标注: 唯一第一作者)

(5) Ziyue Qiao; Pengyang Wang; Yanjie Fu; Yi Du; Pengfei Wang; Yuanchun Zhou ; Tree Structure-Aware Graph Representation Learning via Integrated Hierarchical Aggregation and Relational Metric Learning, *IEEE International Conference on Data Mining*, <http://39.104.72.142:8080/icdm2020/>, 2020-12-17至2020-12-20 (会议论文) (本人标注: 唯一第一作者)

二、论著之外的代表性研究成果和学术奖励:

(1) Ziyue Qiao(1/2); Biendata OAG - WhoIsWho track 1 人工智能竞赛金奖 (1st/131), Biendata Competitions, 科研竞赛, 其他, 2019(Ziyue Qiao; Hanxue Wang) (科研奖励)

(2) Ziyue Qiao(3/7); ICDM 2022 Best-Ranked Papers, 2022 IEEE International Conference on Data Mining (ICDM), 其他, 其他, 2022(Wei Ju; Yifang Qin; Ziyue Qiao; Xiao Luo; Yifan Wang; Yanjie Fu; Ming Zhang) (科研奖励)



附件信息

序号	附件名称	备注	附件类型

（草稿） 请于提交后重新下载PDF的正式稿



项目名称： 基于图提示微调的图预训练模型迁移学习方法研究
资助类型： 青年科学基金项目
申请代码： F0605. 模式识别与数据挖掘

国家自然科学基金项目申请人和参与者承诺书

为了维护国家自然科学基金项目评审公平、公正，共同营造风清气正的科研生态，本人**在此郑重承诺**：严格遵守《中华人民共和国科学技术进步法》《国家自然科学基金条例》《关于进一步加强科研诚信建设的若干意见》《关于进一步弘扬科学家精神加强作风和学风建设的意见》《关于加强科技伦理治理的意见》以及科技部、自然科学基金委关于科研诚信建设有关规定和要求；申请材料信息真实准确，不含任何涉密信息或敏感信息，不含任何违反法律法规或违反科研伦理规范的内容；在国家自然科学基金项目申请、评审和执行全过程中，恪守职业规范和科学道德，遵守评审规则和工作纪律，杜绝以下行为：

- （一）抄袭、剽窃他人申请书、论文等科研成果或者伪造、篡改研究数据、研究结论；
- （二）购买、代写申请书；购买、代写、代投论文，虚构同行评议专家及评议意见；购买实验数据；
- （三）违反成果发表规范、署名规范、引用规范，擅自标注或虚假标注获得科技计划等资助；
- （四）在项目申请书中以高指标通过评审，在项目计划书中故意篡改降低相应指标；
- （五）以任何形式打听或散布尚未公布的评审专家名单及其他评审过程中的保密信息；
- （六）本人或委托他人通过各种方式和途径联系有关专家进行请托、游说、“打招呼”，违规到评审会议驻地窥探、游说、询问等干扰评审或可能影响评审公正性的行为；
- （七）向工作人员、评审专家等提供任何形式的礼品、礼金、有价证券、支付凭证、商业预付卡、电子红包，或提供宴请、旅游、娱乐健身等任何可能影响评审公正性的活动；
- （八）违反财经纪律和相关管理规定的行为；
- （九）其他弄虚作假行为。

如违背上述承诺，本人愿接受国家自然科学基金委员会和相关部门做出的各项处理决定，包括但不限于撤销科学基金资助项目，追回项目资助经费，向社会通报违规情况，取消一定期限国家自然科学基金项目申请资格，记入科研诚信严重失信行为数据库以及接受相应的党纪政务处分等。

申请人签字：



项目名称： 基于图提示微调的图预训练模型迁移学习方法研究

资助类型： 青年科学基金项目

申请代码： F0605. 模式识别与数据挖掘

国家自然科学基金项目申请单位承诺书

为了维护国家自然科学基金项目评审公平、公正，共同营造风清气正的科研生态，**本单位郑重承诺**：申请材料中不存在违背《中华人民共和国科学技术进步法》《国家自然科学基金条例》《关于进一步加强科研诚信建设的若干意见》《关于进一步弘扬科学家精神加强作风和学风建设的意见》《关于加强科技伦理治理的意见》以及科技部、自然科学基金委关于科研诚信建设有关规定和要求的情况；申请材料符合《中华人民共和国保守国家秘密法》和《科学技术保密规定》等有关法律法规和规章制度要求，不含任何涉密信息或敏感信息；申请材料不含任何违反法律法规或违反科研伦理规范的内容；申请人符合相应项目的申请资格；依托单位、合作研究单位、申请人及主要参与者不在限制申报、承担或参与财政性资金支持的科技活动的期限内；在项目申请和评审活动全过程中，遵守有关评审规则和工作纪律，杜绝以下行为：

（一）以任何形式打听或公布未公开的项目评审信息、评审专家信息及其他评审过程中的保密信息，干扰评审专家的评审工作；

（二）组织或协助申请人/参与者向工作人员、评审专家等给予任何形式的礼品、礼金、有价证券、支付凭证、商业预付卡、电子红包等；宴请工作人员、评审专家，或组织任何可能影响科学基金评审公正性的活动；

（三）支持、放任或对申请人/参与者抄袭、剽窃、重复申报、提供虚假信息（含身份和学术信息）等不当手段申报国家自然科学基金项目疏于管理；

（四）支持或协助申请人/参与者采取“打招呼”“围会”等方式影响科学基金项目评审；

（五）其他违反财经纪律和相关管理规定的行为。

如违背上述承诺，本单位愿接受自然科学基金委和相关部门做出的各项处理决定，包括但不限于停拨或核减经费、追回项目已拨经费、取消本单位一定期限国家自然科学基金项目申请资格、记入科研诚信严重失信行为数据库以及主要责任人接受相应党纪政务处分等。

依托单位公章：

日期： 年 月 日