



受理代码	T01
接收部门	交叉科学部
收件日期	
接收编号	9237020027



国家自然科学基金 申 请 书

(2023 版)

资助类别：	重大研究计划		
亚类说明：	重点支持项目		
附注说明：	可解释、可通用的下一代人工智能方法		
项目名称：	支持下一代人工智能的开放型高质量科学数据库		
申 请 人：	周园春	办公电话：	010-58812561
依托单位：	中国科学院计算机网络信息中心		
通讯地址：	北京海淀区东升南路2号院中科院信息化大厦1208		
邮政编码：	100083	单位电话：	010-58812267
电子邮箱：	zyc@cnic.cn		

国家自然科学基金委员会



基本信息

申请人信息	姓名	周园春	性别	男	出生年月	1975年02月	民族	汉族
	学位	博士	职称	研究员				
	是否在站博士后	否		电子邮箱	zyc@cnic.cn			
	办公电话	010-58812561		国别或地区	中国			
	申请人类别		依托单位全职					
	工作单位		中国科学院计算机网络信息中心					
	主要研究领域							
依托单位信息	名称	中国科学院计算机网络信息中心						
	联系人	王侨		电子邮箱	wangqiao@cnic.cn			
	电话	010-58812267		网站地址	www.cnic.cas.cn			
合作研究单位信息	单位名称							
	四川大学 中国科学院国家空间科学中心							
项目基本信息	项目名称	支持下一代人工智能的开放型高质量科学数据库						
	英文名称	Open and High-Quality Scientific Databases Supporting the Next Generation of Artificial Intelligence						
	资助类别	重大研究计划			亚类说明	重点支持项目		
	附注说明	可解释、可通用的下一代人工智能方法						
	受理代码	T01. 物质科学领域						
	申请代码	F0212. 数据科学与大数据计算, F0607. 知识表示与处理, G0111. 数据科学与管理						
	研究方向	科学大数据, 人工智能, 服务机制						
	研究期限	2024年01月01日 -- 2027年12月31日						
	申请直接费用	300.0000万元						
中文关键词		数据共享; 知识图谱; 知识抽取; 数据服务模式						
英文关键词		data sharing; knowledge graph; knowledge extraction; data service mode						



中文摘要	人工智能辅助科学研究（AI for Science）对科学数据的质量和数量有更加迫切的需求。具有一定规模的高质量科学数据库已成为支持科学智能的重要基础。本项目针对当前高质量通用型科学数据库应对多模态大模型训练和预测时在多模态海量数据存储管理和访问、跨尺度科学数据知识化表征、可持续科学数据共享服务模式等方面存在的瓶颈，拟通过研究面向多模态大模型训练和数据存储管理中的统一存储优化、基于预训练模型与主动学习的知识对象抽取与融合方法、基于异构标识与数据影响力评价模型的科学数据共享模式及激励机制。依托国家基础学科数据中心、中科院科学数据总中心、科学数据银行（ScienceDB）等平台的资源积累，形成可良性发展并具有一定规模和国际影响力的覆盖生命、化学、材料、遥感、空间科学等高质量、通用型的科学数据库及社区生态，为人工智能驱动的科学新范式提供基础科学数据资源服务。
英文摘要	Artificial Intelligence for Science (AI for Science) has an increasing demand for the quality and quantity of scientific data, and the high-quality scientific databases have become an essential foundation for supporting scientific intelligence. In this work, we are trying to propose new theory and system to handle the data related issues while training multimodal large model for scientific application, for example, the way to manage and access multimodal data in different places, cross-scale scientific data knowledge representation, and sustainable scientific data sharing service and incentive model. At first, we propose an uniform data model to manage different kinds of data while training multimodal large deep learning model. Then, we are provide the framework for extraction and fusion of knowledge objects based on pre-trained models and active learning. Finally, we propose a scientific data sharing and incentive model based on newly developed heterogeneous data identifiers and influence evaluation models. Based on the data resource accumulation of the National Basic Science Data Center, the Chinese Academy of Sciences Science Data Center, and the Science Data Bank (ScienceDB), we plan to establish a high-quality and general-purpose scientific database covering multiple aspects like life, chemistry, materials, remote sensing, and space science, while building the open and sustainable data sharing community with broad impact.



主要参与者（注：主要参与者不包括项目申请人）

编号	姓名	出生年月	性别	职 称	学 位	工作单位	项目分工	办公电话	证件号码
1	唐明洁	1984-08-15	男	教授	博士	四川大学	数据管理方法研究	17380556200	5*****9
2	邹自明	1971-05-15	男	研究员	博士	中国科学院国家空间科学中心	空间科学数据库构建		3*****7
3	刘峰	1974-08-18	男	研究员	博士	中国科学院计算机网络信息中心	知识对象研究		2*****3
4	王华进	1987-06-28	男	副研究员	博士	中国科学院计算机网络信息中心	数据存储方法研究	010-58812583	3*****3
5	李成赞	1982-10-05	男	高级工程师	博士	中国科学院计算机网络信息中心	数据影响力评价与社区模式研究		4*****X
6	陈昕	1982-11-20	女	高级工程师	博士	中国科学院计算机网络信息中心	服务模式研究	010-58813766	2*****X
7	刘佳	1984-12-29	女	高级工程师	硕士	中国科学院计算机网络信息中心	科学数据标识研究		3*****0
8	方少峰	1993-09-26	男	助理研究员	博士	中国科学院国家空间科学中心	空间科学数据库构建	15600602175	1*****5

总人数统计（注：包括项目申请人、主要参与者及其他参与人员；勿重复计数）

总人数	高级职称	中级职称	初级职称	博士后	博士生	硕士生	本科生及其他学生	其他
30	8	5	0	2	5	10	0	0



国家自然科学基金项目资金预算表

项目申请号：9237020027

项目负责人：周园春

金额单位：万元

序号	科目名称	金额
1	一、项目直接费用合计	300.0000
2	1、设备费	0.0000
3	其中：设备购置费	0.0000
4	2、业务费	115.8000
5	3、劳务费	184.2000
6	二、其他来源资金	0.0000
7	三、合计	300.0000

注：请按照项目研究实际需要合理填写各科目预算金额。



预算说明书

(请按照《国家自然科学基金项目申请书预算表编制说明》等的有关要求,按照政策相符性、目标相关性和经济合理性原则,实事求是编制项目预算。填报时,直接费用应按设备费、业务费、劳务费三个类别填报,每个类别结合科研任务按支出用途进行说明。对单价 ≥ 50 万元的设备详细说明,对单价 < 50 万元的设备费用分类说明,对合作研究单位资质及资金外拨情况、自筹资金进行必要说明。)

直接经费共300万,包括:

1. 设备费

无

2. 业务费,共115.8万元

(1) 燃料动力费,合计10万元:

燃料动力费主要用于服务器的电力消耗。

预计投入5台服务器进行科学数据的存储与计算。单台额定功率1.3Kw,电价按照1元/Kwh计算,3年需要电费 $5 \text{台} \times 1.3\text{Kw} \times 60\% \times 3 \text{年} \times 365 \text{天} \times 24 \text{小时} \times 1 \text{元/Kwh} \approx 10.00 \text{万元}$ 。

(2) 测试化验加工费,40万元:

由于科学数据的数据量很大,数据的获取和整理工作需要大量的人力,项目将委托单位合格供应商承担这些任务,以便项目组集中精力进行核心任务的研发。

预计数据获取和整理工作包含科学数据检索、国内科学数据下载、国外科学数据下载、文献数据检索、文献数据下载、文献内容提取、词库解析、特色数据库资源获取、结构化数据清洗、非结构化数据预处理、数据加工、数据解析、数据标注、数据质量检查、数据入库等20个功能模块,每个功能点预计2万元,合计40万元。

(3) 出版/信息传播/知识产权事务费,合计39.8万元:

发表论文20篇,出版费用约6000元/每篇,计12万元。

按照6000元/项计算,10项专利计6万元。

项目执行过程中产生的文献检索10万元。

资料购置和打印每年按6000元计,共1.8万元。

第三方数据交换费,10万元。

(4) 差旅/会议/国际合作与交流费,26万元

本项目预计差旅/会议/国际合作与交流费26万元,用于课题组成员参加国内外相关会议的交通、住宿、会议注册等费用,不超过总预算的10%。

3. 劳务费,共184.2万元

本项目涉及科学数据融合存储方法、知识对象抽取与融合、标识化、语义化知识对象构建方法研究、面向下一代人工智能的科学数据库服务模式机制研究,以及构建通用型高质量科学数据库等工作。劳务费主要用于项目成员中没有工资性收入的项目聘用、临时聘用及在读研究生的劳务支出。项目聘用人员按照12500元/人月计算。博士生按照4000元/人月,硕士生按照2500元/人月计算。预算165万元,具体分工和资金分配如下:



序号	人员类型	承担任务	劳务费标准 (万元/人/月)	工作时长 (人月)	人数(个)	小计 (万元)
1	博士研究生	参与项目中数据处理模型、知识对象提取和融合模型的实现	0.4	10	10	40
2	硕士研究生	参与项目中数据处理模型、知识对象提取和融合融合模型的实现	0.25	10	20	50
3	项目聘用研究人员	参与本项目核心技术研发	1.25	15	4	75
劳务费合计						165

本项目开展过程中, 拟举行一次技术交流活动, 3 次项目年度报告会及通讯咨询活动。其中拟组织两次技术交流活动邀请国内高级职称专家总计 40 人次, 预算经费 8.00 万元。拟定期举行年度报告会, 拟邀请高级职称专家 36 人次, 预算 7.2 万元。拟组织一次结题报告会, 预算 4 万元。专家咨询费合计 19.20 万元。

序号	咨询事由	咨询人次	资讯次数	咨询天数	人均标准 (元)	经费/万元	备注
1	技术交流活动	40	2	1	高级职称 2000 元/天	8.00	聘请国内资深专家进行专业技术交流。
3	年度报告会	36	4	1	高级职称 2000 元/天	7.20	本项目拟定期举行年度报告会。
4	结题报告会	20	1	1	高级职称 2000 元/天	4.00	本项目拟组织一次结题报告会
专家咨询费合计						19.20	

本项目依托单位中国科学院计算机网络信息中心预算 160 万元, 参与单位中国科学院国家空间科学中心预算 70 万元, 四川大学 70 万元。



报告正文

参照以下提纲撰写，要求内容翔实、清晰，层次分明，标题突出。
请勿删除或改动下述提纲标题及括号中的文字。

(一) 立项依据与研究内容（建议在 5000-10000 字之间）：

1. 项目的立项依据（研究意义、国内外研究现状及发展动态分析，需结合科学研究发展趋势来论述科学意义；或结合国民经济和社会发展中迫切需要解决的关键科技问题来论述其应用前景。附主要参考文献目录）；

本项目符合指南资助研究方向中的重点支持项目“6.支持下一代人工智能的开放型高质量科学数据库”。通过本项目，拟形成具有一定国际影响力的覆盖生命、化学、材料、遥感、空间科学等领域的高质量、通用型科学数据库，可以为人工智能驱动的科学新范式提供基础科学数据资源服务。

1.1 研究意义

近年来，数据密集型科学发现成为科学研究新范式，科学数据既是科学研究的重要产出，也是新一轮创新活动的重要驱动力。例如，DeepMind 公司于 2021 年 8 月发布的 AlphaFold 可以预测 98.5% 的人类蛋白质结构，远超出过去 50 年人类实验测量获得的数据量，对生命科学领域带来巨大冲击。AlphaFold 的成功也得益于 PDB、UniProt 等科学数据库的支撑[1]。在当前科技快速发展的时代，随着数据量的增加，科学人工智能领域对数据质量和数量的需求也越来越高。高质量通用型的科学数据库已成为支持科学人工智能（AI for Science）和进行科研新范式改革的重要一环。高质量通用型科学数据库可以为科学研究提供全面、准确和可重复的数据支持，帮助科学家们更好地理解 and 解决复杂的科学问题；还可以为人工智能算法的训练和优化提



供丰富的数据资源，帮助人工智能更好地理解 and 解决复杂的问题。数据中心人工智能（Data Centric AI）是将数据置于人工智能应用的核心，通过对数据进行治理、整理、清洗等操作，形成高质量、可靠的数据集，从而提高人工智能的效果。作为一种新型人工智能应用模式，数据中心人工智能在科学领域的应用面临以下挑战：

(1) 多模态的海量数据的存储和管理：当前对不同模态的海量数据的存储和管理任务，主要通过各类异构存储系统实现。通常，每种模态对应了一类存储系统。如文档型数据库 MongoDB 适用于存储海量文本数据，对象存储系统 Ceph OSD 适用于存储海量图片数据等。在这种模式下，对多模态数据的成对访问，需要跨越不同架构的系统，不可避免地引入了大量的数据序列化和反序列化开销，以及不同模态成对数据的匹配检索开销，显著降低了对海量多模态数据高并发成对访问的效率。

(2) 科学数据知识化服务能力：科学数据内容间存在着大量普遍关联关系目前没有被有效揭示，限制了科学数据知识化服务的发展，同时科学数据多元异构、领域差异大的特征，使得大部分领域需要手工创建语义本体和词表。面对多学科跨领域的应用场景，需要将不同领域的数据和知识进行语义化表示，提高不同领域数据之间的语义互操作性，并将不同领域的知识对象进行关联和融合，实现数据的共享和复用[2]。但是跨学科、多尺度科学数据的知识对象的多样性与异构性，造成大规模知识对象定位、跟踪及共享等问题，例如在大量学术论文及科学数据中，知识对象来源广泛、关联不明确、粒度不一致等特点，因此目前我国科学数据还没有实现真正意义上的科学数据共享。

(3) 科学数据库质量和服务模式：随着我国科学技术的快速发



展，国家的信息化建设取得了较大进步，科技创新能力不断提升，我国科技数据总量将持续呈爆发式增长的趋势[3]。特别是2018年《科学数据管理办法》发布以来，我国科学数据资源收集与汇聚进一步快速发展，目前我国科学数据资源总量已突破100 PB，形成了一批优秀的科学数据库。国家天文台的LAMOST数据库已成为全球最大的天文光谱数据库。中国科学院微生物研究所建设的全球微生物菌种资源目录是国际上在微生物资源领域最权威的数据库。然而，调研显示，实际科研活动中，90%以上的一线科技工作者仍然优先使用本领域同行认可的国际高质量数据库/数据集[4]，国内缺乏高质量的科学数据集，且数据资源分散，集成化不高，服务效率低，这对人工智能技术在科学领域的应用和发展产生了一定的限制。

以上这些问题给科学人工智能领域技术和研究带来了巨大的挑战，从这些根本问题出发开展本项目的研究具有重要的科学意义。

1.2 国内外研究现状及发展动态分析

1.2.1 跨领域、多模态科学数据融合存储方法

近年来深度学习模型驱动的科研范式在蛋白质折叠、DNA结构预测、细胞结构分析、分子动力学模拟、卫星图像处理、数学问题求解等科研领域的人工智能应用均取得了突破。特别是当前，CLIP、GPT-4等大型多模态预训练模型在诸多下游任务上展示出的强泛化能力和领先的预测性能，预计AI for Science将快速演进为“多模态基础大模型+小样本提示学习”新计算范式，需要结合科学数据的特殊性和科学研究任务的特殊性，训练专门面向科研领域的多模态基础大模型，并构建高质量的科研任务小样本提示文本库。

根据GPT-4的成功实践，预计面向科研领域的多模态基础大模型对海量高质量多模态训练数据（TB级Token）、巨量并行矩阵运



算能力（千级 PF-days）、少量用于精调的标注数据存在迫切需求。

其中，多模态数据资源指数值、文本、图片、视频、音频，序列等以不同模态存在的数据。当前，多模态数据资源融合存储相关技术主要有：

1) 多模型数据存储技术。多模型数据存储技术支持对异构数据的统一查询，但由于层次模型、关系模型、图模型等不同模型在存储原理上的差异，很难实现跨模型的查询和事务，因此不支持基于语义的关联查询和融合存储。联邦数据库于上世纪 80 年代提出，其特征是使用单一的、整合的后端对接不同的数据模型，Multibase[5]是其中的代表系统。PolyStore[6]将异构查询语言转换为统一查询语言，以实现多种数据模型的联合使用，并允许应用程序自行选择合适的数据库模型，其优点是可以充分利用相对已经成熟的存储技术满足多模型数据管理的需要，扩展性较好。MMDBMS[7]为多模型数据库定义了一种理论框架，通过在不同的数据模型之间提供一组共享的数据基础设施服务，支持提供对各种数据模型的声明性访问。MMDBMS 没有主数据模型，用户可以从一个模型开始操作，按需添加新的层次模型、关系模型或图模型，并以整体的方式对其进行管理。Forward[8]基于 JSON 的数据模型组织数据，这种较为灵活的模型使系统可以在异构数据上执行查询。然而，多模型数据存储库的存储结构通常面向直接 IO 需求设计，与 Transformer 等神经网络架构训练需要的向量化数据存在显著差异。如通常作为文件存储的图像数据或作为文档存储的文本数据需要先被表示为向量，才能接入训练流程或下游任务推理流程。

2) 多模态语义对齐技术。这类技术基于底层的 Apache NiFi、PiFlow 等大数据流水线系统、上层的预训练语言模型实现不同模态数据之间的语义对齐。在底层，大数据流水线系统可通过适配器对接各类海量数据管理系统，如管理非结构化数据的分布式文件系统



HDFS[9], 管理半结构化数据的文档数据库 MongoDB[10], 管理结构化数据的关系型数据仓库 Hive[11]。在上层, 通过预训练语言模型从各类复杂结构数据资源的元数据文本中提取命名实体、实体关系等语义对齐信息。该技术的缺点是只支持离线 ETL 形式的语义对齐。这是因为其底层海量数据管理系统多围绕单一数据格式构建, 而异构系统的数据模型在语法、语义上存在很大的异质性, 在进行异构数据语义关联分析时, 往往需要编写专门的 ETL 程序对非结构化数据进行离线语义提取, 造成了“存算”系统之间的脱节, 严重拖累数据分析效率, 而且数据和分析需求的变化会使 ETL 流程失效[12]。

1.2.2 面向科学领域的知识驱动科学发现研究

科技文献和科学数据是获取科研知识的首要途径, 也是核心表现形式。它们具有海量、多源、异构等特性, 蕴含着丰富的知识。以科技文献为例, 仅在 2010 到 2020 年间, 中国发表的国际论文数量就达到了 301 万篇, 这些科技文献存储在不同的数据源中, 包含着大量领域化和专业化的知识。传统的基于关键词匹配的传统信息检索和简单的统计分析已经无法满足对领域知识获取与分析的需求。因此, 基于知识的检索分析技术应运而生。这种技术不仅能够从海量数据中过滤出对用户有价值的知识, 还挖掘和解析结果间存在的内在关联, 从语义角度挖掘深层次的规律和知识, 实现语义和概念层次上的标引工作, 提高查全率和查准率, 降低科研人员的负担, 是一种高效的检索方式。

近年来, 针对海量、多源、异构的科技文献数据带来的挑战, 研究人员通过对文献的挖掘和分析, 探索新材料研发的新路径。美国劳伦斯伯克利国家实验室在 2019 年发表于《Nature》的文章中, 利用



自然语言理解技术从材料领域的科学文献中抽取领域知识,促进了新材料的发现[13]。英国格拉斯哥大学的 Leroy Cronin 提出了一种基于化学合成文献的通用自动化合成方法,成功合成了 12 种化合物,证明了从海量科学文献中抽取相关知识具备可行性[14]。此外,美国 MIT 大学的 Elsa Olivetti 提出了一种基于科学文献数据训练的无机物合成方案推荐智能模型,成功预测了两种钙钛矿材料,证明了从海量科学文献中抽取相关知识具备全面性[15]。这些研究表明,利用知识挖掘技术从科技文献中提取知识,可以为科研人员提供新的思路和方法,推动科研新范式的改革。

近年来,国内对利用科技文献进行材料研发的研究也备受关注。2022 年 1 月。北京科技大学谢建新院士团队在《npj Computational Materials》发表的文章中,通过对超耐热合金相关文献的解析,自动抽取了高温合金成分和性能数据,并成功预测出了溶解温度高于 1250 °C 的新型钴基高温合金[16]。此外,北京大学潘锋教授团队尝试将科学文献中的文本信息转化为结构化的知识,并结合知识关联、融合、推理等方法,构建了知识图谱,帮助研究者准确高效地获取领域内信息,以锂电池正极材料 LiFePO_4 为例,展现了 MatKG 的自动化分析流程[17]。

研究面向科学领域的知识驱动科学发现的相关工作作为验证其可行性提供了有益的参考,但同时也存在局限性。首先,这些研究所构建的网络关系更接近于“共现”分析,未能深入挖掘语义层面上的深层次关联。其次,通过“端到端”的模型架构进行科学发现,其可解释性不足,需要进一步提升。最后,材料、化学或物理领域中存在必须遵守的科学法则难以体现,需要更多的理论指导。

1.2.3 语义化知识对象构建方法研究



语义化知识对象构建方法是人工智能领域的热门研究方向之一，在国内外都得到了广泛关注和研究。谷歌的知识图谱和微软的 Satori [17]都是基于语义化知识对象构建方法而建立的知识图谱，Facebook、亚马逊等公司也在语义化知识对象构建方法方面开展了相关研究。这些研究方法包括传统的知识表示方法，如本体和图谱等，以及基于深度学习的语义表示方法，如词向量和句子向量等。其中，传统的手工构建本体方式已经逐渐被自动化构建方式所替代[19]，如基于自然语言处理技术的自动本体抽取方法。同时，还有一些研究致力于探索协同构建本体的方法，如利用人工智能技术辅助专家进行本体构建。在科学数据领域，生物学是国际语义化知识对象构建方法的重要应用领域，针对不同领域数据，Linked Life Data [20]、Diseasome(人类疾病研究网络)[21]、LinkedGeoData[22]、BioNav[23]等语义数据集成平台都探索了语义化知识对象构建方法，并实践了关联数据即服务。

近年来，国内在语义化知识对象构建方法方面的研究不断深入。清华大学、中科院计算所等高校和研究机构以及百度的知识图谱、腾讯的微信小程序等互联网公司都在该领域取得了一定成果，国内的研究主要是基于传统的知识表示方法[20]，如本体和知识图谱，以及基于深度学习的语义表示方法，如知识融合、实体对齐、关系抽取。中国科学院自动化研究所认知脑建模组开发的 Linked Brain Data (LBD)[25]和 Chem2Bio2RDF[23]等项目积极探索了语义化知识对象构建方法。

在生命科学领域，语义化知识对象构建方法为研究人员更好地理解生物分子之间的关系和生物系统的复杂性提供了重要支持。基于知识图谱和本体的生物信息学研究已经构建了很多基于本体的知识库，例如 Gene Ontology（基因本体论）、Cell Ontology（细胞本体论）、



Protein Ontology (蛋白质本体论) 等, 以描述生物分子之间的关系和生物系统的复杂性。同时, 也构建了很多基于知识图谱的生物信息学资源, 例如 Bio2RDF、STRING、Reactome 等, 以描述生物分子之间的相互作用和生物系统的功能。这些研究方法为生命科学领域的研究提供了有力的支持。

材料科学领域, 语义化知识对象构建方法有助于研究人员更好地理解材料结构、性能和制备方法等方面的关系。基于本体的材料信息学已经成为一个重要的研究领域, 研究人员已经构建了很多基于本体的材料信息学资源, 例如 Materials Ontology (材料本体论)、Materials Project (材料信息学平台) 等, 以描述材料之间的关系。此外, 研究人员还构建了很多基于知识图谱的材料科学资源, 例如 Materials Genome Initiative (材料基因组计划) 和 The Materials Project 等, 以描述材料之间的相互作用和材料系统的功能。

1.2.4 科学数据库及其服务现状

科学数据是长期投入积累的宝贵财富, 也是科技创新的重要驱动力。欧美国家长期致力于科学数据库建设, 创造出多个高质量、权威科学数据库。例如, 剑桥结构数据库是全球最大的晶体结构数据库, 从 1965 年开始提供服务, 收录全球认可的有机及金属有机化合物的晶体结构; 斯特拉斯堡天文数据中心的 SIMBAD 数据库收录了自 1950 年以来的恒星和自 1983 年以来的星系和太阳系外其他物体的信息 GenBank 是国际上最知名的基因组相关数据库, 由 NCBI 建立, 包含所有已知的核苷酸序列和蛋白质序列, 以及相关文献和生物学注释; PubMed 数据库是 NCBI 建设的医学文献检索服务, 数据全面、深度标引, 是目前全球使用率最高的网上免费数据库。中国科技大学机器化学家团队建立了包含 8 千万化合物、1 千万化学反应等资源的



数据库，并基于此建立了物理化学知识图谱，以数据和智能优势加速材料研发，成功研制出“全球首个数据智能驱动的全流程机器化学家平台”[27]。

作为开放科学体系的重要基础设施，科学数据仓储平台在数字资源长期保存、数据共享等方面发挥着重要作用[28]。据 2023 年 4 月 re3data 最新注册数据显示，全球已有 3106 个科学数据仓储平台。这些平台涵盖了 13 个一级学科，其中，生命科学（Life Sciences）、自然科学（Natural Sciences）、人文与社会科学（Humanities and Social Sciences）学科数据仓储平台数量位列前三名。这些平台来自 84 个国家，其中美国、德国和加拿大的平台注册数量位列前三名，而中国注册的平台数量为 81 个，位列第十。在数据质量管理上，54.73%的平台会对数据质量进行控制。提供开放（open）数据访问服务的平台占比 86.14%，48.31%的平台存在受限访问情况（restricted），14.78%的平台提供了数据访问的禁运保护（embargoed），8.53%的平台关闭了数据访问服务[29]。总体来看，我国科学数据仓储平台在可信服务能力、开放生态与影响力方面偏弱，缺乏话语权，无法吸引全球优质科学数据资源的持续汇聚，导致大量数据外流，无法满足人工智能驱动的科学研究新范式高质量数据资源供给需求。

参考文献

- [1] Jumper, J et al. Highly accurate protein structure prediction with AlphaFold. Nature (2021).
- [2] Hagelien T, Preisig H, Friis J, et al. A Practical Approach to Ontology-Based Data Modelling for Semantic Interoperability[C]//14th World Congress on Computational Mechanics. 2021.
- [3] 国家科技基础条件平台中心. 国家科学数据资源发展报告 2019. 北京: 科学技术文献出版社, 2020: 19-29. [National Science and Technology Basic Article Platform Center. National



- Report on the Development of Scientific Data Resources 2019. Beijing: Science and Technology Academic Press, 2020:19-29.]
- [4] 中国科学院. 科技强国建设之路: 中国与世界[M]. 北京: 科学出版社, 2018: 424-455.
[Chinese Academy of Sciences. The road to building a powerful country through science and technology: China and the world[M]. Beijing: Science Press, 2018: 424-455.]
- [5] Smith, John Miles, Philip A. Bernstein, Umeshwar Dayal, Nathan Goodman, Terry Landers, Ken WT Lin, and Eugene Wong. "Multibase: integrating heterogeneous distributed database systems. Proceedings of the 1981 National Computer Conference, pp. 487-499.
- [6] Duggan J, Elmore AJ, Stonebraker M, Balazinska M, Howe B, Kepner J, Madden S, Maier D, Mattson T, Zdonik S. The bigdawg polystore system. ACM Sigmod Record. 2015,44(2):11-6.
- [7] Liu, Zhen Hua, et al. Multi-Model Database Management Systems: A Look Forward. International Conference of Very Large Databases. 2018: 16-29.
- [8] Ong KW, Papakonstantinou Y, Vernoux R. The SQL++ unifying semi-structured query language, and an expressiveness benchmark of SQL-on-Hadoop, NoSQL and NewSQL databases. CoRR, abs/1405.3631, 2014.
- [9] Shvachko K, Kuang H, Radia S, Chansler R. The hadoop distributed file system. 2010 IEEE 26th symposium on mass storage systems and technologies (MSST), IEEE, 2010: 1-10.
- [10] Chodorow K. MongoDB: the definitive guide: powerful and scalable data storage. O'Reilly Media, Inc.; 2013 May 10.
- [11] Thusoo A, Sarma JS, Jain N, Shao Z, Chakka P, Anthony S, Liu H, Wyckoff P, Murthy R. Hive: a warehousing solution over a map-reduce framework. Proceedings of the VLDB Endowment. 2009, 2(2):1626-1629.
- [12] Tan R, Chirkova R, Gadepally V, et al. Enabling query processing across heterogeneous data models: A survey. 2017 IEEE International Conference on Big Data (Big Data). IEEE, 2017: 3211-3220.
- [13] HUANG, Shu; COLE, Jacqueline M. A database of battery materials auto-generated using ChemDataExtractor. Scientific Data , 2020, 7.1: 260.
- [14] Tang, J., Zhang, J., Yao, L., Li, J., Zhang, L., & Su, Z. (2008, August). Arnetminer: extraction and mining of academic social networks. In Proceedings of the 14th ACM SIGKDD international conference on Knowledge discovery and data mining (pp. 990-998).



- [15] Shi, W., Fan, G., Shen, Z., Hu, C., Ma, J., Zhou, Y., ... & Wu, L. (2022). gcCov: Linked open data for global coronavirus studies. *Mlife*, 1(1), 92-95.
- [16] Tshitoyan, V., Dagdelen, J., Weston, L., Dunn, A., Rong, Z., Kononova, O., ... & Jain, A. (2019). Unsupervised word embeddings capture latent knowledge from materials science literature. *Nature*, 571(7763), 95-98.
- [17] He, T., Sun, W., Huo, H., Kononova, O., Rong, Z., Tshitoyan, V., ... & Ceder, G. (2020). Similarity of precursors in solid-state synthesis as text-mined from scientific literature. *Chemistry of Materials*, 32(18), 7861-7873.
- [18] 官赛萍, 靳小龙, 贾岩涛, 等. 面向知识图谱的知识推理研究进展[J]. 软件学报, 2018, 29(10): 2966-2994.
- [19] Wu, Y., Feng, Y., & Zhang, Z. (2019). A survey of ontology learning methods and techniques. *Journal of Computer Science and Technology*, 34(1), 1-40.
- [20] Jupp S, Malone J, Bolleman J, et al. The EBI RDF platform: linked open data for the life sciences[J]. *Bioinformatics*, 2014, 30(9): 1338-1339.
- [21] Wysocki K, Ritter L. Diseasesome[J]. *Annual review of nursing research*, 2011, 29(1): 55-72.
- [22] Auer S, Lehmann J, Hellmann S. Linkedgeodata: Adding a spatial dimension to the web of data[C]//International Semantic Web Conference, Springer, Berlin, Heidelberg, 2009: 731-746.
- [23] Maria-Esther Vidal, Louiqa Raschid. Vidal M E, Raschid L, Márquez N, et al. Bionav: An ontology-based framework to discover semantic links in the cloud of linked data[C]//Extended Semantic Web Conference, Springer, Berlin, Heidelberg, 2010: 441-445.
- [24] Ma, L., Liu, L., & Huang, Y. (2020). A review on knowledge graph construction. *Science China Information Sciences*, 63(4), 1-18.
- [25] linked-brain-data[EB/OL].[2022-11-11]. <http://www.linked-brain-data.org/>.
- [26] Dong X, Ding Y, Wang H, et al. Chem2Bio2RDF dashboard: Ranking semantic associations in systems chemical biology space[J]. *Future of the Web in Collaborative Science (FWCS)*, WWW, 2010, 1 (2): 34.
- [27] Qing Zhu, Fei Zhang, Yan Huang, Hengyu Xiao, Lu Yuan Zhao, Xu Chun Zhang, Tao Song, Xin Sheng Tang, Xiang Li, Guo He, Bao Chen Chong, Jun Yi Zhou, Yi Han Zhang, Baicheng Zhang, Jia Qi Cao, Man Luo, Song Wang, Gui Lin Ye, Wan Jun Zhang, Xin Chen, Shuang Cong, Donglai



Zhou,Huirong Li,Jialei Li,Gang Zou,Wei Wei Shang,Jun Jiang,Yi Luo.An all-round AI-Chemist with a scientific mind[J].National Science Review,2022,9(10):158-168.

- [28] 姜璐璐, 张泽钰, 李宗闻, 等. 全球科学数据仓储平台的建设实践现状与展望[J/OL]. 中国科学数据, 2023, 8(1). (2023-03-27). DOI: 10.11922/11-6035.csd.2023.0027.zh.
- [29] re3data [OL]. 2023, <https://www.re3data.org>.

NSFC 2023



2. 项目的研究内容、研究目标，以及拟解决的关键科学问题（此部分为重点阐述内容；另外，请说明本项目与重大研究计划总体目标的关系）；

2.1 研究内容

本项目拟从跨领域多模态科学数据融合存储方法、基于主动学习及预训练模型的知识对象抽取与融合、标识化语义化知识对象构建方法及通用型科学数据库服务模式与平台服务四个方面展开研究。



图 1 研究内容框架

2.1.1 面向多模态大模型训练和预测的科学数据读取优化

(1) 面向大模型的多模态分布式数据存储模型和容错机制。针对多模态基础大模型训练与推理全流程对多模态数据的高并发访问需求，研究复杂结构数据的统一数据访问模型，提供可自匹配可分片的数据对象、支持跨语言跨框架的数据访问和内存共享机制等。数据对象对同一个标识物的文本、图像、序列、图结构等不同模态数据的元数据、关联关系、操作方法进行封装，提供多模态数据的访问抽象。同时，跨节点的内存访问共享机制支持数据对象的分布式内存加载与本地化并行处理，支持内存数据对象的近计算端零拷贝式访问。最后，



针对训练过程中，数据读取 I/O 错误率高的问题，提出基于血缘的数据容错管理和访问自动化重试机制，通过分布式数据对象屏蔽模型训练对于多源异构数据访问的数据存储问题。

(2) 面向大模型训练的云原生分布式数据缓存的关键算法研究。

针对云原生环境下的模型训练集群和存储集群存储和计算分离的问题，基于模型训练过程在数据资源读取上的 Batch/Random/Shuffle 模式，研究面向 AI 训练和预测的动态数据资源调度和缓存机制，满足训练框架对数据资源的高吞吐访问需求，支撑多模态大模型训练和预测的需求。

(3) 基于 CPU/RDMA 的大模型数据预处理流水线的优化研究。

针对单个节点训练的数据处理瓶颈，基于统一的数据存储模型，提供通用的基于 CPU 的数据预处理计算模型，高效的建立 CPU 和 GPU 的数据流水，最大化利用 GPU 的高性能计算能力，减少 GPU 的等待模型训练数据的时间。并且针对多个训练节点的数据通讯瓶颈，提供基于 NVIDIA GPUDirect RDMA 的数据通讯模型，打通跨节点多 GPU 之间的参数和数据通讯。最后针对跨节点之间以及跨机架的服务器之间的数据通讯瓶颈，提出分层通信调度策略可以更好地利用不同层次的带宽资源，提高通信效率，减少训练过程中的数据 I/O 代价。

2.1.2 基于主动学习及预训练模型的知识对象抽取与融合

(1) 基于科学数据结构和语义关联的预训练方法。研究新的基于文献结构和语义关联的预训练方法，设计篇章级的预训练模型；研究基于并行策略的大规模领域化预训练方法；利用多任务自监督学习方法与多尺度空间感知自注意力机制的语义编码器，结合无标注科技文献进行文本语义及文献结构的联合预训练。

(2) 基于远程监督及迁移学习的领域知识抽取方法。研究基于



语义化知识对象的非结构化数据标注方法，解决数据标注的规模问题；研究引入专家标注样本、多实例学习、分段最大池化等方法的领域知识抽取方法；研究基于迁移学习的预训练模型迁移方法，提升语义化知识识别模型的识别精度。

(3) 基于表示学习的语义化领域知识对象融合方法。研究基于异质网络表示学习的实体链接与冲突消解，解决知识对象融合中的冗余、不确定、非完备问题；研究基于复杂网络嵌入与图神经网络模型算法，挖掘隐式领域知识，提升领域知识对象融合效率。

2.1.3 标识化、语义化知识对象构建方法

(1) 跨学科、多尺度科学数据的知识对象标识化构建方法。研究跨学科、多尺度科学数据的知识对象统一编码方法，研究针对分级分层、不同颗粒度等不同领域或类型的知识对象编码规则；研究基于异构标识的知识对象标识互操作方法，实现不同领域知识对象的全局发现；研究不同来源知识对象标识关联融合方法，实现跨学科、跨领域知识对象的共享和复用。

(2) 面向多标识体系的知识对象异构标识解析方法。研究支持 CSTR（国家科技资源标识）、Handle 等多种异构标识解析和互通技术。异构标识解析即提供自主核心标识，又提供自主标识与其他现有标识兼容互通能力，实现针对不同标识体系下的科学数据及知识对象标识提供异构标识解析技术，数据资源的互联互通将为科学数据智能化应用提供技术支撑。

(3) 面向结构化与长文本科学数据的知识本体构建方法。研究基于数据库表结构和关系，实现领域本体自动映射和构建；研究基于国际本体查找服务（OLS）、BioPorta 和 BARTOC 等搜索引擎相关接口实现本体标准化规范化复用；研究融合知识库的长文本科学数据



知识本体构建方法,实现结构化与长文本科学数据的知识本体自动构建。

2.1.4 面向下一代人工智能的高质量科学数据服务模式

(1) 面向智能化服务的科学数据共享模式及激励机制。研究机器可理解、可操作性且模型集成适用的科学数据库服务形式;研究可持续的科学数据库共享和服务模式,支持领域知识融合与科学数据主动发现;研究科学数据库智能化服务能力评价方法,探索新型科研范式下的科学数据库激励机制。

(2) 跨领域、多模态科学数据的主动发现关键技术。面向全球开放科学数据资源,研究数据开放平台数据政策,研究跨领域、多模态科学数据的主动发现关键技术,在遵循数据政策与许可协议的前提下,利用分布式爬虫技术收录国内外多学科领域权威开放数据平台海量科学数据,主动发现并持续聚合全球开放数据,通过大数据处理技术实现科学数据的存储管理、清洗、加工处理,形成统一的科学数据元数据标准,为人工智能驱动的科学研究新范式提供开放科学数据资源发现与获取服务。

(3) 高质量通用型科学数据库服务平台构建。研究可信赖原则(Trust Principles)等国际原则与标准规范,建设遵循国际规范、自主可控、具有国际影响力的通用型可信科学数据存储库服务平台,以云服务模式建设领域科学数据社区生态,充分发挥领域数据资源、数据治理、影响力等优势,持续吸引汇聚全学科领域海内外优质科学数据资源,形成具有一定国际影响力的覆盖生命、化学、材料、遥感、空间科学等领域的高质量、通用型科学数据库,为人工智能驱动的科学研究新范式提供基础科学数据资源支撑和数据深度融合知识化服务。



2.2 研究目标

本项目针对科学人工智能领域开放性高质量科学数据库建设中存在的数据多源异构多模态、高质量数据匮乏、跨领域数据语义表示以及科学数据服务模式等问题展开研究，从数据存储、对象抽取与融合、标识构建、平台服务四个角度展开研究。研究多模态科学数据存储优化，支持多模态数据成对融合存储模型与人工智能框架的高效对接；研究基于主动学习和预训练模型的知识对象抽取与融合方法，智能抽取科学文献中科学数据的相互关联关系，解决跨学科数据对齐训练访问的问题；研究科学数据的标识化语义化知识对象构建方法，实现知识对象的统一标识、定位、关联及追踪，研究基于异构标识与数据影响力评价模型的科学数据共享模式及激励机制。依托国家基础学科数据中心、中国科学院科学数据总中心、科学数据银行(ScienceDB)等资源积累，构建可良性发展并具有国际影响力的高质量、通用型科学数据库，覆盖生命、化学、材料、遥感、空间科学等学科，并实现科学数据与科技文献的关联，为人工智能驱动的科学研究提供基础科学数据资源支撑和数据深度融合知识化服务，为形成支撑 AI for Science 的数据与知识库系统奠定坚实的基础。

2.3 关键科学问题

(1) 针对多模态大模型训练和预测的科学数据统一访问模型和读写问题。通过面向异构多模态数据进行统一的数据访问抽象，设计面向 AI+ 学科应用场景下的分布式数据读取，以及分布式缓存算法理论研究和系统实现，减少大模型训练过程的 I/O 瓶颈，提高训练和预测的资源利用率(GPU/内存/CPU)和任务成功率，满足大模型训练和推理对多源异构数据的跨集群，跨数据中心，分布式访问与处理实际需求。



(2) 跨学科、多尺度科学数据的知识对象全局定位和互操作问题。

跨学科、多尺度科学数据的知识对象的多样性与异构性，造成大规模知识对象定位、跟踪及共享等问题，如何结合科技资源标识、小样本专家标注与海量无标注数据库，进行高质量知识对象的定位、抽取与融合，以构建面向科学发现的数据库与知识库，是本项目需要解决的关键科学问题之一。

(3) 面向下一代人工智能科学数据库的服务模式与机制问题。如何结合科学数据引用、确权、影响力评价，通过共享模式、激励机制等方面的创新，以及跨领域、多模态科学数据的主动发现方法，实现持续、稳定的提供高质量、通用型科学数据服务，面向下一代人工智能的科学数据库可持续发展需要解决的关键科学问题。

2.4 与重大研究计划总体目标的关系

可解释、可通用的下一代人工智能方法重大研究计划面向以深度学习为代表的人工智能方法鲁棒性差、可解释性差、对数据的依赖性强等基础科学问题，挖掘机器学习的基本原理，发展可解释、可通用的下一代人工智能方法，并推动人工智能方法在科学领域的创新应用。通过“支持下一代人工智能的开放型高质量科学数据库”项目的建设，形成具有一定国际影响力的覆盖生命、化学、材料、遥感、空间科学等领域的高质量、通用型科学数据库，可以为人工智能驱动的科学新范式提供基础科学数据资源服务。

3. 拟采取的研究方案及可行性分析（包括研究方法、技术路线、实验手段、关键技术等说明）；

3.1 研究方案

本项目的总体研究方案如图 2。首先研究跨领域多模态科学数据融合存储方法，主要包括跨数据源多模态数据向量化查询机制、多模



态数据近计算端成对融合存储模型、支持云原生架构的数据资源按需动态预存取优化机制。在数据集和模型方面,研究基于主动学习及预训练模型的知识对象抽取与融合方法,包括基于科学数据结构和语义关联的预训练方法、基于远程监督及迁移学习的领域知识抽取方法、基于表示学习的语义化领域知识对象融合方法。同时研究跨学科、多尺度科学数据知识对象的构建以及知识对象标识化的构建方法,提升知识对象全局定位与共享能力。最后对研究跨领域、多模态科学数据的主动发现关键技术,以及多学科通用型科学数据库平台服务建设,以云服务模式建设领域科学数据社区生态,形成具有一定国际影响力的覆盖生命、化学、材料、遥感、空间科学等领域的高质量、通用型科学数据库,为人工智能驱动的科学新范式提供基础科学数据资源支撑和数据深度融合知识化服务。





图 2 研究方案框架图



3.1.1 面向大模型训练和预测的跨领域、多模态科学数据融合存储方法

为支撑多模态基础大模型训推全流程对复杂异构数据的关联访问和向量化访问,须对多模态数据的存储、组织、访问方式进行改进,构建跨模态数据资源统一视图,支持人工智能训推框架。



(1) 面向多模态深度学习模型训练和预测的数据统一模型。在多模态的预训练和微调的场景中,针对同一对象,需要读取不同类型的数据。多模态数据由于包含多种类型的数据(如文本、图像和声音),因此数据处理和存储可能会比较复杂。每种数据类型可能需要不同的处理和存储方法,如图像需要进行压缩和解压缩,文本可能需要进行编码和解码,声音可能需要进行采样和量化。同时,不同的数据类型可能需要不同的格式转换。例如,图像可能需要转换为张量,文本可能需要转换为词向量,声音可能需要转换为频谱。这些转换过程可能涉及大量的 I/O 操作。

在多模态训练中,不同类型的数据需要同时处理和整合。比如说,神经网络模型结构的多个 encoder,需要等待其他 encoder 的数据的



处理结果，从而进入下一步的训练。如果数据的加载和处理速度不同步，可能会导致训练效率降低。同时，不同的数据的读取的 reader 和转换需要的计算资源和处理速度是不一致的，不同类型的数据处理的算子是存在相互等待的关系。最后，针对多模态训练需要的多学科的科学数据，需要设计相应的数据预处理算子。比如针对中国西北高山冻土的地表检测数据和空间遥感监测数据，都需要针对不同的存储底层系统，设计相应的数据处理算子，这增加了用户访问多模态数据的大模型训练的困难。需要有统一的数据访问对象，帮助大模型训练屏蔽掉底层的数据存储，数据预处理，容错等方面的问题。

首先，针对多模态训练数据，构建统一的针对多模态数据的数据访问模型和抽象。非结构化数据经特征提取和关联关系提取后会转变为张量和图数据结构。本项目据此对非结构化、张量、图进行统一抽象，形成可编程数据对象(CDO):

$$CDO = (Data\ Payload, Type, Structure, Operations)$$

CDO 在逻辑上分为两部分，实体数据 (Data Payload) 和元数据 (包括类型、结构、存储地址，存储类型，数据访问控制以及操作方法)，其中实体数据可以分片，以支持对超大规模的张量等数据进行分布式处理。拟将数据片(Data Fragment, DFrag)通过进程间调用 (IPC) 方式加载到内存，并使其成为内存不可变对象 (Immutable DFrag, IDFrag)，供本地计算进程 (Worker) 对其进行只读访问。这种机制，既支持对 CDO 进行本地化 (Co-located) 的分布式并行处理，又支持不同编程语言、人工智能框架的 Worker 进程通过内存映射 (Memory mapping) 方式直接访问 IDFrag,从而实现跨语言、跨框架零拷贝式内存数据共享,避免进行序列化和反序列操作带来的额外磁盘 I/O 操作，加速端到端工作流的数据传输效率。Worker 通过远



程过程调用机制 (RPC) 访问元数据存储服务, 获取全局一致的 CDO 元数据信息, 从而获知对 IDFrag 的具体处理方法。为适配复杂非结构化数据类型, 拟提供类型扩展机制, 允许用户自行注册新 CDO 类型, 注册信息包括新类型的数据加载、元数据提取、操作方法等。

其次, 基于统一数据对象, 设计针对不同数据类型和学科的可扩展数据预处理框架。针对模型训练过程中的数据预处理流程, 设计通用的基于函数的分布式数据处理流程, 支持不同类型的科学数据进行高效的分布式处理。提供通过基于函数方式的可热插拔的数据处理模型, 减少数据预处理的二次开发的复杂度, 同时最大化的提供处理的效率。并且通过理解统一数据对象的 Meta data 和 底层数据的存储分布, 通过动态和静态的执行计划优化, 实现高效的数据预处理计算优化。可以利用计算算子下压, 数据在线压缩和解压, 错误 block 的自动跳过, 实现面向学科的预计算算子的计算优化, 提高数据处理的效率。




图 4 超大规模数据对象的本地化分布式处理机制

(2) 云原生面向大模型训练的分布式数据缓存关键算法研究。

在深度模型训练过程中, 超过 30% 的大模型任务, 网络 I/O 会成为性能瓶颈之一。背后原因主要有: (1) 特征计算算子不能下压到数据库



系统，造成数据读取的 I/O 过大。(2) 云计算环境中存储和计算节点的分离的设计，I/O 带宽和延迟会影响训练性能。当多个训练节点并行地读取数据，这可能会导致更大的 I/O 负载。(3) 模型训练任务需要通过工作流串联整个流程，中间结果的持久化存储，会带来了巨大的 I/O 开销。如何减少训练数据的 I/O 代价，是本研究需要结合多模态的分布式训练对象的研究重点之一。

需要利用现有的分布式高性能存储系统，设计优化训练数据的缓存机制。这需要考虑：缓存的空间大小、训练任务的 I/O 代价、任务的优先级等因素，这是一个多因子的优化问题。同时，针对端到端的训练任务，不仅需要有灵活的工作流的编排框架来定义不同的多模型训练策略，还需要框架层支持多个任务数据读取的共享缓存，以减少中间数据的持久化存储 I/O 代价。这需要统一的针对模型训练的云原生工作流调度系统，并支持多训练任务的数据自动缓存算法和系统。

首先，通过基于深度神经网络的多目标优化器，解决基于有限存储限制下的多目标数据缓存的优化分配问题。实现有限资源场景下的数据缓存和数据更新算法，实现训练任务的数据高效读取，减少从远程数据集读取数据的网络和磁盘 I/O。同时提出基于分布式缓存系统的数据亲和性调度算法，让多训练节点和存储节点根据底层计算资源和存储资源的资源利用率，实现分布式缓存和训练节点的动态一致性调度，坚决计算节点和计算缓存节点的资源不匹配问题。其次，研究云计算环境下的模型训练工作流 I/O 自动化优化和系统实现。针对模型训练过程中，需要工作流来定义整个训练的流程。基于统一的数据对象，设计一套完整、统一的工作流接口和算子，使用户可以通过统一的编程接口来定义 AI 工作流程。并且通过 AI 工作流的静态分析，提出针对多个大模型训练任务的数据自动缓存策略算法，减少数



据多次从远程集群读取数据的 I/O 代价。

(3) **基于 CPU/RDMA 的大模型数据预处理流水线的优化研究。**在模型训练和预测中，通常情况是，GPU 负责模型的训练，CPU 负责数据的预处理和数据的读取工作。因为 CPU 和 GPU 之间的计算能力和协调不一致，导致的 GPU 需要长期等待数据块，GPU 的利用率普遍低于 50% (来源于 OpenAI 的资源利用率报告)。特别是在多模态训练中，针对不同类型的科学数据处理，相应的 CPU 计算需要的资源和复杂度不一致，常常导致，不同的数据预处理模型和 GPU 计算之间的等待关系，这就需要有一个统一的针对多个数据预处理以及模型训练的优化和调度器，让多个计算任务之间的处理能力能够协调一致，提高模型训练的融合能力。

首先，通过设计 CPU 和 GPU 之间的数据传送的合并机制，避免频繁的小数据传输，设计优化的基于 GPU 处理速度和多个数据计算任务的数据合并机制，动态的合并小数据传输为大数据传输可以减少数据传输开销。同时，根据 GPU 的内存访问模式，针对多个数据预处理任务的计算结果优化数据的布局（如使用对齐的内存），设计面向多类型的数据访问结构，提高数据内存访问的效率。其次，针对多个训练节点的同步和异步训练过程中，数据 Shuffle 带来的数据访问的代价问题。通过基于 RDMA 的新型硬件，支持 GPU 更加高效的访问远程的数据，提出基于 CUDA Streams 和 CUDA RDMA 的支持多模态数据的，数据通讯和访问模型，可以使多个 GPU 操作（包括计算和数据传输）在不同的流中同时进行，进一步提高 GPU 的利用率和并行性。

3.1.2 基于主动学习及预训练模型的知识对象抽取与融合

(1) **基于科学数据结构和语义关联的预训练方法。**科学数据与

科技文献中除了包括海量的语义信息之外，其复杂多变的文件结构、版式结构背后也蕴含丰富的信息，拟基于科学数据与文献结构和语义关联，设计面向数据块及篇章级预训练模型。该模型基于多任务自监督学习方法，通过多尺度空间感知自注意力机制和层级 Transformer 的语义编码器分别从结构数据与语义数据中进行信息捕捉，通过设计有效的联合损失函数，利用海量无标注科技文献进行文本语义及文献结构的联合预训练。




图 5 基于科学数据结构和语义关联的预训练方法

随着预模型规模扩大、训练数据增多，单机训练已无法满足参数规模和数据吞吐的需求，并行训练开始成为大规模训练必不可少的部分，设计高效合理的并行策略有助于计算性能与模型效果的提升。在分布式训练方面，拟将基于混合专家模型（MoE）方法，通过设计适合的、面向全机规模的混合并行策略，将大模型切分为多个专家模型，在每次运算中，稀疏地选取一部分模型进行激活，进而减小整体计算量。因此，该方法可以在扩展模型参数、增大模型规模的同时，在相同的训练时间内，达到优于稠密大模型的准确度。

(2) 基于远程监督及迁移学习的领域知识抽取方法。本研究内容构建领域深度融合的实体识别、属性抽取和关系预测模型，实现准

确的领域知识的语义分割、聚类与自动标签。拟基于远程监督方法，利用初步建立的知识体系和开放的结构化数据，对科学数据及科学文献中的非结构化数据进行标注，以解决数据标注的规模问题。为了解决远程监督假设性过强的问题，通过引入专家标注样本、多实例学习、分段最大池化等方法，考虑标签的不确定性，提升知识抽取效果。同时，基于迁移学习算法将类似领域的预训练模型进行迁移，进一步提升识别模型的识别精度，加快并优化模型的学习效率。在该部分研究中，将基于远程监督及迁移学习构建包括实体识别、属性抽取及关系预测等模型，为后续提供知识检索与分析服务提供知识基础。

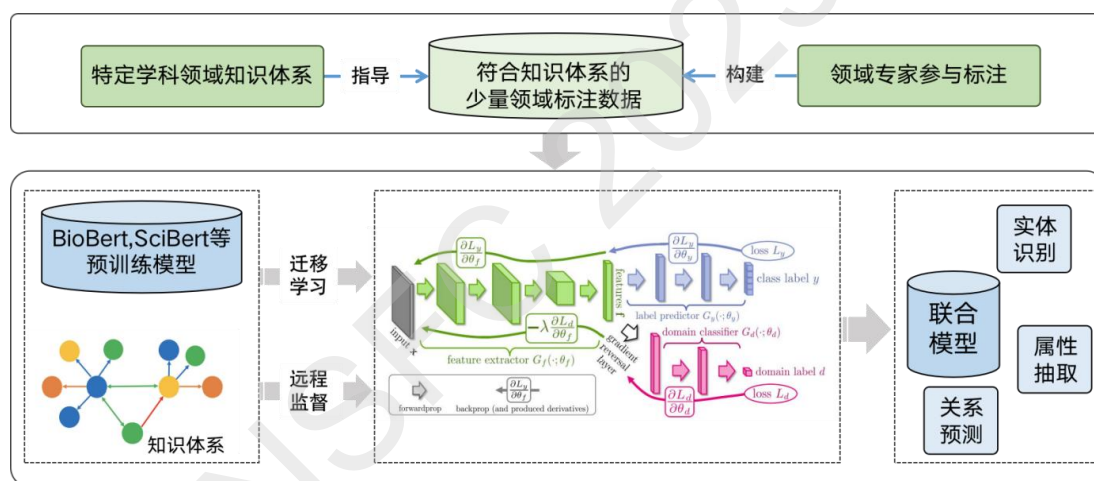


图 6 基于远程监督及迁移学习的领域知识抽取方法研究内容

通过远程监督和迁移学习算法，解决知识抽取过程面临的标注样本欠缺而导致抽取效果差的关键技术问题。拟利用研究初步构建的语义化知识对象体系、开放结构化数据以及少量专家标注的小样本数据作为远程监督的知识基础，同时利用相近领域的预训练模型，基于迁移学习进行包括实体识别、属性抽取和关系预测的知识抽取模型的训练，对科学数据及科技文献中的领域知识进行高效抽取，实现准确的领域知识的语义分割、聚类与自动标签。在抽取与融合方法上，本研

究方案拟充分利用已有大规模语言模型（LLM）在内容生成方面所体现的能力，探索借鉴大规模语言模型的能力提升基于主动学习知识抽取融合方法的能力。

(3) 基于表示学习的语义化领域知识对象融合方法。针对领域知识融合效率问题，构建包括实体链接、冲突消解、关联分析和关系推理在内的知识融合模型。在研究方法上，首先对知识实体准确的分布式语义表示，即基于表示学习方法将实体、关系等转换为低维空间中的向量，从而进一步进行匹配链接、相似度分析、关联分析和关系推理等工作。拟基于复杂网络嵌入与图神经网络模型算法，以实体自身属性和语义向量作为初始表示向量，构建深度学习的表示模型，利用其在知识网络中的关联结构对向量进行反馈更新，获得包括结构信息、属性信息和语义信息的向量化表示。从而实现文献抽取的领域实体与自身图表、文献抽取的知识与已有结构化知识的高效融合，构建准确、全面的知识网络，挖掘隐式领域知识。




图 7 领域知识融合过程示意

3.1.3 标识化、语义化知识对象构建方法

(1) 跨学科、多尺度科学数据的知识对象标识化构建方法。

如图 8 所示，首先研究跨学科、多尺度科学数据的知识对象统一编码规则；然后通过对多源知识对象进行标识化构建，并基于标识



注册解析获得全局定位及互操作能力；再基于语义关联建立知识对象的标识化关联，最后通过知识对象异构标识解析为实现跨学科知识对象智能化应用提供支撑。




图 8 知识对象标识化构建方法的研究方案

研究基于异构标识的知识对象标识互操作方法。基于在大量学术论文及科学数据抽取海量知识对象，为了有效管理、定位和追踪知识对象，实现不同领域知识对象的全局发现，通过知识对象标识注册实现构建知识对象标识数据编码与其对应信息地址间映射关系，通过知识对象标识解析提供知识对象定位与获取、共享及互操作。研究不同来源知识对象标识关联融合方法，基于语义层面关联关系构建标识化关联，通过关联标识追踪知识对象来源及研究过程，实现跨学科、跨领域知识对象的全局发现和使用。

研究面向多标识体系的知识对象异构标识解析方法。科学数据标识体系之间由于应用领域的不同，具有异构性，如编码数据格式、标识颗粒度、共享方式等均不相同，因此知识对象标识和科学数据标识也具有异构性，科学数据、知识对象之间需要兼容互通，跨领域获取知识对象存在异构数据互通的技术壁垒。研究支持国家标准科技资源标识 CSTR、Handle 等多种异构标识解析和互通技术，为不同标识体系下科学数据及知识对象提供异构标识解析技术实现路径。

(2) 科学数据语义化知识对象构建方法。如图 9 所示，首先研



究领域科学数据语义词表构建方法，核心内容包括词频统计与筛选、词间关系发现和同义词发现；然后针对结构化科学数据开展知识本体构建方法研究，核心内容包括表结构映射和外键映射；再针对长文本科学数据开展知识本体构建方法研究，核心内容包括命名实体识别、语义依存分析和外部本体关联。最后根据本体和词表规范形成完整的知识本体和语义词表。



图 9 科学数据语义化知识对象构建方法技术路线

领域科学数据语义词表构建方法研究基于大量的领域文本数据或文献资源，首先对文本数据进行分词处理、词干提取、停用词去除，接着统计和计算每个词的词频，然后根据预设的阈值筛选出高频词，再对关键词进行加权处理，同时结合机器学习的方法，以达到更准确的抽取效果。在开放语义词典（如：WordNet）中通过接口查询相关关键词的同义词及词间关系，最后集成关键词、同义、近义、上位，下位等词间关系形成完整的语义词表。

面向结构化科学数据的知识本体构建方法研究基于结构化科学数据，将表名、非外键属性、外键属性分别对应到本体中的类（owl:Class）、数据属性（owl:DatatypeProperty）、对象属性（owl:ObjectProperty）。对于数据属性和对象属性，指定属性的定义



域 (rdfs:domain) 为当前表所对应的本体类；对于数据属性，指定值域 (rdfs:range) 为 XML Schema 所对应的数据类型；对于对象属性，指定值域为关联表所对应的本体类。

面向长文本科学数据的知识本体构建方法研究首先基于大量的领域文本数据或文献资源，进行分句，分词处理，并提取句子结构及依存关系，通过命名实体识别的方式解析得到句子中实体对象，然后调用开放知识库（如 DBpedia）中的检索接口获取实体对象所属的类型及实体关联关系；同时基于本体查找服务（OLS）等搜索引擎相关接口实现本体标准化规范化复用，最终实现长文本科学数据的知识本体自动构建。

3.1.4 面向下一代人工智能的科学数据库服务模式研究

(1) 领域社区驱动的多元服务模式设计。面向高质量科学数据库的智能化服务建设需求，基于内容型激励机制理论，从涉及的主体对象及其内在动力和影响因素等方面展开分析，重点关注科学数据服务的可持续性以及服务过程中的数据交换机制。




图 10 高质量科学数据库驱动因素分析

服务模式与激励机制研究。分析下一代人工智能驱动的科技创新的核心业务目标和价值目标，识别各参与主体及其协同模式和价值分



配方式，设计不同主体间价值流动和业务流程，以领域研究和创新为主要核心价值和能力需求，以领域研究社区价值目标单元，构建创新主体间合作网络。以领域聚合与服务集成为主要模式，探索高质量科学数据库的服务聚合方法，并提升数据库及其服务的按需交付能力。其中激励模式构建的重要因素是对激励对象贡献的最大化，影响因素包括驱动力、习惯性的业务流程（交换机制）以及激励因素等，这里，激励因素和价值激励密切相关。

面向智能化服务能力的数据价值度量和交换协议研究。探索以量化算法预测和决策数据的价值，涉及公平估值、价值补偿等，其中价值补偿包括不同业务体系和场景下的价值度量。在科学数据共享范畴内，综合考虑经济价值、学术价值、社会价值等价值测度。在价值度量方面，以用户和使用价值为主要决定因素，按照共享进行分配。特别需要考虑面向智能化服务和人工智能等新的应用，设计机器学习的背景下处理数据评估的原则性框架，量化数据对创新成果的度量。在交换协议方面，综合设计组织协议、法规协议和技术协议。在组织协议方面，需要符合现有平台和主体（包括提供方和使用方）的业务流程和价值体系；在法规协议方面，重点从共享范畴、访问限制、许可协议、价值分配等方面制定政策和交换协议；在技术协议方面，从技术互操作视角，建立主动收割、推荐等交互形式和数据交换传输协议，从语法语义视角，定义高质量数据集的接入规范和描述要求，并研究共性基本知识库需求。此外，建立数据交换的监管机制，以技术监测和协议共识共同促进和约束共享和利用行为。在服务模式上，通过基于引文网络的社区发现提升科学数据效率，拟改进基于模块度的Louvain算法实现。

模块度 Q 用于描述划分的社区内部节点的紧密程度，是评价社区



划分效果的重要指标。在利用 Louvain 算法进行社区划分过程中，对每个节点 i ，依次尝试把节点 i 分配到其每个邻居节点所在的社区，并计算分配前后的模块度增量 ΔQ ，其计算公式为：

$$\Delta Q = \left[\frac{k_{i,in}}{2m} - \frac{\sum_{tot} k_i}{2m^2} \right]$$

其中， $k_{i,in}$ 表示社区 c 内节点与节点 i 的边权重之和； $\sum_{tot}$ 表示与社区 c 内的节点相连的边的权重之和。

在服务价值和服务质量度量方面，综合考虑数据可获取性 f_a 、数据贡献学术质量 f_{ac} 、数据质量 f_q 和可靠性 f_r 等维度。对于给定的数据集 d_j ，其数据可获取性由其服务等级及评价可访问性指标综合加权获取， $f_a(d_j) = w_{sl} * sl(d_j) + w_a * avg(A(d_j))$ 。数据贡献学术质量由数据所产出的学术成果的水平 and 影响力决定，包括领域权重引用影响力 FWCI 和高被引指数等， $f_{ac}(d_j) = \frac{1}{2} * fwci + \frac{1}{2} * \frac{AC_{1\%}(d_j)}{avg(AC_{1\%})}$ 。数据质量度量，

在科学数据 FAIR 原则（可发现、可访问、可互操作、可重用）基础上，利用可量化的计算测度综合计算， $f_q(d_j) = w_f * f_f(d_j) + w_a * f_a(d_j) + w_i * f_i(d_j) + w_{re} * f_{re}(d_j)$ ；数据集可靠性将综合考虑用户反馈等情况。综合服务价值 $f(d_j) = \frac{1}{4} * f_a(d_j) + \frac{1}{4} * f_{ac}(d_j) + \frac{1}{4} * f_q(d_j) + \frac{1}{4} * f_r(d_j)$ ，具体权重系数可根据实际情况调整。

在服务体系价值分配方面，借鉴合作博弈论的夏普利值计算方面，按照贡献进行分配。对于给定的参与主体集合 $I = \{1, 2, \dots, n\}$ ， $\varphi_i(v) = \sum_{s \in S_i} w(|s|) * [v(s) - v(s \setminus \{i\})]$ ，其中， S_i 是 I 中包含成员 i 的所有子集形成的集合， $|s|$ 是集合 s 元素的个数， $w(|s|)$ 是加权因子， $s \setminus \{i\}$ ，是集合 s 中去掉元素 i 的集合， $v(s) - v(s \setminus \{i\})$ 是成员 i 在联盟中的贡献，进而计算出成员的边际贡献。



在此基础上,进行综合评价机制设计与验证。从资源、服务、成效等方面构建科学数据库智能化服务能力的评价指标体系,综合考虑语法、语义、技术、服务等多个维度,形成多层级的能力层级和提升路径,保障面向领域创新需求的资源及其智能化服务能力的可持续发展。

(2) 跨领域、多模态科学数据的主动发现关键技术。面向全球开放科学数据资源,在充分调研国内外数据开放平台数据政策与数据许可协议基础上,利用分布式数据爬虫技术,基于容器和动态代理主动收录全球权威通用或领域数据存储库的开放科学数据资源,实现主动获取科学数据的清洗、加工处理和存储管理,形成统一的科学数据元数据标准和科学数据资源目录。利用高效索引技术、科学数据链接探测分析技术研制科学数据垂直搜索引擎,为人工智能驱动的科学研究新范式提供持续可靠的基础科学数据资源快速发现与获取服务。

在开放数据主动发现方面,拟设计科学数据动态二进制向量哈希随机映射算法提升检索性能,解决互联网海量科学数据资源的高性能检测、搜索、过滤、资源采集任务编排等问题。

科学数据动态二进制向量哈希随机映射算法将散列 M 位数组中的顶点扩展为多位图 Bit Map 的计数器,然后使用哈希函数 $f(\text{Scientific data vector})$ 将资源集合 $U=\{\text{sdv1},\text{sdv2},\text{sdv3} \dots, \text{sdvn}\}$ 中的元素全部映射到散列 M 中 k 个不均匀分区的 $m_i(1 \leq i \leq k)$ 位数组中, m_i 表示第 i 个分区大小,当插入元素时,经过哈希函数映射与取模运算得到 k 个哈希值,对应散列 M 中 m 位数组中的 k 个位置并对计数器进行操作。

$$m = \sum_{i=1}^k m_i$$



应用时首先要先由资源目标决定元素数 n 和期望的误差率 P ，然后通过参数计算，并由此建立散列 M 。

但在海量互联网开放资源中对数据主动发现的场景中使用还是需要经过优化调整，空间维度因资源量大且具有计数器的原因开销增大，优化路线为对散列 M 的多位数据在物理存储需要开辟的空间进行预估使空间占用更小。

首先要计算需要的内存大小 m bits。

$$P = 2^{-\ln 2 \cdot \frac{m}{n}} \Rightarrow \ln P = \ln 2 \cdot (-\ln 2) \cdot \frac{m}{n} \Rightarrow m = -\frac{n \cdot \ln P}{(\ln 2)^2}$$

再由 m ， n 得科学数据特征再哈希散列函数的个数：

$$k = \ln 2 \cdot \frac{m}{n} = 0.7 \cdot \frac{m}{n}$$

根据公式，当 k 最优时：

$$P(\text{error}) = 2^{-k} \Rightarrow \log_2 P = -k \Rightarrow k = \log_2 \frac{1}{P} \Rightarrow \ln 2 \frac{m}{n} = \log_2 \frac{1}{P}$$

以此科学数据动态二进制向量哈希随机映射算法为基础科学数据资源快速发现与获取采编等服务能力进行优化与提升。

(3) 多学科通用型科学数据库平台服务构建。基于国际可信数据仓储平台国际原则与标准规范 TRUST Principles 和科学数据 FAIR 原则等，形成数据存储库建设元数据规范、标识、许可协议、引用规范等标准规范，面向全球科研人员提供科学数据的开放提交、质量审核、全球标识注册、数据发布、影响力追踪评价、数据深度融合与知识服务等，建设生命、化学、材料、遥感、空间科学等领域科学数据社区，持续吸引汇聚全学科领域海内外优质科学数据资源，形成具有一定国际影响力的覆盖的高质量、通用型科学数据库，为人工智能驱动的科学新范式提供基础科学数据资源支撑和数据深度融合知



识化服务。

3.2 可行性分析

(1) 项目研究目标明确，内容具体，要点清晰，各部分内容之间逻辑清晰，具有内在的关联性，方案可行。项目组成员单位具有很好的互补性，牵头单位中科院计算机网络信息中心在关键技术、数据资源和平台建设有很好的基础，参与单位中科院国家空间科学中心在空间科学数据资源和人工智能在空间领域创新应用具有很好的基础，四川大学在理论与关键技术具有很好的基础；研究方法规范、具体，很好地将定性定量、理论分析与实证研究相结合在一起，技术路线清晰，操作性强。

(2) 研究基础。中科院计算机网络信息中心是具有 40 多年科学数据的工作，研究团队在科学数据标识化、科学数据构建方法、多模态数据存储与管理、知识表征与抽取、数据融合与分析等等方面具有坚实的研究基础，发布和立项国际标准 1 项、国家标准 4 项，在包括 SIGMOD、VLDB、ICDE、WWW、IJCAI、AAAI、IEEE TKDE、IEEE TFS、ACM TKDD、ACM TIST、Scientific Data、Nucleic Acids Research 等数据管理与分析的国际顶级会议和期刊发表论文 60 多篇，研发了科学数据银行、科技资源标识等具有一定国际影响力的科学数据服务平台，形成了 AI 融合图数据库系统，可支持千亿级数据对象和百亿级图数据管理，支持对非结构化数据进行 AI 语义提取与关联检索，与国际主流系统 Neo4j 相比，复杂查询性能提升 50% 以上，已获国家



发明专利授权 4 项，并在 2021 年 6 月获天使轮融资（融资额 1200 万元，估值 8000 万元）。

(3) 工作量及时间保障。本课题的研究内容与课题组各成员的研究方向高度吻合，有利于已有研究基础的充分利用。本项目的各项研究内容之间联系紧密、逐层递进，有利于相关研究结果的复用，节省研究时间。此外，人员搭配合理，时间计划可行。

(4) 从工作条件上看，项目牵头单位拥有中国科技网、国家基础学科公共科学数据中心、国家超级计算（中科院）中心等国家级创新平台。与国内各互联网骨干网（超过 400G）和欧美主要学术网络高速互联，与欧洲科研网 GEANT 共建跨洲际 100G 网络高速互联，正推进加入亚太欧洲 100G 科研环网 AER，实现 100G 资源互备；拥有 315PF 算力资源，150PB 存储资源。项目团队所在单位国家基础学科公共科学数据中心、国家空间科学数据中心、中科院科学数据总中心的依托单位，具有丰富的科学数据资源和文献资源。

综上所述，无论是从项目研究的整体方法的科学性，从项目参与者组成的合理性，以及从项目参与单位在相关研究方向和应用的积累方面，均为本项目的顺利开展并达到预期目标提供了可靠的保障。

4. 本项目的特色与创新之处；

本项目研究特色与创新之处主要体现在以下几个方面：

(1) 基于表示学习的科学数据与科技文献的语义化知识对象融合方法。在支撑 AI for Science 中，知识嵌入的数据驱动模式非常关键，而科学数据与科技文献中除了包括海量的语义信息之外，其复杂



多变的文件结构、版式结构背后也蕴含丰富的信息，本研究拟提出基于科学数据结构和语义关联的预训练方法，在此基础上基于复杂网络嵌入与图神经网络模型算法，构建深度学习的表示模型，获得包括结构信息、属性信息和语义信息的向量化表示，实现文献抽取的领域实体与自身图表、文献抽取的知识与已有结构化知识的高效融合，实现高知识密度的科技文献与科学数据关联融合，构建准确、全面的文献与科学数据互通的知识网络。

(2) 跨学科、多尺度科学数据的知识对象标识化构建方法。跨学科、多尺度科学数据的知识对象的多样性与异构性，提出跨学科、多尺度科学数据的知识对象统一编码规则，通过对多源知识对象进行标识化构建，实现基于自主标识注册解析获得全局定位及互操作能力；再基于语义关联建立知识对象的标识化关联，最后通过知识对象异构标识解析为实现跨学科知识对象智能化应用。

(3) 基于激励机制的可扩展的科学数据服务模式。针对高质量科学数据库构建过程中科学数据资源版权以及科研人员共享数据意愿不强的问题，提出基于异构标识识别技术的科学数据全球引用追踪技术，在此基础上提出科学数据影响力评价模型，并基于内容型激励机制理论，提出融合主体对象及其内在动力和影响因素等激励机制的科学数据共享服务模式，构建自我增长的科学数据社区，支撑高质量科学数据库的可持续发展。

5. 年度研究计划及预期研究结果（包括拟组织的重要学术交流活动、国际合作与交流计划等）。



5.1 年度研究计划

本项目计划用4年时间完成，具体计划如下：

第一年度（2024年1月-2024年12月）

调研、梳理和分析面向科学人工智能的跨领域、多模态科学数据融合存储方法、基于文献结构和语义关联的预训练方法、结构化科学数据知识本体自动构建方法，以及跨学科多尺度科学数据的知识对象统一编码方法；研究数据开放平台数据政策和开发数据库相关国际原则与标准规范，在遵循数据政策与许可协议的前提下，利用分布式爬虫技术收录国内外多学科领域权威开放数据平台海量科学数据。

第二年度（2025年1月-2025年12月）

研究跨域跨库的异构数据向量化查询机制和复杂结构数据的成对融合存储模型；完成篇章级预训练模型的设计，利用无标注科技文献进行文本语义及文献结构的联合预训练；构建形成领域科学数据语义词表；持续收录国内外多学科领域权威开放数据，并通过大数据处理技术实现科学数据的存储管理、清洗、加工处理，形成统一的科学数据元数据标准。

课题中期检查。

第三年度（2026年1月-2026年12月）

完成跨领域、多模态科学数据融合存储研发工作；完成基于语义化知识对象的非结构化数据标注方法研究和基于异质网络表示学习的实体链接与冲突消解研究；实现长文本科学数据的知识本体自动构建；完成语义化和标识化知识对象构建；初步形成覆盖生命、化学、材料、遥感、空间科学等领域通用型科学数据库。



第四年度（2027 年 1 月-2027 年 12 月）

持续吸引汇聚全学科领域海内外优质科学数据资源，支持 AI for Science 的研究，不断完善科学数据共享服务模式，形成具有国际高质量、通用型科学数据库，为形成支撑 AI for Science 的数据与知识库系统奠定坚实的基础。

项目结项。

5.2 预期研究成果

通过本项目的研究，将形成支持人工智能的通用型科学数据库构建的理论、方法和技术，并形成具有一定国际影响力的覆盖生命、化学、材料、遥感、空间科学等领域的高质量、通用型科学数据库。

(1). 从支持 AI for Science 的数据与知识平台的构建需求出发，研究形成一套跨领域多模态科学数据融合存储方法、基于主动学习及预训练模型的知识对象抽取与融合、标识化语义化知识对象构建方法、科学数据共享服务机理及通用型科学数据库社区服务构建模式等的理论、技术与方法。

(2). 突破多模态大模型训练和预测的科学数据读取优化，基于主动学习及预训练模型的知识对象抽取与融合，标识化、语义化科学数据知识对象构建方法、面向智能服务科学数据共享机理等关键技术，发表国内外高水平期刊、会议论文不少于 20 篇，申请发明专利不少于 10 项。

(3). 形成具有国际影响力的覆盖生命、化学、材料、遥感、空间科学等领域的高质量、通用型科学数据库服务平台，实现科学数据与



科技文献融合关联，通过数据价值体现、数据社区等实现平台的可持续性。

(4). 培养一批科学数据与数据科学方向的交叉学科人才，其中博士生 6 人，硕士生 10 人。

(5). 本项目将安排赴国外参与短期合作交流 5 人次以上；同时邀请境外知名专家学者 5 人次以上，就科学数据开放共享、数据与知识双驱动的一些关键问题进行深入交流。

(二) 研究基础与工作条件

1. 研究基础（与本项目相关的研究工作积累和已取得的研究工作成绩）；

项目牵头单位中国科学院计算机网络信息中心（以下简称中心）有近 40 年科学数据工作基础，是中国科学数据工作的引领者。1986 年承担国家计委项目“科学数据库及其应用”，2001 年牵头承担科技部国家科技基础条件平台项目“国家基础科学数据共享服务平台”，该平台在 2019 年产生了 6 个国家科学数据中心（全国共 20 个），中心目前是国家基础科学数据中心依托单位。中心一直是中科院科学数据工作总体单位，目前作为中国科学院科学数据总中心依托单位牵头建设中国科学院科学数据中心体系，该体系有一个总中心、18 个学科中心和 13 个所级中心。中心是国际数据委员会（CODATA）中国全国委员会秘书长依托单位，代表中国参与国际科学数据共享工作；是中国信息协会科学数据专业委员会发起单位和秘书长依托单位。项目参与单位中国科学院国家空间科学中心和牵头单位中科院计算机网



络信息中心是全国科技平台标准化技术委员会 (TC486) 科学数据工作组**的正副组长**，负责全国科学数据标准制定的相关工作。参与单位中国科学院国家空间科学中心是我国空间科学及其卫星项目和中国科学院月球与深空探测任务的总体性研究机构，负责组织开展国家空间科学发展战略规划研究，具体负责中国科学院空间科学先导专项的组织与实施，开展空间科学及相关应用领域的创新性科学研究与技术发展和试验工作；其牵头建设的国家空间科学数据中心是已覆盖我国空间科学领域大部分科学数据资源，并且代表中国开展与国际空间科学领域的科学数据资源共享合作。项目参与单位四川大学是教育部直属全国重点大学，国家“双一流”建设高校（A类），其计算机学院人工智能研究所长期从事人工智能理论和系统相关的研究，在人工智能和大数据领域发表多篇顶级论文，并且具有很强大数据关键技术与系统的研发经验。

科学数据资源基础：依托中国科学院科学数据总中心实现对全院18个学科中心（其中11个是国家科学数据中心）、13个所级中心超过100PB的科学数据资源分布式汇聚与集成，实体数据在线服务量超过20PB。中科院科学数据总中心建设的国际化科学数据出版和共享平台-科学数据银行（Science Data Bank, ScienceDB），平台已发布生命科学、化学、材料科学、遥感、空间科学、生态、天文等科学数据集超过680万个；动态汇聚并能开放共享实体遥感数据量超过1PB。通过科技资源标识平台汇聚包含科学数据集、学术论文、学位论文、专利、物种名录、预印本、仪器设备等11种类型的2.6亿条



科技资源。申请人是国家生物信息中心建设总工程师，该中心已汇聚超过 3PB 的生命领域的相关数据资源。国家基础学科公共科学数据中心汇聚了超过 1800 个国家重点研发计划项目的数据，数据量近 2PB。国家空间科学数据中心汇聚的数据资源从学科覆盖性、数据来源项目、时空覆盖率、要素多样性和探测手段多样性等已覆盖我国空间科学领域大部分科学数据资源，目前数据资源总量超过 2PB。建设的国际化关联数据语义服务平台科学数据关联网络 OpenCSDB 为科研人员提供多领域数据的精准化语义融合和知识发现服务，目前已整合来自化学化工、植物、微生物等过 9.5 千万个语义三元组、3.8 千万个语义链接。

研究工作积累：研究团队在科学数据标识化、科学数据构建方法、多模态数据存储与管理、知识表征与抽取、数据融合与分析等等方面具有坚实的研究基础，发布和立项国际标准 1 项、国家标准 4 项，在包括 SIGMOD、VLDB、ICDE、WWW、IJCAI、AAAI、IEEE TKDE、IEEE TFS、ACM TKDD、ACM TIST、Scientific Data、Nucleic Acids Research 等数据管理与分析的国际顶级会议和期刊发表论文 60 多篇。在基于多源数据融合形成高质量科学数据集构建方法上，与国家纳米科学中心合作构建了描述电催化还原过程的开源数据集电催发表在 *Nature 子刊 Scientific Data* 上，与中科院动物所等合作建立了组学、细胞谱系全景数据库 Lineage Landscape，收集了超过 660 万个细胞的数据包括 1500 万个差异表达基因条目信息，实现了对细胞谱系不同



层次、不同时期的多维组学数据的收录和整合，相关成果发表在生信息领域顶级期刊 *Nucleic Acids Research* 上。

系统与平台工作基础：针对多元异构数据融合管理问题，研发了 AI 融合图数据库系统 PandaDB，可支持千亿级数据对象和百亿级图数据管理，支持对非结构化数据进行 AI 语义提取与关联检索，与国际主流系统 Neo4j 相比，复杂查询性能提升 50% 以上，已获国家发明专利授权 4 项，并在 2021 年 6 月获天使轮融资（融资额 1200 万元，估值 8000 万元）。支撑论文关联数据的汇交和共享平台 **科学数据银行 ScienceDB** 目前已获得国际广泛认可，包括成为 Springer Nature、Elsevier、Cell Press、Taylor & Francis Group、Wiley、AGU、科学出版社等国内外权威学术出版社推荐认可的通用型数据存储库，被 Google Dataset Search、Web of Science 的 Data Citation Index、Scopus、DataCite 等收录索引；与 Figshare、Zenodo 等国际著名公共科学数据存储库建立数据资源镜像，全球 70 个国家和地区的科研人员提交共享数据，180 多个国家和地区的科研人员下载数据（见图 11）；平台及时追踪科学数据全球引用情况（见图 12）。依托国家标准建设的科技资源标识平台（www.cstr.cn），实现了科学数据资源确权和全球引用追踪服务，已被国际 Internet 域名系统的最高权威机构 IANA (Internet Assigned Numbers Authority) 采纳，通过实现与 ORCID、DOI 等互认互通，目前已汇聚包含科学数据集、学术论文、学位论文、专利、物种名录、预印本、仪器设备等 11 种类型的 2.6 亿条资源（见图 13）。地理空间数据云（www.gscloud.cn）动态持续汇聚全球遥感



影像数据，为用户提供数据下载、在线计算、数据众包等服务，实名注册用户超过 80 万（见图 14）。




图 11 科学数据银行 ScienceDB 首页




图 12 ScienceDB 的一个数据集被全球引用 92 次



图 13 科技资源标识平台首页



图 14 地理空间数据云首页

2. 工作条件（包括已具备的实验条件，尚缺少的实验条件和拟解决的途径，包括利用国家实验室、国家重点实验室和部门重点实验室等研究基地的计划与落实情况）；

中国科学院计算机网络信息中心是中国互联网的诞生地，拥有中国科技网（CSTNET）、大数据分析计算技术国家地方联合工程实



验室、国家基础学科公共科学数据中心、国家超级计算（中科院）中心等国家级创新平台，形成了国家信息化基础设施-中国科技云。

中国科技网（CSTNET）是国内顶级运营商之一（其他包括中国移动、中国电信、中国联通、中国教育网等），是国际学术网络的重要成员，与国内各互联网骨干网（超过 400G）和欧美主要学术网络高速互联，与欧洲科研网 GEANT 共建跨洲际 100G 网络高速互联，正推进加入亚太欧洲 100G 科研环网 AER，实现 100G 资源互备，有力支持 ITER、SKA 等全球大科学合作计划，同时为支持 AI For Science 的材料、生命、遥感、空间等领域的科学数据资源的全球汇聚、传输和共享提供安全高效的基础网络资源支撑。

中国科学院计算机网络信息中心是国家超级计算（中科院）中心的依托单位，在我国最早提供超级计算服务，是中国国家网络运行管理中心和北方主节点，拥有 315PF 算力资源，是中国超级计算创新联盟的发起单位和中国首家英特尔并行计算中心，在高性能计算领域的算法、软件与应用研发及人才培养方面发挥着重要作用，曾获国际上高性能计算应用领域的最高学术奖项“戈登贝尔奖”的提名奖，国家超级计算基础设施支撑软件系统获 2020 年国家科学技术进步二等奖。依托中国科学院科学数据总中心、国家基础学科公共科学数据中心，基于中国科技网构建了海量分布式存储和处理环境，整个存储容量达到 150PB，有效支持大规模科学数据存储、处理和异地容灾。

3. 正在承担的与本项目相关的科研项目情况（申请人和主要参与者正在承担的与本项目相关的科研项目情况，包括国家自然科学基金的项目和国家其他科技计划项目，要注明项目的资助机构、项目类



别、批准号、项目名称、获资助金额、起止年月、与本项目的关系及负责的内容等)；

无。

4. 完成国家自然科学基金项目情况 (对申请人负责的前一个已资助期满的科学基金项目 (项目名称及批准号) 完成情况、后续研究进展及与本申请项目的关系加以详细说明。另附该项目的研究工作总结摘要 (限 500 字) 和相关成果详细目录)。

面向候鸟迁徙行为的数据挖掘算法研究, 61003138

该项目完成了既定的工作目标, 后续研究已在候鸟迁徙行为挖掘成果的基础上结合多源数据 (生态环境数据、疾病数据) 研究候鸟迁徙行为和生态环境之间的关联关系、候鸟迁徙行为与疾病传播之间的关联关系, 为生态环境的保护及疾病防护提供支持; 在后续研究过程中发现跨领域数据资源的融合关联越来越重要, 特别是对于支持新科研范式条件的多源数据融合管理需求迫切, 这也是本申请项目研究的重要的场景需求。

工作总结摘要:

候鸟迁徙行为过程主要中涉及到栖息地发现、迁徙路线追踪以及栖息地之间的活动关系等。为此如何寻找候鸟迁徙过程的栖息地、追踪候鸟的迁徙路线、挖掘栖息地之间的关系对候鸟和生态环境的保护、禽流感等疾病传播和防治的研究具有重要的意义。本项目研究相关数据挖掘算法并应用这些算法对百万级数据量的候鸟迁徙的卫星跟踪数据进行数据分析。研究基于密度的层次聚类算法发现栖息地、基于聚类的多时间序列关联性分析算法追踪候鸟迁徙的路线、以带权重的连通图挖掘的算法寻找栖息地之间的关系, 最后将这些算法应用到实际的青海湖区域候鸟迁徙卫星跟踪数据当中, 并以 WebGIS 平



台可视化展现算法挖掘的结果,为动物学家和生态学家进一步的研究提供坚实的基础。

(三) 其他需要说明的情况

1. 申请人同年申请不同类型的国家自然科学基金项目情况(列明同年申请的其他项目的项目类型、项目名称信息,并说明与本项目之间的区别与联系)。

同年申请国际(地区)合作与交流项目“面向车路协同的车道级路径引导关键算法研究”。该项目主要面向城市化中的交通网络图结构的连接、传导等性质,研究基于时空网络的城市规划关键方法。在使用过程中使用及产生的相关数据,可以作为本次申请项目的相关数据进行数据平台服务能力的验证。

2. 具有高级专业技术职务(职称)的申请人或者主要参与者是否存在同年申请或者参与申请国家自然科学基金项目的单位不一致的情况;如存在上述情况,列明所涉及人员的姓名,申请或参与申请的其他项目的项目类型、项目名称、单位名称、上述人员在该项目中是申请人还是参与者,并说明单位不一致原因。

无。

3. 具有高级专业技术职务(职称)的申请人或者主要参与者是否存在与正在承担的国家自然科学基金项目的单位不一致的情况;如存在上述情况,列明所涉及人员的姓名,正在承担项目的批准号、项目类型、项目名称、单位名称、起止年月,并说明单位不一致原因。

无。

4. 其他。

无。



周园春 简历

2023版

中国科学院计算机网络信息中心， 研究员

教育经历：

- (1) 2002-09 至 2006-07，中国科学院计算技术研究所，计算机系统结构，博士
- (2) 1999-09 至 2002-07，中国科学院合肥智能机械研究所，模式识别与智能系统，硕士
- (3) 1994-09 至 1997-07，中国科学技术大学，计算机软件，其他

博士后工作经历：

无

科研与学术工作经历（博士后工作经历除外）：

- (1) 2021-01 至 今，中国科学院科学数据总中心，主任，研究员
- (2) 2022-05 至 今，大数据分析系统国家工程研究中心，副主任，研究员
- (3) 2020-12 至 今，中国科学院计算机网络信息中心，副主任，研究员
- (4) 2018-06 至 2021-05，中国科学院计算机网络信息中心，大数据部主任，研究员
- (5) 2014-01 至 2018-06，中国科学院计算机网络信息中心，科学数据中心（大数据部）副主任，研究员
- (6) 2013-09 至 2014-03，美国罗格斯大学，商学院（熊辉教授组）高级访问学者，研究员
- (7) 2009-01 至 2013-12，中国科学院计算机网络信息中心，科学数据中心，副研究员
- (8) 2006-04 至 2008-12，中国科学院计算机网络信息中心，科学数据中心，助理研究员

曾使用其他证件信息：

无

近五年主持或参加的国家自然科学基金项目/课题：

- (1) 国家自然科学基金委员会，专项项目，J2224012，基于信创环境科学基金全过程管理的架构设计与实践研究，2023-01-01 至 2023-12-31，42万元，在研，参与
- (2) 国家自然科学基金委员会，专项项目，L1924075，国家自然科学基金成果开放共享政策与平台架构设计研究，2020-01-01 至 2021-12-31，40万元，结题，参与
- (3) 国家自然科学基金委员会，重点项目，61836013，面向领域大数据的知识图谱构建，2019-01-01 至 2023-12-31，288万元，在研，主持

近五年主持或参加的其他科研项目/课题（国家自然科学基金项目除外）：

- (1) 国家发改委，国家“十四五”生物经济发展重大项目，2112-000000-04-01-922949，国家生物信息中心项目，2022-01 至 2026-12，108036万元，在研，主持
- (2) 中国科学院，战略性先导科技专项（B类）课题，XDB38030300，人群队列大数据管理关键技术研发，2020-01 至 2024-12，300万元，在研，主持
- (3) 中国科学院，战略性先导科技专项（A类）子课题，XDA16021403，器官模拟数据管理与可视分析关键技术研究，2021-01 至 2022-12，497万元，结题，主持
- (4) 科技部，创新方法工作专项，2019IM020100，基于群智理论的创新方法新系统研究与应用示范，2019-



12 至 2021-12, 142万元, 结题, 主持

(5) 科技部, 国家重点研发计划课题, 2016YFB0501901, 协同精密定位总体构架与服务平台设计, 2016-07 至 2021-06, 2720.65万元, 结题, 主持

(6) 中国科学院, 十三五信息化专项, XXH13505, 科学大数据工程, 2017-01 至 2020-12, 4600万元, 结题, 主持

(7) 中国科学院, 十三五信息化专项, XXH13514, 中国科学院科学数据中心体系建设, 2019-01 至 2020-12, 3000万元, 结题, 主持

代表性研究成果和学术奖励情况(填写代表性论文时应根据其发表时的真实情况如实规范列出所有作者署名, 不再标注第一作者或通讯作者):

一、代表性论著(请在“申请书详情”界面, 点开“人员信息”-“代表性成果”卡片查看对应的全文):

(1) Meng Xiao; Ziyue Qiao; Yanjie Fu; Hao Dong; Yi Du; Pengyang Wang; Hui Xiong; **Yuanchun Zhou (通讯作者)**; Hierarchical Interdisciplinary Topic Detection Model for Research Proposal Classification, *IEEE Transactions on Knowledge and Data Engineering (IEEE TKDE)* (CCF A), 2023 (期刊论文)

(2) Pengyang Wang; Yanjie Fu; **Yuanchun Zhou (通讯作者)**; Kunpeng Liu; Xiaolin Li; Kien Hua; Exploiting Mutual Information for Substructure-aware Graph Representation Learning, *Twenty-Ninth International Joint Conference on Artificial Intelligence (IJCAI 2020)* (CCF A), Yokohama, Japan, 2021-1-7至2021-1-15 (会议论文)

(3) Haoteng Yan; Ronghao Wang; Shuai Ma; Daoran Huang; Si Wang; Jie Ren; Changfa Lu; Xin Chen; Xiaoyong Lu; Zikai Zheng; Weiqi Zhang; Jing Qu; **Yuanchun Zhou (通讯作者)**; Guang-Hui Liu; Lineage Landscape: a comprehensive database that records lineage commitment across species, *Nucleic Acids Research* (生命领域发表数据论文的顶级期刊, 最新影响因子19.16), 2023, 51(D1): D1061-D1066 (期刊论文)

(4) Yang Yang; Zhen-Qiang Sun; Hengshu Zhu; Yanjie Fu; **Yuanchun Zhou**; Hui Xiong; Jian Yang; Learning Adaptive Embedding Considering Incremental Class, *IEEE Transactions on Knowledge and Data Engineering (IEEE TKDE)* (CCF A), 2023, 35(3): 2736-2749 (期刊论文)

(5) 周园春; 吴俊杰; 钱力; 杜一; 刘冠男; 创新方法新系统, 科学出版社, 2022 (学术专著)

二、论著之外的代表性研究成果和学术奖励:

(1) 周园春(2/10); 大规模地理空间数据云服务关键技术与应用, 北京市政府, 科学技术奖, 省部二等奖, 2016(黎建辉; 周园春; 王学志; 林青慧; 杨风雷; 胡良霖; 张波; 沈志宏; 吴章生; 薛正华) (科研奖励)

(2) 周园春(2/20); 烟草科研大数据资源标准体系、总体架构和关键技术研究与应用, 国家烟草专卖局/中国烟草总公司, 科技进步, 省部一等奖, 2022(谢剑平; 周园春; 冯伟华; 邱纪青; 郑新章; 胡良霖; 贾楠; 沈志宏; 刘亚丽; 王锐; 王爱国; 邢军; 王迪; 张晨; 汪志波; 汪洋; 王新伟; 杨松; 曾世通; 王峙) (科研奖励)

(3) 周园春; Science Data Bank: the building and service of an international data repository, 第四届世界科技期刊论坛, 北京新青海喜来登酒店, 2021-07-28至2021-07-29 (会议报告)

(4) 周园春; 科学数据银行: 国际化科学数据出版与共享平台的建设和服务, 第七届生物多样性信息学研讨会, 南京, 2021-09-25至2021-09-27 (会议报告)

(5) 周园春; 科学大数据管理技术、系统与服务, 第七届中国科学数据大会, 内蒙古呼和浩特, 2021-10-



11至2021-10-14 (会议报告)

(6) 周园春 ; 科学数据出版与开放共享, 第十八届全国少数民族语言文字信息处理学术研讨会, 北京, 2021-11-27至2021-11-28 (会议报告)

(7) 中国标准, 潘贤章; 潘恺; 周园春; 郑重; 周广军 ; 土壤质量 土壤相关数据的数字交换, GB/T 41224-2021, 全国土壤质量标准化技术委员会, 2021-12-31 (标准)

(8) 中国标准, 黎建辉; 胡良霖; 朱艳华; 王静; 王卫华; 尹海清; 王卷乐; 周园春; 李冰; 张辉; 刘宇峰; 高瑜蔚; 柏永青; 姜雪; 马文静 ; 科学数据引用, GB/T 35294-2017, 全国信息技术标准化技术委员会, 2017-12-29 (标准)

(9) 中国标准, 胡良霖; 黎建辉; 陈希; 王静; 李娜; 郭晓峰; 赵辉; 尹海清; 周园春; 李冰; 于铁强; 蔡立志; 龙凯; 夏琦; 黄先芝; 崔云鹏; 陈曙东; 周力; 姜雪; 高瑞鑫; 王建华 ; 数据溯源描述模型, GB/T 34945-2017, 全国信息技术标准化技术委员会, 2017-11-1 (标准)

(10) 图数据库系统相关专利许可, 专利, 技术许可, 中科知道(北京)科技有限公司(每年授权使用费为公司营业额的千分之三)(2021年6月获天使轮融资1200万元, 估值8000万元), 0.0000万元, 2019-12-01 (成果技术转移)



唐明洁 简历

2023版

四川大学， 计算机学院， 教授

教育经历：

- (1) 2013-12 至 2016-09, Purdue University, 普渡大学, 计算机, 博士
- (2) 2010-10 至 2013-12, Purdue University, 普渡大学, 计算机, 硕士
- (3) 2007-10 至 2010-07, 中国科学院大学, 计算机, 硕士
- (4) 2003-09 至 2007-07, 四川大学, 计算机, 学士

博士后工作经历：

无

科研与学术工作经历（博士后工作经历除外）：

- (1) 2022-10 至 今, 四川大学, 计算机学院, 教授
- (2) 2018-10 至 2022-09, 蚂蚁集团美国, 大数据和人工智能, 其他正高级职称
- (3) 2016-09 至 2018-10, Hortonworks, Research Lab, 其他正高级职称
- (4) 2015-05 至 2015-09, IBM, Research Lab, 无
- (5) 2012-05 至 2012-09, Microsoft, Research Lab, 无

曾使用其他证件信息：

无

近五年主持或参加的国家自然科学基金项目/课题：

- (1) 国家自然科学基金委员会, 青年科学基金项目, 61802364, 基于内存的大规模空间数据管理和机器学习系统, 2019-01-01 至 2021-12-31, 25万元, 结题, 主持

近五年主持或参加的其他科研项目/课题（国家自然科学基金项目除外）：

- (1) 科技部, 国家重点研发计划, 2022YFF0711701, 冰冻圈大数据智能管理挖掘及自动化生产技术, 2022-11 至 2025-10, 270万元, 在研, 主持

代表性研究成果和学术奖励情况（填写代表性论文时应根据其发表时的真实情况如实规范列出所有作者署名，不再标注第一作者或通讯作者）：

一、代表性论著（请在“申请书详情”界面，点开“人员信息”-“代表性成果”卡片查看对应的全文）：

- (1) Weiqing Yang; **Mingjie Tang**; Yongyang Yu; Yanbo Liang; Bikas Saha ; SHC: Distributed Query Processing for Non-Relational Data Store, *34th IEEE International Conference on Data Engineering (ICDE)*, Paris, 2018-03-01至2018-03-05 (会议论文)

- (2) Bo Sang; Shuwei Gu; Xiaojun Zhan; **Mingjie Tang** ; Cougar: A General Framework for Jobs Optimization In Cloud., *39th IEEE International Conference on Data Engineering*(, USA LA, 2023-01-11至2023-02-01 (会议论文)

- (3) **Mingjie Tang**; Yongyang Yu; Qutaibah M Malluhi; Mourad Ouzzani; Walid G Aref ;



Locationspark: a distributed in-memory data management system for big spatial data, *Proceedings of the VLDB Endowment*, 2016, 9(13): 1565-1568 (期刊论文)

(4) **MingJie Tang**; Ruby Y. Tahboub; Walid G. Aref; Mikhail J. Atallah; Mourad Ouzzani ; Similarity Group-By operators for multi-dimensional relational data., *32nd IEEE International Conference on Data Engineering*, Helsinki, 2016-03-16至2016-03-20 (会议论文)

(5) **Mingjie Tang**; Yongyang Yu; Walid G. Aref; Qutaibah Malluhi; Mourad Ouzzani ; Efficient Parallel Skyline Query Processing for High-Dimensional Data, *IEEE Transactions on Knowledge and Data Engineering*, 2018, 2(99): 12-24 (期刊论文)

二、论著之外的代表性研究成果和学术奖励:

无

NSFC 2023



邹自明 简历

2023版

中国科学院国家空间科学中心， 研究员

教育经历：

- (1) 2004-09 至 2014-04, 中国科学技术大学, 空间物理学, 博士
- (2) 1998-09 至 2001-07, 北京大学, 空间物理学, 硕士
- (3) 1988-09 至 1993-07, 中国科学技术大学, 空间物理学, 学士

博士后工作经历：

无

科研与学术工作经历（博士后工作经历除外）：

- (1) 2009-12 至 今, 中国科学院国家空间科学中心, 大数据技术研究实验室, 研究员
- (2) 2004-05 至 2009-11, 中国科学院国家空间科学中心, 大数据技术研究实验室, 副研究员
- (3) 1999-12 至 2004-04, 中国科学院国家空间科学中心, 空间环境研究预报室, 副研究员
- (4) 1998-01 至 1999-11, 中国科学院国家空间科学中心, 空间环境研究预报室, 助理研究员
- (5) 1993-08 至 1997-12, 中国科学院国家空间科学中心, 空间环境研究预报室, 研究实习员

曾使用其他证件信息：

无

近五年主持或参加的国家自然科学基金项目/课题：

- (1) 国家自然科学基金委员会, 专项项目, 42242403, 战略研究类: 空间科学领域的开放科学发展及其影响战略调研, 2023-01-01 至 2023-12-31, 23万元, 在研, 参与

近五年主持或参加的其他科研项目/课题（国家自然科学基金项目除外）：

- (1) 中国科学院, 网络安全和信息化专项, CAS-WX2022SF-0103, 空间天气典型事件知识挖掘与智能建模研究, 2023-01 至 今, 220万元, 在研, 参与
- (2) 中国科学院, 中国科学院战略性先导科技专项(A类), XDA15040000, 空间科学先导专项(二期)科学卫星地面支撑项目, 2018-01 至 今, 13511万元, 在研, 主持
- (3) 中华人民共和国科学技术部, 国家科技资源共享服务平台项目, 192020000210, 国家空间科学数据中心, 2020-01 至 今, 1200万元, 在研, 主持
- (4) 国家科技基础条件平台中心, 委托任务, 2022WT12, 科学数据平台建设发展标准框架设计和专家组工作支撑, 2022-07 至 今, 10万元, 在研, 主持
- (5) 中华人民共和国科学技术部门, 国家重点研发计划, 2022YFF0711400, 空间科学大数据智能管理与分析挖掘关键技术及应用, 2022-11 至 今, 1400万元, 在研, 主持
- (6) 中国科学院, 网络安全和信息化专项, CAS-WX2021PY-0101, 空间天气典型事件知识挖掘与智能建模研究, 2022-01 至 2022-12, 80万元, 结题, 参与
- (7) 国家科技基础条件平台中心, 委托任务, 2021WT08, 2021年度科技平台标准化工作支撑和战略研究——科学数据领域, 2021-06 至 2022-06, 10万元, 结题, 主持
- (8) 国家科技基础条件平台中心, 委托任务, 2020WT03, 科学数据与野外台站领域标准化工作与支撑,



2020-08 至 2021-07, 10万元, 结题, 主持

(9) 北京市科学技术委员会, 北京市科技计划项目, Z181100002918002, 空间科学大数据管理与应用服务平台建设, 2018-08 至 2020-09, 1500万元, 结题, 主持

(10) 中国科学院, 信息化专项, XXH13505-04, 大数据驱动的空间科学领域创新示范平台, 2018-01 至 2019-12, 400万元, 结题, 主持

代表性研究成果和学术奖励情况(填写代表性论文时应根据其发表时的真实情况如实规范列出所有作者署名, 不再标注第一作者或通讯作者):

一、代表性论著(请在“申请书详情”界面, 点开“人员信息”-“代表性成果”卡片查看对应的全文):

(1) 宫哲; 邹自明; 陆阳; 基于集成学习的太阳质子事件短期预报方法, *空间科学学报*, 2022, 42(3): 340-345 (期刊论文)

(2) 殷梦婷; 邹自明; 钟佳; 一种电离层TEC格点预测模型, *空间科学学报*, 2021, 41(4): 568-579 (期刊论文)

(3) 佟欣; 邹自明; 白曦; 钟佳; 胡泽骏; 李斌; 喉区极光的机器识别, *空间科学学报*, 2021, 41(4): 654-666 (期刊论文)

(4) Ziming Zou; Senlin Xiong; Xiaoyan Hu; e-Science Applications of China's Space Science Satellite Missions, Springer Nature, 2019 (学术专著)

(5) 邹自明; 胡晓彦; 熊森林; 空间科学大数据的机遇与挑战, *中国科学院院刊*, 2018, 33(8): 877-883 (期刊论文)

二、论著之外的代表性研究成果和学术奖励:

(1) 钟佳; 邹自明; 佟继周; 一种地震电离层TEC关联分析方法, 2020-2-28, 中国, CN202010128083.8 (专利)

(2) 钟佳; 邹自明; 佟继周; 一种电离层TEC异常值提取方法及系统, 2020-2-28, 中国, CN202010128064.5 (专利)

(3) 王慈枫; 邹自明; 胡晓彦; 李云龙; 数字地球磁层的构建及基于数字地球磁层的时空计算方法, 2020-3-11, 中国, CN202010165674.2 (专利)

(4) 佟欣; 邹自明; 一种全天空喉区极光识别方法及系统, 2020-1-13, 中国, CN202010032041.4 (专利)

(5) 殷梦婷; 钟佳; 李云龙; 胡晓彦; 邹自明; 一种基于GRU网络模型的电离层TEC单点预测方法及系统, 2020-01-19, 中国, CN202010058571.6 (专利)



刘峰 简历

2023版

中国科学院计算机网络信息中心， 研究员

教育经历：

- (1) 2012-09 至 2017-01，中国科学院大学，图书馆学，博士
- (2) 2001-09 至 2004-04，大连理工大学，计算机应用技术，硕士
- (3) 1993-09 至 1997-07，东北大学，计算机及应用，学士

博士后工作经历：

无

科研与学术工作经历（博士后工作经历除外）：

- (1) 2020-12 至 今，中国科学院计算机网络信息中心，大数据技术与应用发展部，研究员
- (2) 2011-12 至 2020-11，中国科学院计算机网络信息中心，大数据技术与应用发展部，高级工程师
- (3) 2005-12 至 2011-11，中国科学院计算机网络信息中心，科学数据中心，工程师
- (4) 2004-04 至 2005-11，中国科学院计算机网络信息中心，科学数据库，助理工程师

曾使用其他证件信息：

无

近五年主持或参加的国家自然科学基金项目/课题：

无

近五年主持或参加的其他科研项目/课题（国家自然科学基金项目除外）：

- (1) 中国科学院科学传播局，中国科学院网信专项，CAS-WX2022GC-0203，科学大数据工程（三期）项目—科学数据资源网络建设课题，2021-01 至 2025-12，500万元，在研，主持
- (2) 中华人民共和国科学技术部，“十二五”国家重大科技基础设施，HUAN-J03-2020-02，地球系统数值模拟装置支撑数据库和可视化分系统-地球系统数值模拟装置支撑数据库子课题，2020-10 至 2025-05，1057.2万元，在研，主持
- (3) 中华人民共和国科学技术部，国家重点研发计划，2021YFF0704203，面向国家科学数据中心的基础软件栈及系统项目—多学科跨领域数据融合服务网络系统课题，2021-12 至 2024-11，603万元，在研，主持

代表性研究成果和学术奖励情况（填写代表性论文时应根据其发表时的真实情况如实规范列出所有作者署名，不再标注第一作者或通讯作者）：

一、代表性论著（请在“申请书详情”界面，点开“人员信息”-“代表性成果”卡片查看对应的全文）：

- (1) 刘峰；韩芳；魏天珂；陈锬；赵月红；吴慧；范国梅；科学数据语义关联技术研究与应用，*数据与计算发展前沿*，2023，5(01)：28-40 （期刊论文）
- (2) 许淞源；李成赞；刘峰；基于知识图谱和主题模型的短文本特征增强方法，*数据与计算发展前沿*，2023，5(02)：97-105 （期刊论文）
- (3) 刘峰；陈昕；黎建辉；刘昂；韩芳；大规模分布式科学数据管理与服务技术架构及系统，*大数据*，2016，0(06)：14-24 （期刊论文）



(4) 刘峰; 黎建辉; 张进; 韩芳; 刘昂 ; TeamDR:面向科研团队的数据知识库管理系统, *现代图书情报技术*, 2016, 03: 82-89 (期刊论文)

(5) 刘峰; 张晓林 ; 数据管理计划构成规范及其可操作数据监护模型研究, *现代图书情报技术*, 2016, 01: 11-16 (期刊论文)

二、论著之外的代表性研究成果和学术奖励:

(1) 刘峰; 周园春; 韩芳; 沈志宏; 夏景隆 ; 一种通用的分布式异构数据一体化物理汇聚、组织、发布与服务方法及系统, 2023-04-12, 中国, CN202010020974.1 (专利)

(2) 刘峰; 韩芳; 夏景隆; 周园春; 陈昕 ; 一种通用的信息资源定制化汇交、发布方法, 2023-3-28, 中国, CN202010139717.X (专利)

(3) 刘峰; 陈昕; 夏景隆; 韩芳; 周园春 ; 一种通用的分布式异构数据一体化逻辑汇聚组织、发布与服务方法及系统, 2023-03-10, 中国, CN202010021145.5 (专利)

(4) 刘峰; 陈昕; 周园春; 刘宁; 夏景隆; 常青玲; 高瑜蔚 ; 一种领域多标准元数据定制化在线汇交与服务方法及系统, 2021-12-10, 中国, CN201810841547.2 (专利)

(5) 刘峰; 黎建辉; 夏景隆; 何洪林; 沈志宏; 郭学兵; 苏文; 唐新斋 ; 一种基于扩展库表数据字典的数据汇交系统定制化方法, 2021-03-30, 中国, CN201710368274.X (专利)

(6) 刘峰; 张晓林; 黎建辉; 周园春 ; 一种基于量化DMP的科研项目生命周期数据管理定制化控制方法和系统, 2021-01-12, 中国, CN201710454837.7 (专利)

(7) 刘峰; 陈昕; 黎建辉; 夏景隆; 吴志坚; 黄维 ; 一种面向关系数据库的通用数据服务定制化封装方法, 2020-12-18, 中国, CN201710724604.4 (专利)

(8) 刘峰; 黎建辉; 胡良霖; 沈志宏; 虞路清; 朱艳华 ; 一种通用的在线服务平台定制化评估方法和系统, 2020-10-20, 中国, CN201710549593.0 (专利)



王华进 简历

2023版

中国科学院计算机网络信息中心， 副研究员

教育经历：

- (1) 2011-09 至 2018-06, 中国科学院大学, 计算机应用技术, 博士
- (2) 2006-09 至 2010-06, 山东大学威海分校, 软件工程, 学士

博士后工作经历：

无

科研与学术工作经历（博士后工作经历除外）：

- (1) 2023-01 至 今, 中国科学院计算机网络信息中心, 大数据技术与应用发展部, 副研究员
- (2) 2018-07 至 今, 中国科学院计算机网络信息中心, 大数据技术与应用发展部, 助理研究员

曾使用其他证件信息：

无

近五年主持或参加的国家自然科学基金项目/课题：

无

近五年主持或参加的其他科研项目/课题（国家自然科学基金项目除外）：

- (1) 科技部, 国家重点研发计划, 2021YFF0704200, 面向国家科学数据中心的基础软件栈及系统, 2021-12 至 2024-11, 1918.60万元, 在研, 参与
- (2) 中国科学院, 战略性先导科技专项(A类)子课题, XDA16021502, 知识库与公共数据平台建设, 2021-11 至 2022-12, 45.20万元, 结题, 主持

代表性研究成果和学术奖励情况（填写代表性论文时应根据其发表时的真实情况如实规范列出所有作者署名，不再标注第一作者或通讯作者）：

一、代表性论著（请在“申请书详情”界面，点开“人员信息”-“代表性成果”卡片查看对应的全文）：

(1) **Huajin Wang**; Jianhui Li; Zhihong Shen; Yuanchun Zhou ; Approximations and Bounds for (n, k) Fork-Join Queues: A Linear Transformation Approach, *2018 18th IEEE/ACM International Symposium on Cluster, Cloud and Grid Computing (CCGRID)*, Washington, DC, USA, 2018-5-1至2018-5-4 (会议论文)

(2) 沈志宏; 赵子豪; **王华进**; 刘忠新; 胡川; 周园春 ; PandaDB:一种异构数据智能融合管理系统, *软件学报*, 2021, 32(3): 763-780 (期刊论文)

(3) 黎建辉; 李跃鹏; **王华进**; 陈明奇 ; 科学大数据管理技术与系统, *中国科学院院刊*, 2018, 33(8): 796-803 (期刊论文)

(4) Li, Liang; Shen, Zhihong; Li, Jianhui; Liu, Dongjiang; **Wang, Huajin**; Wang, Lipeng; Sun, Qinglan ; A Resilient Index Graph for Querying Large Biological Scientific Data, *IEEE 6th International Congress on Big Data (BigData Congress)*, Honolulu, HI, USA, 2017-6-25至2017-6-30 (会议论文)



(5) **Huajin Wang**; Jianhui Li; Haiming Zhang; Yuanchun Zhou ; Benchmarking replication and consistency strategies in cloud serving databases: HBase and Cassandra, *Workshop on big data benchmarks, performance optimization, and emerging hardware*, Hangzhou, China, 2014-9-5至2014-9-5
5 (会议论文)

二、论著之外的代表性研究成果和学术奖励：

无

NSFC 2023



李成赞 简历

2023版

中国科学院计算机网络信息中心， 高级工程师

教育经历：

- (1) 2013-09 至 2020-06，中国科学院大学，计算机应用技术，博士
- (2) 2006-09 至 2009-06，北京林业大学，森林经理，硕士
- (3) 2002-09 至 2006-06，北京林业大学，信息管理与信息系统，学士

博士后工作经历：

无

科研与学术工作经历（博士后工作经历除外）：

- (1) 2009-09 至 今，中国科学院计算机网络信息中心，大数据技术与应用发展部，高级工程师

曾使用其他证件信息：

无

近五年主持或参加的国家自然科学基金项目/课题：

无

近五年主持或参加的其他科研项目/课题（国家自然科学基金项目除外）：

- (1) 中科院科学传播局，中国科学院期刊出版领域引进优秀人才择优支持，无，科学数据出版模式探索实践与生态建设，2023-01 至 2025-12，110万元，在研，主持
- (2) 中国科学院网信办，中国科学院网络安全和信息化专项，CAS-WX2022YW-0103，2022 年数据云平台运行维护与应用支持，2022-01 至 2022-12，160万元，结题，主持
- (3) 中华人民共和国科学技术部，国家重点研发计划，2016YFB0501901，协同精密定位总体构架与服务平台设计，2016-07 至 2021-06，3610.65万元，结题，参与

代表性研究成果和学术奖励情况（填写代表性论文时应根据其发表时的真实情况如实规范列出所有作者署名，不再标注第一作者或通讯作者）：

一、代表性论著（请在“申请书详情”界面，点开“人员信息”-“代表性成果”卡片查看对应的全文）：

- (1) Chengzan Li; Yuanchun Zhou; Xiaohuan Zheng; Zeyu Zhang; Lulu Jiang; Zongwen Li; Pengyao Wang; Jianhui Li; Songyuan Xu; Zhanjie Wang ; Tracing the footsteps of open research data in China, *Learned Publishing*, 2022, 35(1): 46-55 (期刊论文)
- (2) 李成赞; 张丽丽; 侯艳飞; 周园春; 黎建辉 ; 科学大数据开放共享:模式与机制, *情报理论与实践*, 2017, 40(11): 45-51 (期刊论文)
- (3) 李成赞; 黎建辉; 王学志; 沈志宏; 杜一 ; 基于引文网络社区发现的数据推荐研究, *情报学报*, 2021, 40(8): 879-886 (期刊论文)

二、论著之外的代表性研究成果和学术奖励：

- (1) 李成赞; 杜一 ; 一种数据出版物学术影响力评价预测方法, 2019-08-14, 中国, CN201910749170.2 (专利)



(2) 李成赞; 杜一 ; 一种基于引文网络社区发现的数据推荐方法, 2019-08-14, 中国,
CN201910748028.6 (专利)

NSFC 2023



陈昕 简历

2023版

中国科学院计算机网络信息中心，高级工程师

教育经历：

- (1) 2004-09 至 2011-01，中国科学院软件研究所，计算机应用技术，博士
- (2) 2000-09 至 2004-07，北京信息工程学院，计算机科学与技术，学士

博士后工作经历：

无

科研与学术工作经历（博士后工作经历除外）：

- (1) 2011-02 至 中国科学院计算机网络信息中心，大数据技术与应用发展部，高级工程师

曾使用其他证件信息：

无

近五年主持或参加的国家自然科学基金项目/课题：

- (1) 国家自然科学基金委员会，专项项目，L1924075，国家自然科学基金成果开放共享政策与平台架构设计研究，2020-01-01 至 2021-12-31，40万元，结题，参与

近五年主持或参加的其他科研项目/课题（国家自然科学基金项目除外）：

- (1) 中国科学院，网信专项，CAS-WX2022SDC-ZZX，中国科学院科学数据总中心运行维护，2022-01 至 2025-12，400万元，在研，主持
- (2) 中国科学院，网信专项，CAS-WX2022GC-0202，面向科学数据体系的公共服务平台，2021-01 至 2025-12，630万元，在研，主持
- (3) 科技部，国家重点研发计划子课题，2021YFF0704204-03，科学数据与分析软件共享社区及搜索引擎研发，2021-12 至 2024-11，135.6万元，在研，主持
- (4) 中国科学院，网信专项，CAS-WX2021SF-020102，植物物种关联数据网络建设，2022-01 至 2023-12，50万元，在研，主持
- (5) 中国科学院，网信专项，CAS-WX2022ZX01-05，中国科学院数据安全管理制度研究，2022-04 至 2023-03，90万元，在研，参与
- (6) 中国科学院，战略性先导科技专项，XDA19020000，大数据云服务平台，2018-01 至 2022-12，24418.02万元，结题，参与
- (7) 中国科学院，战略性先导科技专项子课题，XDA16021503，数据资源与服务规范研制，2021-11 至 2022-12，45.2万元，结题，主持
- (8) 科技部，国家重点研发计划子课题，2017YFB1400203-02，资源业务协同服务关键技术研究，2017-12 至 2020-11，50万元，结题，主持

代表性研究成果和学术奖励情况（填写代表性论文时应根据其发表时的真实情况如实规范列出所有作者署名，不再标注第一作者或通讯作者）：

一、代表性论著（请在“申请书详情”界面，点开“人员信息”-“代表性成果”卡片查看对应的全文）：



(1) 陈昕; 郑晓欢; 潘博雅; 沈志宏; 周园春; 褚大伟 ; 中国科学院科学数据中心体系建设实践及展望, *中国科学数据*, 2023, 8(1) (期刊论文)

(2) Haoteng Yan; Ronghao Wang; Shuai Ma; Daoran Huang; Si Wang; Jie Ren; Changfa Lu; **Xin Chen**; Xiaoyong Lu; Zikai Zheng; Weiqi Zhang; Jing Qu; Yuanchun Zhou; Guang-Hui Liu ; Lineage Landscape: a comprehensive database that records lineage commitment across species, *Nucleic Acids Research*, 2022, 51(D1): D1061-D1066 (期刊论文)

(3) 唐新斋; 陈昕; 何洪林; 郭学兵; 苏文; 谢传节; 沈志宏; 张黎; 任小丽; 侯艳飞; 刘峰 ; 新一代“生态网络云”大数据平台的设计与实现, *数据与计算发展前沿*, 2022, 4(1): 53-68 (期刊论文)

(4) 王卫军; 李成赞; 郑晓欢; 褚大伟; 姜璐璐; 陈昕; 杜一; 周园春 ; 全球科学数据出版发展态势分析——基于Web of Science数据库的调研, *中国科学数据*, 2021, 6(3): 1-19 (期刊论文)

二、论著之外的代表性研究成果和学术奖励:

无



刘佳 简历

2023版

中国科学院计算机网络信息中心，高级工程师

教育经历：

(1) 2007-08 至 2009-08，韩国汉阳大学（Hanyang University, South Korean），电子电气控制测量工学，硕士

(2) 2003-09 至 2007-08，青岛大学，通信工程，学士

博士后工作经历：

无

科研与学术工作经历（博士后工作经历除外）：

(1) 2016-05 至今，中国科学院计算机网络信息中心，大数据与应用发展部，高级工程师

(2) 2010-01 至 2016-05，中国物品编码中心，技术研究部，工程师

曾使用其他证件信息：

无

近五年主持或参加的国家自然科学基金项目/课题：

无

近五年主持或参加的其他科研项目/课题（国家自然科学基金项目除外）：

(1) 中国科学院，中国科学院人才支撑体系专项（中科院青促会），2020176，数字对象标识技术研究，2020-01 至 2024-12，80万元，在研，主持

(2) 科技部，重点研发子课题，2021YFF0704200，科学数据全局可发现和可信共享，2021-12 至 2024-11，120万元，在研，主持

(3) 内蒙古自治区科学技术厅，内蒙古自治区科技成果转化专项，2021CG0033，基于区块链技术的智慧生态畜牧业大数据平台研制与示范化，2021-06 至 2023-05，130万元，在研，主持

(4) 国家市场监督管理总局，国家市场监督管理总局委托专项，2022，进口冷链食品追溯数据管理及分析规范，2022-08 至 2022-12，25万元，结题，主持

(5) 工业和信息化部，工业互联网创新发展工程，TC190A3WK-2，2019年工业互联网创新发展工程工业互联网标识解析公共服务支撑平台，2019-06 至 2022-05，10000万元，结题，参与

(6) 吉林省科技厅，吉林省重点科技研发项目，20180201104GX，基于物联网标识解析的生产流程追溯和智能优化服务平台开发及应用示范，2018-01 至 2020-12，36万元，结题，主持

(7) 工业和信息化部，2018年工业互联网创新发展工程，2018，工业互联网标识解析整体架构技术标准制定与试验验证，2018-08 至 2020-12，400万元，结题，主持

(8) 国家科技基础条件平台中心，国家科技基础条件平台中心专项课题，2019DDJ1BZ02，科技资源标识体系建设共性技术标准研制，2019-09 至 2020-08，30万元，结题，主持

代表性研究成果和学术奖励情况（填写代表性论文时应根据其发表时的真实情况如实规范列出所有作者署名，不再标注第一作者或通讯作者）：

一、代表性论著（请在“申请书详情”界面，点开“人员信息”-“代表性成果”卡片查看对



应的全文)：

(1) 王丽娟；刘佳；王姝；郭志斌；周园春；基于区块链的工业互联网标识公共服务应用初探, *数据与计算发展前沿*, 2021, 3(1): 60-73 (期刊论文)

(2) Wenyu Shi; Heyuan Qi; Qinglan Sun; Guomei Fan; Shuangjiang Liu; Jun Wang; Baoli Zhu; Hongwei Liu; Fangqing Zhao; Xiaochen Wang; Xiaoxuan Hu; Wei Li; **Jia Liu**; Ye Tian; Linhuan Wu; Juncal Ma; gcMeta: a Global Catalogue of Metagenomics platform to support the archiving, standardization and analysis of microbiome data, *Nucleic Acids Research*, 2018, 47(D1): 637-648 (期刊论文)

(3) 王姝；晏敏；**刘佳**；周启惠；郭志斌；王雅哲；周园春；基于区块链的科学数据标识技术创新应用模式, *数据与计算发展前沿*, 2019, 1(2): 62-74 (期刊论文)

(4) 王姝；孙善鹏；樊景超；**刘佳**；郭志斌；王丽娟；李成赞；周国民；周园春；基于区块链的农业科学数据溯源应用初探, *农业大数据学报*, 2020, (02): 47 (期刊论文)

(5) **刘佳**；夏晓蕾；王丽娟；王姝；吕雪峰；路长发；孙利；李素彩；进口冷链食品追溯管理平台及创新应用, *农业大数据学报*, 2022.3月, 4(1): 69-76 (期刊论文)

二、论著之外的代表性研究成果和学术奖励：

(1) 刘佳；田野；一种基于标识服务的工业用大麻追溯系统及方法, 2022-06-24, 中国, CN201810124014.2 (专利)

(2) 王姝；刘佳；郭志斌；周园春；一种基于区块链技术的可信标识关联关系查询方法及相应存储介质与电子装置, 2022-11-15, 中国, CN201911292750.X (专利)

(3) 王姝；刘佳；郭志斌；一种基于标识的实体对象和数据对象的关联方法及系统, 2019-11-06, 中国, CN201911076690.8 (专利)

(4) 刘佳；王姝；郭志斌；王丽娟；夏晓蕾；周园春；一种基于二次追溯的进口冷链食品追溯方法和系统, 2021-03-16, 中国, CN202110280979.2 (专利)

(5) 刘佳；夏晓蕾；王姝；王丽娟；吕雪峰；一种标识体系互通系统及方法, 2022-07-20, 中国, CN202210872390.6 (专利)



方少峰 简历

2023版

中国科学院国家空间科学中心， 助理研究员

教育经历：

- (1) 2013-09 至 2018-07，中国科学院大学，计算数学，博士
- (2) 2009-09 至 2013-07，吉林大学，计算数学，学士

博士后工作经历：

无

科研与学术工作经历（博士后工作经历除外）：

- (1) 2018-07 至 今，中国科学院国家空间科学中心，空间大数据技术研究室，助理研究员

曾使用其他证件信息：

无

近五年主持或参加的国家自然科学基金项目/课题：

无

近五年主持或参加的其他科研项目/课题（国家自然科学基金项目除外）：

- (1) 中华人民共和国科学技术部，国家科技资源共享服务平台项目，192020000210，国家空间科学数据中心，2020-01 至 今，1200万元，在研，参与
- (2) 中华人民共和国科学技术部门，国家重点研发计划，2022YFF0711400，空间科学大数据智能管理与分析挖掘关键技术及应用，2022-11 至 今，1400万元，在研，参与
- (3) 中国科学院，网络安全和信息化专项，CAS-WX2022SF-0103，空间天气典型事件知识挖掘与智能建模研究，2023-01 至 今，220万元，在研，参与
- (4) 中国科学院，网络安全和信息化专项，CAS-WX2021PY-0101，空间天气典型事件知识挖掘与智能建模研究，2022-01 至 2022-12，80万元，结题，参与
- (5) 北京市科学技术委员会，北京市科技成果转化平台建设(科研)，Z181100000118001，基于机器学习的数据资产扫描和侦测系统研制及应用，2018-04 至 2020-04，500万元，结题，参与

代表性研究成果和学术奖励情况（填写代表性论文时应根据其发表时的真实情况如实规范列出所有作者署名，不再标注第一作者或通讯作者）：

一、代表性论著（请在“申请书详情”界面，点开“人员信息”-“代表性成果”卡片查看对应的全文）：

- (1) Chen, Zhiming; Fang, Shao Feng; Huang, Guanghui ; A direct imaging method for the half-space inverse scattering problem with phaseless data, *Inverse Problems & Imaging*, 2017, 11(5): 901 (期刊论文)
- (2) 于佳斌; 佟继周; 方少峰; 胡晓彦 ; 利用转移熵研究引起磁暴扰动的太阳风参数重要性排序, *空间科学学报*, 2022, 42(3): 346-356 (期刊论文)
- (3) 熊森林; 李昕璐; 方少峰; 邹自明 ; 基于机器学习方法对23太阳活动周质子事件的研究, *空间科学学报*, 2021, 41(3): 368-374 (期刊论文)



二、论著之外的代表性研究成果和学术奖励：

(1) 方少峰；孙鹏科；闫振中；郑岩；马福利；佟继周；一种网络流量数据分析方法及系统，2022-11-01，中国，CN201910739001.0 (专利)

(2) 方少峰；孙鹏科；闫振中；郑岩；马福利；佟继周；一种基于异常检测和情感分析的内部威胁分析方法及系统，2022-11-22，中国，CN201910905053.0 (专利)

NSFC 2023



附件信息

序号	附件名称	备注	附件类型
1	Hierarchical Interdisciplinary Topic Detection Mod	IEEE TKDE (CCF A类国际期刊)	代表性论著
2	Exploiting Mutual Information for Substructure-awa	IJCAI 2020 (CCF A类国际会议)	代表性论著
3	Learning Adaptive Embedding Considering Incrementa	IEEE TKDE (CCF A类国际期刊)	代表性论著
4	Lineage Landscape: A comprehensive database that r	Nucleic Acids Research (一区, 影响因子为19.1606), 建立了谱系全景数据库——Lineage Landscape, 收集了超过660万个细胞的数据, 包括1500万个差异表达基因条目信息从转录组、单细胞转录组、表观基因组等不同层面的数据集, 实现对细胞谱系不同层次、不同时期的多维组学数据的收录和整合。	代表性论著
5	Integrating Representation and Imitation in Reinfo	AAAI 2021 (CCF A类国际会议)	代表性论著



项目名称： 支持下一代人工智能的开放型高质量科学数据库

资助类型： 重大研究计划/重点支持项目/可解释、可通用的下一代人工智能方法

受理代码： T01. 物质科学领域

国家自然科学基金项目申请人和参与者承诺书

为了维护国家自然科学基金项目评审公平、公正，共同营造风清气正的科研生态，本人**在此郑重承诺**：严格遵守《中华人民共和国科学技术进步法》《国家自然科学基金条例》《关于进一步加强科研诚信建设的若干意见》《关于进一步弘扬科学家精神加强作风和学风建设的意见》《关于加强科技伦理治理的意见》以及科技部、自然科学基金委关于科研诚信建设有关规定和要求；申请材料信息真实准确，不含任何涉密信息或敏感信息，不含任何违反法律法规或违反科研伦理规范的内容；在国家自然科学基金项目申请、评审和执行全过程中，恪守职业规范和科学道德，遵守评审规则和工作纪律，杜绝以下行为：

- (一) 抄袭、剽窃他人申请书、论文等科研成果或者伪造、篡改研究数据、研究结论；
- (二) 购买、代写申请书；购买、代写、代投论文，虚构同行评议专家及评议意见；购买实验数据；
- (三) 违反成果发表规范、署名规范、引用规范，擅自标注或虚假标注获得科技计划等资助；
- (四) 在项目申请书中以高指标通过评审，在项目计划书中故意篡改降低相应指标；
- (五) 以任何形式打听或散布尚未公布的评审专家名单及其他评审过程中的保密信息；
- (六) 本人或委托他人通过各种方式和途径联系有关专家进行请托、游说、“打招呼”，违规到评审会议驻地窥探、游说、询问等干扰评审或可能影响评审公正性的行为；
- (七) 向工作人员、评审专家等提供任何形式的礼品、礼金、有价证券、支付凭证、商业预付卡、电子红包，或提供宴请、旅游、娱乐健身等任何可能影响评审公正性的活动；
- (八) 违反财经纪律和相关管理规定的行为；
- (九) 其他弄虚作假行为。

如违背上述承诺，本人愿接受国家自然科学基金委员会和相关部门做出的各项处理决定，包括但不限于撤销科学基金资助项目，追回项目资助经费，向社会通报违规情况，取消一定期限国家自然科学基金项目申请资格，记入科研诚信严重失信行为数据库以及接受相应的党纪政务处分等。

申请人签字：

编号	参与者姓名 / 工作单位名称（应与加盖公章一致） / 证件号码	签字
1	唐明洁 / 四川大学 / 5*****9	
2	邹自明 / 中国科学院国家空间科学中心 / 3*****7	
3	刘峰 / 中国科学院计算机网络信息中心 / 2*****3	
4	王华进 / 中国科学院计算机网络信息中心 / 3*****3	
5	李成赞 / 中国科学院计算机网络信息中心 / 4*****X	
6	陈昕 / 中国科学院计算机网络信息中心 / 2*****X	
7	刘佳 / 中国科学院计算机网络信息中心 / 3*****0	
8	方少峰 / 中国科学院国家空间科学中心 / 1*****5	
9		



项目名称： 支持下一代人工智能的开放型高质量科学数据库
资助类型： 重大研究计划/重点支持项目/可解释、可通用的下一代人工智能方法
受理代码： T01. 物质科学领域

国家自然科学基金项目申请单位承诺书

为了维护国家自然科学基金项目评审公平、公正，共同营造风清气正的科研生态，**本单位郑重承诺**：申请材料中不存在违背《中华人民共和国科学技术进步法》《国家自然科学基金条例》《关于进一步加强科研诚信建设的若干意见》《关于进一步弘扬科学家精神加强作风和学风建设的意见》《关于加强科技伦理治理的意见》以及科技部、自然科学基金委关于科研诚信建设有关规定和要求的情况；申请材料符合《中华人民共和国保守国家秘密法》和《科学技术保密规定》等有关法律法规和规章制度要求，不含任何涉密信息或敏感信息；申请材料不含任何违反法律法规或违反科研伦理规范的内容；申请人符合相应项目的申请资格；依托单位、合作研究单位、申请人及主要参与者不在限制申报、承担或参与财政性资金支持的科技活动的期限内；在项目申请和评审活动全过程中，遵守有关评审规则和工作纪律，杜绝以下行为：

（一）以任何形式打听或公布未公开的项目评审信息、评审专家信息及其他评审过程中的保密信息，干扰评审专家的评审工作；

（二）组织或协助申请人/参与者向工作人员、评审专家等给予任何形式的礼品、礼金、有价证券、支付凭证、商业预付卡、电子红包等；宴请工作人员、评审专家，或组织任何可能影响科学基金评审公正性的活动；

（三）支持、放任或对申请人/参与者抄袭、剽窃、重复申报、提供虚假信息（含身份和学术信息）等不当手段申报国家自然科学基金项目疏于管理；

（四）支持或协助申请人/参与者采取“打招呼”“围会”等方式影响科学基金项目评审；

（五）其他违反财经纪律和相关管理规定的行为。

如违背上述承诺，本单位愿接受自然科学基金委和相关部门做出的各项处理决定，包括但不限于停拨或核减经费、追回项目已拨经费、取消本单位一定期限国家自然科学基金项目申请资格、记入科研诚信严重失信行为数据库以及主要责任人接受相应党纪政务处分等。

依托单位公章：

日期： 年 月 日

合作研究单位公章：

日期： 年 月 日

合作研究单位公章：

日期： 年 月 日